



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Introducción a la Minería de Datos


Profesores: Cinthia Sánchez y Cristian Llull

Objetivos del curso

- Aprender a aplicar el proceso de DM a datos reales.
- Conocer, seleccionar y utilizar las técnicas básicas de DM.
- Aprender a interpretar los resultados de estos procesos.
- Proveer la base para adquirir conocimiento más avanzado.

¿Qué significa **Minar**?

EL PROCESO DE PRODUCCIÓN PASO A PASO



UN VISTAZO A LA MAQUINARIA



2006

Yanacocha fue reconocida como la primera productora de oro a nivel mundial durante ese año.

Más de 12 millones de onzas de oro se produjeron entre el 2003 y el 2007.


Más de 400 millones de inversión ambiental desde el inicio de las operaciones de Yanacocha.

EL PROCESO DEL ORO DE PRINCIPIO A FIN

UNA VEZ DESCUBIERTA LA ZONA MINERALIZADA, EL ÁREA DE GEOLOGÍA DE YANACOCCHA REALIZA ESTUDIOS MÁS DETALLADOS DE LA ZONA QUE PERMITEN IDENTIFICAR CANTIDADES PRECISAS DE MINERAL. EN 1990 SE LLEVARON A CABO LOS ESTUDIOS DE FACTIBILIDAD PARA INICIAR LOS TRABAJOS EN UNA PLANTA PILOTO PARA LA LIXIVIACIÓN EN PILAS. CON EL INICIO DE LAS OPERACIONES DE CARACHUGO, EL 7 DE AGOSTO DE 1992, LA EMPRESA PRODUJO SU PRIMERA BARRA DORÉ. PARA EXPLOTAR Y OBTENER EL ORO UTILIZA EL MÉTODO DE MINERÍA A TAJO ABIERTO O A CIELO ABIERTO.

3.3 millones de onzas ha sido el récord absoluto de producción durante un año. Esta cifra se consiguió en 2005.

LAS ETAPAS DE UN GRAN PROCESO



¿Qué significa **Minar**?

Según la RAE:

“Hacer grandes diligencias para conseguir algo”

¿Qué es la Minería de Datos?

- Descubrir automáticamente información útil en grandes repositorios de datos

¿Qué es la Minería de Datos?

- Descubrir **automáticamente** información útil en grandes repositorios de datos

¿Qué es la Minería de Datos?

- Descubrir automáticamente información **útil** en grandes repositorios de datos


¿Qué es la Minería de Datos?

- Descubrir automáticamente información útil en **grandes repositorios de datos**

¿Qué es la Minería de Datos?

En ciertos contextos, los métodos tradicionales no son adecuados. Muchas veces usamos modelos de Machine Learning como herramientas. Por ejemplo:

- Cuando hacemos clasificación en Machine Learning queremos automatizar una tarea (e.g., reconocer rostros en imágenes).
- Cuando hacemos clasificación en DM queremos encontrar un patrón en los datos (i.e., queremos entender cómo se relaciona X con y por medio de un modelo predictivo).



¿Cuál es la diferencia entre Data Science, Machine Learning e Inteligencia Artificial?

- Están de moda, pero no son lo mismo, ni son intercambiables.
- **Data Science** es el nombre reciente para algo mucho más antiguo: **Data Mining (90's)**
- Definición (sobre) simplista:
 - **Data mining** genera entendimiento.
 - **Machine learning** genera predicciones.
 - **Artificial intelligence** genera acciones.

¿Cuál es la diferencia entre Data Science, Machine Learning e Inteligencia Artificial?


- **Artificial Intelligence:** auto reconoce una señal de STOP y toma la acción de frenar.
- **Machine Learning:** auto reconoce señales de STOP usando cámaras y **predice** en base a un entrenamiento cuando debe parar.
- **Data Mining:** auto transita por las calles y nos damos cuenta que su rendimiento no es el esperado. Luego, **entendemos** que esto se debe a varios factores externos.



¿Cuál es la diferencia entre Data Science, Machine Learning e Inteligencia Artificial?

En resumen:

- Data Science se centra en el análisis de datos para extraer conocimiento,
- Machine Learning utiliza algoritmos para hacer predicciones y tomar decisiones basadas en datos, e
- Artificial Intelligence se refiere al desarrollo de sistemas que pueden realizar tareas inteligentes de manera autónoma.



Propiedad que exhiben los sistemas computacionales o “máquinas” para realizar una tarea como lo hacen los humanos.

Algoritmos que permiten a las “máquinas” aprender de ejemplos sin ser explícitamente programadas.

Algoritmos basados en **redes neuronales artificiales (ANNs)** profundas. Las ANNs son modelos de aprendizaje inspirados en el cerebro.


¿Por qué es importante entender estas diferencias?

- Este no es un curso de **Machine Learning**, es un curso de **Minería de Datos**.
- Sin embargo, sí se enseñan los conceptos principales de Machine Learning.
- **ML: Estudio, diseño y desarrollo de algoritmos** que permiten a los computadores aprender sin ser explícitamente programados (Arthur Samuel). Técnicas genéricas, aplicables a varios dominios.
- **Minería de Datos:** El enfoque está en **extraer conocimiento**, o patrones previamente desconocidos, a partir de (grandes) volúmenes de datos. Para esto se pueden utilizar técnicas de ML, entre otras. Requiere conocimiento de los datos mismos y su dominio.

BIG BANG

- 2006 Hadoop
- Análisis de datos masivos al alcance de todos (cientos de start-ups)





- 1 They know what you're going to buy 2 They know when you're going to sneeze 3 They know when you're about to have a heart attack
4 They know the shoes you like 5 They know when you're being bad 6 They know what you want for dinner 7 Sorry, can't help you there

Datos

Diferentes tipos de datos:

Estructurados

Datos sociales: Edad, Salario, Color de piel, Lugar de residencia, ...



Datos métricos: Likes de una publicación, Tiempo pasado en una página, Número de amigos en común, ...

No estructurados

Texto: Frase, Párrafo, Documento

Sonido: Canción, Discurso

Imagen: Foto, Video



¿Por qué hacer minería de datos?

- Aspecto comercial
- Aspecto científico



¿Por qué hacer minería de datos?

¿Motivación Comercial?

Recolección de MUCHOS datos comerciales:

- Datos Web, e-commerce
- Compras en tiendas
- Transacciones en Bancos/
Tarjetas de Crédito



Propuesta de recomendaciones a un usuario

amazon

Try Prime

All ▾

Q

Shop by Department ▾

Shopping History ▾

Barbara's Amazon.com

Today's Deals

Gift Cards

Sell

Help

Hello, Barbara

Your Account ▾

Try Prime ▾

Your Lists ▾

4

Cart

Your Amazon.com

Your Browsing History

Recommended For You

Improve Your Recommendations

Your Profile

Learn More



Barbara's Amazon

ON ORDER

0 items

AMAZON PRIME

Try Prime

View benefits

AUDIBLE AUDIOBOOKS

Try Audible

Get 2 free audiobooks

CUSTOMER SINCE

2008

Recommended for you, Barbara

 Literature & Fiction 100 ITEMS	 Science Fiction & Fantasy Books 41 ITEMS	 Prime Video – Unlimited Streaming for Prime Members 27 ITEMS	 Mystery, Thriller & Suspense Books 55 ITEMS
 Personal Care Products 81 ITEMS	 Recommended Based On Sketching User Experiences: Getting the Design... 16 ITEMS	 Office & School Supplies 20 ITEMS	 Cell Phones & Accessories 10 ITEMS

Propuesta de recomendaciones a un usuario



Roll over image to zoom in

1 X Disney Frozen Pencil Case

by Innovative Designs, LLC

★★★★★ 4 customer reviews

Price: **\$5.30**

In Stock.

This item ships to **Santiago, Chile**. Want it Friday, March 11? Order within **9 hrs 49 mins** and choose **Amazon Global Priority Shipping** at checkout. [Learn more](#)

Sold by JACOB'S and Fulfilled by Amazon. Gift-wrap available.

Package Quantity: **1**

Style Name: **Purple**

1 Disney Frozen Pencil Case

15 new from \$1.50



Frequently Bought Together



Total price: **\$22.55**

[Add both to Cart](#)

[Add both to List](#)

☒ This item: 1 X Disney Frozen Pencil Case \$5.30

☒ Thermos 12 Ounce Funtainer Bottle, Frozen Purple \$17.25

Customers Who Bought This Item Also Bought

Page



Disney Frozen Light Blue Stationery Set Pack with Case (13 Pcs)
★★★★☆ 39
\$7.40 [Prime](#)



Disney Frozen Rolling 16" Backpack and Lunch Bag Lunchbox 2pc
★★★★☆ 12
\$49.95 [Prime](#)



Disney Frozen 1 Subject Wide Ruled Notebook - (Colors/Graphics Vary)
★★★★☆ 14
\$4.67



Disney Frozen Elsa and Anna Kids Stationery Set (17 Pcs)
★★★★☆ 19
\$8.95 [Prime](#)



American Greetings Frozen Party Accessories, Pencils, 12 Count
★★★★☆ 89
\$5.26 [Prime](#)



Disney Frozen Hot Pink Elsa Anna and Olaf Stationery Set Pack with Case (13 Pcs)
★★★★☆ 34



Thermos 12 Oz. Funtainer Bottle Purple
★★★★☆ 4
\$17.25 [Prime](#)

Propuesta de recomendaciones a un usuario

NETFLIX Browse Kids Search 1 Barbara

Top Picks for Barbara



House, M.D. X



★★★★★ 2014 TV-14 9 Seasons
An awkward forensic anthropologist. An arrogant FBI agent. Together, they find justice in the dead.

★★★★★ 2010 TV-14 9 Seasons
His deception detection is second to none. But his social skills? Well, they could use a little work.

★★★★★ 2015 18 11 Seasons
Neither their patients' problems nor their own relationships are black-and-white. It's all shades of grey.

★★★★★ 2013 14 1 Season
Elite FBI profilers play minds games to catch serial killers. Getting into murderers' heads can also get into yours.


★★★★★ 2015 TV-14 3 Seasons
The legendary detective needs a doctor to keep him clean -- and maybe help round up a few murderers.

OVERVIEW EPISODES MORE LIKE THIS DETAILS

Because you watched Cooked



Procesamiento automático de opiniones de usuarios




¿qué caracteriza las opiniones negativas?

¿Por qué hacer minería de datos?

¿Motivación Científica?

- Datos (observaciones) recolectadas a gran velocidad (GB/hr, Tb/día)
- Telescopios, Satélites, Requerimientos Web, ADN, etc (Google Flu Trends)



Tendencias de salud pública basadas en consultas de búsqueda web (Google Flu Trends)



Métodos utilizados en Minería de Datos

- **Métodos predictivos:** Usar variables para predecir variables desconocidas o valores futuros de otras variables.
- **Métodos descriptivos:** Encontrar patrones interpretables por humanos que permitan describir los datos.



Diferentes tipos de tareas


Tareas Predictivas	Tareas Descriptivas
● Clasificación ● Regresión ● Detección de Desviación/Anomalía	● Descubrimiento de Reglas de Asociación ● Clustering ● Descubrimiento de Patrones Secuenciales

Diferentes tipos de tareas

Aprendizaje
supervisado


Clasificación

Técnica para clasificar objetos en dos o más clases determinadas, en base a un conjunto de atributos. Este aprendizaje requiere datos etiquetados (clasificados).



Regresión


Técnica para predecir valores numéricos de objetos, en base a un conjunto de atributos. Este aprendizaje requiere datos etiquetados (valor de interés es numérico).



Aprendizaje
no supervisado

Clustering

Técnica para encontrar grupos de objetos tal que: Los objetos en un grupo sean similares (o relacionados) entre sí y diferentes (o no relacionados) a los objetos en otros grupos.



Diferentes tipos de tareas

Aprendizaje
supervisado

Clasificación



Age Predictor

0-2:	0.23%
4-6:	0.10%
8-12:	6.74%
15-20:	4.16%
25-32:	57.51%
38-43:	28.43%
48-53:	2.52%
60+:	0.31%

Regresión




Age Predictor


31

Aprendizaje
no supervisado

Clustering



Algoritmo de
Agrupamiento



Clasificación

Objetivo: Asignar objetos no vistos anteriormente a una clase dentro de un conjunto determinado de clases con la mayor precisión posible. Aprender un modelo para el atributo de clase (y) como función de los otros atributos (X).



Clasificación

Componentes principales:

Conjunto de entrenamiento

Algoritmo de clasificación

Conjunto de evaluación

-> Producen un “Modelo de Clasificación”

¿Cómo obtenemos estas etiquetas?




Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Conjunto de entrenamiento

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Conjunto de evaluación



Clasificación: Aplicación 1

- Marketing directo
- Meta: Reducir costos de publicidad apuntando directamente a potenciales compradores.

Clasificación: Aplicación 2

- Detección de Fraude
- Meta: Predecir transacciones fraudulentas en el uso de tarjetas de crédito

Clasificación: Aplicación 3

- Fidelidad de Clientes
- Meta: Predecir si es posible perder a un cliente a la competencia.


Clustering

- Busca capturar agrupaciones naturales en los datos.
- Conjunto de puntos (datos), cada uno con un set de atributos y una medida de similitud
- Encontrar conjuntos tales que:
 - Puntos en un *cluster* sean más similares entre sí
 - Puntos en conjuntos diferentes sean menos similares entre sí

Clustering

<i>Tid</i>	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Clustering



Los grupos de elementos se identifican sólo en base a las características que tienen los datos.

Clustering: Aplicación 1

- Segmentación de mercado
 - Meta: Subdividir un mercado en subconjuntos de clientes en donde cualquier conjunto es un potencial objetivo de marketing (ej: Netflix, Amazon)

Clustering: Aplicación 2


- Clustering de documentos
 - Meta: Encontrar grupos de documentos que son similares entre sí, basándose en las palabras más importantes que contienen.

Clustering: Aplicación 3


- Clustering de redes sociales
 - Meta: Caracterizar fenómenos sociales de grupos en redes sociales.

Regresión

- Predecir el valor de una variable continua, en base a valores de otras variables, asumiendo modelo de dependencia lineal o no-lineal.



Classification



Regression

Regresión: Aplicación 1

- Predicción del consumo energético
 - Meta: Optimizar la generación y distribución de energía para reducir costos operativos y prevenir sobrecargas en la red.

Regresión: Aplicación 2

- Pronóstico financiero
 - Meta: Minimizar el riesgo y maximizar el rendimiento de las inversiones anticipando las tendencias y la volatilidad del mercado.

Regresión: Aplicación 3

- Estimación de la demanda de productos para la gestión del stock
 - Meta: Evitar la escasez de productos (pérdida de ventas) y reducir el exceso de mercancía (costos de almacenamiento).

Desafíos de DM


- Escalabilidad
- Dimensionalidad
- Datos complejos y heterogéneos
- Calidad de los datos
- Distribución de los datos y propiedad
- Privacidad
- Streaming

Próxima Clase

- Datos I
- **Leer reglas del curso:** ver que no haya problemas con los requisitos de asistencia a actividades. Se entiende que Ud. puede cumplirlos si sigue en el curso.

Libro del curso

- [Introduction to Data Mining](#)
- Autores: Pang-Ning Tan, Michael Steinbach, Vipin Kumar



Herramientas



<https://www.python.org>



<https://colab.research.google.com/>



<https://pandas.pydata.org/>



<https://scikit-learn.org/stable/>



<https://matplotlib.org/stable/gallery/index.html>