



dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Datos

Profesores: Cinthia Sánchez y Cristian Llull

Contenidos


- ¿Qué entendemos por dato?
- Atributos y métricas
- Formatos de datos
- Calidad de los datos

HEY, LOOK, WE HAVE A BUNCH
OF DATA! I'M GONNA ANALYZE IT.


NO, YOU FOOL! *THAT WILL
ONLY CREATE MORE DATA!*



¿Qué entendemos por dato?



¿Qué entendemos por dato?



Juan Pérez obtuvo un 5.8
en la segunda prueba de
historia


Juan Pérez obtuvo mejor
nota que el 75% del resto
del curso

Juan Pérez es un buen
alumno

¿Qué entendemos por dato?

Colección de hechos tales como números, palabras, mediciones, o solo descripción de cosas.

Utilizado generalmente para análisis.



Datos estructurados (Estructura básica)

- Usualmente se organizan en **tablas**.
- Colección de objetos de datos y sus atributos.
- Ejemplo: excel, .csv o tablas relacionales (SQL)
- Datos que han sido **formateados** y **modelados** para un “fácil” acceso.
- Poseen una estructura fija mediante **columnas**.
- Un nuevo valor se representa como una **fila**.

Datos estructurados (Estructura básica)

Una tabla es una colección de objetos de datos y sus atributos.

Atributo: propiedad de un objeto. Puede ser cualitativo o cuantitativo.


- **Escala de medición o métrica:** El mismo atributo se puede asignar a diferentes valores de atributo. Ejemplo: centímetros, metros.

Atributos, variables, características, dimensiones

**Objetos,
observaciones,
instancias,
registros**

cat_periodo	id	gen_alu	rango_edad	anio_ing_carr_ori	tipo_inst_1	nomb_inst
2023	927537	1	20 a 24 años	2023	Institutos Profesionales	IP DUOC UC
2023	927464	2	20 a 24 años	2022	Universidades	UNIVERSIDAD DEL DESARROLLO
2023	362242	1	25 a 29 años	2017	Universidades	UNIVERSIDAD AUTONOMA DE CHILE
2023	1330048	2	30 a 34 años	2020	Universidades	UNIVERSIDAD DE CHILE
2023	81882	2	40 y más años	2022	Institutos Profesionales	IP AIEP
2023	741023	2	20 a 24 años	2021	Institutos Profesionales	IP DUOC UC
2023	741076	1	20 a 24 años	2021	Institutos Profesionales	IP DUOC UC
2023	1056467	2	15 a 19 años	2023	Universidades	UNIVERSIDAD DE MAGALLANES
2023	605161	1	20 a 24 años	2021	Centros de Formación Técnica	CFT INACAP

Tipos de atributos



Dirección de ordenamiento

Sequential



Hay un punto de origen, y de ahí sólo se crece. Ejemplo: edad.



Diverging



Hay un punto de origen, y de ahí se puede avanzar en dos direcciones opuestas. Ejemplo: temperatura en °C, correlación lineal.



Cyclic



Hay un punto de origen, y de ahí se puede avanzar hacia adelante, pero hay atributos que se repiten en ciclos (ejemplo: los meses del año).



Tipos de atributos

- **NOMINAL** (IDs, color de ojos, categorías de bacterias)
- **ORDINAL** (rankings, notas, altura en {alto, mediano, bajo})
- **INTERVALO** (Fechas, temperaturas °C o °F)
- **RAZÓN** (Temperatura Kelvin, largo, hora)

Tipos de atributos


Cualitativos

- **NOMINAL** (IDs, color de ojos, categorías de bacterias)
- **ORDINAL** (rankings, notas, altura en {alto, mediano, bajo})

Cuantitativos

- **INTERVALO** (Fechas, temperaturas °C o °F)
- **RAZÓN** (Temperatura Kelvin, largo, hora)

Por qué la temperatura en Kelvin es Razón y Celsius es Intervalo?



<https://blog.beamex.com/es/unidades-de-temperatura-y-sus-conversiones>

- **CUALITATIVOS** (Categóricos)

Nominal y Ordinal, aunque sean numéricos deben ser tratados como símbolos

- **CUANTITATIVOS** (Numéricos)

Intervalo y Razón deben ser tratados como números y tienen propiedades numéricas (continuos o discretos)

Atributos DISCRETOS:

- Atributos categóricos.
- A menudo representados como enteros
- binarios (finitos)
- Ej: códigos postales o conjunto de palabras en docs.

Atributos CONTINUOS:

- Números reales o valores flotantes
- Ej: temperatura, altura, peso (infinitos)

Datos estructurados

Nombre mascota	Especie	Raza	Edad	Sexo	Peso
Doris	Canino	Schnauzer	3	Hembra	8
Clotilde	Canino	Mestizo	14	Hembra	7
Tony	Felino	DPC	0.5	Macho	2
Lorenzo	Canino	Mestizo	3	Macho	1.5

Datos estructurados

Nombre mascota	Especie	Raza	Edad	Sexo	Peso
Doris	Canino	Schnauzer	3	Hembra	8
Clotilde	Canino	Mestizo	14	Hembra	7
Tony	Felino	DPC	0.5	Macho	2
Lorenzo	Canino	Mestizo	3	Macho	1.5

¿Qué **problemas** podríamos tener con **datos** en este formato?

Datos estructurados

Nombre mascota	Especie	Raza	Edad	Sexo	Peso
Doris	Canino	Schnauzer	3	Hembra	8
Clotilde	Canino	Mestizo	14	Hembra	7
Tony	Felino	DPC	0.5	Macho	2
Lorenzo	Canino	Mestizo	3	Macho	1.5

Agregar nuevas columnas:

- Chip
- Celo
- Castración
- Esterilización
- Alergias

Datos estructurados

Nombre mascota	Especie	Raza	Edad	Sexo	Peso	Celo	Alergias
Doris	Canino	Schnauzer	3	Hembra	8	NO	SI
Clotilde	Canino	Mestizo	14	Hembra	7	SI	NO
Tony	Felino	Ángora	0.5	Macho	2	??	??
Lorenzo	Canino	Mestizo	3	Macho	1.5	??	SI

Agregar nuevas columnas:


- Chip
- Celo
- Castración
- Esterilización
- Alergias

Datos estructurados

Nombre mascota	Especie	Raza	Edad	Sexo	Peso	Celo	Alergias
Doris	Canino	Schnauzer	3	Hembra	8	NO	SI
Clotilde	Canino	Mestizo	14	Hembra	7	SI	NO
Tony	Felino	Ángora	0.5	Macho	2	??	??
Lorenzo	Canino	Mestizo	3	Macho	1.5	??	SI

Agregar nuevas columnas:

- Chip
- Celo
- Castración
- Esterilización
- Alergias



Muchos valores
VACÍOS


¡Ejercicio!

Describa los siguientes atributos
(¿*cualitativo/cuantitativo, nominal/ordinal, etc.*?):

Atributos


- A. Regiones: {África, Europa, América, ...}
- B. Población por ciudades
- C. Nivel de satisfacción: {Muy insatisfecho, Insatisfecho, Neutral, Satisfecho, Muy satisfecho}
- D. Nombres de integrantes de un curso
- E. Tamaño de estrellas

Datos Estructurados / No Estructurados




Datos no estructurados


- Datos no poseen estructura alguna **previamente** definida.
- Ejemplos: documentos de texto, imágenes, video, audio, etc.
- > **80%** de los datos están en este formato.
- Es posible encontrar **patrones** de cómo están organizados los datos.
- Sin embargo, involucra mucho trabajo de pre-procesamiento de datos.



Hola, mundo!



23



Dato con estructura

Nombre mascota	Especie	Raza	Edad	Sexo	Peso
Doris	Canino	Schnauzer	3	Hembra	8
Clotilde	Canino	Mestizo	14	Hembra	7

Dato con
estructura

Nombre mascota	Especie	Raza	Edad	Sexo	Peso
Doris	Canino	Schnauzer	3	Hembra	8
Clotilde	Canino	Mestizo	14	Hembra	7



Misma
información,
sin estructura

Se ha ingresado el paciente **Doris**, de especie **canino**. Nació aproximadamente el 2017, por lo que tiene **3 años**. Su manto es color **sal y pimienta** y patas blancas. Este es su primer control, pesando **8kg** aproximadamente.



¿Cómo representamos los datos no estructurados para que sean procesables por el computador?

Extracción de Características o Vectorización

Ejemplo vectorización de texto con Bag-of-Words (bolsa de palabras)

- Enfoque popular en el que las frecuencias de las palabras son los valores de los atributos.
- Se basa en una matriz en la que una fila representa un documento con una columna para cada palabra del vocabulario.

documento	el	gato	está	feliz	triste	perro	con	en	patio	juega
el gato está feliz	1	1	1	1	0	0	0	0	0	0
el gato está triste	1	1	1	0	1	0	0	0	0	0
el gato está con el perro	2	1	1	0	0	1	1	0	0	0
el gato con el perro	2	1	0	0	0	1	1	0	0	0
el perro juega en el patio	2	0	0	0	0	1	0	1	1	1

vector del documento

NO Estructurados

Estructurados



(+) cantidad

(-) cantidad



(+) pre-procesamiento

(-) pre-procesamiento

Datos semi-estructurados

Datos que sigue una estructura más **dinámica** y **flexible**.


Usualmente se organizan de manera jerárquica.

No necesita modificar la estructura completa al agregar un nuevo atributo.

En lugar de utilizar columnas, se usan “**tags**” para representar atributos

Ejemplos: XML, json, e-mails, algunas web

Semi-Structured Data



Datos semi-estructurados

Nombre mascota	Especie	Raza	Edad	Sexo	Peso
Doris	Canino	Schnauzer	3	Hembra	8
Clotilde	Canino	Mestizo	14	Hembra	7



XML

```
<mascota>
  <nombre>Doris</nombre>
  <especie>Canino</especie>
  <raza>Schnauzer</raza>
  <edad>3</edad>
  <color>Sal y pimienta</color>
  <peso>8</peso>
  <celo>SI </celo>
</mascota>
```


json

```
{
  "nombre": "Doris",
  "especie": "Canino",
  "raza": "Schnauzer",
  "edad": "3",
  "color": "Sal y pimienta",
  "peso": "8"
}
```

¿Qué entendemos por dato?

Colección de hechos tales como números, palabras, mediciones, o solo descripción de cosas.

Utilizado generalmente para análisis.



Datos tipo records

El conjunto de datos es una colección de registros, cada uno caracterizado por un conjunto fijo de atributos.


- Ej: Datos de transacciones, donde cada registro implica un conjunto de ítems (ej. las compras de un cliente en un supermercado). Se puede representar con atributos binarios (compra, no compra)

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Datos tipo grafos

Los datos capturan relaciones complejas entre entidades. Tenemos nodos y aristas.

Se pueden representar como tablas (Ej: Matriz de adyacencia, indicando la existencia de la relación o su peso). Lo importante es que no se pierda la información de conectividad, dependencia, relación, etc., entre nodos.




Matriz de adyacencia:

	1	2	3	4
1	0	0	1	1
2	0	0	0	1
3	0	1	0	0
4	0	0	1	0


Datos tipo grafos

Grafo: Colección de dos conjuntos V y E , donde V es un conjunto de vértices (o nodos) y E es un conjunto de aristas o arcos (o enlaces). Se denota como $G = (V, E)$.



Datos tipo grafos

- Nodos
 - > con sus atributos
- Enlaces / Aristas
 - > con sus atributos
 - > con un nodo de origen y otro de destino
 - > opcionalmente con dirección
- Ej.: *El club de Karate de Zachary*. Un data set típico para análisis de redes. Fuente: [Zachary's karate club - Wikipedia](#)
 - nodo 1: Instructor "Mr. Hi"
 - nodo 34: Administrador/presidente




Suponemos que la composición del grupo tras la separación se debió en gran medida a los vínculos sociales. Por lo tanto, esperamos que un buen algoritmo de detección de comunidades prediga la composición del grupo después de la división con gran precisión.

Datos ordenados

Los atributos tienen relaciones que involucran orden en el tiempo o el espacio:

- **Datos secuenciales** (transacciones con tiempo asociado: libros embarazo -> pañales)
- **Secuencias datos ordenados pero sin tiempo** (ADN, secuencias de genes, etc.)
- **Datos ordenados en el espacio:** mapas de temperatura regional
- **Datos ordenados en el tiempo:** series de tiempo (fluctuaciones de la bolsa)
- **Autocorrelación temporal:** objetos cercanos en el tiempo son parecidos (Ej: temp. ambiente a las 10:00 h y a las 10:02 h)
- **Autocorrelación espacial:** obj. cercanos en el espacio son parecidos (Ej. la calidad del aire)



Características Generales (sets de Datos)

- **Dimensionalidad:** nro. de atributos, maldición de la dimensionalidad (***curse of dimensionality***) tiene que ver con problemas al trabajar con muchas dimensiones (preprocesamiento: reducción de dimensionalidad)

Características Generales (sets de Datos)

- **Dispersión:** mayoría de las dimensiones son 0 para los datos, puede tener ventajas, como no necesitar almacenar los valores 0, sólo los 1s. (Ej. Grafo de la Web y sus enlaces).

Características Generales (sets de Datos)

- **Resolución** (ej. variaciones de presión atmosférica en horas es notoria, pero en meses no se detecta).

¿Por qué es importante conocer los tipos de datasets y atributos?

Nos permitirá **elegir herramientas** para trabajar con los datos

- Hay herramientas y modelos para cada tipo de dataset. Ej.: algoritmos de detección de comunidades (redes) y algoritmos de clustering (tablas) generan resultados similares: grupos de elementos.
- Preprocesamiento según el tipo de atributo. Ej.: codificación de categorías nominales versus categorías ordinales.

En general, **los datos tenderán a estar representados como tablas.**

Los datasets **fluyen entre representaciones**. Ej.: es posible derivar una red a partir de datos de tabla.

Fuentes de Datos

Encuestas

Censos

Conteos

Sensores

GPS

Registros

Trazas Digitales

(hay más dispositivos generando trazas digitales que personas)



Calidad de los datos

- No poseen la calidad deseada a priori, los algoritmos de DM se enfocan en:
 1. Detección y corrección de problemas de calidad
 2. Usar algoritmos que toleren datos de poca calidad
- i.e., limpieza de datos

¿Por qué se producen errores?

Tipos de errores:



- Ruido y outliers
- Valores faltantes
- Datos duplicados



Calidad de los datos: Ruido


Irregularidad aleatoria que encontramos en cualquier dato de la vida real. No tienen ningún patrón.

Componente aleatoria en la medición (distorsión de voz en un teléfono malo).



Calidad de los datos: Outliers

Objetos con características considerablemente diferentes a los otros objetos en el dataset.



Calidad de los datos: Outliers


Valores atípicos ruidosos:

- Variabilidad natural: cola de la distribución
- Errores de medición: mal sensor, mala entrada, ...
- Eventos excepcionales: eventos inusuales o extremos que no siguen el patrón típico de los datos (y no es interesante de modelizar)

Valores atípicos “buenos”

- ¡Evento raro tipo anomalía que queremos predecir! Terremoto, mantención de máquinas, anomalías en un producto, etc...

Calidad de los datos: Outliers



Ejemplos del MVTEC Anomaly Detection Dataset

Calidad de los datos: Valores faltantes

¿Motivos?

- Información no recolectada (e.j: no quieren dar edad y/o peso)
- Atributos no aplicables a todos (e.j: impuesto en niños)

¿Cómo los manejo?

- Eliminando el objeto.
- Estimando (interpolando) valores.
- Ignorar.

Calidad de los datos: Duplicados

El dataset incluye datos duplicados o cuasi-duplicados. Generalmente debido a:

- Error humano durante la entrada de datos
- Esta es la realidad (pero no necesariamente sirve). E.j: Retweets (casos deseados, no deseados)
- Hay una falla en el sistema de recolección: herramientas de extracción, transformación y carga
- Gran problema al juntar datos de fuentes múltiples

Necesitamos controles de calidad de los datos durante la recolección y procesamiento.

Limpieza y Procesado

Time spent in a life of a Data Scientist

@datavizzdom

Gulrez

Perception



Reality

