



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Análisis Exploratorio de Datos

Profesores: Cinthia Sánchez y Cristian Llull

Contenidos

- Metodología para el tratamiento de los datos
- Herramientas en Python
- Estadística descriptiva
- Visualización de datos

Metodología para el tratamiento de los datos

*Múltiples fuentes de datos:
Temperatura, presión,
lluvias, nubosidad, relieve,
tendencias del cambio
climático, etc...*

*Limpieza y preparación de
los datos. Trabajo con
datos faltantes,
selección/generación de
características relevantes*

*Poner el modelo en
producción*

Definición del
Problema

Recolección de
Datos

Análisis
Exploratorio de
datos

Preprocesamien
to de datos

Entrenamiento
y Validación del
Modelo

Despliegue del
Modelo

*Heladas en el valle central
provocan pérdidas en la
producción de frutales.*

Solución: Predicción de
Heladas

*Exploración usando
estadísticas de resumen
(frecuencias, medidas de
tendencia central y
dispersión) y visualización.*

*Creación, evaluación y
ajuste de modelos de
Machine Learning*


Retroalimentación: Evaluar el
rendimiento del modelo
desplegado en los nuevos datos.
Reentrenar en caso que el modelo
quede desactualizado.

Metodología para el tratamiento de los datos

*Múltiples fuentes de datos:
Temperatura, presión,
lluvias, nubosidad, relieve,
tendencias del cambio
climático, etc...*

*Limpieza y preparación de
los datos. Trabajo con
datos faltantes,
selección/generación de
características relevantes*

*Poner el modelo en
producción*



*Heladas en el valle central
provocan pérdidas en la
producción de frutales.*

Solución: Predicción de
Heladas


*Exploración usando
estadísticas de resumen
(frecuencias, medidas de
tendencia central y
dispersión) y visualización.*

*Creación, evaluación y
ajuste de modelos de
Machine Learning*

Retroalimentación: Evaluar el
rendimiento del modelo
desplegado en los nuevos datos.
Reentrenar en caso que el modelo
quede desactualizado.

Análisis exploratorio de datos (EDA)

- Engloba un conjunto de técnicas para poder comprender/resumir las características más importantes de un conjunto de datos o **dataset**.
- Esta metodología fue impulsada por el estadístico John Tukey.
- Se basa principalmente en dos criterios:
 - **Estadísticas de resumen (descriptiva)** y
 - **Visualización de datos**
- En esta clase se verán ambos tipos de técnicas, y aplicación en **python**.



John Tukey

Herramientas: Python y Anaconda

Python es un lenguaje de programación interpretado y de propósito general. Open Source:
<https://www.python.org/>

- Lenguaje completo que soporta diferentes paradigmas como programación orientada a objeto.

Anaconda es una distribución de Python que incluye una gran colección de paquetes científicos preinstalados.

- Configuración de entornos para ciencia de datos y aprendizaje automático más sencilla y rápida.



Herramientas: Pandas

- Es una biblioteca externa de Python para manipulación y análisis de datos.
- Ofrece estructuras de datos y operaciones para manipular datos tabulares y series temporales.
- Permite una variedad de operaciones de manipulación de datos incluyendo:
 - Fusionar, unir y concatenar datos.
 - Filtrar, agrupar y transformar datos.
- Introduce dos estructuras de datos a Python: DataFrame y Series, inspirados en los dataframes de R.



Herramientas: NumPy y SciPy

NumPy:

- Proporciona arrays multidimensionales, que son más rápidos y menos pesados que las listas de Python tradicionales.
- Sirve como base para otras bibliotecas científicas y de análisis de datos como pandas, SciPy y scikit-learn, debido a su integración y rendimiento.



SciPy:

- SciPy se basa en NumPy y ofrece módulos adicionales para optimización, álgebra lineal, integración, interpolación, funciones especiales, procesamiento de señales y de imágenes.
- Extiende las funcionalidades de NumPy con herramientas más especializadas



Herramientas: Scikit-Learn

- Biblioteca que provee una gran variedad de algoritmos supervisados y no supervisados.
- Incluye funciones para preprocesamiento de datos, reducción de dimensionalidad, selección de modelos y validación cruzada, fundamentales para la preparación de datos y la evaluación de modelos.
- Funciona bien con otras bibliotecas de Python, como NumPy y SciPy, y es compatible con muchos formatos de datos, permitiendo una integración fluida en el flujo de trabajo de ciencia de datos.



Ejemplos con dataset Iris

Trabajaremos con un dataset muy conocido en análisis de datos llamado **Iris**.

- Se compone de 150 observaciones de flores de la planta iris.
- Tiene tres tipos de clases de flores iris: **virginica**, **setosa** y **versicolor**.
- Hay 50 observaciones de cada una.
- Las variables o atributos que se miden de cada flor son:
 - El **tipo de flor** como variable categórica.
 - El **largo y el ancho del pétalo** en cm como variables numéricas.
 - El **largo y el ancho del sépalo** en cm como variables numéricas.



Virginica



Setosa



Versicolor

Ejemplos con dataset Iris

El dataset se encuentra disponible en Scikit-Learn, una librería de Machine Learning en Python:

```
> from sklearn.datasets import load_iris
> import pandas as pd
> iris = load_iris()
> iris_df = pd.DataFrame(iris.data, columns=iris.feature_names)
> iris_df.columns
```

```
Index(['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)', 'species'], dtype='object')
```



Virginica



Setosa



Versicolor

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	virginica
146	6.3	2.5	5.0	1.9	virginica
147	6.5	3.0	5.2	2.0	virginica
148	6.2	3.4	5.4	2.3	virginica
149	5.9	3.0	5.1	1.8	virginica

150 rows x 5 columns

Datos Categóricos en Pandas

- `Categoricals` son un tipo de datos de pandas que corresponden a variables categóricas
- Una variable categórica asume un número limitado y usualmente fijo de valores posibles
- Ejemplos son el género, clase social, tipo de sangre, afiliación a un país, tiempo de observación o calificación mediante escalas de Likert.

```
> iris_df['species'] = pd.Categorical.from_codes(iris.target, iris.target_names)
```

```
['setosa', 'versicolor', 'virginica']
```

```
Categories (3, object): ['setosa', 'versicolor', 'virginica']
```

Estadística descriptiva

Resumir y describir los datos de manera cuantitativa (valores que explican propiedades de los datos). Es muy frecuente el uso de tablas y gráficos.

- *Por ejemplo: Si estamos analizando registros de estudiantes de una escuela, una estadística descriptiva podría ser el porcentaje de estudiantes por género, o la edad promedio por curso, etc.*

Suelen utilizarse varias estadísticas descriptivas a la vez para ofrecer una imagen completa de los datos. Estas son sólo descriptivas. No implican una generalización más allá de los datos que tenemos a mano.

- *Generalizar a partir de nuestros datos a otro conjunto de casos se estudia en estadística inferencial.*

Estadística univariada

Estadística descriptiva

Entre las medidas descriptivas están las de:

- **Tendencia central** (media, mediana, moda),
- **Dispersión o variabilidad** (desviación estándar, varianza, rango),
- **Posición** (cuartiles, deciles, percentiles).

Entre los gráficos tenemos:

- Dispersión
- Barras
- Líneas
- Histogramas
- Boxplots (Caja y bigotes)

El uso de las estadísticas de resumen está sujeto al tipo de atributo. Por ejemplo, cuando son categóricos, generalmente hacemos estadísticas basadas en conteo.

Frecuencia

- La frecuencia de un valor de atributo es el porcentaje de veces que éste es observado. Es decir, frecuencias de aparición de cada valor distinto de un vector:

```
> iris_df['species'].value_counts()
species
setosa          50
versicolor     50
virginica       50
Name: count, dtype: int64
```

- Frecuencias porcentuales:

```
> iris_df['species'].value_counts(normalize=True)
species
setosa          0.333333
versicolor     0.333333
virginica       0.333333
Name: proportion, dtype: float64
```


Medidas de Tendencia Central

Estas medidas tratan de resumir los valores observados en único valor asociado al valor localizado en el centro.

Media

- La media es la medida más común de tendencia central para una variable numérica.
- Si tenemos m observaciones se calcula como la media aritmética o promedio.
- Es una medida muy sensible a outliers o valores atípicos.

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{x_1 + x_2 + \dots + x_N}{N}$$

Ejemplo:

```
> iris_df['petal length (cm)'].mean()  
3.7580000000000005
```

Medidas de Tendencia Central

Mediana

- La mediana representa la posición central de la variable que separa la mitad inferior y la mitad superior de las observaciones.
- Intuitivamente, consiste en el valor donde para una mitad de las observaciones todos los valores son mayores que ésta, y para la otra mitad todos son menores.
- Es más robusta al ruido que la media.

$$\text{median}(x) = \begin{cases} x_{r+1} & \text{Si } m \text{ es impar con } m = 2r + 1 \\ \frac{1}{2}(x_r + x_{r+1}) & \text{Si } m \text{ es par con } m = 2r \end{cases}$$

Ejemplo:

```
> iris_df['petal length (cm)'].median()  
4.35
```

Medidas de Tendencia Central

Moda


- La moda de un atributo es el valor más frecuente observado.
- Pueden ser varios valores.
- Generalmente usamos la frecuencia y la moda para estudiar variables categóricas.

Ejemplo:

```
> iris_df['petal length (cm)'].mode()
```

```
0    1.4  
1    1.5
```

Comparación entre la moda, la mediana y la media



Resumiendo un Data Frame

- En pandas podemos resumir varias estadísticas de resumen de una variable de un *DataFrame* usando el comando *describe*.
- Para las variables numéricas nos entrega el mínimo, los cuartiles, la media y el máximo.

```
> iris_df.describe()
```

21

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

Ejercicio

- Usando el comando groupby analice distintas estadísticas de resumen para las tres especies de Iris para las cuatro variables.
- ¿Nota alguna diferencia en las distintas especies?

```
iris_df.groupby('species')['sepal length (cm)'].describe()  
iris_df.groupby('species')['sepal width (cm)'].describe()  
iris_df.groupby('species')['petal length (cm)'].describe()  
iris_df.groupby('species')['petal width (cm)'].describe()
```

Respuesta:

```
> iris_df.groupby('species')['petal length (cm)'].describe()
```

	count	mean	std	min	25%	50%	75%	max
species								
setosa	50.0	1.462	0.173664	1.0	1.4	1.50	1.575	1.9
versicolor	50.0	4.260	0.469911	3.0	4.0	4.35	4.600	5.1
virginica	50.0	5.552	0.551895	4.5	5.1	5.55	5.875	6.9

Medidas de Dispersión

Estas medidas nos dicen qué tan distintas o similares tienden a ser las observaciones respecto a un valor particular. Generalmente este valor particular se refiere a alguna medida de tendencia central.

Rango

El rango es la diferencia entre el valor máximo y el mínimo:

Ejemplo:

```
> iris_df['petal length (cm)'].max() - iris_df['petal length  
(cm)'].min()
```

5.9

Medidas de Dispersión

Desviación estándar y varianza

La **desviación estándar** es la raíz cuadrada de la **varianza** que mide las diferencias cuadráticas promedio de las observaciones con respecto a la media.

$$\text{var}(x) = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2$$

$$\text{sd}(x) = \sqrt{\text{var}(x)}$$

Ejemplo:

```
> iris_df['petal length (cm)'].std()  
1.7652982332594662
```

```
> iris_df['petal length (cm)'].var()  
3.116277852348993
```


Medidas de Dispersión

Al igual que la media, la desviación estándar es sensible a outliers.

Las medidas más robustas se basan en la mediana.

Desviación absoluta promedio

Sea $m(x)$ una medida de tendencia central de x (usualmente la mediana), se define la desviación absoluta promedio o average absolute deviation (AAD) como:

$$AAD = \frac{1}{n} \sum_{i=1}^n |x_i - m(x)|$$

```
> import numpy as np
> def aad(x, fun=np.median):
    return np.mean(abs(x - fun(x)))
> aad(iris_df['petal length (cm)'])
1.4886666666666668
```

Medidas de Dispersión

Desviación mediana absoluta

Sea b una constante de escala se define la desviación mediana absoluta o median absolute deviation (MAD) como:

$$MAD = b \cdot \text{median}(|x_i - \text{median}(x)|)$$

```
> from scipy import stats  
> stats.median_abs_deviation(iris_df['petal length (cm)'])  
1.25
```

Percentiles o Cuantiles

- El k-ésimo percentil de una variable numérica es un valor tal que el k% de las observaciones se encuentran debajo del percentil y el (100 - k)% se encuentran sobre este valor.
- En estadística se usan generalmente los cuantiles que son equivalentes a los percentiles expresados en fracciones en vez de porcentajes. Percentil va de 1 a 100. Cuantiles (va de 0 a 1 = percentil/100).

Ejemplo:


```
> iris_df['petal length (cm)'].quantile([0.0, 0.25, 0.5, 0.75, 1.0])
```

0.00	1.00	→	mínimo = percentil 0%
0.25	1.60		
0.50	4.35	→	mediana = percentil 50%
0.75	5.10		
1.00	6.90	→	máximo = percentil 100%

Percentiles o Cuantiles

Además es muy común hablar de los **cuartiles** que son tres percentiles específicos:

- El **primer cuartil Q1** (lower quartile) es el percentil con $k = 25$.
- El **segundo cuartil Q2** es con $k = 50$ que equivale a la mediana.
- El **tercer cuartil Q3** (upper quartile) es con $k = 75$.




<https://clauswilke.com/dataviz/>

Gráficos de cajas (boxplots): La caja muestra los cuartiles del conjunto de datos, mientras que los bigotes se extienden para mostrar el resto de la distribución.

Rango intercuartil (IQR)

Los percentiles nos permiten definir el Rango Intercuartil: diferencia entre el tercer y primer cuartil ($RIC = Q3 - Q1$).

¿Qué representa el RIC? El 50% central de nuestro conjunto de datos. El rango de valores entre el percentil 25 y el percentil 75.




<https://clauswilke.com/dataviz/>

Un valor se clasifica como atípico u "outlier" si se encuentra a una distancia mayor a 1.5 veces el RIC. Límite inferior: $Q1 - (1.5 \times RIC)$. Límite superior: $Q3 + (1.5 \times RIC)$

Rango intercuartil (IQR)

```
iris_df['petal length (cm)'].quantile(0.75)  
- iris_df['petal length (cm)'].quantile(0.25)  
3.4999999999999996
```



Estadística multivariadas

Estadísticas de Resumen Multivariadas

- Para comparar cómo varía una variable respecto a otra, usamos medidas multivariadas.
- La covarianza $\text{cov}(\mathbf{x}, \mathbf{y})$ mide el grado de variación lineal conjunta de un par de variables x, y :

$$\text{cov}(x, y) = \frac{1}{m-1} \sum_{i=1}^n (x - \bar{x})(y - \bar{y})$$

- Si dos variables son independientes entre sí, su covarianza es cero.

Estadísticas de Resumen Multivariadas

Para datasets de varias columnas numéricas uno puede calcular una matriz de covarianza. Cada celda i,j de esta matriz contiene la covarianza entre los atributos i y j . Esta matriz es simétrica.

Ejemplo:

```
> iris_df.cov(numeric_only=True)
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
sepal length (cm)	0.685694	-0.042434	1.274315	0.516271
sepal width (cm)	-0.042434	0.189979	-0.329656	-0.121639
petal length (cm)	1.274315	-0.329656	3.116278	1.295609
petal width (cm)	0.516271	-0.121639	1.295609	0.581006

Estadísticas de Resumen Multivariadas


- Para tener una medida de relación que no dependa de la escala de cada variable, usamos la **correlación lineal**.
- Se define a la correlación lineal o coeficiente de correlación de **Pearson** $r(x, y)$ como:

$$r(x, y) = \frac{cov(x, y)}{sd(x)sd(y)}$$


La correlación lineal varía entre -1 a 1.

- Un valor cercano a 1 indica que mientras una variable crece la otra también lo hace en una proporción lineal.
- Un valor cercano a -1 indica una relación inversa (una crece la otra decrece).


Estadísticas de Resumen Multivariadas



Positive
Correlation



Negative
Correlation



No
Correlation

Estadísticas de Resumen Multivariadas

- Una correlación cercana a 0 no implica que no pueda haber una relación no-lineal entre las variables.
- Podemos usarla de forma análoga a la covarianza para obtener una matriz de correlaciones (covarianzas normalizadas).

¡Hay que interpretar con cuidado las correlaciones!

Ejemplo:

```
> iris_df.corr(numeric_only=True)
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
sepal length (cm)	1.000000	-0.117570	0.871754	0.817941
sepal width (cm)	-0.117570	1.000000	-0.428440	-0.366126
petal length (cm)	0.871754	-0.428440	1.000000	0.962865
petal width (cm)	0.817941	-0.366126	0.962865	1.000000

Tablas de Contingencia

- Para analizar la relación entre variables de naturaleza categórica usamos **tablas de contingencia**.
- La tabla se llena con las frecuencias de co-ocurrencia de todos los pares de valores entre dos variables categóricas.

Ejemplo:

```
pd.crosstab(data.estudios, data.sexo)
```

	estudios	sexo
0	universitario	hombre
1	secundario	hombre
2	secundario	mujer
3	postgrado	hombre
4	secundario	mujer
5	universitario	mujer



	sexo	hombre	mujer
estudios			
postgrado		1	0
secundario		1	2
universitario		1	1

Tablas de Contingencia

- Para analizar la relación entre variables de naturaleza categórica usamos **tablas de contingencia**.
- La tabla se llena con las frecuencias de co-ocurrencia de todos los pares de valores entre dos variables categóricas.

Ejemplo:

```
pd.crosstab(data.sexo, data.estudios)
```


	estudios	sexo
0	universitario	hombre
1	secundario	hombre
2	secundario	mujer
3	postgrado	hombre
4	secundario	mujer
5	universitario	mujer



	estudios	postgrado	secundario	universitario
sexo				
hombre		1	1	1
mujer		0	2	1

Visualización de Datos

- La visualización de datos es la transformación de un dataset a un formato visual que permita a las personas identificar las características y las relaciones entre sus elementos (columnas y filas).
- La visualización permite que las personas reconozcan patrones o tendencias en base a su criterio o conocimiento en el dominio de aplicación.



Es importante mostrar los datos





Las estadísticas descriptivas ocultan variabilidad que puede ser importante. No mostrarla puede inducir **errores de interpretación**.

Los datos agregados pueden ocultar patrones en los datos. **Limita la capacidad de encontrar algo que no esperábamos**, porque la agregación usualmente se hace pensando en un fin específico.

Visualizar es necesario para poder distinguir


Anscombe's Quartet: Raw Data

	1		2		3		4	
	X	Y	X	Y	X	Y	X	Y
	10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
	8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
	13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
	9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
	11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
	14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
	6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
	4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
	12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
	7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
	5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89
Mean	9.0	7.5	9.0	7.5	9.0	7.5	9.0	7.5
Variance	10.0	3.75	10.0	3.75	10.0	3.75	10.0	3.75
Correlation	0.816		0.816		0.816		0.816	



Datasaurus dozen


Los números resúmenes
pueden ocultar la verdadera
estructura de los datos



X Mean: 54.26
Y Mean: 47.83
X SD : 16.76
Y SD : 26.93
Corr. : -0.06



Same Stats, Different Graphs: Generating Datasets with Varied Appearance and Identical Statistics through Simulated Annealing. Justin Matejka, George Fitzmaurice. ACM SIGCHI Conference on Human Factors in Computing Systems, 2017.



Same Stats, Different Graphs: Generating Datasets with Varied Appearance and Identical Statistics through Simulated Annealing. Justin Matejka, George Fitzmaurice. ACM SIGCHI Conference on Human Factors in Computing Systems, 2017.

Visualización en Python

- Matplotlib es una biblioteca de gráficos en Python que permite la creación de una amplia gama de gráficos y figuras estáticos, animados e interactivos.



- Se integra bien con pandas y NumPy, facilitando la visualización de datos de DataFrames y arrays, respectivamente.

44




- Contiene módulos y funciones para trazar una variedad de gráficos, desde histogramas y gráficos de dispersión hasta gráficos complejos en 3D.
- Sin embargo, para gráficos más elaborados existen otras librerías como plotly y seaborn




Histogramas

- Muestran la distribución de los valores de una variable.
- Los valores de los elementos se dividen en contenedores (bins) y se crean gráficos de barra por cada contenedor.
- La altura de cada barra indica el número de elementos o frecuencia del contenedor.
- En pyplot se crean con el comando *hist*.



Histogramas

- La forma del histograma depende del número de contenedores.
- En pyplot se puede definir esa cantidad con el parámetro *bins*.
- Ejemplo con bins=100




Densidad

- Otra forma de visualizar cómo se distribuyen los datos es estimando una densidad.
- Se calculan usando técnicas estadísticas no paramétricas llamadas estimación de densidad de **kernel**.
- La densidad es una versión suavizada del histograma y nos permite determinar más claramente si los datos observados se comportan como una densidad conocida ej: normal.


Densidad

- En python se crean con el comando *gaussian_kde* de scipy para luego visualizarlas con el comando *plot*.




Gráficos de Torta o Pie Charts

- Los gráficos de torta, gráficos circulares o pie charts representan la frecuencia de los elementos en un círculo.
- Cada elemento tiene una participación proporcional a su frecuencia relativa.
- El total debe sumar 1 (o 100%)
- Se usan generalmente para variables categóricas.
- No se recomienda mucho su uso, pues pueden entregar información engañosa.



Boxplots


- 0 diagramas de caja se construyen a **partir de los cuartiles**.
- Se construye una rectángulo usando el primer y el tercer cuartil (Q1 y Q3).
- La altura del rectángulo es el rango intercuartil RIC.
- La mediana es una línea que divide el rectángulo.
- Cada extremo del rectángulo se extiende con una recta o brazos de largo $Q1 - 1,5 \cdot RIC$ para la recta inferior y $Q3 + 1,5 \cdot RIC$ para la recta superior.
- Los valores más extremos que el largo de los brazos son considerados atípicos.
- Entrega información sobre la simetría de la distribución de los datos. Si la mediana no está en el centro del rectángulo, la distribución no es simétrica.
- Son útiles para ver la presencia de valores atípicos u outliers.




Fuente:

<http://commons.wikimedia.org/wiki/File:Boxplot.svg>


El largo de los brazos así como el criterio para identificar valores atípicos se basa en el comportamiento de una normal.



- Si tenemos una variable categórica es útil crear un boxplot para cada valor de ésta con respecto a otra variable numérica:




- También podemos comparar varios boxplots en un mismo gráfico:



Diagramas de Dispersión

- Los diagramas de dispersión o scatter plots usan coordenadas cartesianas para mostrar los valores de dos variables numéricas del mismo largo.
- Los valores de los atributos determinan la posición de los elementos.
- Otros atributos pueden usarse para definir el tamaño, la forma o el color de los objetos.
- En matplotlib podemos graficar un scatterplot de dos variables numéricas usando el comando `scatter(x,y)`, que sería y vs x.




Gráficos de Coordenadas Paralelas

- Los gráficos de coordenadas paralelas ofrecen una alternativa para visualizar datos multidimensionales.
- En vez de usar ejes perpendiculares (x-y-z) usamos varios ejes paralelos entre sí.
- Cada atributo es representado por uno de los ejes paralelo con sus respectivos valores.
- Los valores de los distintos atributos son escalados para que cada eje tenga la misma altura.
- Cada observación representa una línea que une los distintos ejes de acuerdo a sus valores.
- De esta manera, objetos similares entre sí tienden a agruparse en líneas con trayectoria similar.
- En muchas ocasiones es necesario realizar un reordenamiento de los ejes para poder visualizar un patrón.


- En Python podemos crear gráficos de coordenadas paralelas con el comando *parallel_coordinates* de la librería pandas y utilizando matplotlib para visualizar con pyplot.

```
pd.plotting.parallel_coordinates(data, 'Species', colormap=plt.get_cmap("Set1"))  
plt.title('Parallel Coordinates Plot for Iris Data')
```



Gráficos de Radar (o de Estrellas)

- Permiten visualizar y comparar múltiples variables cuantitativas de forma simultánea en un plano bidimensional.
- Cada variable se representa en su propio eje radial partiendo de un punto central común. Los valores individuales se conectan para formar un polígono.
- La geometría resultante revela el "perfil" característico de los datos. Es especialmente útil para detectar patrones visuales, similitudes o asimetrías al comparar diferentes grupos o categorías.



Hay muchos tipos de visualizaciones más!



Installing **Gallery** Tutorial API Releases Citing FAQ



Example gallery

