



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Análisis Exploratorio de Datos II

Profesores: Cinthia Sánchez y Cristian Llull

Visualizar Tablas

Recordemos que en las tablas hay **observaciones**

Cada **observación** tiene:

- **atributos**, que la caracterizan
- **una llave**, que la identifica

Algunos de esos atributos son numéricos. No todos.

Veamos y discutamos sobre algunas visualizaciones con más detalle

Diagramas de Dispersión

Expresa atributos cuantitativos.

No usa llaves, solamente valores.



Datos: 2 atributos cuantitativos.

Marca: puntos.

Canales: posición horizontal y vertical.

Tareas: **encontrar patrones**,
identificar outliers, medir
correlaciones, determinar *clusters*.


Escalabilidad: cientos de ítemes.



¿Qué pasa si hago la curva de tendencia general y no por especie?


Penguin bill dimensions

Bill length and depth for Adelie, Chinstrap and Gentoo Penguins at Palmer Station LTER



Paradoja de Simpson: Fenómeno estadístico donde una tendencia observada en varios grupos de datos desaparece o se invierte al combinar dichos grupos.

The **fatality rate** is roughly seven times higher when colliding with a heavy pickup truck than with a compact car. As the weight of your car increases, the risk of killing others increases dramatically.



La curva de tendencia puede tener una forma arbitraria, ya que también es una visualización.


Gráfico de líneas

Datos: una llave y un valor: 2 atributos cuantitativos.


Marca: puntos, que se conectan a través de líneas


Canales: la posición vertical de los puntos expresa un valor cuantitativo, la posición horizontal es ordenada por el atributo llave.

Tareas: encontrar tendencias/patrones. Las líneas que conectan cada par consecutivo de puntos enfatizan la relación (pendiente) que hay entre un ítem y el siguiente.



Fuente: [Wikipedia Pageviews](https://www.wikipedia.org/wiki/Pageviews)





¡[Versión actual](#) del mismo gráfico!

Gráfico de áreas


Si rellenamos el espacio debajo de la línea tenemos un gráfico de áreas o *area chart*.

Esto introduce cambios en la interpretación del gráfico: además de las pendientes y posiciones, comparamos la altura de las áreas. Se pone énfasis en la cantidad o el volumen, más que en la evolución temporal.

Si comparamos la altura, estamos comparando distancias.


Dificultad: cuando las áreas se cubren entre sí.

US music sales by format (inflation-adjusted)
IN BILLIONS (USD)



[what is an area graph, how does an area graph work, and what is an area graph good for? – storytelling with data](#)


US music sales by format (inflation-adjusted)
IN BILLIONS (USD)



US music sales by format (inflation-adjusted)

IN BILLIONS (USD)

[what is an area graph, how does an area graph work, and what is an area graph good for? – storytelling with data](#)




SOURCE: Recording Industry Association of America

Las áreas se pueden apilar: **stacked area chart**. ¡Esto permite ver el volumen total! Pero dificulta las comparaciones porque las áreas perdieron su base común.

In well-vaccinated countries, the Delta surge in **cases** is no longer mirrored in **deaths**.
In countries where few have been vaccinated, **death rates** are reaching record highs

Weekly **cases** per 100k people, and weekly **deaths** per 2 million



Source: FT analysis of data from Johns Hopkins CSSE. Cases shifted forward to account for lag between infection and death
© FT

Se pueden crear variaciones interesantes con áreas. Por ejemplo, aquí el eje y es simétrico.

Fuente: <https://twitter.com/jburnmurdoch/status/1416805508724502533/photo/1>

Gráficos de barras

Datos: 1 atributo categórico, 1 cuantitativo.



Marca: líneas.

Canales:

1) largo de la barra para expresar valores cuantitativos.
2) Regiones del espacio: una por marca. Separadas horizontalmente, alineadas verticalmente. Las líneas pueden ser ordenadas (por ej., orden alfabético).

Tareas: **comparar**, encontrar valores, **encontrar extremos**.

Escalabilidad: decenas a cientos de niveles para atributo llave.



Gráficos de barras

Datos: 1 atributo categórico, 1 cuantitativo.


Marca: líneas.

Canales:

1) largo de la barra para expresar valores cuantitativos.
2) Regiones del espacio: una por marca. Separadas horizontalmente, alineadas verticalmente. Las líneas pueden ser ordenadas (por ej., orden alfabético).

Tareas: **comparar**, encontrar valores, **encontrar extremos**.

Escalabilidad: decenas a cientos de niveles para atributo llave.



Gráficos de barras

Datos: 1 atributo categórico, 1 cuantitativo.

Marca: líneas.

Canales:

1) largo de la barra para expresar valores cuantitativos.
2) Regiones del espacio: una por marca. Separadas horizontalmente, alineadas verticalmente. Las líneas pueden ser ordenadas (por ej., orden alfabético).

Tareas: **comparar**, encontrar valores, **encontrar extremos**.

Escalabilidad: decenas a cientos de niveles para atributo llave.





Gráfico de barras apiladas



Fuente: <https://t-redactyl.io/posts/2016-01-19-ggplot-graphs-part-4-stacked-bar-graphs/>


Gráfico de barras apiladas normalizado

Tarea: **entender relaciones parte-de-un-todo.**

Normalized stacked bar chart: es un *stacked bar chart*, normalizado para que utilice todo el espacio vertical.

Cada barra es el equivalente a un gráfico de torta (*pie chart*).

En contraste, tiene **alta densidad de información:** un rectángulo delgado codifica la distribución.



Fuente: <https://t-redactyl.io/posts/2016-01-19-ggplot-graphs-part-4-stacked-bar-graphs/>

¿barras o líneas?





Depende del tipo de llave

- barras si es categórica
- líneas si es ordinal o cuantitativa

NO usar líneas con llaves categóricas no ordinales. Hacerlo viola el principio de expresividad.

Como consecuencia tendemos a ver tendencias o patrones muy fuertes que no respetan la semántica.

“Mientras más hombre sea el sexo de una persona, más alta es”.




Basado en [Bars and Lines: A Study of Graphic Communication](#). Zacks and Tversky. Memory and Cognition 27:6 (1999), 1073–1079.

[Por hora, 9 mulheres denunciam crime de stalking no Brasil - 30/03/2024 - Cotidiano - Folha](#)

Un **histograma** es un gráfico de barras cuyo atributo categórico es **ordinal** y cada categoría abarca un rango de datos.


Faixa etária das vítimas de stalking no município de São Paulo

Entre 2021 e 2023, por gênero



Fonte: Análise do DeltaFolha com base nos dados da Secretaria de Segurança Pública do estado de São Paulo

Como los histogramas aproximan distribuciones, algunas personas argumentan que no puede haber espacios entre las barras. Es decir, es un gráfico de áreas que utiliza una *step function* en vez de una función suave.



Heatmap


Datos: dos llaves categóricas, un valor cuantitativo.

Marcas: área, separadas y alineadas en una matriz 2D. La posición de cada área es determinada por los dos atributos categóricos, uno por cada eje.


Canales: color determinado por el atributo cuantitativo.

Tareas: **encontrar clusters, outliers.**

Escalabilidad: 1M ítemes, 100s de niveles categóricos, aprox. 10 niveles en el atributo cuantitativo



	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
sepal length (cm)	1.000000	-0.117570	0.871754	0.817941
sepal width (cm)	-0.117570	1.000000	-0.428440	-0.366126
petal length (cm)	0.871754	-0.428440	1.000000	0.962865
petal width (cm)	0.817941	-0.366126	0.962865	1.000000



Cluster heatmap

Extiende la técnica anterior con datos derivados: 2 jerarquías de clusters, una para llave.

Dendrograma: árbol que determina las relaciones entre ítems asociados a cada llave, visualizado con líneas conectadas entre sí.

Las hojas de cada dendrograma (las llaves) están alineadas por lo que es fácil comparar elementos del árbol.

Heatmap: las marcas son (re-)ordenadas de acuerdo a su posición en los árboles






Figure 6: Hierarchical agglomerative clustering of diet and fitness subreddits by text similarity in submissions, based on the All MPNet Base V2 sentence embedding model (Song et al., 2020) and the Fréchet Inception Distance (Heusel et al., 2017; Kour et al., 2022). Cells with dark colors indicate more similarity (less distance) between the subreddits.

Rutinas Diarias en Santiago



¡Usamos un clustermap para organizar los resultados!



¿Cómo caracterizar las rutinas de Santiago en función de los viajes que realizan las personas? Lo podemos calcular a partir de la Encuesta Origen Destino.

Qué llevarse para la casa

La mayoría de las visualizaciones que hemos visto ya eran **conocidas**.

Nos enfocamos en la **manera de describirlas** utilizando marcas y canales, y permite indagar en cómo se **define** una visualización en función del **qué** (datos) y el **cómo** (codificación).

Así, podemos comparar entre distintas visualizaciones para elegir la mejor opción en función de la **tarea a realizar** (para qué).

Teorema Central del Límite (TCL)

Si $X_1, X_2, \dots, X_n$ son variables Independiente e Idénticamente Distribuida (i.i.d.), con media μ y varianza σ^2 , entonces para n suficientemente grande:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{d} \mathcal{N} \left(\mu, \frac{\sigma^2}{n} \right)$$


En **palabras simples**: sin importar la distribución original de los datos, el promedio de muchas muestras se distribuye aproximadamente normal.

Demostración TCL con Iris

La distribución de **petal length** es bimodal (no normal).

Al tomar muestras aleatorias y graficar sus **medias**, la nueva distribución converge hacia una curva Normal a medida que el tamaño de la muestra n aumenta.

¿Por qué? En muestras grandes, las flores pequeñas y grandes se compensan. Al promediarlas, los extremos se cancelan y el resultado se acerca casi siempre al promedio real de la población.



Comparen el eje X de cada gráfico. A mayor n , la escala se comprime: menor varianza y mayor precisión.

TCL en Minería de Datos

El TCL justifica procedimientos fundamentales:

- Calcular **intervalos de confianza** sobre cualquier promedio (edad promedio, valor medio de *feature*)
- Sustentar que **promediar resultados** de experimentos produce estimaciones confiables
- Es el fundamento de por qué “**más datos = mejores estimaciones**”

Ejemplo práctico:

Si mides el error de predicción sobre 1000 muestras de test, el promedio del error se distribuye aproximadamente normal, sin importar la distribución original del error.

Estimación puntual

Dado que nunca tenemos acceso a la población completa, estimamos parámetros desde una muestra.

Un estimador $\hat{\theta}$ es una función de los datos que aproxima un parámetro θ .

Ejemplo con Titanic

Problema: estimar la proporción de pasajeros que sobrevivieron según clase de cabina.

- Con 216 pasajeros de primera clase: $\hat{p}_{1ra\ class} = 0.63$
- Con 491 pasajeros de tercera clase: $\hat{p}_{3ra\ class} = 0.24$

Ambas son **estimaciones puntuales** de la probabilidad real de sobrevivir en cada grupo.

Pregunta para reflexionar: si tuvieras solo 20 pasajeros de primera clase en tu muestra en vez de 216, ¿confiarías igual en $\hat{p}$? ¿Por qué?

Estimación por intervalo

Un intervalo de confianza (IC) al $(1 - \alpha)\%$ es un rango que contiene el parámetro verdadero con esa probabilidad, bajo muestreo repetido.

Para una proporción (con n grande):

$$IC = \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Para la media con σ conocida:

$$IC = \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Estimación por intervalo

Importante: el IC no dice que hay 95% de probabilidad de que el parámetro esté en ese intervalo.

Interpretación correcta

El IC dice que el **procedimiento** produce intervalos que capturan el parámetro verdadero el 95% de las veces.

Si repitiéramos el experimento muchas veces y calculáramos un IC 95% cada vez, aproximadamente el 95% de esos intervalos contendrían el valor verdadero.

https://es.wikipedia.org/wiki/Intervalo_de_confianza

Ejemplo con Titanic: Supervivencia femenina

Datos: 314 mujeres, 233 sobrevivieron ($\hat{p} = 0.742$)


IC 95%:

$$IC = 0.742 \pm 1.96 \sqrt{\frac{0.742 \times 0.258}{314}} = [0.694, 0.790]$$

Entre el 69% y 79% de las mujeres sobrevivieron, con 95% de confianza.

Podemos repetir el cálculo para hombres ($\hat{p} = 0.189$) y ver que los intervalos no se solapan - hay una diferencia real.

Visualización de Intervalos de Confianza



Reportar una estimación con su IC es más informativo que un solo número.

El solapamiento visual de los intervalos da intuición sobre si hay diferencias reales.

Técnicas de visualización

Sitios recomendados:

- <https://www.data-to-viz.com/>
- <https://datavizcatalogue.com/>
- <https://datavizproject.com/>