



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Preprocesamiento de Datos

Profesores: Cinthia Sánchez y Cristian Llull

Metodología para el tratamiento de los datos

*Múltiples fuentes de datos:
Temperatura, presión,
lluvias, nubosidad, relieve,
tendencias del cambio
climático, etc...*

*Limpieza y preparación de
los datos. Trabajo con
datos faltantes,
selección/generación de
características relevantes*

*Poner el modelo en
producción*

Definición del
Problema

Recolección de
Datos

Análisis
Exploratorio de
datos

Preprocesamien
to de datos

Entrenamiento
y Validación del
Modelo

Despliegue del
Modelo

*Heladas en el valle central
provocan pérdidas en la
producción de frutales.*

Solución: Predicción de
Heladas

*Exploración usando
estadísticas de resumen
(frecuencias, medidas de
tendencia central y
dispersión) y visualización.*

*Creación, evaluación y
ajuste de modelos de
Machine Learning*


Retroalimentación: Evaluar el
rendimiento del modelo
desplegado en los nuevos datos.
Reentrenar en caso que el modelo
quede desactualizado.

Metodología para el tratamiento de los datos

*Múltiples fuentes de datos:
Temperatura, presión,
lluvias, nubosidad, relieve,
tendencias del cambio
climático, etc...*

*Limpieza y preparación de
los datos. Trabajo con
datos faltantes,
selección/generación de
características relevantes*

*Poner el modelo en
producción*



*Heladas en el valle central
provocan pérdidas en la
producción de frutales.*

Solución: Predicción de
Heladas

*Exploración usando
estadísticas de resumen
(frecuencias, medidas de
tendencia central y
dispersión) y visualización.*

*Creación, evaluación y
ajuste de modelos de
Machine Learning*


Retroalimentación: Evaluar el
rendimiento del modelo
desplegado en los nuevos datos.
Reentrenar en caso que el modelo
quede desactualizado.

Calidad de los datos


- Datos no poseen la calidad deseada a priori.
- Los algoritmos de DM se enfocan en:
 1. Limpieza de Datos: Detección y corrección de problemas de calidad.
 2. Usar algoritmos que toleren datos de poca calidad.

Valores faltantes


- Información no recolectada
(e.j: no quieren dar edad
y/o peso)
- Atributos no aplicables a
todos
(e.j: impuesto en niños)




¿Qué hacemos con los valores faltantes?



Eliminar filas con datos faltantes



Eliminar atributo que tiene muchos valores faltantes
(selección o reducción de atributos)



Imputación de datos

Imputación de Datos

La imputación es el proceso de reemplazar los datos faltantes con valores sustituidos.



¿Cuándo podemos imputar datos?

- Toda manipulación de datos tiene consecuencias.
- Debe evaluarse el impacto de imputar datos nulos.
- En minería de datos, al usar técnicas descriptivas, **es más recomendable** trabajar con **datos sin imputación**.
- En minería de datos o machine learning, la imputación de datos nos puede ayudar a obtener mejores resultados en modelos predictivos.


¿Cuándo podemos imputar datos?

- **Nunca imputar la variable que queremos predecir (La clase, categoría o variable objetivo)**

Ej. Si queremos detectar un patrón que nos permita predecir si un estudiante eliminará un ramo. No podemos imputar valores nulos en la columna que nos dice si eliminó o no el ramo.

¿Cuándo podemos imputar datos?

- Si un atributo del dataset tiene valores nulos sistemáticamente, entonces es más conveniente considerar eliminar la columna en vez de aplicar imputación de datos. (selección de atributos)



¿Cuándo podemos imputar datos?


- Si algunos **registros** del dataset tienen muchos atributos faltantes, entonces podría ser más conveniente eliminar esos registros.



Técnicas de Imputación de Datos

Métodos Simples

- Valor fijo
- Media o Mediana
- Valor más frecuente
- Valor máximo o mínimo




Este método se ocupa si sabemos que los datos varían dentro de un rango o si la razón de que falte se debe a que alcanzó o sobrepasó un límite.

Técnicas de Imputación de Datos

Métodos basados en técnicas de minería de datos

- K-Nearest Neighbour Imputation
- Otros métodos predictivos (regresiones, clasificadores) que ocupan otros atributos no nulos del objeto para predecir el valor del atributo faltante.

Técnicas de Imputación de Datos



Profundizaremos en esto más adelante cuando veamos métodos de clasificación.

Técnicas de Imputación de Datos

Métodos para datos ordenados o series temporales

- Valor anterior o siguiente
- Interpolación promedio o linear

Datos duplicados

- Duplicados exactos (Filas idénticas): Todos los atributos/columnas tienen el mismo valor.
- Puede ocurrir al juntar datos de fuentes múltiples.




Estrategias de tratamiento

- Conservar la primera aparición (Keep First): Útil cuando se asume que el primer registro cronológico es el original o el más puro.
- Conservar la última aparición (Keep Last): Ideal para datos transaccionales donde el último registro refleja el estado más actualizado de un usuario o entidad.

Outliers

- Objetos con características considerablemente diferentes a los otros objetos en el dataset.
- Recordemos que hay valores atípicos “buenos”. Ejemplo, evento raro tipo anomalía que queremos predecir!



Estrategias para detectar/remover Outliers

- Z-Score (Puntaje Z): Útil cuando la variable asume una distribución normal. Mide a cuántas desviaciones estándar se encuentra un dato respecto a la media. Usualmente cuando $|Z| > 3$

$$Z = \frac{x - \mu}{\sigma}$$



Z = standard score

x = observed value

μ = mean of the sample


σ = standard deviation of the sample

- Rango Intercuartílico (IQR): Método estadístico más robusto para distribuciones asimétricas.



Maldición de la Dimensionalidad

- Al aumentar la dimensionalidad, los datos se vuelven más dispersos en el espacio.
- Pierden significado las medidas, i.e. densidad y distancia entre puntos



Diferencia relativa entre la distancia máxima y la distancia mínima entre los puntos. A medida que aumentan las dimensiones, la curva decae. Esto significa: **la distancia al punto más cercano se vuelve casi idéntica a la distancia al punto más lejano.**

Reducción de Dimensionalidad y Selección de Atributos

Propósito

- Evitar maldición de la dimensionalidad
- Reducir costos asociados a aplicar algoritmos (tiempo, memoria)
- Mejor visualización de los datos
- Ayuda a quitar atributos irrelevantes o ruidosos

Selección de Atributos

Elegimos atributos

- Missing Values Ratio
- Low Variance Filter
- High Correlation Filter

Si una columna posee muchos valores nulos podría ser candidata para eliminarla

Si una columna tiene varianza casi cero, quiere decir que no aporta mucha info.

Si dos columnas están muy correlacionadas, me puedo quedar con una solamente

Selección de Atributos

Técnicas automáticas que seleccionan atributos

- Random Forest / Ensemble Trees
- Backwards/Forward Feature Elimination/Construction



**Muy costosas
computacionalmente**

Reducción de Dimensionalidad


Datos de alta dimensión: Objetos son representados por un alto número de características.

- Cuando la dimensionalidad aumenta, los datos se vuelven cada vez más **dispersos** en el espacio.
- Pierden sentido los conceptos de densidad y distancia entre puntos (fundamentales para clustering y detección de outliers).
- Los datos son difíciles de visualizar, especialmente cuando alguna de las características no es discriminatoria.

Reducción de Dimensionalidad

Técnicas de Álgebra lineal para transformar el espacio dimensional a uno de menor tamaño


- PCA (Análisis de componentes principales)
- LDA (Análisis discriminante lineal)
- SVD
- Isomap



Cuidado! Pérdida de interpretabilidad

PCA: Principal Component Analysis


- Sirve para encontrar patrones en los datos
- Sirve para reducir su dimensión sin perder “much” información





Retiene características de los datos que contribuyen más a su varianza (hablaremos más adelante de este y otros algoritmos)

Reducir la dimensionalidad también nos sirve para visualizar los datos!

Reducción de la dimensionalidad (PCA)



<https://archive.ics.uci.edu/ml/datasets/iris>



```
from sklearn.decomposition import PCA
pca = PCA(n_components=2)
X_r = pca.fit(X).transform(X)
```


Agregación

Combinar dos o más atributos (u objetos) en un solo atributo (u objeto).

- Propósito:
 - Reducción de datos (número de atributos u objetos).
 - Cambio de escala (granularidad del análisis). Ejemplo: Ciudades agregadas en regiones; días agregados en semanas, meses o años.
 - Datos más “estables”.

Agregación

Series temporales de precipitaciones diarias de una estación meteorológica.



Average Happiness for Twitter

All Tweets in English.



https://hedonometer.org/timeseries/en_all/

Muestreo

Técnica para la reducción de datos. Útil cuando la obtención/procesamiento de todo el conjunto de datos es demasiado caro o requiere mucho tiempo.

- **Principios:**

- El uso de una muestra funcionará casi tan bien como el uso de todo el conjunto de datos, si la muestra es **representativa**.
- Una muestra es representativa si tiene aproximadamente las mismas propiedades (de interés) que el conjunto original de datos.


- **Tipos de muestreo:**

- Muestreo aleatorio simple (sin reemplazo o con reemplazo).
- Muestreo estratificado.


Muestreo aleatorio




Muestreo estratificado




Muestras proporcionales
al tamaño de la
población real



8000 points



2000 Points



500 Points


Ejemplo de la pérdida de estructura con muestreo.

Discretizar y Binarizar


- Proceso de convertir un atributo continuo en un atributo categórico
- Decidir cuántas categorías tendremos
- Supervisado (yo elijo cuáles clases)
- No-supervisado (ej. división usando intervalos fijos, usando clustering, etc.)

Discretización


Proceso de convertir un atributo continuo en un atributo categórico.



(0.901, 20.8]	9
(20.8, 40.6]	14
(40.6, 60.4]	9
(60.4, 80.2]	13
(80.2, 100.0]	5



(0.999, 23.8]	10
(23.8, 35.0]	11
(35.0, 55.2]	9
(55.2, 73.6]	10
(73.6, 100.0]	10




o usando clustering, por ej K-means

Discretización

```
data.sample(5)
```

	age	value	age_binned
14	33	0.163998	(20.8, 40.6]
46	80	0.995226	(60.4, 80.2]
38	66	0.661530	(60.4, 80.2]
29	50	0.816981	(40.6, 60.4]
25	30	0.925797	(20.8, 40.6]



Transformación de atributos

- **Estandarización y normalización:**

- Estandarización: variable con media 0 y desviación estándar 1.
- Normalización: variable con rango 0-1.

$$x' = (x - \bar{x}) / s_x$$


$$= \frac{x - \min(x)}{\max(x) - \min(x)}$$

- **Convertir un atributo en otro usando alguna función:**


- Logaritmo para enfatizar valores pequeños / mitigar valores grandes. Se recomienda en casos con grandes diferencias de magnitud entre observaciones.
- Potencia (x^2) para exacerbar diferencias.
- Módulo ($|x|$) cuando no nos importa la dirección o signo.

Transformación de atributos

La población se distribuye simétricamente en torno a la mediana. Escala lineal oculta las diferencias.




Usando escala lineal



Using a log scale


Creación de atributos

- Aplicamos una función a uno o más atributos para crear uno nuevo.
- Mapeamos atributos a un nuevo espacio



**Ej. Word Embeddings
(Word 2 Vec)**

Mapear a un nuevo espacio



Two Sine Waves +
Noise

Frequency

La transformada de Fourier nos permite llevar la señal al dominio de la frecuencia y detectar ruido

Resumen de preprocesamiento de datos

- Puede mejorar la eficacia de la visualización, y el rendimiento de modelos de Machine Learning.
- Ayuda a interpretar los resultados.
- Estar consciente de los problemas con los datos (resolución, métricas, dispersión, datos faltantes, duplicados, erróneos).
- Comunicar al usuario que estos procesos han sido aplicados a los datos. De otro modo, se pueden obtener de los datos malas interpretaciones o conclusiones erróneas.