Minería de Datos

Clasificación

(Introducción, Framework, Evaluación)

Valentin Barriere / Mauricio Cerda / Cinthia Sánchez

CC5205, Otoño 2026

Basado en las slides de Bárbara Poblete

CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

¿Qué es la Clasificación?

- Técnica que “aprende” automáticamente cómo clasificar objetos en dos o más clases determinadas.
- Este aprendizaje se basa en datos previamente etiquetados (clasificados).
- Se aplica en caso en que “etiquetar” tiene un alto costo (por ejemplo: trabajo humano experto).

Ejemplo de aplicación

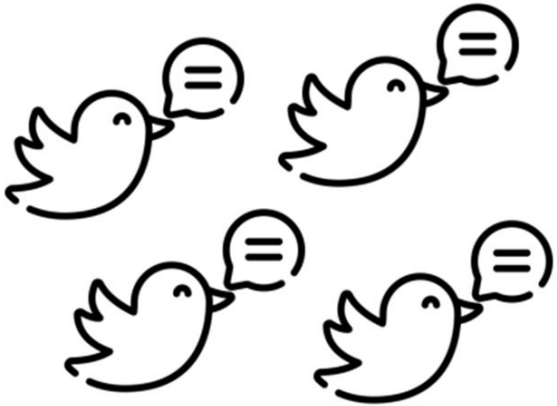

Mensajes	¿Relevante para la crisis?
Ascienden 52 los muertos y 1,2 millones de afectados por terremoto en Guatemala: La cifra de muertos por el... http://t.co/YyCHBArU	Sí
No sé si preocuparme porque no sentí el temblor de ahorita o qué.	No
...	

Aprendizaje

Nuevos mensajes	¿Relevante para la crisis?
Fuerte terremoto de 6,5 magnitud en #Ecuador. https://t.co/vU4N7babRb	?

¿Qué es la Clasificación?

Objetivo: Asignar objetos no vistos anteriormente a una clase dentro de un conjunto determinado de clases con la mayor precisión posible.

La clase usualmente es denotada por los valores 0,1 para el caso binario o bien {1,2,3,…K} para cuando se tienen K categorías.

Enfoque:

- Dada una colección de registros (conjunto de entrenamiento)
  - cada registro contiene un conjunto de atributos
  - uno de los atributos es la clase (etiqueta) que debe predecirse
- Aprender un modelo para el atributo de clase como función de los otros atributos.

Tarea de mapear set X a una clase *y*

Input
Conjunto de atributos (X)

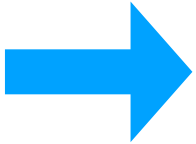

Modelo de Clasificación

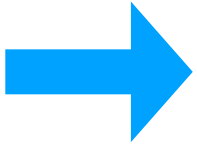

Output
Etiqueta de la clase (y)

¿Qué es la Clasificación?

Variantes:

- Clasificación **binaria** (fraude/no fraude o verdadero/falso)
- Clasificación **multi-clase** (bajo, medio, alto)
- Clasificación **multi-etiqueta** (más de una clase por registro, por ejemplo, intereses del usuario)

Machine learning vs Data Mining

- Cuando hacemos clasificación en Machine Learning queremos **automatizar una** [illegible] onocer rostros en imágenes).

Muchas veces usamos los mismos tipos de modelos pero con objetivos distintos.

- Cuando hacemos clasificación en Data Mining queremos **encontrar un patrón** en los datos (i.e., queremos entender cómo se relaciona x con y por medio de un modelo predictivo).

Ejemplos de clasificación

Evaluación del riesgo crediticio
- Atributos: su edad, ingresos, deudas, …
- Clase: ¿recibes crédito de tu banco?

Marketing
- Atributos: productos comprados anteriormente, comportamiento de navegación
- Clase: ¿es usted un cliente objetivo para un nuevo producto?

Detección de SPAM
- Atributos: palabras y campos de la cabecera de un correo electrónico
- Clase: ¿correo electrónico normal o correo basura?

Detección de sentimiento
- Atributos: palabras del mensaje.
- Clase: ¿el texto transmite un sentimiento negativo?

Identificación de células tumorales
- Atributos: características extraídas de radiografías o resonancias magnéticas
- Clase: células malignas o benignas

Actividad

Mencionen 1 tarea de clasificación, ¿cuáles serían los atributos y cuál la clase objetivo?

Reunirse y discutir en grupo (5 minutos)

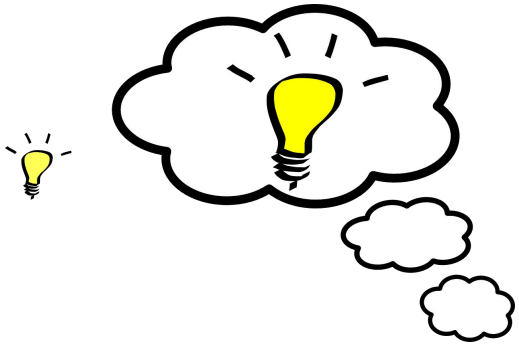

Proceso de Clasificación

Componentes principales:

Conjunto de entrenamiento

Algoritmo de clasificación

Conjunto de evaluación

-> Producen un “Modelo de Clasificación”

¿Cómo obtenemos estas etiquetas?

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Conjunto de entrenamiento

Algoritmo de aprendizaje

Inducción

Aprender modelo

Modelo

Aplicar modelo

Deducción

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Conjunto de evaluación

Usos de los modelos

Descriptivo: el modelo se utiliza como una herramienta descriptiva.

Ayuda a describir las clases
¿Cuáles atributos influyen más?
Descubrir los patrones o asociaciones interesantes que relacionan los datos.

Predictivo: se utiliza para predecir la clase de objetos nuevos.

Nota sobre la clasificación

- Es mejor para **datos binarios y nominales**,
- **No es tan bueno para ordinales**, ya que **no consideran relación de orden** entre clases (ej. alto, mediano, bajo), también ignora información de subclases-superclases (mamíferos -> primates -> {humanos, monos}).
- Nos enfocamos en clases binarias y nominales.

Técnicas de clasificación

- Basados en Árboles de Decisión
- Métodos basados en Reglas
- Razonamiento en base a memoria
- Redes Neuronales
- Naïve Bayes y Redes de Soporte Bayesianas
- Support Vector Machines

Clasificación: Evaluación

- Resumimos la capacidad predictiva de un modelo mediante **métricas de desempeño** (performance metrics).
- Las métricas se calculan **contrastando** los valores predichos versus los valores reales de la variable objetivo.
- Este se hace con datos no usados durante entrenamiento.
- Diseñamos experimentos en que comparamos las métricas de desempeño para varios modelos distintos y nos quedamos con el mejor.

Clasificación: Evaluación

Métodos para evaluar el desempeño de un modelo:

La idea es estimar la capacidad de generalización de modelo, evaluándolo en datos distintos a los de entrenamiento.

- Holdout (partición de entrenamiento y evaluación)
- Random subsampling (subsampleo aleatorio)
- Cross validation (validación cruzada)

Holdout

Particionamos los datos etiquetados en una partición de training y otra de testing.

- Usualmente usamos 2/3 para entrenamiento y 1/3 para evaluación.

Limitaciones:

- La evaluación puede variar mucho según las particiones escogidas.
- Training muy pequeño => modelo sesgado.
- Testing muy pequeño => accuracy poco confiable.

Random Subsampling

Se repite el método holdout varias veces sobre varias particiones de training y testing. Permite obtener una distribución de los errores o medidas de desempeño.

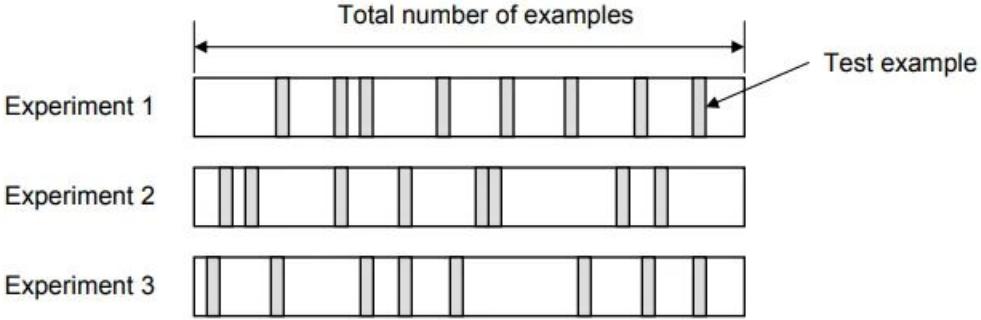

Limitaciones:

- Puede que algunos datos nunca se usen para entrenar.
- Puede que algunos datos nunca se usen para evaluar.

Validación cruzada (cross-validation)

Se particiona el dataset en **k** conjuntos disjuntos o folds (manteniendo distribución de las clases en cada fold).

Entrenamos el modelo k veces

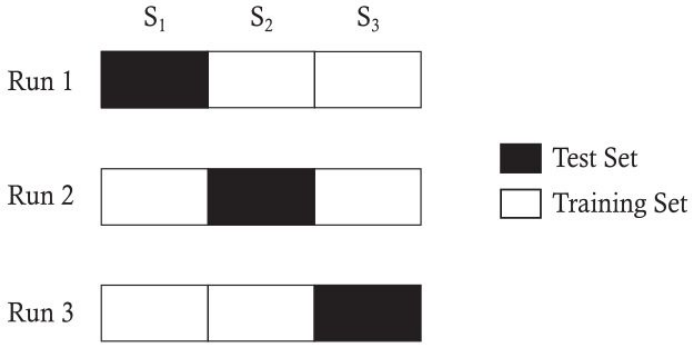

Para cada partición i:

- Entrenar el modelo sobre las k-1 particiones restantes.
- Evaluar el modelo en la partición i.
- Calcular el error total, sumando los errores de cada fold de testing.

Trabajar con clases desbalanceadas

Para mejorar el rendimiento de un clasificador cuando se tienen clases desbalanceadas existen varias técnicas. Por ejemplo:

Oversampling: Repetir aleatoriamente ejemplos de la clase minoritaria.

Undersampling: Eliminar aleatoriamente ejemplos de la clase mayoritaria.

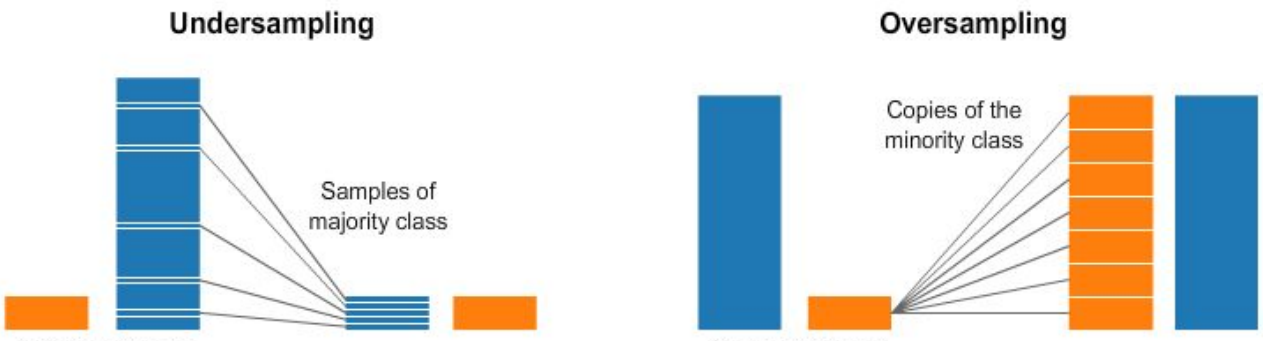

Fuente: https://www.kaggle.com/code/rafjaa/resampling-strategies-for-imbalanced-datasets/notebook

Trabajar con clases desbalanceadas

- Antes de hacer algo para tratar el desbalance entre las clases primero debemos dividir en train-test.
- Aplicar oversampling y/o subsampling **únicamente sobre la partición de entrenamiento (train)**.
    - ¡Precaución! Si se aplicase (erroneamente) a todo el dataset, el test no será una fiel representación de lo que ocurre en realidad.

Clasificación: Métricas de desempeño

- Basadas en **contar** datos **correcta e incorrectamente clasificados**.
- Accuracy (Exactitud): métrica más usada, o
- Error rate (Tasa de error)

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

Matriz de confusión

Accuracy (Exactitud)

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

Número de casos clasificados correctamente dividido por el número total de casos evaluados.

Limitaciones del Accuracy

Consideren un problema de 2-clases

- Num. de ejemplos de la Clase 0 = 9990
- Num. de ejemplos de la Clase 1 = 10

¿Cuál es el problema?

- Modelo que clasifica todo como Clase 0, accuracy es 9990/10000 = 99.9%
- Pero el modelo no detecta nada de la Clase 1 podría ser una f(x)=0.
- No es una buena métrica cuando tenemos clases desbalanceadas.

Métricas más sensibles

Precisión y Recall

En un problema de clasificación binaria tenemos que escoger cual es la clase positiva. Podemos pensar que clasificar algo como “positivo” es equivalente a “seleccionarlo”.

- **Precision:** % de los casos “seleccionados” que son correctos.
- **Recall:** % de los casos “positivos” que son “seleccionados”.
- Existe un trade-off entre Precision y Recall (**F1-score**).

Precisión

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$P = \frac{TP}{TP + FP}$$

Proporción de verdaderos positivos sobre el número de casos predichos como positivos.
Determina lo bueno que es un clasificador para evitar los falsos positivos.

Recall

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$R = \frac{TP}{TP + FN}$$

Proporción de verdaderos positivos sobre el número de positivos reales.
Determina lo bueno que es un clasificador para evitar los falsos negativos.

F1-score

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Media armónica de la precisión y recall. Es conservadora y tiende a estar más cerca del mínimo. Generalmente usamos la F1 measure.

Curva ROC (Receiver Operating Characteristic Curve)

- De manera similar que el trade-off entre Precision y Recall también existe un tradeoff entre la tasa de verdaderos positivos y la tasa de falsos positivos.

  TP Rate: TP / (TP + FN)
  FP Rate: FP / (FP + TN)

- La curva ROC se construye graficando <u>TP Rate vs FP Rate para varios umbrales</u> de clasificación de un clasificador probabilístico (ej: regresión logística, naive Bayes).

Curva ROC (Receiver Operating Characteristic Curve)

- Entre mayor sea el área bajo la curva mejor es el modelo.
- El área bajo la curva ROC se conoce como AUC y es una métrica ampliamente usada.
- Un tutorial recomendado: https://towardsdatascience.com/understanding-auc-roc-curve-68b2303cc9c5

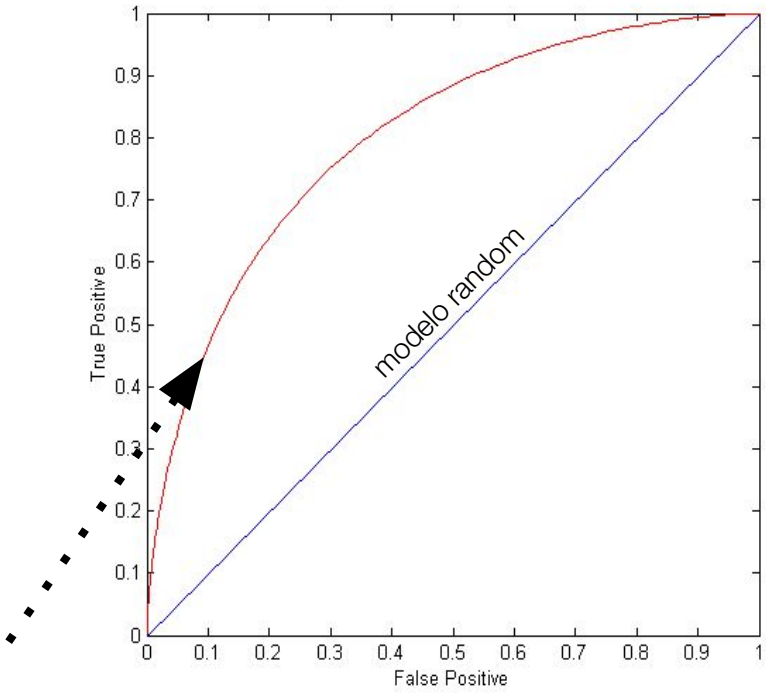

Otros factores a considerar

El desempeño de un modelo puede depender de factores diferentes al algoritmo de aprendizaje:

- Distribución de las clases
- Costo de clasificaciones erróneas
- Tamaño de los datos de entrenamiento y test

Ejercicio: reincidencia de cáncer

Considere 286 mujeres: 201 no tienen reincidencia de cáncer después de 5 años y 85 sí tienen. Compare los modelos:

M1: "todas reinciden"

		Clase predicha	
		+	-
Clase real	+	85	0
	-	201	0

M2: "ninguna reincide"

		Clase predicha	
		+	-
Clase real	+	0	85
	-	0	201

Calcular accuracy, precision, recall y F1.

Ejercicio: reincidencia de cáncer

Considere 286 mujeres: 201 no tienen reincidencia de cáncer después de 5 años y 85 sí tienen. Compare los modelos:

M1: "todas reinciden"

		Clase predicha	
		+	-
Clase real	+	85	0
	-	201	0

Accuracy: 85/286= 0.3
Precision: 85/286= 0.3
Recall: 1
F1: 2*0.3/(0.3+1)=0.46

M2: "ninguna reincide"

		Clase predicha	
		+	-
Clase real	+	0	85
	-	0	201

Accuracy: 201/286 = 0.7
Precision: 0/0 = undef
Recall: 0/85=0
F1: undef

Matriz de Costo

A veces yo se cuales errores son más costosos y cuales aciertos son más valiosos. Puedo hacer una evaluación sensible al costo.

	Clase predicha		
Clase real	C(i|j)	clase = +	clase = -
	clase = +	C(+|+)	C(-|+)
	clase = -	C(+|-)	C(-|-)

C(i|j): Costo de clasificar un objeto como clase j dado que es clase i

Calculando el costo de la clasificación

A mayor costo peor el modelo.

Matrix Costo	Clase predicha		
Clase real	C(i|j)	+	-
	+	-1	100
	-	1	0

Modelo M1	Clase predicha		
Clase real		+	-
	+	150	40
	-	60	250

Accuracy(M1) = 400/500 = 0.8
C(M1) = -1*150+100*40+1*60+0*250 = 3910

Modelo M2	Clase predicha		
Clase real		+	-
	+	250	45
	-	5	200

Accuracy(M2) = 450/500 = 0.9
C(M2) = -1*250+100*45+1*5+0*200 = 4255

Clasificación Multi-clase

Cuando tenemos k etiquetas, la matriz de confusión es una matriz de k X k.

Docs in test set	Assigned UK	Assigned poultry	Assigned wheat	Assigned coffee	Assigned interest	Assigned trade
True UK	**95**	1	13	0	1	0
True poultry	0	**1**	0	0	0	0
True wheat	10	90	**0**	1	0	0
True coffee	0	0	0	**34**	3	7
True interest	0	1	2	13	**26**	5
True trade	0	0	2	14	5	**10**

Métricas de desempeño por clase

Clasificador binario: One-Vs-Rest

Recall: Fracción de ejemplos de la clase i correc

Precision: Fracción de ejemplos asignados a la clase i que realmente son de la clase i.

Accuracy: (1 - error rate). Fracción total de ejemplos correctamente clasificados.

Es posible agregarlas para tener una sola métrica que resuma el desempeño del clasificador.

Micro- vs. Macro-Averaging

Si tenemos más de una clase, ¿cómo combinamos múltiples métricas de desempeño en un solo valor?

Macroaveraging: computar métrica para cada clase y luego promediar.

Microaveraging: crear matriz de confusión binaria para cada clase, combinar las matrices y luego evaluar.

Promedio ponderado por soporte (cantidad de ejemplos) por clase

	precision	recall	f1-score	support
class 0	0.75	1.00	0.86	3
class 1	0.67	0.67	0.67	3
class 2	1.00	0.75	0.86	4
accuracy			0.80	10
macro avg	0.81	0.81	0.79	10
weighted avg	0.82	0.80	0.80	10

sklearn.metrics.classification_report

Revisar en casa:

Ejemplo de clasificación de Spam

Micro- vs. Macro-Averaging: Ejemplo clasificación de Spam

		gold labels			
		urgent	normal	spam	
system output	urgent	8	10	1	**precision**$_u$ = $\frac{8}{8+10+1}$
	normal	5	60	50	**precision**$_n$ = $\frac{60}{5+60+50}$
	spam	3	30	200	**precision**$_s$ = $\frac{200}{3+30+200}$
		recall$_u$ = $\frac{8}{8+5+3}$	**recall**$_n$ = $\frac{60}{10+60+30}$	**recall**$_s$ = $\frac{200}{1+50+200}$	

Figure 4.5 Confusion matrix for a three-class categorization task, showing for each pair of classes (c_1, c_2), how many documents from c_1 were (in)correctly assigned to c_2

Fuente: https://web.stanford.edu/~jurafsky/slp3/4.pdf

Micro- vs. Macro-Averaging: Ejemplo clasificación de Spam

Class 1: Urgent

	true urgent	true not
system urgent	8	11
system not	8	340

Class 2: Normal

	true normal	true not
system normal	60	55
system not	40	212

Class 3: Spam

	true spam	true not
system spam	200	33
system not	51	83

Pooled

	true yes	true no
system yes	268	99
system no	99	635

$$\text{precision} = \frac{8}{8+11} = .42 \qquad \text{precision} = \frac{60}{60+55} = .52 \qquad \text{precision} = \frac{200}{200+33} = .86 \qquad \text{microaverage precision} = \frac{268}{268+99} = \mathbf{.73}$$

$$\text{macroaverage precision} = \frac{.42+.52+.86}{3} = \mathbf{.60}$$

Figure 4.6 Separate contingency tables for the 3 classes from the previous figure, showing the pooled contingency table and the microaveraged and macroaveraged precision.

- Los micro-promedios son dominados por las clases más frecuentes.
- Los macro-promedios pueden sobre-representar a clases minoritarias.

Fuente: https://web.stanford.edu/~jurafsky/slp3/4.pdf