



dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Selección y Reducción de Atributos

Profesores: Cinthia Sánchez y Cristian Llull

Selección y Reducción de Atributos

Propósito

- Evitar maldición de la dimensionalidad
- Reducir costos asociados a aplicar algoritmos (tiempo, memoria)
- Mejor visualización de los datos
- Ayuda a quitar atributos irrelevantes o ruidosos
- *En muchos problemas de aprendizaje, los atributos irrelevantes o redundantes pueden afectar negativamente el desempeño de nuestros modelos o hacer más costoso el entrenamiento.*

Enfoques principales

Existen dos enfoques principales:

- **Selección de atributos (supervisado)**: escoger un subconjunto de atributos que sea más útil para la tarea (clasificación, regresión, etc.).
- **Reducción de dimensionalidad (no supervisado)**: encontrar una proyección de menor dimensión que concentre la mayor información.

Selección de Atributos

Feature-based o scheme-independent (filtros):

- Evalúan los atributos a partir de **propiedades generales** de los datos (por ejemplo, varianza, correlación, información mutua).
- No utilizan un modelo de clasificación para medir la relevancia de atributos.
- Son rápidos y menos propensos a overfitting, pero **no tienen en cuenta** interacciones complejas entre atributos y la tarea predictiva.

Model-based o scheme-dependent (wrappers):

- Seleccionan atributos **entrenando un clasificador** (o regresor) y evaluando su desempeño sobre cada subconjunto.
- Su objetivo es maximizar la capacidad predictiva de ese modelo.
- Son **computacionalmente más costosos** y pueden sobre ajustarse
- Encontrar subconjuntos de atributos más específicos a la tarea.

Selección de Atributos: Feature-based (Scheme-independent)

En el esquema scheme-independent o de filtro, se evalúa el subconjunto de atributos usando una métrica general basada en los datos.

No dependen de un modelo específico para medir la relevancia de los atributos $\Rightarrow$ **Univariate Feature Selection**.

Algunos ejemplos populares incluyen:

- Information Gain (basado en entropía)
- Mutual Information
- Correlation-based Feature Selection (CFS)
- Low variance

Son métodos **rápidos** y sencillos de implementar, aunque **no consideran** la interacción con el modelo de clasificación final.

Selección de Atributos: Feature-based

Elegimos atributos

- Missing Values Ratio
- Low Variance Filter
- High Correlation Filter

Si una columna posee muchos valores nulos podría ser candidata para eliminarla

Si una columna tiene varianza casi cero, quiere decir que no aporta mucha info.

Si dos columnas están muy correlacionadas, me puedo quedar con una solamente

Selección de Atributos: Feature-based

Correlation-based Feature Selection (CFS). Busca atributos que:

- Tengan **alta correlación** con la clase.
- Tengan **baja correlación** entre ellos (evitar redundancia).
- Se mide la correlación entre atributos categóricos usando **symmetric uncertainty**:

$$\text{SymmUnc}(A, B) = \frac{2 \times (H(A) - H(A|B))}{H(A) + H(B)} = \frac{2 \times IG(A, B)}{H(A) + H(B)},$$



donde $H(\cdot)$ es la entropía e $IG(A, B)$ es la ganancia de información.

$$H(A|B) = H(A, B) - H(B); H(x, y) = - \sum_{x, y} p(x, y) \log p(x, y)$$



Normaliza la Ganancia de Información al dividir por la entropía, penalizando así a los atributos con demasiados valores distintos.

Ejemplo:

- Visualmente, ¿cuál de las dos variables (izquierda o derecha) es más relevante para clasificar en rojo o azul?
- ¿qué criterio podría usar para apoyar su elección?



Limitaciones: Los métodos univariados no puede solucionar todos los problemas



Al evaluar cada variable de forma aislada, los métodos univariados ignoran las dependencias múltiples.

Por ello, descartan atributos que solo tienen poder predictivo cuando se combinan

Selección de Atributos: Model-based

- El número total de subconjuntos de atributos es exponencial en el número de atributos (2^n).
- Se utilizan **heurísticas greedy** para no recorrer todo el espacio:
 - **Forward selection:** partir sin atributos y agregarlos uno a uno si mejoran un criterio.
 - **Backward elimination:** partir con todos los atributos y eliminar los que no aporten.

Selección de Atributos: Model-based

Selección de atributos basada en importancia:

Se puede seleccionar post-training los n atributos más importantes de un modelo entrenado mediante la importancia de cada atributo.

- Asigna una **importancia** a cada atributo.
- Se basa en algún atributo específico (por ejemplo, **coef** o **feature importances**) o en un callable que devuelva la importancia de cada atributo después de ajustar el modelo.
- Los atributos se consideran **poco importantes** y se eliminan si su valor de importancia es **menor** que un cierto **umbral** (threshold).
- Además, el parámetro **max features** permite fijar un **límite** máximo al número de atributos seleccionados.

Selección de Atributos: Model-based

Selección de atributos por “Wrapper”

- Evalúa cada subconjunto de atributos entrenando un modelo de aprendizaje y midiendo su **performance** (p.ej. accuracy, F1, AUC).
- Es **computacionalmente más costoso** porque implica entrenar el modelo repetidamente para cada subconjunto evaluado (p.ej., en un 10-fold cross-validation).
- En una estrategia “greedy”, cada nuevo atributo a probar se evalúa múltiples veces.
- Se comporta muy bien con modelos como Naive Bayes, pero el costo puede ser prohibitivo con un número grande de atributos.

Selección de Atributos: Model-based

Técnicas automáticas que seleccionan atributos

- Random Forest / Ensemble Trees
- Backwards/Forward Feature Elimination/Construction



**Muy costosas
computacionalmente**

Reducción de Dimensionalidad


Datos de alta dimensión: Objetos son representados por un alto número de características.

- Cuando la dimensionalidad aumenta, los datos se vuelven cada vez más **dispersos** en el espacio.
- Pierden sentido los conceptos de densidad y distancia entre puntos (fundamentales para clustering y detección de outliers).
- Los datos son difíciles de visualizar, especialmente cuando alguna de las características no es discriminativa.

Reducción de Dimensionalidad

Técnicas de Álgebra lineal para transformar el espacio dimensional a uno de menor tamaño

- PCA (Análisis de componentes principales)
- LDA (Análisis discriminante lineal)
- SVD
- Isomap




Cuidado! Pérdida de interpretabilidad

PCA: Principal Component Analysis

- Proyecta los atributos de los datos desde su espacio original de alta dimensión a un espacio de menor dimensión. Por ejemplo, de 10 a 2 columnas.
- Sirve para reducir la dimensionalidad sin perder “much” información. Retiene características de los datos que contribuyen más a su varianza.
- Utiliza los vectores propios de la matriz de covarianza de los datos para encontrar las representaciones que son más generales.
- Propiedades de los nuevos atributos (componentes):
 1. Son combinaciones lineales de los atributos originales,
 2. Son ortogonales (perpendiculares) entre sí, y
 3. Capturan la máxima cantidad de variación en los datos.


PCA: Principal Component Analysis

- **Redundancia de atributos:** Supongamos que tenemos atributos casi linealmente dependientes, como la velocidad en km/h y en mph.
- Esto puede considerarse como “información repetida”: a menudo queremos eliminar esa redundancia y quedarnos con un único atributo más representativo.
- **Objetivo de PCA:** Encontrar una proyección de los datos donde la mayoría de la varianza sea capturada con la menor cantidad de componentes posibles.




PCA: Principal Component Analysis

- **Redundancia de atributos:** Supongamos que tenemos atributos casi linealmente dependientes, como la velocidad en km/h y en mph.
- Esto puede considerarse como “información repetida”: a menudo queremos eliminar esa redundancia y quedarnos con un único atributo más representativo.
- **Objetivo de PCA:** Encontrar una proyección de los datos donde la mayoría de la varianza sea capturada con la menor cantidad de componentes posibles.




PCA: Principal Component Analysis

- **Redundancia de atributos:** Supongamos que tenemos atributos casi linealmente dependientes, como la velocidad en km/h y en mph.
- Esto puede considerarse como “información repetida”: a menudo queremos eliminar esa redundancia y quedarnos con un único atributo más representativo.
- **Objetivo de PCA:** Encontrar una proyección de los datos donde la mayoría de la varianza sea capturada con la menor cantidad de componentes posibles.




PCA: Visualización de las Transformaciones

- El dataset inicial




PCA: Visualización de las Transformaciones

- El dataset inicial
- Los datos normalizados con los ejes de la PCA




PCA: Visualización de las Transformaciones

- El dataset inicial
- Los datos normalizados con los ejes de la PCA
- Los datos transformados y normalizados (con los nuevos ejes)




PCA: Visualización de las Transformaciones

- El dataset inicial
- Los datos normalizados con los ejes de la PCA
- Los datos transformados y normalizados (con los nuevos ejes)
- Los datos reconstruidos por la PCA (con pérdida de información)




PCA: Visualización de las Transformaciones

- El dataset inicial
- Los datos normalizados con los ejes de la PCA
- Los datos transformados y normalizados (con los nuevos ejes)
- Los datos reconstruidos por la PCA (con pérdida de información)





Reducción de la dimensionalidad (PCA)



<https://archive.ics.uci.edu/ml/datasets/iris>

S



```
from sklearn.decomposition import PCA
pca = PCA(n_components=2)
X_r = pca.fit(X).transform(X)
```

Recordatorio sobre vectores y valores propios

- Sea A una matriz cuadrada de tamaño $n \times n$
- Los **vectores propios** son las soluciones de la ecuación:

$$A\mathbf{u} = \lambda\mathbf{u}$$

donde λ se llama el **valor propio**

- El valor de λ es significativo en términos de su importancia para **representar el conjunto de vectores imagen** obtenidos a través de la matriz A

Si $\det(A) \neq 0$ entonces $\exists U = \begin{pmatrix} | & | & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & | & | \end{pmatrix}$ y $D = \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_d \end{pmatrix}$

tal que $A = UDU^{-1}$ tiene como vectores y valores propios $\mathbf{u}_i$ y λ_i

Recordatorio sobre la Covarianza

- **Definición:** La covarianza entre dos variables aleatorias X e Y se define como:

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

- **Interpretación:**
 - $\text{cov}(X, Y) > 0$ indica que cuando X aumenta, Y tiende a aumentar también (relación directa).
 - $\text{cov}(X, Y) < 0$ indica que cuando X aumenta, Y tiende a disminuir (relación inversa).
 - $\text{cov}(X, Y) = 0$ sugiere que no hay relación lineal aparente entre X y Y .
- **Matriz de Covarianza:** Para un conjunto de variables, se construye una matriz cuadrada donde cada entrada es la covarianza entre un par de variables.

PCA: Aproximación de los Datos

Si aproximamos los datos $\mathbf{X} = (\mathbf{X}_i)_i$ mediante un espacio de menor dimensión L , entonces el error de aproximación sería mínimo para un espacio L con base

$$(\mathbf{b}_i)_{i=1..L} = \arg \max_{(\mathbf{b}_i)_{i=1..L}} \sum_{i=1}^L \mathbf{b}_i^T \text{cov}(\mathbf{X}) \mathbf{b}_i$$

Solución

Eso corresponde a los **vectores propios de $\text{cov}(\mathbf{X})$** ¹ con los valores propios más grandes.

Intuición: Maximizar la cantidad proyectada sobre u

$$\max_{\|u\|=1} \sum_{i=1}^d (X_{0,i}^T \cdot u) = (\mathbf{X}_0 u)^T (\mathbf{X}_0 u) = u^T (\mathbf{X}_0^T \mathbf{X}_0) u = \max_{\|u\|=1} u^T \Sigma u$$

Este se revuelve simplemente con un Lagrangiano!

¹ $\text{cov}(\mathbf{X}) = (\mathbf{X} - \mu_{\mathbf{X}})^T (\mathbf{X} - \mu_{\mathbf{X}})$

PCA: Normalización por Centrado de las Muestras

Tomemos nuestra base de datos $\mathbf{X} = \begin{pmatrix} | & | & | \\ \mathbf{x}_1 & \dots & \mathbf{x}_n \\ | & | & | \end{pmatrix}$

- Para no tener en cuenta los sesgos en el cálculo, el procedimiento debe aplicarse a la base de datos normalizada $\mathbf{X}_0$
- Se resta la media empírica a cada columna de $\mathbf{X}$:

$$\mathbf{X}_0 = \begin{pmatrix} | & | & | \\ \mathbf{x}_1 - \mu_1 & \dots & \mathbf{x}_n - \mu_n \\ | & | & | \end{pmatrix}, \text{ donde } \mu_i = \frac{1}{d} \sum_{k=1}^d \mathbf{x}_i^{(k)}$$

También podemos elegir normalizar con la varianza:

$$\mathbf{X} = \begin{pmatrix} | & | & | \\ \frac{\mathbf{x}_1 - \mu_1}{\sigma(\mathbf{x}_1)} & \dots & \frac{\mathbf{x}_n - \mu_n}{\sigma(\mathbf{x}_n)} \\ | & | & | \end{pmatrix}, \text{ donde } \sigma_i^2 = \frac{1}{d} \sum_{k=1}^d (\mathbf{x}_i^{(k)} - \mu_i)^2$$

PCA: Principio

- Cada uno de los datos $\mathbf{X}_i$ del conjunto se considera como un vector en el espacio de los descriptores (puede ser un sonido, una imagen)
- Buscamos encontrar vectores que sean más representativos de estos datos:
 - El espacio de datos tiene una base ortogonal natural que se puede utilizar para esto.
 - Cada uno de los datos se puede expresar en función de los vectores de esta base ortogonal.
- Esta base es la base de los vectores propios de la matriz de covarianza de los datos centrados $\Sigma = \mathbf{X}_0^T \mathbf{X}_0$

Valor propio

Cada uno de los vectores de esta nueva base puede clasificarse según su propensión a representar la mayoría de los $\mathbf{X}_{0,i}$. Esta propensión corresponde al valor propio asociado al vector de la nueva base.

PCA: Método

1. Crear una matriz de datos $\mathbf{X} = \begin{pmatrix} | & | & | \\ \mathbf{x}_1 & \dots & \mathbf{x}_n \\ | & | & | \end{pmatrix}$

2. Normalizar los datos:

$$\mathbf{X}_0 = \mathbf{X} - \mu, \text{ donde } \mu_i = \frac{1}{d} \sum_{k=1}^d \mathbf{x}_i^{(k)}$$

3. Calcular la matriz de covarianza $\Sigma = \mathbf{X}_0^T \mathbf{X}_0$

4. Encontrar los vectores propios u_k y valores propios λ_k de Σ

5. Tomar los L vectores propios tales que $\frac{\sum_k^L \lambda_k}{\sum_k^n \lambda_k} > 0.99$ para reconstruir el 99% de los datos

6. Recuperar las representaciones de las imágenes en $\mathbb{R}^L$ (si se reduce la dimensión)

PCA: Ejemplo con 32 imágenes



PCA: Ejemplo

Visualización y reconstrucción

- Reconstrucción de la imagen desde nuestros 4 vectores base $\mathbf{u}_i, i = 1 \dots 4$.
- La combinación lineal se calculó de la siguiente manera:

$$0,078\mathbf{u}_1 + 0,062\mathbf{u}_2 - 0,182\mathbf{u}_3 + 0,179\mathbf{u}_4$$




Reconstrucción: 4 componentes



Reconstrucción: Datos brutos



PCA: Otro ejemplo



Otros algoritmos de reducción de dimensión

- **Multidimensional Scaling (MDS):** Mapea los objetos a una dimensionalidad menor, buscando mantener las distancias relativas entre objetos
- **t-Distributed Stochastic Neighbor Embedding (TSNE):** Modela cada objeto de alta dimensión por un punto de dos o tres dimensiones de tal manera que los objetos similares son modelados por puntos cercanos y los objetos diferentes son modelados por puntos distantes con alta probabilidad. Más explicaciones [aca](#)
- **ICA (Independent Component Analysis):**
- **Uniform Manifold Approximation and Projection for Dimension Reduction (UMAP):** Basado Geometría Riemanniana y topología algebraica. Más explicaciones [aca](#)
- **Auto-encoder:** red neuronal no supervisada que comprime los datos (encoder) y la expande nuevamente (decoder) para reconstruir la entrada minimizando el error, aprovechando así su capa latente como reducción de dimensionalidad.

Conclusiones

- **Selección de atributos** (filter o wrapper) reduce la complejidad del modelo y puede mejorar rendimiento, sobre todo para clasificadores sensibles a atributos irrelevantes.
- **Reducción de dimensionalidad** (PCA, Autoencoders, MDS, TSNE, etc.) agrupa la información en menos dimensiones, pudiendo mejorar visualización y la robustez de métodos basados en distancias.
- Siempre debemos balancear la **ganancia en simplicidad** con la **pérdida de información** al eliminar/proyectar atributos.