



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Introducción al Aprendizaje

Profesores: Cinthia Sánchez y Cristian Llull

Contenidos

- IA: Programación clásica versus machine learning
- Tipos de Aprendizaje
 - Supervisado
 - No supervisado


Antes, conversemos sobre cómo construir una IA

Paradigmas para construir una IA:


- i) Programación clásica
- ii) Mediante aprendizaje de máquinas (machine learning)

i) Programación clásica

Requiere conocimiento sobre la resolución del problema.



i) Programación clásica



Rule:

IF (num legs $\geq$ 4

AND

Num eyes $\geq$ 3)




THEN

spider


ii) Mediante aprendizaje de máquinas

Algoritmos que pueden aprender de forma automática a través de datos. Esperamos que la máquina desarrolle su propia representación.


- Algoritmos tradicionales. Ej:




- Algoritmos basados en redes neuronales. Ej:



Red Neuronal Artificial (ANN)



Red Neuronal Convolucional (CNN)




Red Neuronal Recurrente (RNN)

ii) Mediante aprendizaje de máquinas

<i>Tid</i>	<i>Refund</i>	<i>Marital Status</i>	<i>Taxable Income</i>	<i>Cheat</i>
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Datos de Entrenamiento




Modelo: Árbol de Decisión

ii) Mediante aprendizaje de máquinas

<i>Tid</i>	<i>Refund</i>	<i>Marital Status</i>	<i>Taxable Income</i>	<i>Cheat</i>
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes


Datos de Entrenamiento



¡Puede existir más de un árbol que se ajuste a los datos!

Aplicamos el modelo

Comenzamos en la raíz



Dato de Evaluación

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

Fáciles de interpretar
y visualizar

El Machine Learning es el campo de estudio que da a los computadores la capacidad de aprender sin ser explícitamente programados.

— Arthur Samuel (1959)

Machine learning: Tipos de Aprendizaje

Aprendizaje supervisado

- Aprende a través de ejemplos etiquetados.
- Regresión (continuo) o Clasificación (discreto)
- Predecir una salida dada una entrada.

Regression Data

X ₁	X ₂	X ₃	X _p	Y
				5.2
				1.3
				23.0
				7.4

Numeric
Target

Classification Data

X ₁	X ₂	X ₃	X _p	Y
				cat
				dog
				cat
				cat


Categorical
"Labels"

Fuente de la imagen: <https://www.sharpsightlabs.com/blog/regression-vs-classification/>

Aprendizaje no supervisado

- Aprende patrones a partir de datos no etiquetados.
- Clustering (agrupaciones naturales)
- Encontrar una buena representación de los datos.

Busca capturar agrupaciones naturales en los datos




Machine learning: Tipos de Aprendizaje

Tareas

Aprendizaje
supervisado


Clasificación

Técnica para clasificar objetos en dos o más clases determinadas, en base a un conjunto de atributos. Este aprendizaje requiere datos etiquetados (clasificados).



Regresión


Técnica para predecir valores numéricos de objetos, en base a un conjunto de atributos. Este aprendizaje requiere datos etiquetados (valor de interés es numérico).



Aprendizaje
no supervisado

Clustering

Técnica para encontrar grupos de objetos tal que: Los objetos en un grupo sean similares (o relacionados) entre sí y diferentes (o no relacionados) a los objetos en otros grupos.



Machine learning: Tipos de Aprendizaje


Ejemplos de aplicaciones

Aprendizaje
supervisado

Clasificación

Evaluación del riesgo crediticio


- Atributos: edad, ingresos, deudas, ...
- Objetivo: Recibe o no recibe crédito



Regresión

Predicción del Índice del Coste de la Vida

- Atributos: índice de alquiler, índice de precios de restaurantes, índice de poder adquisitivo local, ...
- Objetivo: Índice del Coste de la Vida




Aprendizaje
no supervisado

Clustering

Agrupar discursos políticos de presidentes/as para detectar las temáticas principales y elementos diferenciadores

- Atributos: palabras del discurso
- Objetivo: ¿?




Aprendizaje Supervisado

Depende de datos "etiquetados" proporcionados por humanos.


Objetivo: Mapear una variable de entrada (X) a una variable de salida (Y).

Validación: Comparamos predicciones versus etiquetas reales en un set de prueba.

La regresión y la clasificación (ambas tareas predictivas) son bastante similares entre sí, con la diferencia que: *En la clasificación las salidas son discretas, en la regresión son valores continuos.*




Classification



Regression

Flujo de trabajo del Aprendizaje Supervisado



Descriptores y etiquetas




Atributos

Un conjunto de datos estructurados

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

Atributos

Imágenes: Histograma de colores



Atributos

Documentos: Bag-of-Words (bolsa de palabras)

documento	el	gato	está	feliz	triste	perro	con	en	patio	juega	vector del documento
el gato está feliz	1	1	1	1	0	0	0	0	0	0	
el gato está triste	1	1	1	0	1	0	0	0	0	0	
el gato está con el perro	2	1	1	0	0	1	1	0	0	0	
el gato con el perro	2	1	0	0	0	1	1	0	0	0	
el perro juega en el patio	2	0	0	0	0	1	0	1	1	1	

Resumen - Aprendizaje supervisado

1. Tener datos etiquetados
2. Extraer los descriptores = transformar documentos en vectores
3. Crear un modelo matemático f_{θ} , mediante una función de costo (error) a minimizar (sobre conjunto de entrenamiento)
 - Encontrar los parámetros θ^* que minimicen el error
4. Probar f_{θ}^* en nuevos datos (datos de evaluación) con una métrica de evaluación adecuada

¿Qué es la Clasificación?

Objetivo: Asignar objetos no vistos anteriormente a una clase dentro de un conjunto determinado de clases con la mayor precisión posible.


La clase usualmente es denotada por los valores 0,1 para el caso binario o bien $\{1,2,3,\dots,K\}$ para cuando se tienen K categorías.

Enfoque:


- Dada una colección de registros (conjunto de entrenamiento)
 - cada registro contiene un conjunto de atributos
 - uno de los atributos es la clase (etiqueta) que debe predecirse
- Aprender un modelo para el atributo de clase como función de los otros atributos.

Tarea de mapear set X a una clase y

Input
Conjunto de
atributos (X)




Modelo de
Clasificación




Output
Etiqueta de la
clase (y)

Ejemplo de aplicación



Aprendizaje



Mensajes	¿Relevante para la crisis?
Ascienden 52 los muertos y 1,2 millones de afectados por terremoto en Guatemala: La cifra de muertos por el... http://t.co/YyCHBarU	Si
No sé si preocuparme porque no sentí el temblor de ahorita o qué.	No
...	

Nuevos mensajes	¿Relevante para la crisis?
Fuerte terremoto de 6,5 magnitud en #Ecuador. https://t.co/vU4N7babRb	?

Nota sobre la clasificación

- Es mejor para **datos binarios y nominales**,
- **No es tan bueno para ordinales**, ya que **no consideran relación de orden** entre clases (ej. alto, mediano, bajo), también ignora información de subclases-superclases (mamíferos -> primates -> {humanos, monos}).
- Nos enfocamos en clases binarias y nominales.

¿Qué es la Clasificación?

Variantes:

- Clasificación **binaria** (fraude/no fraude o verdadero/falso)
- Clasificación **multi-clase** (bajo, medio, alto)
- Clasificación **multi-etiqueta** (más de una clase por registro, por ejemplo, intereses del usuario)

Proceso de Clasificación

¿Cómo obtenemos estas etiquetas?

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Conjunto de entrenamiento

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Conjunto de evaluación


Componentes principales:

Conjunto de entrenamiento

Algoritmo de clasificación

Conjunto de evaluación

-> Producen un “Modelo de Clasificación”




Machine learning vs Data Mining

- Cuando hacemos clasificación en Machine Learning queremos **automatizar una** tarea (ej. reconocer rostros en imágenes).
- Cuando hacemos clasificación en Data Mining queremos **encontrar un patrón** en los datos (i.e., queremos entender cómo se relaciona x con y por medio de un modelo predictivo).

Muchas veces usamos los mismos tipos de modelos pero con objetivos distintos.

Usos de los modelos

Descriptivo: el modelo se utiliza como una herramienta descriptiva.



Ayuda a describir las clases
¿Cuáles atributos influyen más?
Descubrir los patrones o
asociaciones interesantes que
relacionan los datos.

Predictivo: se utiliza para predecir la clase de objetos nuevos.

Ejemplos de clasificación

Evaluación del riesgo crediticio

- Atributos: su edad, ingresos, deudas, ...
- Clase: ¿recibes crédito de tu banco?

Marketing

- Atributos: productos comprados anteriormente, comportamiento de navegación
- Clase: ¿es usted un cliente objetivo para un nuevo producto?

Detección de SPAM

- Atributos: palabras y campos de la cabecera de un correo electrónico
- Clase: ¿correo electrónico normal o correo basura?

Detección de sentimiento

- Atributos: palabras del mensaje.
- Clase: ¿el texto transmite un sentimiento negativo?


Identificación de células tumorales

- Atributos: características extraídas de radiografías o resonancias magnéticas
- Clase: células malignas o benignas

Actividad

Mencionen 1 tarea de clasificación, ¿cuáles serían los atributos y cuál la clase objetivo?

Reunirse y discutir en grupo (5 minutos)



Regresión

Ejemplo: Predicción del precio de una propiedad

habitaciones_desde	bannos_desde	metros_construidos_desde	metros_terreno	precio_desde
4.0	3.0	105.0	120.0	3.051520e+08
3.0	3.0	95.0	113.0	1.928006e+08
4.0	3.0	120.0	137.0	2.663145e+08
2.0	2.0	72.0	86.0	1.886394e+08
4.0	3.0	120.0	130.0	2.912815e+08
...	...	...	...	...

x = Variables independientes (o explicativas)

y = Variable dependiente

¿Qué hace un algoritmo de Machine Learning para resolver la tarea de regresión?

Regresión

x1	x2	...	xd	y
...	...	...	...	...

A partir de los datos, el algoritmo construye una función o modelo que estima $\hat{y}$ dada una entrada x .

Algoritmo de aprendizaje


Utiliza una función de costo para medir la discrepancia (error) entre la predicción y el valor real.
Objetivo: Minimizar el error

$x = (x_1, x_2, \dots, x_d)$

Modelo de Regresión


$\hat{y} = \text{predicción}$

Sobre-aprendizaje y sub-aprendizaje



- Según la complejidad del modelo se observa un comportamiento diferente.
- Subajuste (Underfitting): El modelo no logra capturar los patrones de los datos. Se caracteriza por tener un alto error de entrenamiento y, consecuentemente, un alto error de generalización (datos nuevos).
- Sobreajuste (Overfitting): El modelo memoriza el ruido y los detalles específicos de los datos de entrenamiento en lugar del patrón general. Error de entrenamiento bajo, pero un error de generalización alto.


Sobre-aprendizaje: Problema




Error y riesgos

- El riesgo empírico (error en el conjunto de entrenamiento) disminuye con el aumento de la complejidad del modelo
- El riesgo real (error en observaciones de un nuevo conjunto) es muy diferente. ¡Tenemos un problema de generalización!
- Sobre-aprendizaje: los parámetros aprendidos son demasiado específicos para el conjunto de entrenamiento
- Se debe usar un criterio diferente al error en el conjunto de entrenamiento.


Sobre-aprendizaje: Problema



Underfitted



Good Fit/Robust



Overfitted

O cuando queremos descubrir
patrones/grupos naturales en los datos

¿Qué pasa cuando no tenemos etiquetas?

- Ahora tenemos sólo $D_n = \{x_1, x_2, \dots x_n\}$
- ¡Ya no tenemos Y !
- Todos los métodos que hemos estudiado hasta ahora dependen de una etiqueta, de algo a lo que nos queremos “parecer”

Aprendizaje no supervisado

Aprendizaje no supervisado


- Conseguir etiquetas suele ser un proceso costoso (dinero y/o tiempo).
- A veces, ni siquiera se sabe cómo etiquetarlos (¿cuántas etiquetas hay?).
- Por otro lado, datos no etiquetados son más fáciles de conseguir.
- Aún así, sobre los datos no etiquetados podemos aprender (o descubrir) cosas.
- Una pregunta interesante es si podemos encontrar grupos dentro de los datos -> esto es lo que se conoce como **Clustering**.

Clustering


Técnica para encontrar grupos de objetos tal que:

- Los objetos en un grupo sean similares (o relacionados) entre sí y
- Que sean diferentes (o no relacionados) a los objetos en otros grupos

Busca capturar
agrupaciones naturales
en los datos



¿Qué es análisis de clusters?



Los grupos de elementos se identifican sólo en base a las características que tienen los datos.