



dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Clasificación I

(Introducción, framework, evaluación)

Profesores: Cinthia Sánchez y Cristian Llull

¿Qué es la Clasificación?

- Técnica que “aprende” automáticamente cómo clasificar objetos en dos o más clases determinadas.
- Este aprendizaje se basa en datos previamente etiquetados (clasificados).
- Se aplica en caso en que “etiquetar” tiene un alto costo (por ejemplo: trabajo humano experto).

¿Qué es la Clasificación?

Objetivo: Asignar objetos no vistos anteriormente a una clase dentro de un conjunto determinado de clases con la mayor precisión posible.


La clase usualmente es denotada por los valores 0,1 para el caso binario o bien $\{1,2,3,\dots,K\}$ para cuando se tienen K categorías.

Enfoque:


- Dada una colección de registros (conjunto de entrenamiento)
 - cada registro contiene un conjunto de atributos
 - uno de los atributos es la clase (etiqueta) que debe predecirse
- Aprender un modelo para el atributo de clase como función de los otros atributos.

Tarea de mapear set X a una clase y

Input
Conjunto de
atributos (X)



Modelo de
Clasificación



Output
Etiqueta de la
clase (y)

Técnicas de clasificación

- Basados en Árboles de Decisión
- Métodos basados en Reglas
- Razonamiento en base a memoria
- Redes Neuronales
- Naïve Bayes y Redes de Soporte Bayesianas
- Support Vector Machines

Clasificación: Evaluación

- Resumimos la capacidad predictiva de un modelo mediante **métricas de desempeño** (performance metrics).
- Las métricas se calculan **contrastando** los valores predichos versus los valores reales de la variable objetivo.
- Este se hace con datos no usados durante entrenamiento.
- Diseñamos experimentos en que comparamos las métricas de desempeño para varios modelos distintos y nos quedamos con el mejor.

Clasificación: Evaluación

Métodos para evaluar el desempeño de un modelo:

La idea es estimar la capacidad de generalización de modelo, evaluándolo en datos distintos a los de entrenamiento.

- Holdout (partición de entrenamiento y evaluación)
- Random subsampling (submuestreo aleatorio)
- Cross validation (validación cruzada)

Holdout

Particionamos los datos etiquetados en una partición de training y otra de testing.

- Usualmente usamos $2/3$ para entrenamiento y $1/3$ para evaluación.




Limitaciones:

- La evaluación puede variar mucho según las particiones escogidas.
- Training muy pequeño => modelo sesgado.
- Testing muy pequeño => accuracy poco confiable.

Random Subsampling

Se repite el método holdout varias veces sobre varias particiones de training y testing. Permite obtener una distribución de los errores o medidas de desempeño.




Limitaciones:

- Puede que algunos datos nunca se usen para entrenar.
- Puede que algunos datos nunca se usen para evaluar.

Validación cruzada (cross-validation)

Se particiona el dataset en k conjuntos disjuntos o folds (manteniendo distribución de las clases en cada fold).

Entrenamos el
modelo k veces



Para cada partición i :

- Entrenar el modelo sobre las $k-1$ particiones restantes.
- Evaluar el modelo en la partición i .
- Calcular el error total, sumando los errores de cada fold de testing.

Trabajar con clases desbalanceadas

Para mejorar el rendimiento de un clasificador cuando se tienen clases desbalanceadas existen varias técnicas. Por ejemplo:

Oversampling: Repetir aleatoriamente ejemplos de la clase minoritaria.

Undersampling: Eliminar aleatoriamente ejemplos de la clase mayoritaria.



Trabajar con clases desbalanceadas

- Antes de hacer algo para tratar el desbalance entre las clases primero debemos dividir en train-test.
- Aplicar oversampling y/o subsampling **únicamente sobre la partición de entrenamiento (train)**.
 - ¡Precaución! Si se aplicase (erroneamente) a todo el dataset, el test no será una fiel representación de lo que ocurre en realidad.

Clasificación: Métricas de desempeño

- Basadas en contar datos correcta e incorrectamente clasificados.
- Accuracy (Exactitud): métrica más usada, o
- Error rate (Tasa de error)

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

Matriz de confusión

Accuracy (Exactitud)

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

Número de casos clasificados correctamente dividido por el número total de casos evaluados.


Limitaciones del Accuracy

Consideren un problema de 2-clases

- Num. de ejemplos de la Clase 0 = 9990
- Num. de ejemplos de la Clase 1 = 10

¿Cuál es el problema?

- Modelo que clasifica todo como Clase 0, accuracy es $9990/10000 = 99.9\%$
- Pero el modelo no detecta nada de la Clase 1 podría ser una $f(x)=0$.
- No es una buena métrica cuando tenemos clases desbalanceadas.



Métricas más sensibles

Precisión y Recall

En un problema de clasificación binaria tenemos que escoger cual es la clase positiva. Podemos pensar que clasificar algo como “positivo” es equivalente a “seleccionarlo”.

- **Precision:** % de los casos “seleccionados” que son correctos.
- **Recall:** % de los casos “positivos” que son “seleccionados”.
- Existe un trade-off entre Precision y Recall (**F1-score**).

Precisión

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$P = \frac{TP}{TP + FP}$$

Proporción de verdaderos positivos sobre el número de casos predichos como positivos.

Determina lo bueno que es un clasificador para evitar los falsos positivos.

Recall

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$R = \frac{TP}{TP + FN}$$

Proporción de verdaderos positivos sobre el número de positivos reales.
Determina lo bueno que es un clasificador para evitar los falsos negativos.

F1-score

		Predicted Class	
		1	0
Actual Class	1	True Positives (TP)	False Negatives (FN)
	0	False Positives (FP)	True Negatives (TN)

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

Media armónica de la precisión y recall. Es conservadora y tiende a estar más cerca del mínimo. Generalmente usamos la F1 measure.

Curva ROC (Receiver Operating Characteristic Curve)

- De manera similar que el trade-off entre Precision y Recall también existe un tradeoff entre la tasa de verdaderos positivos y la tasa de falsos positivos.

TP Rate: $TP / (TP + FN)$

FP Rate: $FP / (FP + TN)$


- La curva ROC se construye graficando TP Rate vs FP Rate para varios umbrales de clasificación de un clasificador probabilístico (ej: regresión logística, naive Bayes).

Curva ROC (Receiver Operating Characteristic Curve)

- Entre mayor sea el área bajo la curva mejor es el modelo.
- El área bajo la curva ROC se conoce como AUC y es una métrica ampliamente usada.
- Un tutorial recomendado:
<https://towardsdatascience.com/understanding-auc-roc-curve-68b2303cc9c5>

Ejercicios

<https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc>



Otros factores a considerar

El desempeño de un modelo puede depender de factores diferentes al algoritmo de aprendizaje:

- Distribución de las clases
- Costo de clasificaciones erróneas
- Tamaño de los datos de entrenamiento y test

Ejercicio: reincidencia de cáncer

Considere 286 mujeres: 201 no tienen reincidencia de cáncer después de 5 años y 85 sí tienen. Compare los modelos:

M1: "todas reinciden"

Clase real	Clase predicha		
		+	-
		+	-
Clase real	+	85	0
	-	201	0

M2: "ninguna reincide"

Clase real	Clase predicha		
		+	-
		+	-
Clase real	+	0	85
	-	0	201

Calcular accuracy, precision, recall y F1.

Ejercicio: reincidencia de cáncer

Considere 286 mujeres: 201 no tienen reincidencia de cáncer después de 5 años y 85 sí tienen. Compare los modelos:

M1: "todas reinciden"

Clase real	Clase predicha		
		+	-
		+	-
+	85	0	
-	201	0	

Accuracy: $85/286 = 0.3$

Precision: $85/85 = 1$

Recall: 1

F1: $2 \cdot 0.3 / (0.3 + 1) = 0.46$

M2: "ninguna reincide"

Clase real	Clase predicha		
		+	-
		+	-
+	0	85	
-	0	201	

Accuracy: $201/286 = 0.7$

Precision: $0/0 = \text{undef}$

Recall: $0/85 = 0$

F1: undef

Matriz de Costo

A veces yo se cuales errores son más costosos y cuales aciertos son más valiosos. Puedo hacer una evaluación sensible al costo.

Clase real	Clase predicha		
	$C(i j)$	clase = +	clase = -
	clase = +	$C(+ +)$	$C(- +)$
	clase = -	$C(+ -)$	$C(- -)$

$C(i|j)$: Costo de clasificar un objeto como clase j dado que es clase i

Calculando el costo de la clasificación

A mayor costo
peor el modelo.

Matrix Costo	Clase predicha		
Clase real	C(i j)	+	-
	+	-1	100
	-	1	0

Modelo M1	Clase predicha		
Clase real		+	-
	+	150	40
	-	60	250

$$\text{Accuracy(M1)} = 400/500 = 0.8$$

$$\text{C(M1)} = -1*150 + 100*40 + 1*60 + 0*250 = 3910$$

Modelo M2	Clase predicha		
Clase real		+	-
	+	250	45
	-	5	200

$$\text{Accuracy(M2)} = 450/500 = 0.9$$

$$\text{C(M2)} = -1*250 + 100*45 + 1*5 + 0*200 = 4255$$

Clasificación Multi-clase

Cuando tenemos k etiquetas, la matriz de confusión es una matriz de k X k.

Docs in test set	Assigned UK	Assigned poultry	Assigned wheat	Assigned coffee	Assigned interest	Assigned trade
True UK	95	1	13	0	1	0
True poultry	0	1	0	0	0	0
True wheat	10	90	0	1	0	0
True coffee	0	0	0	34	3	7
True interest	0	1	2	13	26	5
True trade	0	0	2	14	5	10

Métricas de desempeño por clase

Clasificador binario: One-Vs-Rest

Recall: Fracción de ejemplos de la clase i correctamente clasificados.

Precision: Fracción de ejemplos asignados a la clase i que realmente son de la clase i .

Accuracy: $(1 - \text{error rate})$. Fracción total de ejemplos correctamente clasificados.

Es posible agregarlas para tener una sola métrica que resuma el desempeño del clasificador.

Micro- vs. Macro-Averaging

Si tenemos más de una clase, ¿cómo combinamos múltiples métricas de desempeño en un solo valor?

Macroaveraging: computar métrica para cada clase y luego promediar.

Microaveraging: crear matriz de confusión binaria para cada clase, combinar las matrices y luego evaluar.

Promedio ponderado por soporte (cantidad de ejemplos) por clase

	precision	recall	f1-score	support
class 0	0.75	1.00	0.86	3
class 1	0.67	0.67	0.67	3
class 2	1.00	0.75	0.86	4
accuracy			0.80	10
macro avg	0.81	0.81	0.79	10
weighted avg	0.82	0.80	0.80	10



`sklearn.metrics.classification_report`

Revisar en casa:

Ejemplo de clasificación de Spam

Micro- vs. Macro-Averaging: Ejemplo clasificación de Spam

		<i>gold labels</i>			
		urgent	normal	spam	
<i>system output</i>	urgent	8	10	1	precision_u = $\frac{8}{8+10+1}$
	normal	5	60	50	precision_n = $\frac{60}{5+60+50}$
	spam	3	30	200	precision_s = $\frac{200}{3+30+200}$
		recall_u = $\frac{8}{8+5+3}$	recall_n = $\frac{60}{10+60+30}$	recall_s = $\frac{200}{1+50+200}$	

Figure 4.5 Confusion matrix for a three-class categorization task, showing for each pair of classes (c_1, c_2), how many documents from c_1 were (in)correctly assigned to c_2

Micro- vs. Macro-Averaging: Ejemplo clasificación de Spam




Figure 4.6 Separate contingency tables for the 3 classes from the previous figure, showing the pooled contingency table and the microaveraged and macroaveraged precision.

- Los micro-promedios son dominados por las clases más frecuentes.
- Los macro-promedios pueden sobre-representar a clases minoritarias.