Minería de Datos

Clustering

Introducción, Algoritmos e Implementación

Valentin Barriere / Mauricio Cerda / Cinthia Sánchez

CC5205, Otoño 2026

Basada en versiones previas de Felipe Bravo y Bárbara Poblete

CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

Recordatorio: Aprendizaje supervisado

- Conjunto de entrenamiento $D_n = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$
- $X = \{x_1, x_2, \ldots, x_n\} \in \mathbb{X}$: atributos o features
- $Y = \{y_1, y_2, \ldots, y_n\} \in \mathbb{Y}$: etiquetas o labels
- Sabemos que $(X, Y) \sim f$, pero f es desconocida
- Objetivo: construir una función g: $\mathbb{X} \to \mathbb{Y}$, que se parezca a f

Regression Data

X_1	X_2	X_3	X_n	Y
				5.2
				1.3
				23.0
				7.4

Numeric Target

Classification Data

X_1	X_2	X_3	X_n	Y
				'cat'
				'dog'
				'cat'
				'cat'

Categorical "Labels"

¿Qué pasa cuando no tenemos etiquetas?

- Ahora tenemos sólo $D_n = \{x_1, x_2, \ldots x_n\}$
- ¡Ya no tenemos Y!
- Todos los métodos que hemos estudiado hasta ahora dependen de una etiqueta, de algo a lo que nos queremos “parecer”

Aprendizaje no supervisado

Aprendizaje no supervisado

- Conseguir etiquetas suele ser un proceso costoso (dinero y/o tiempo).
- A veces, ni siquiera se sabe cómo etiquetarlos (¿cuántas etiquetas hay?).
- Por otro lado, datos no etiquetados son más fáciles de conseguir.
- Aún así, sobre los datos no etiquetados podemos aprender (o descubrir) cosas.
- Una pregunta interesante es si podemos encontrar grupos dentro de los datos -> esto es lo que se conoce como **Clustering.**

Clustering

Técnica para encontrar grupos de objetos tal que:

- Los objetos en un grupo sean similares (o relacionados) entre sí y
- Que sean diferentes (o no relacionados) a los objetos en otros grupos

Busca capturar agrupaciones naturales en los datos

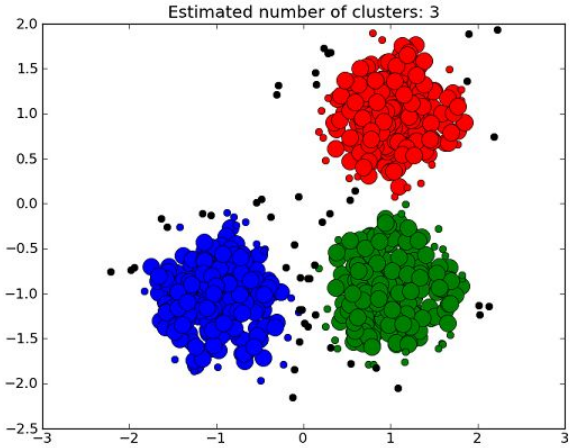

¿Cuándo y para qué usar clustering?

Cuando necesitemos dividir nuestros datos en grupos que sean: **significativos y/o útiles**

- Debemos preocuparnos de capturar la estructura natural de los datos
- A veces es sólo un punto de partida

Capturar agrupaciones naturales en los datos

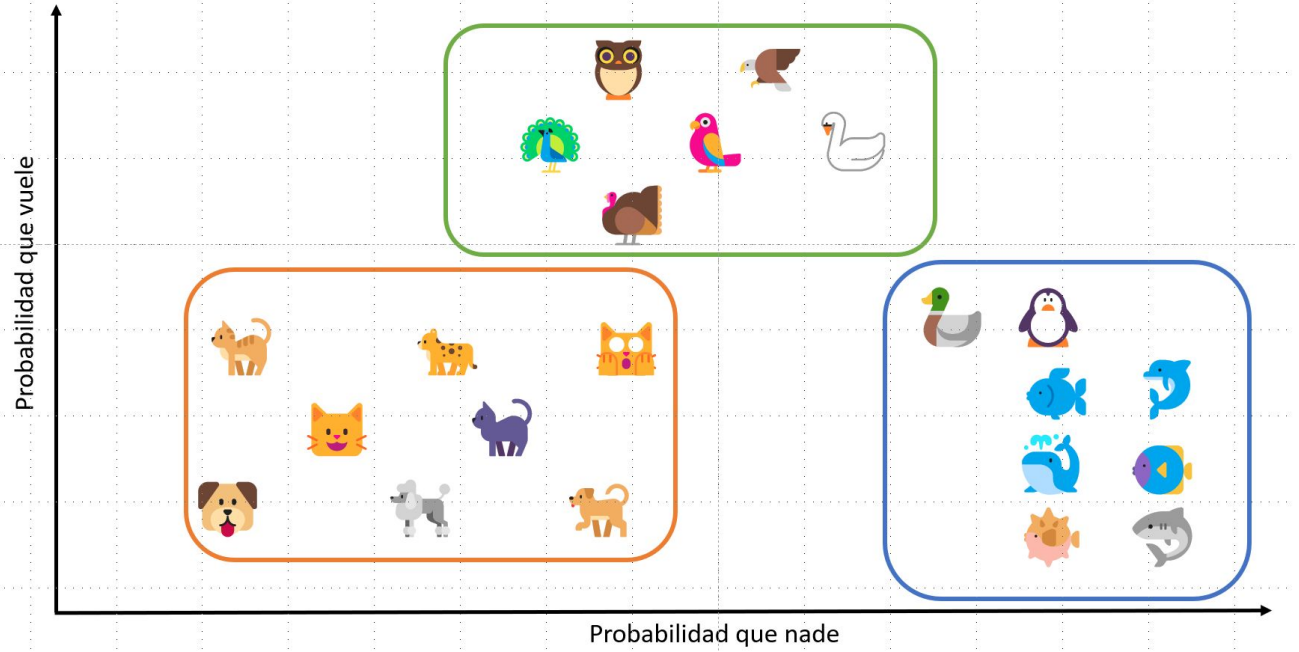

Fuente: Repositorio Github Pablo Badilla. https://github.com/pbadillatorrealba/MDS7202

Análisis de clusters es una tarea esencial para muchas aplicaciones

Por ej:

- Encontrar clusters naturales y describir sus propiedades (**data understanding**)
- Encontrar agrupamientos útiles (**data class identification**)
- Encontrar representantes para grupos homogéneos (**data reduction**)
- Encontrar objetos inusuales (**outliers detection**)
- Encontrar perturbaciones aleatorias de los datos (**noise detection**)

Formulación del problema

- Dado un conjunto de puntos, organizarlos en clusters (grupos, clases).
- Clustering: el proceso de agrupar objetos físicos en clases de objetos similares

source: http://www.cs.put.poznan.pl/jstefanowski/sed/DM-7clusteringnew.pdf

¿Qué es análisis de clusters?

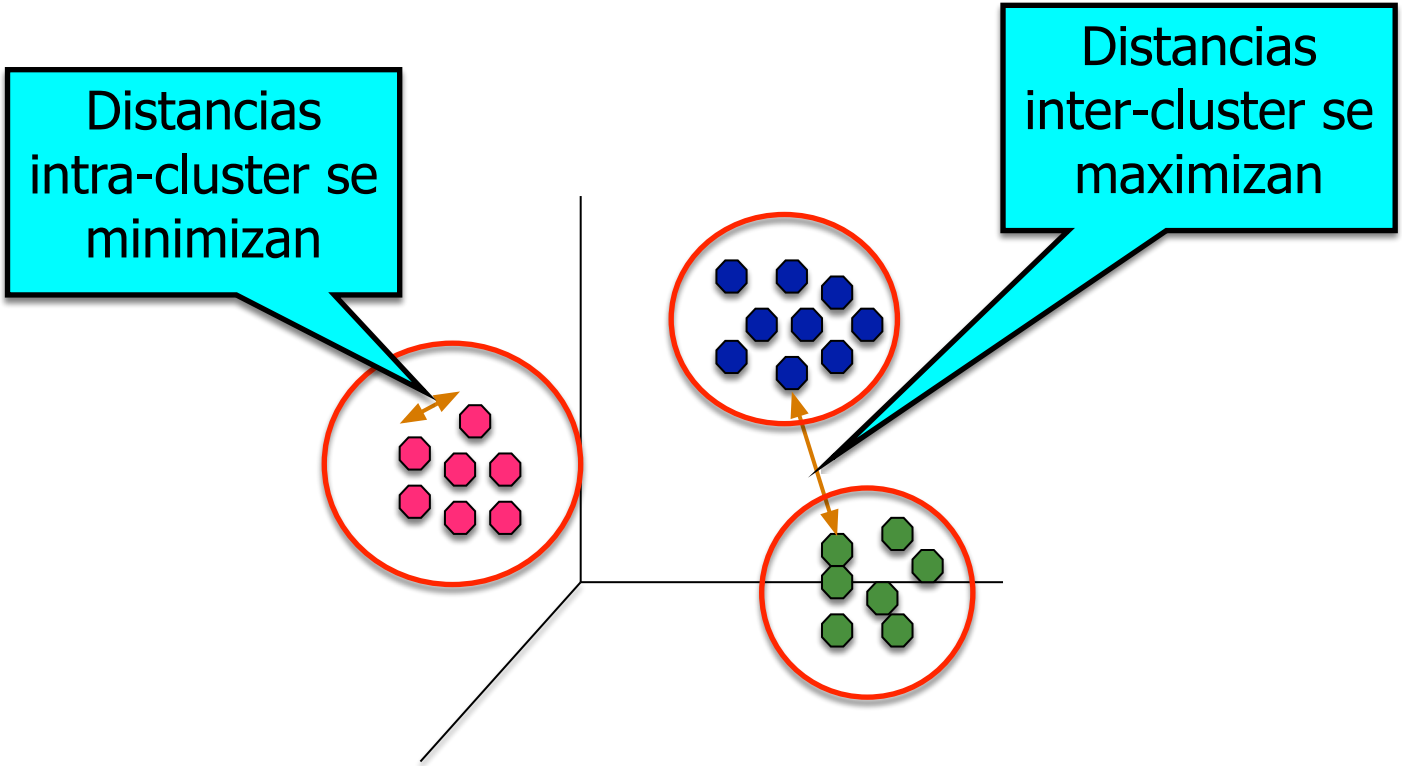

Los grupos de elementos se identifican sólo en base a las características que tienen los datos.

La noción de cluster puede ser ambigua

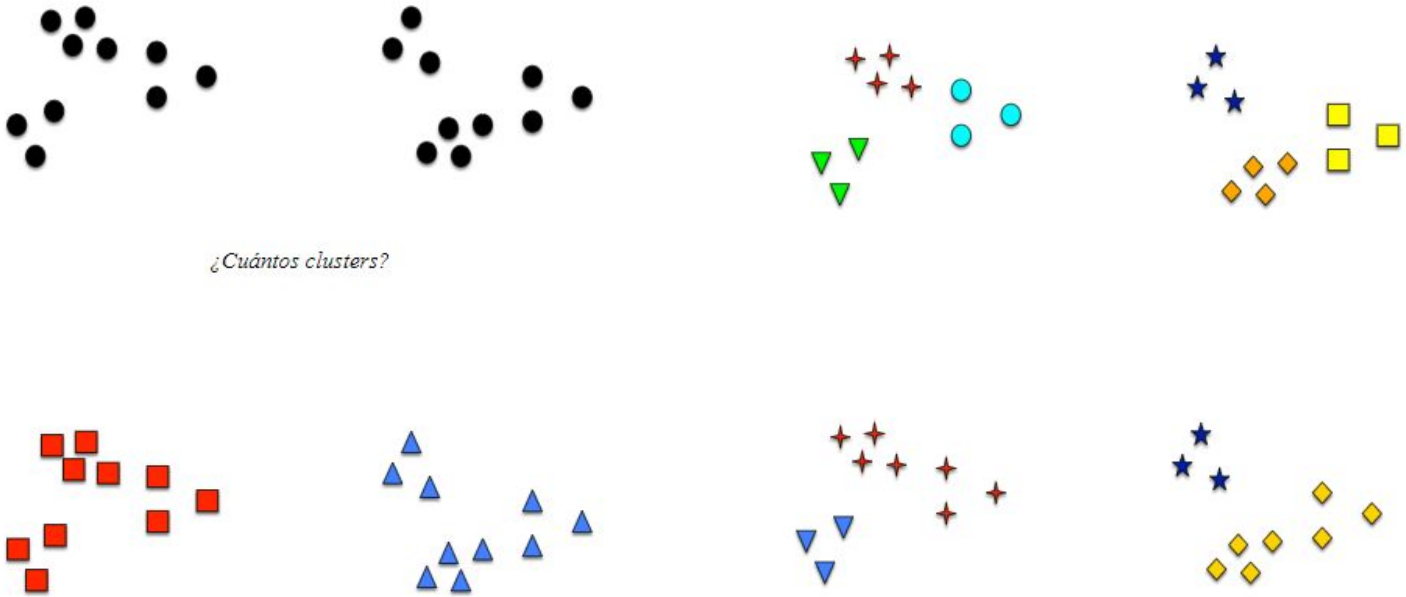

La noción de cluster puede ser ambigua

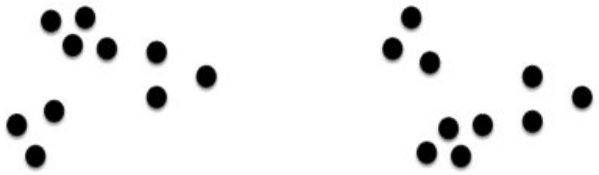

¿Cuántos clusters?

Seis clusters

Dos clusters

Cuatro clusters

Ejemplos y Casos de Uso

Ciencias

- Agrupar estrellas en base a su brillo
- Explorar muestras genéticas detectando grupos y analizandolos para identificar patrones de expresión relacionados
- Agrupar sonidos de ballenas para detectar patrones y analizar su forma de comunicación
- Análisis de imágenes para agruparlas y detectar outliers que pueden ser asociados, por ejemplo, a enfermedades

Retail y ventas

- Detectar grupos de clientes para caracterizarlos y definir estrategias que mejoren su experiencia de compra
- Detectar grupos de productos en base a volumen de ventas y frecuencia de compra para tomar decisiones enfocándose en lo más importante
- Agrupar tiendas para detectar patrones de compra que dependen de la localidad

Sociedad

- Análisis de grupos en redes sociales para caracterizar fenómenos sociales
- Detectar temáticas principales presentes en medios de comunicación en un periodo determinado
- Agrupar personas que responden una encuesta para detectar estructuras naturales e implícitas
- Agrupar discursos políticos de presidentes y presidentas para detectar las temáticas principales y elementos diferenciadores

Tipos de clustering

Tipos de clustering

Particional

Divide los datos en subconjuntos sin traslape (clusters), tal que cada dato está en un solo subconjunto.

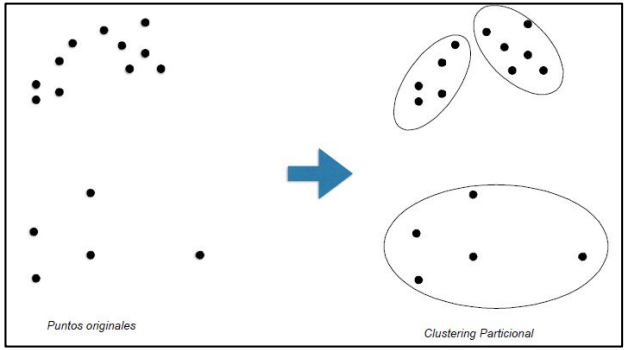

Jerárquico

Un conjunto de clusters anidados, organizados como un árbol.

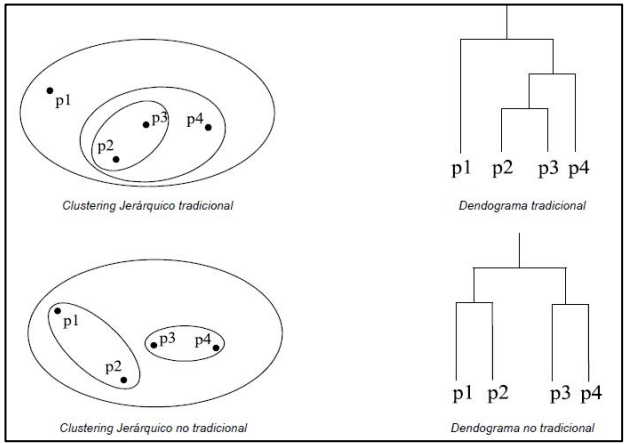

Diferentes Métodos de Clustering

Fuzzy C-means

K-Means

DBSCAN

Mezcla de Gaussianas
y algoritmo EM

Método
jerárquico
aglomerativo

Mapas
auto-organizados de
Kohonem (SOM)

Diferentes Métodos de Clustering

Fuzzy C-means

K-Means

DBSCAN

Mezcla de Gaussianas
y algoritmo EM

**Método
jerárquico
aglomerativo**

Mapas
auto-organizados de
Kohonem (SOM)

Dataset de atributos numéricos

Número de clusters K

K-Means

Algoritmo de clustering particional

K clusters y todos los puntos fueron asignados a alguno de los clusters.

K-means

¿Cómo funciona?

1. Se asignan K centroides iniciales.
2. Itera hasta converger:
    a. Asignar puntos a su centroide más cercano
    b. Recalcular centroides promediando puntos.

¿Qué es un centroide?

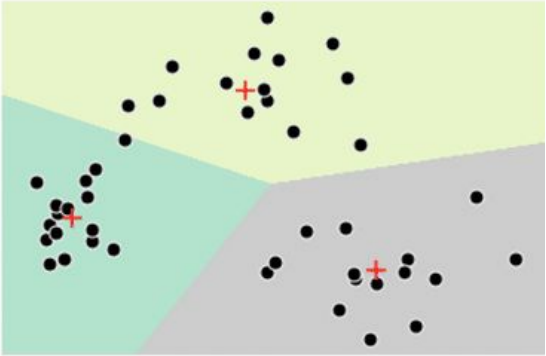

Sean 3 vectores de 3 dimensiones:

$X_1 = [6,4,3]$

$X_2 = [4,5,1]$

$X_3 = [2,-3,5]$

El centroide de estos vectores es:

$C(X_1, X_2, X_3) = [(6+4+2)/3, (4+5-3)/3, (3+1+5)/3] = [4,2,3]$

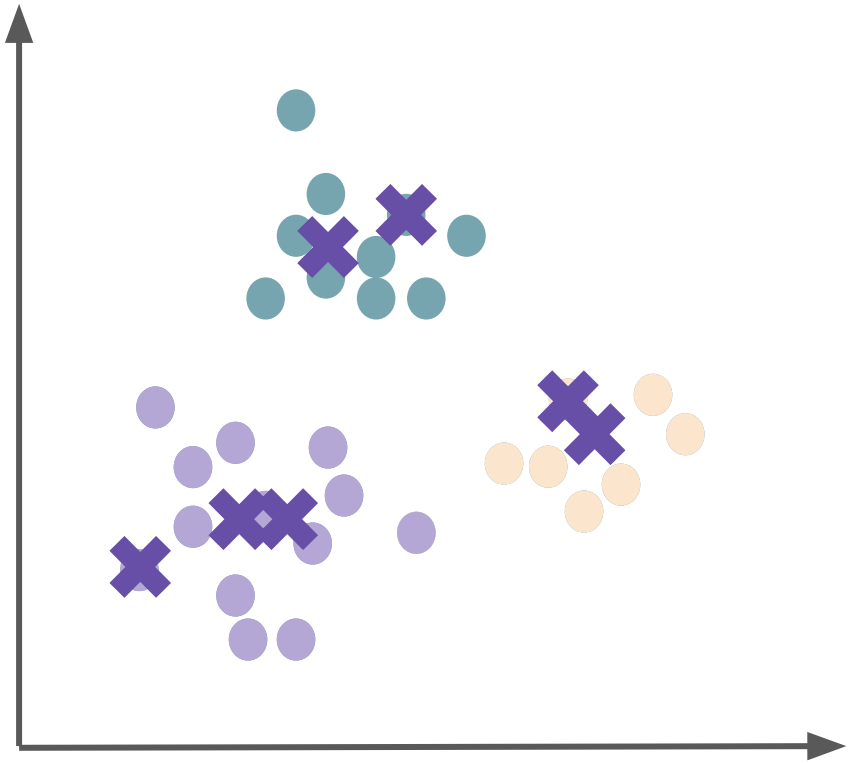

Otras variables a tener en cuenta

- ¿Cómo se escogen centroides iniciales?

  El enfoque tradicional es escogerlos aleatoriamente

- ¿Qué medida de distancia usar?

  Generalmente se usa distancia Euclideana

- ¿Cómo estimar la cantidad de clusters?

  Podemos usar una técnica visual: Método del codo.

¿Qué consecuencias tiene el que los clusters iniciales se asignen aleatoriamente?

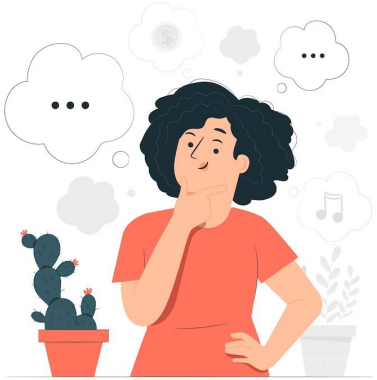

SSE: Sum Square Error

Mide la varianza de un cluster

Suma de las distancias cuadradas de cada punto al centroide de su cluster asignado.

$$\mathrm{SSE} = \sum_{i=1}^{K} \sum_{\mathbf{x} \in C_i} dist(\mathbf{c}_i, \mathbf{x})^2$$

SSE: Sum Square Error

Mide la varianza de un cluster

Permite calcular el aporte individual de cada cluster al SSE total.

Permite juzgar si un cluster es bueno o no.

Limitantes

K-means no asegura encontrar clusters óptimos

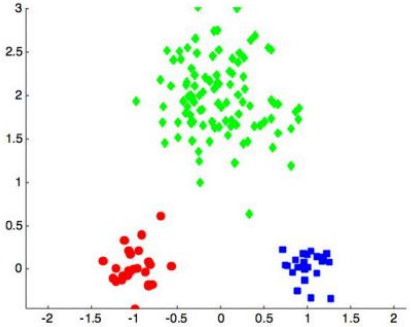

Puntos originales

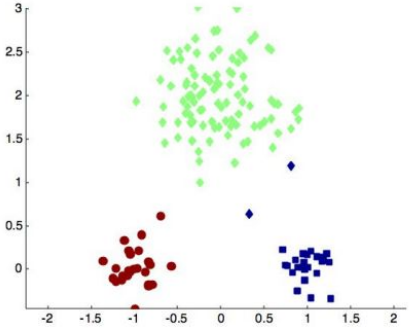

Clustering óptimo

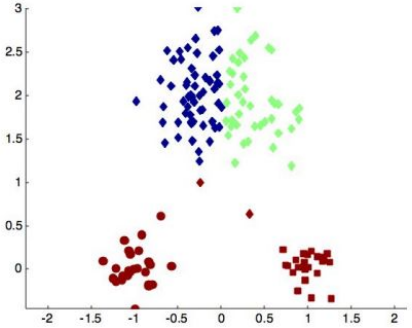

Clustering sub-optimal

Comparación de inicializaciones

Caso 1:

Aunque los centroides iniciales están todos en un único cluster, igual **se converge a los clusters deseados**.

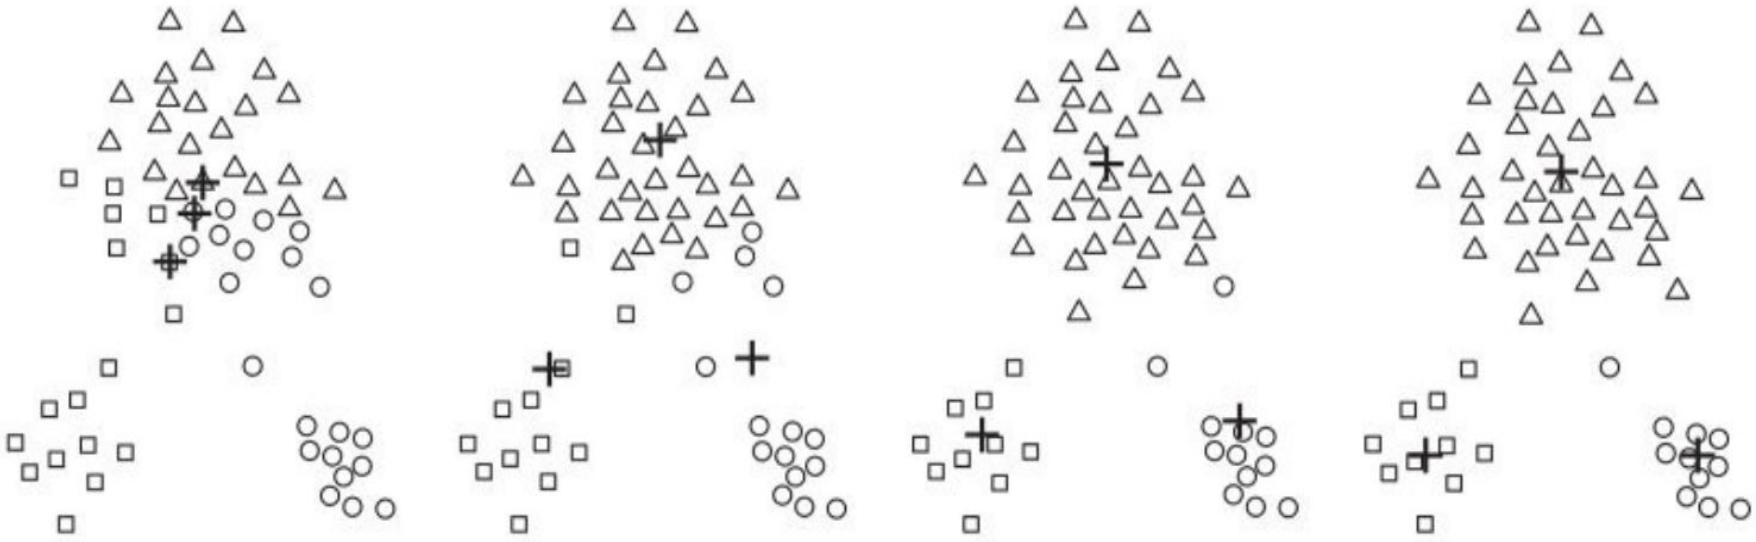

(a) Iteration 1. (b) Iteration 2. (c) Iteration 3. (d) Iteration 4.

Caso 2:

Aunque los centroides iniciales parecen estar mejor repartidos, llegamos a una **peor solución**.

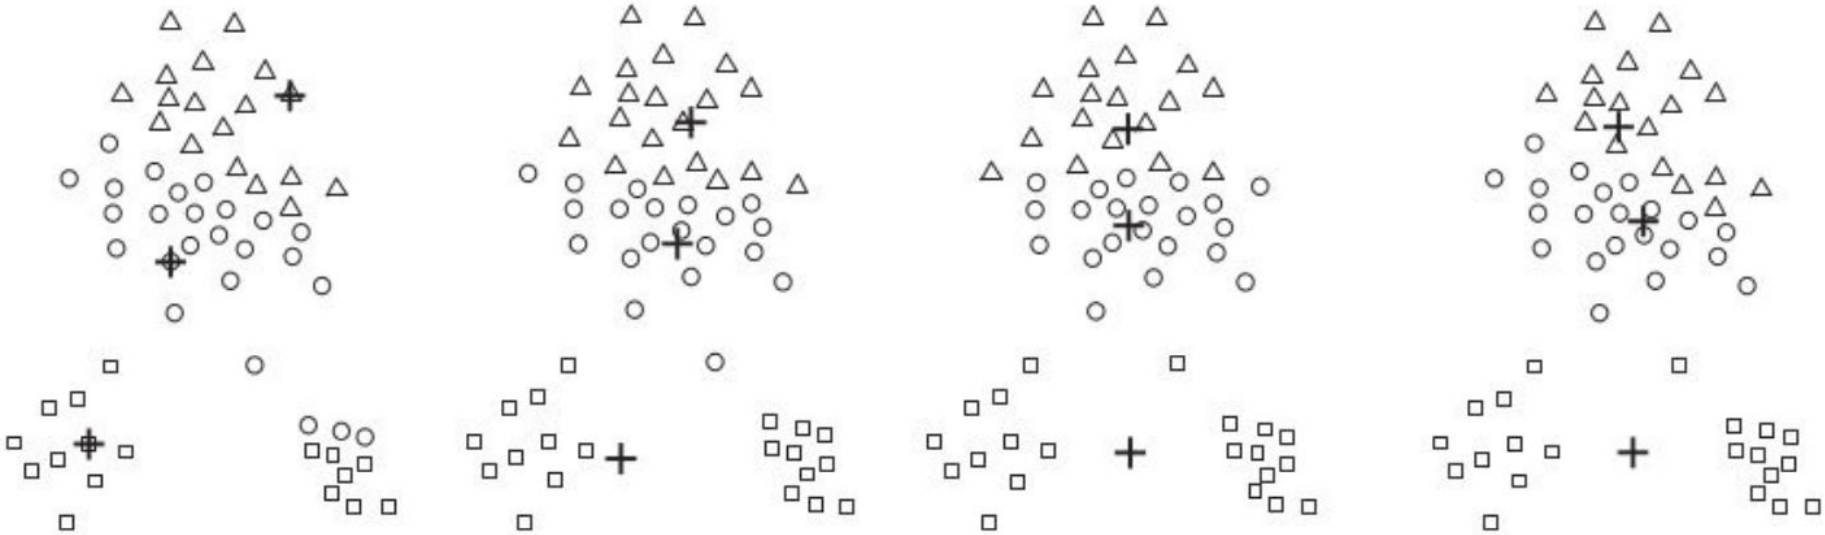

(a) Iteration 1. (b) Iteration 2. (c) Iteration 3. (d) Iteration 4.

La probabilidad de escoger un centroide por cada cluster óptimo es baja.

$$P = \frac{\#\text{ formas de escoger un centroide de cada cluster}}{\#\text{ formas de escoger K centroides}} = \frac{K!n^K}{(Kn)^K} = \frac{K!}{K^K}$$

Ej.: si K = 10, entonces P= $10!/10^{10}$ = 0.00036

También puede pasar que queden clusters vacíos

Esto pasa si es que no se le asignan puntos al cluster en el paso de asignación.

Algunas soluciones a estos problemas

Ejecutar K-means varias veces variando la semilla aleatoria y quedarse con el modelo de menor SSE.

Reemplazar centroides de clusters vacíos escogiendo el punto más lejano a todos los centroides como nuevo centroide u otro punto aleatorio con mayor SSE.

K-means: ¿Cómo elegir k?

- Hasta ahora, hemos asumido que k es un hiperparámetro: algo que fijamos al inicio del algoritmo.
- ¿Cómo elegimos el k óptimo?
- En aprendizaje supervisado, podíamos optimizar los hiperparámetros usando cross-validation y fijándonos en alguna métrica, pero acá no podemos
- La forma de escoger es mucho más subjetiva

K-means: ¿Cómo elegir k?

Técnica visual: **Método del codo**:

1. Calculamos el SSE para varios números de clusters*.
2. Graficamos cómo varía el SSE.
3. Elegimos el punto de inflexión, cuando añadir un nuevo cluster no provee un gran cambio en el SSE (cuando aumentar a más clusters da una mejora muy pequeña)
    - La inercia siempre disminuye al aumentar K -> no podemos simplemente elegir el K con menor inercia. Un clustering con K=n (donde n es el número total de observaciones) tendrá inercia 0, y eso no sirve.

Sum of Squared Error (SSE): scikit-learn este dato se llama inertia_

```
sse = []

clusters = list(range(1, 16))
for k in clusters:
    kmeans = KMeans(n_clusters=k).fit(X)
    sse.append(kmeans.inertia_)

plt.plot(clusters, sse, marker="o")
plt.title("Metodo del codo de 1 a 15 clusters")
plt.grid(True)
plt.show()
```

Ojo que este método es una heurística y no siempre el codo es claramente visible.

¿Cómo afectan los outliers a K-Means?

Eliminar outliers: outliers producen centroides no representativos con alto SSE

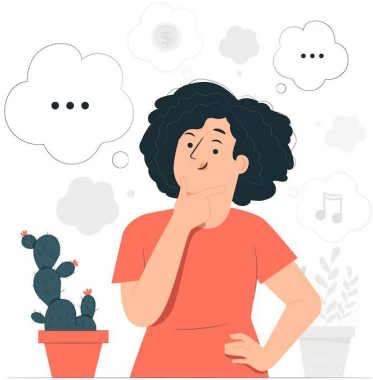

¿Qué pasa si los datos no están normalizados?

Normalizar datos: que todos los atributos aporten lo mismo al cálculo de distancias

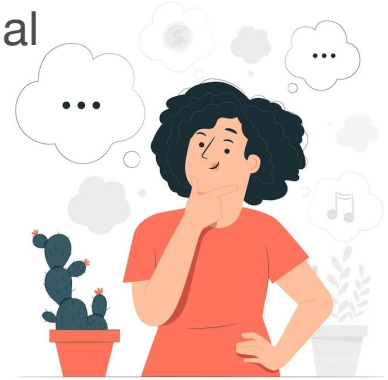

Otras limitantes a considerar

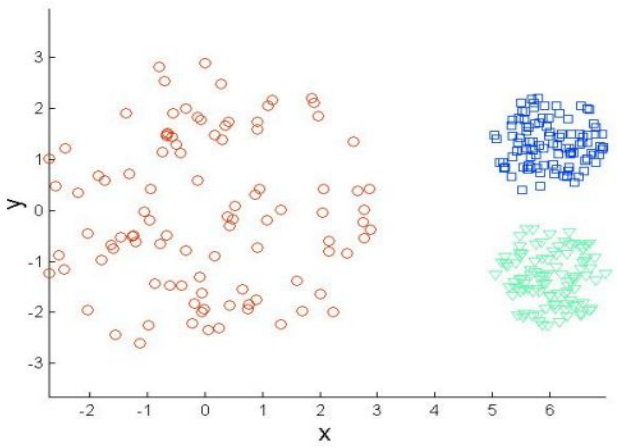

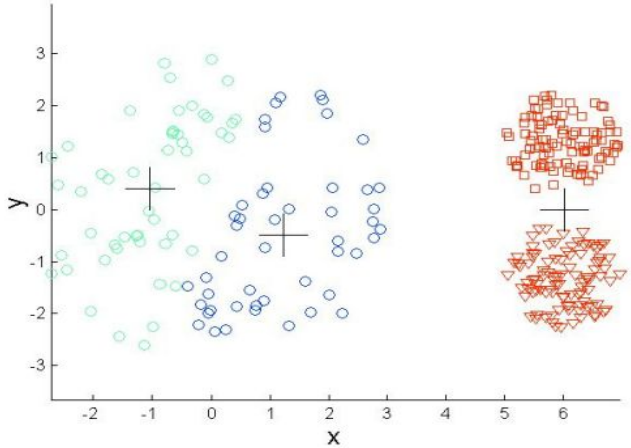

K-means tiene limitaciones cuando los clusters tienen diferentes densidades.

Otras limitantes a considerar

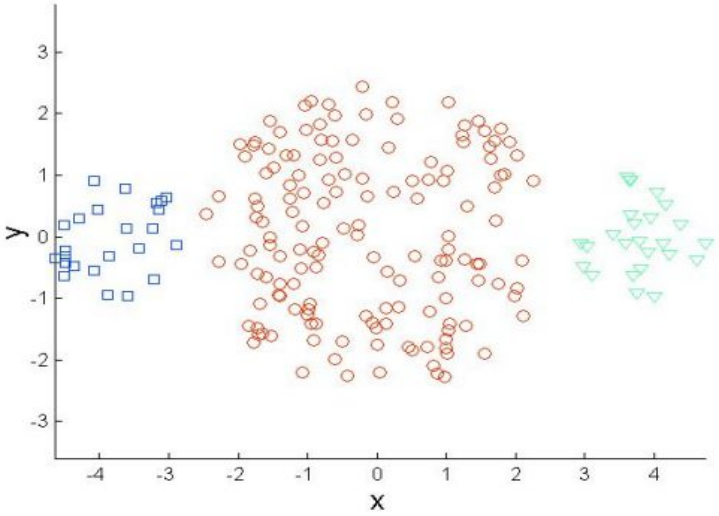

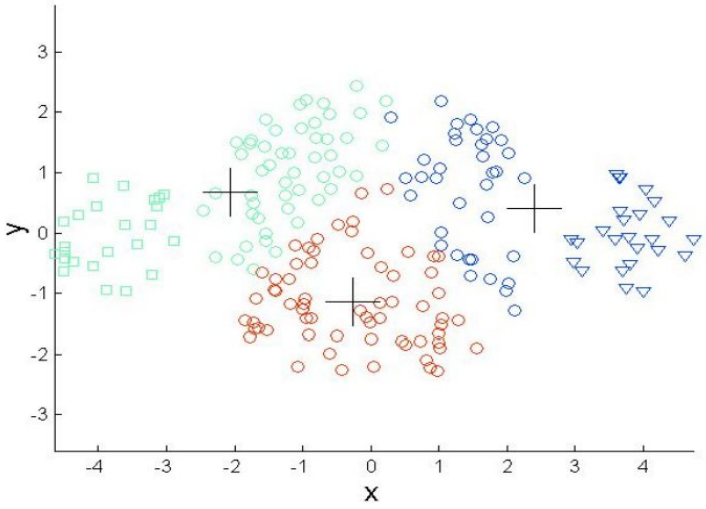

O tamaños diferentes.

Otras limitantes a considerar

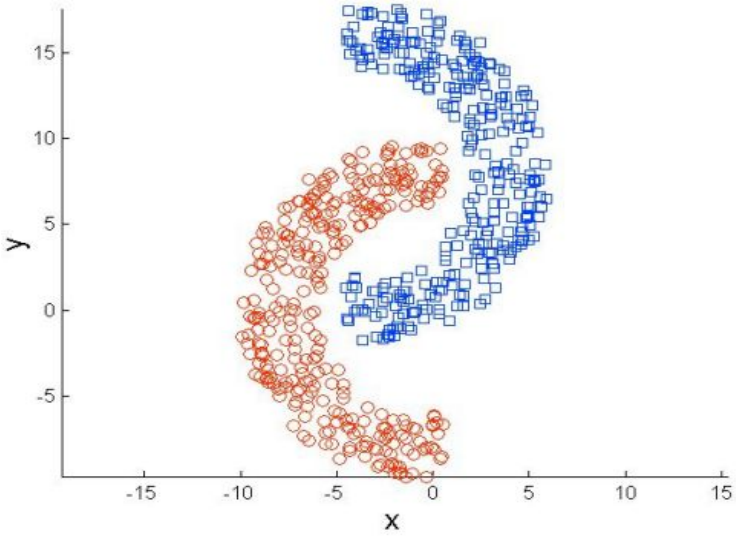

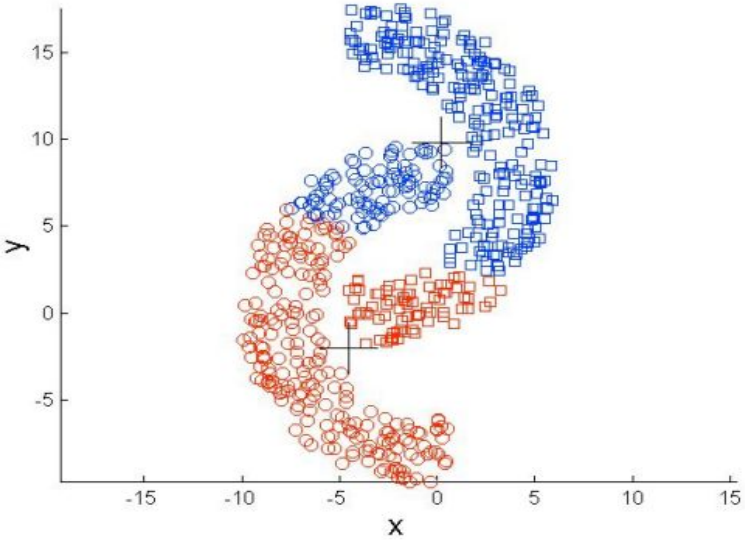

O formas no esféricas

Técnica de post-procesamiento para estos casos

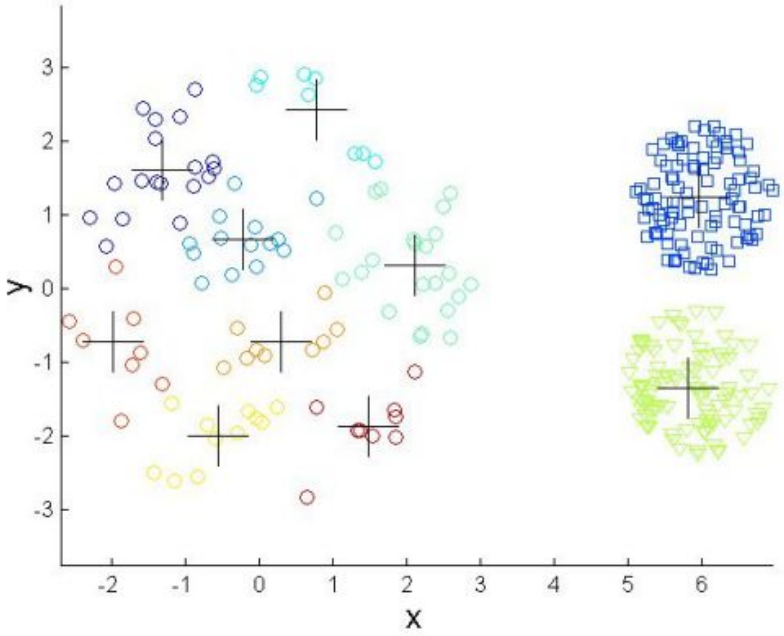

Usar un K más alto y luego mezclar los clusters durante una fase de post-procesamiento.

Bisecting K-means

Extensión de K-means que se basa en dividir el conjunto siempre en 2 clusters, escoger uno de ellos y continuar dividiendo en 2, iterando hasta llegar a K clusters.

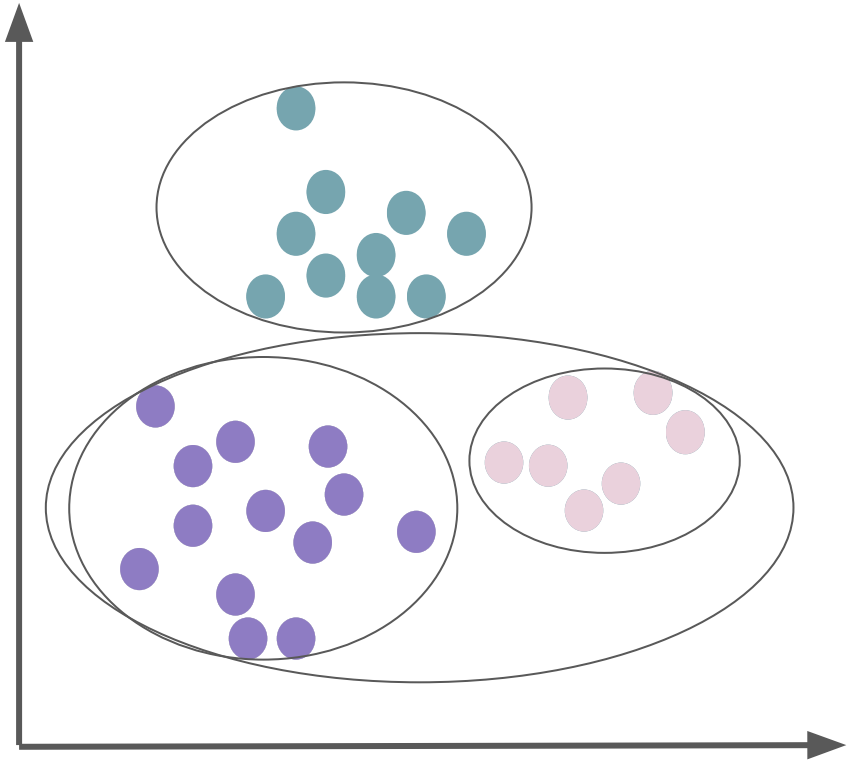

Bisecting K-means

Cada división se obtiene ejecutando K-means (k=2)

El siguiente cluster a dividir se puede escoger considerando su tamaño, su SSE o una estrategia híbrida.

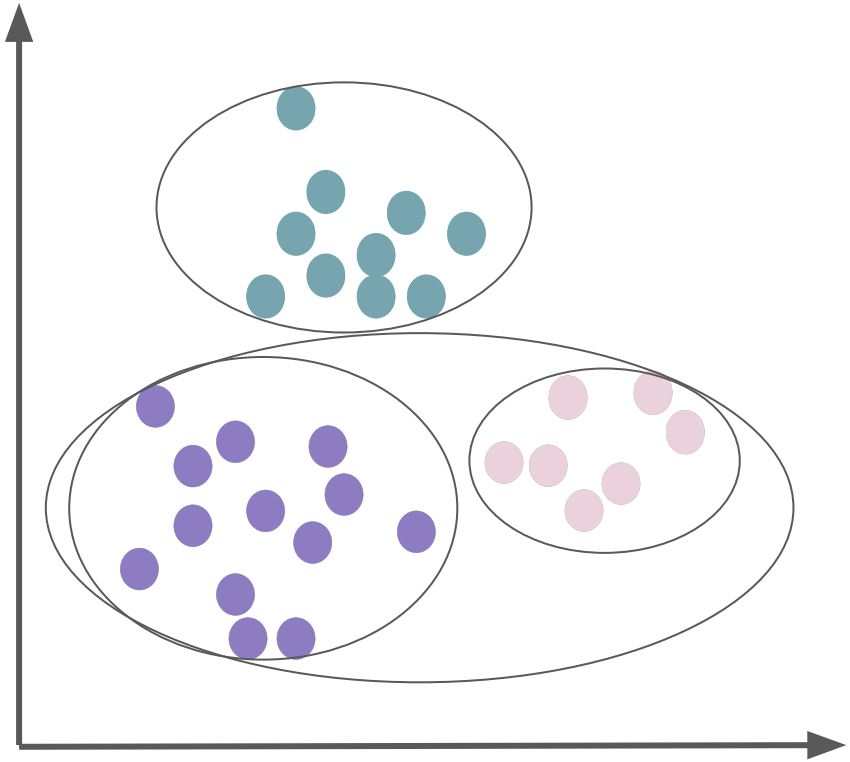

Bisecting K-means

Menos problemas de inicialización que K-means ya que realiza varios intentos de bisección y toma la que minimiza el SSE.

Si se registra la secuencia de clusters bisectados podemos producir un clustering jerárquico.

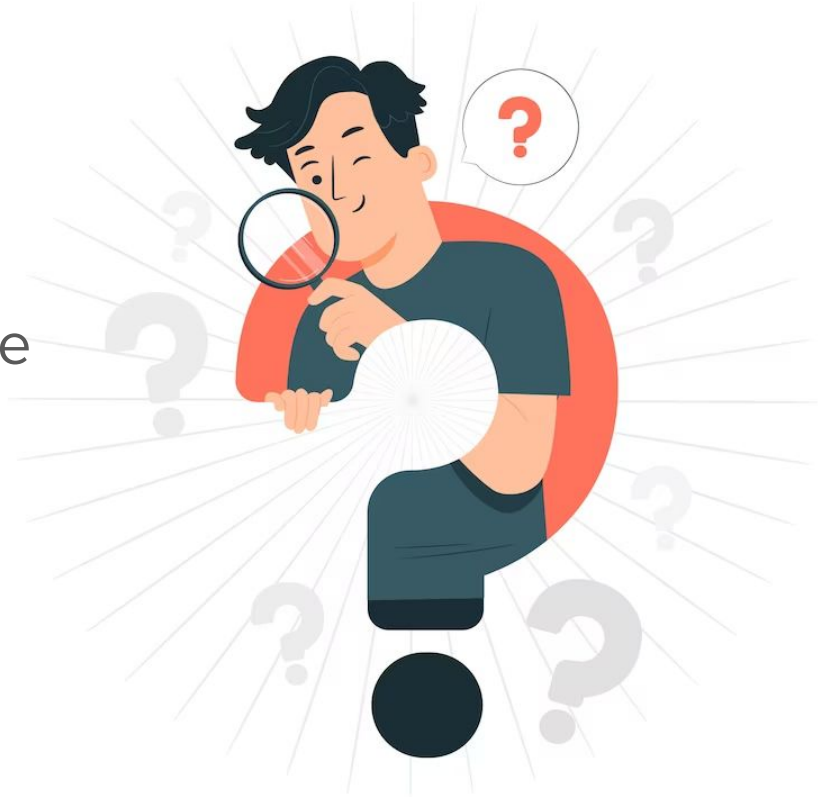

Dataset de atributos numéricos

Clustering Jerárquico Aglomerativo

Clusters anidados organizados en un árbol jerárquico.

Clustering Jerárquico

- Produce un conjunto de clusters anidados organizados en un árbol jerárquico.
- Principal fortaleza: no supone un número de clusters a priori
- Visualizaciones:
  - Dendograma: árbol que muestra las relaciones cluster-subcluster y el orden en que los clusters fueron mezclados o divididos
  - Diagrama de clusters anidados: sólo para puntos 2-dimensionales.

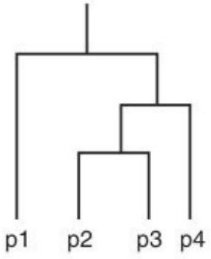

(a) Dendrogram.

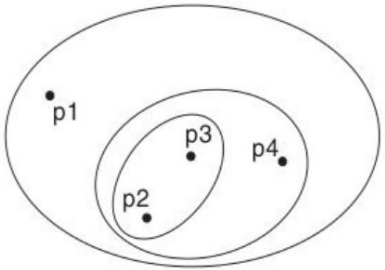

(b) Nested cluster diagram.

Tipos de Clustering Jerárquico

En esta clase nos enfocaremos en cluster aglomerativo.

Aglomerativo	**Divisivo**
Empieza con cada punto como un cluster individual. En cada paso mezcla el par de clusters más cercanos hasta que queda un solo cluster o k clusters.	Empieza con un cluster que contiene todos los puntos. En cada paso divide un cluster en dos hasta que todo cluster contenga un solo punto (o haya k clusters)

¿Cómo funciona el algoritmo aglomerativo?

1. Calcular matriz de distancias
2. Sea cada punto un cluster
3. Iterar hasta que quede un cluster
    a. Mezclar par de clusters más cercanos
    b. Actualizar matriz de distancias

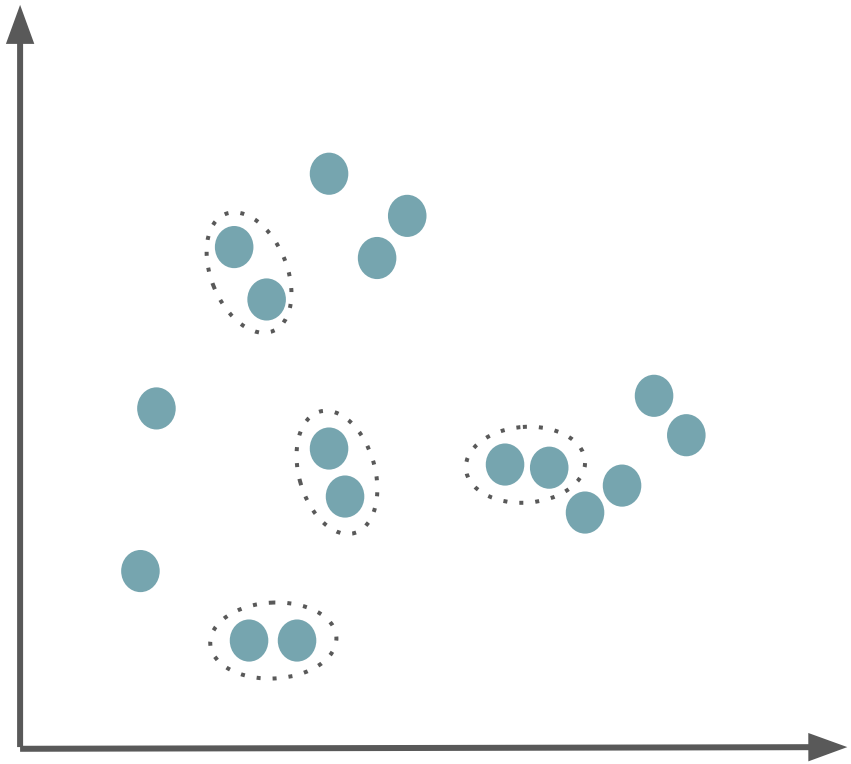

	p1	p2	p3	p4	p5	. . .
p1						
p2						
p3						
p4						
p5						
.						
.						

Matriz de distancias

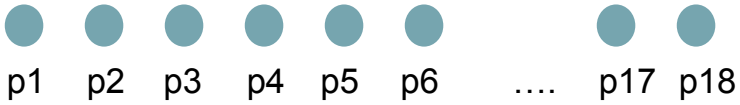

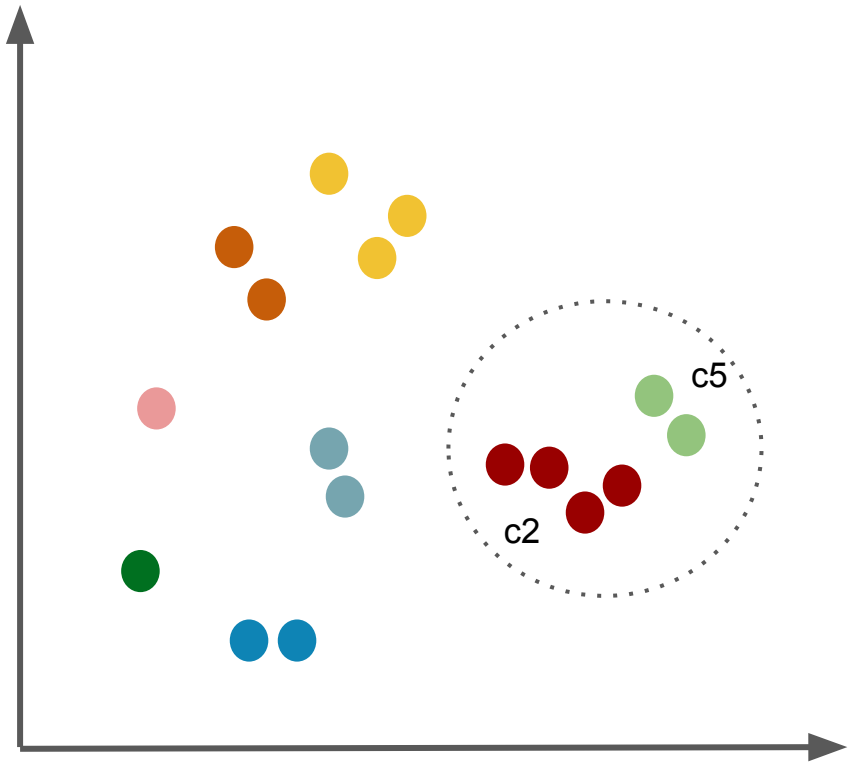

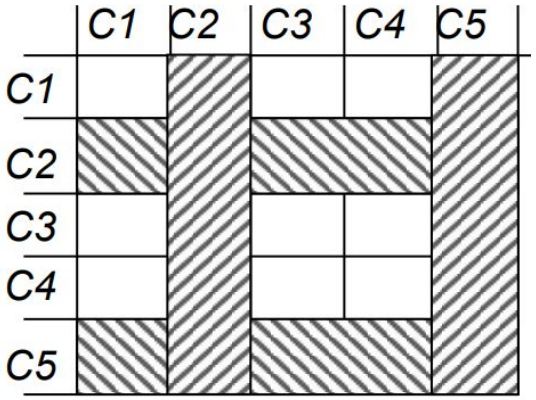

Matriz de distancias

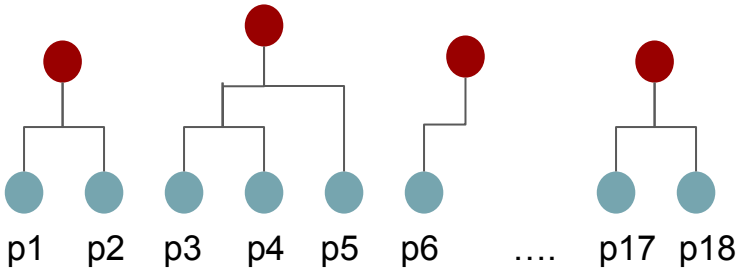

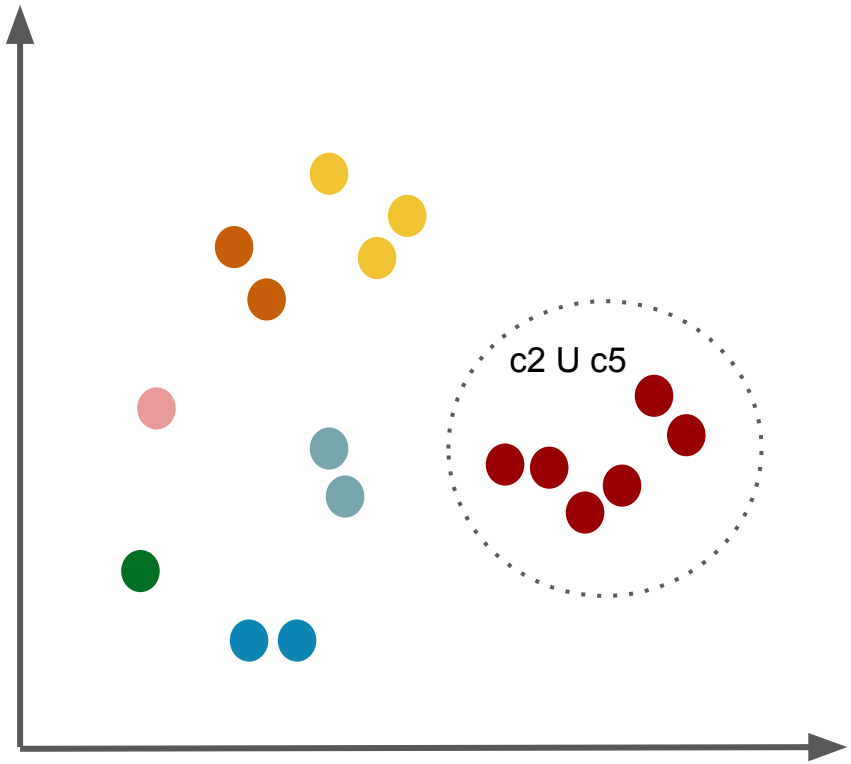

	C1	C2 U C5	C3	C4
C1		?		
C2 U C5	?	?	?	?
C3		?		
C4		?		

Matriz de distancias

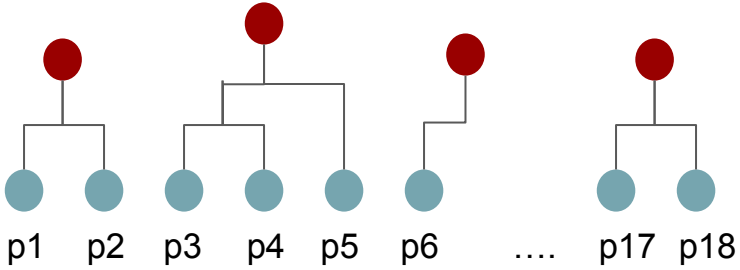

¿Cómo calcular cuáles son los clusters más cercanos?

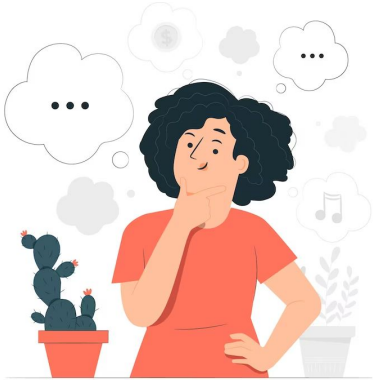

Existen varias métricas de distancia entre clusters

MIN (single link)

MAX (complete link)

Promedio del grupo

Método de Ward

Método MIN (single link)

Considero los dos puntos más cercanos entre sí (cada uno de un cluster distinto)

Fortaleza: Puede manejar formas no elípticas.

Limitante: Sensible al ruido y outliers

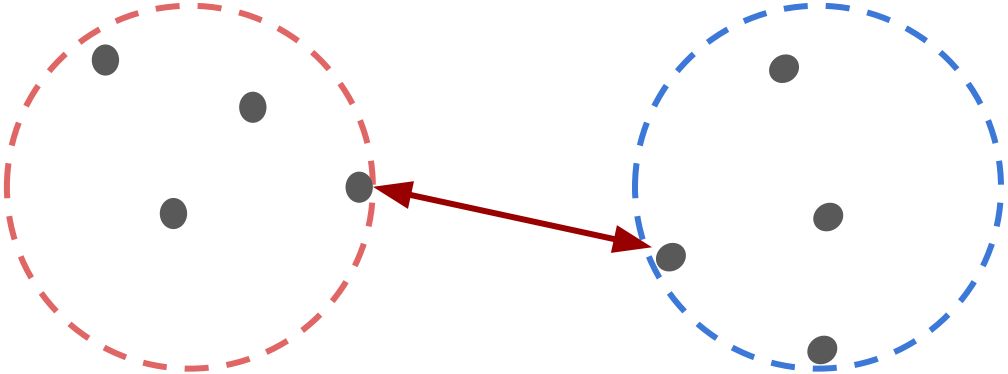

Método MAX (complete link)

Considero los dos puntos más lejanos entre sí (cada uno de un cluster distinto)

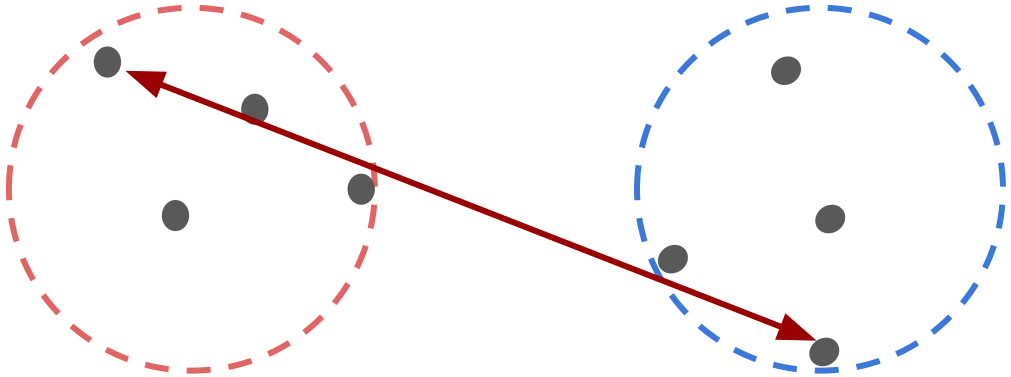

Fortaleza: Menos susceptible al ruido y outliers.

Limitante: Tiende a quebrar clusters grandes y es sesgado a clusters esféricos.

Método Promedio del grupo

Distancia promedio de todos los pares de puntos (cada par tiene un punto por cluster)

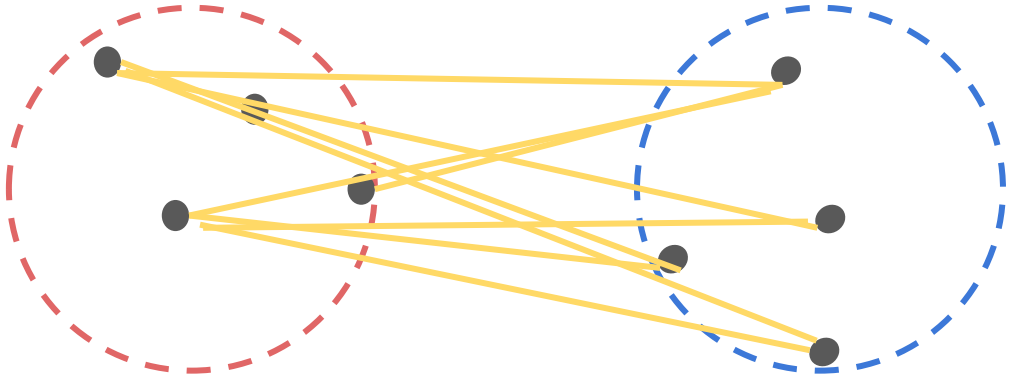

Fortaleza: Menos susceptible al ruido y outliers.

Limitante: sesgado a clusters esféricos.

Método Ward

Se basa en el incremento de SSE cuando se mezclan dos clusters.

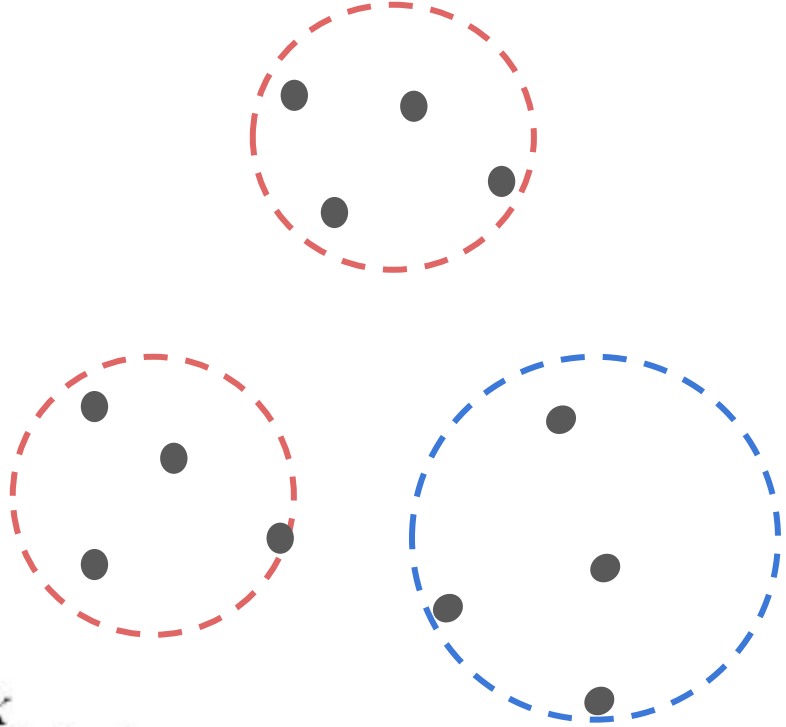

Fortaleza: Menos susceptible al ruido y outliers.

Limitante: sesgado a clusters esféricos.

$$\mathrm{SSE} = \sum_{i=1}^{K} \sum_{\mathbf{x} \in C_i} dist(\mathbf{c}_i, \mathbf{x})^2$$

Distintos clusters dependiendo del método utilizado

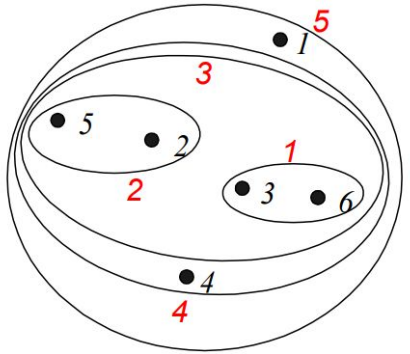

MIN

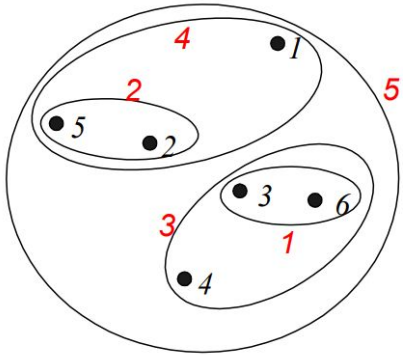

MAX

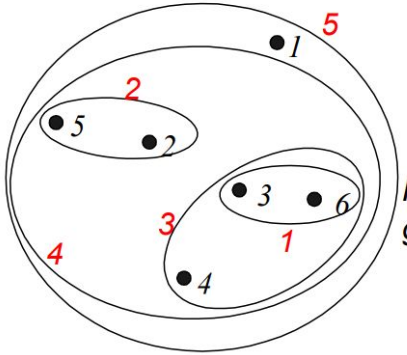

Promedio de grupo

Método de Ward

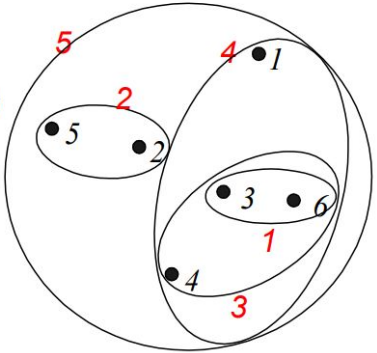

Problemas y limitaciones

- No hay una función objetivo que sea directamente minimizada.
- Sensibles a ruido y outliers.
- Dificultad para manejar clusters de distinto tamaño.
- Pueden romper clusters grandes.
- No escala muy bien.

Distancia entre clusters

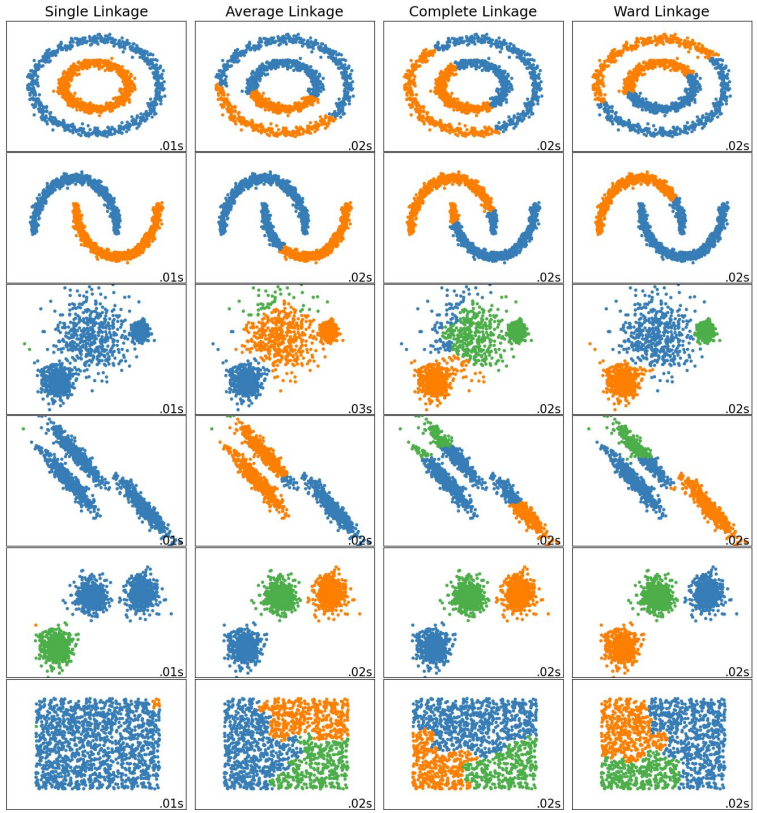

Fuente: https://scikit-learn.org/stable/auto_examples/cluster/plot_linkage_comparison.html

Dataset de atributos numéricos

Eps: Radio especificado

MinPts: Número min de puntos en una región

DBSCAN

Algoritmo de clustering basado en densidad

Conjunto de clusters densos y puntos que no quedaron en ningún cluster (outliers)

¿Qué es la densidad?

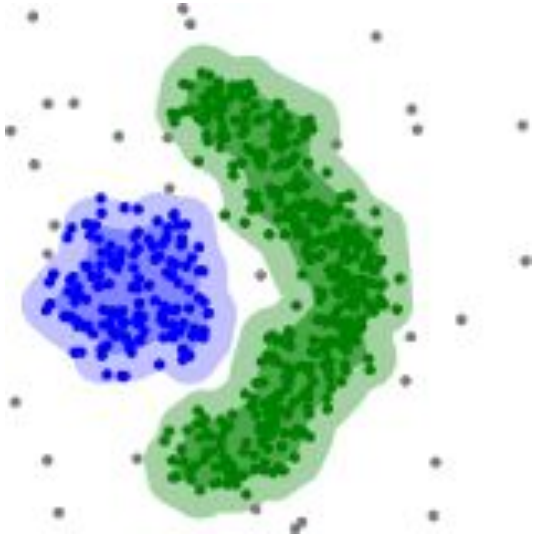

La densidad de un punto es el número de puntos que tiene dentro de un radio dado.

- Idea: encontrar regiones de alta densidad de puntos separadas por regiones de baja densidad.
- Las regiones densas corresponden a los clusters.

Tipos de puntos

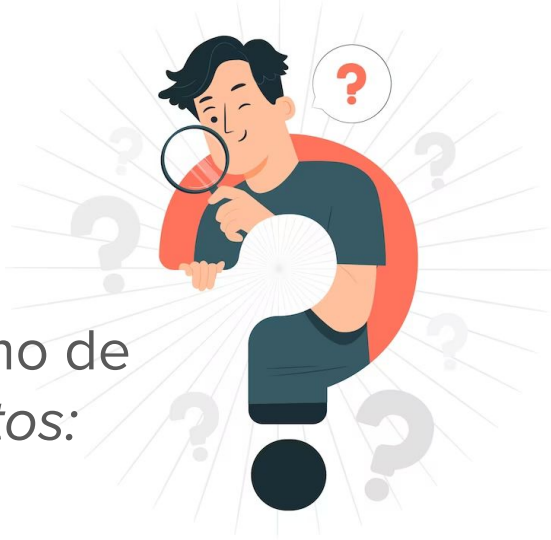

Considerando los parámetros del modelo ***Eps*** (radio especificado) y ***MinPts*** (número mínimo de puntos en una región)*, existen tres tipos de puntos:*

- Punto "***core***": punto con más de *MinPts* puntos a distancia *Eps*
- Punto "***border***": punto con menos de MinPts puntos en el radio Eps, pero está en la vecindad de un punto core.
- Punto "***noise***": cualquier punto que no es core ni border.

¿Cómo funciona?

1. Etiqueta todos los puntos en ***core***, ***border*** o ***noise***
2. Elimina los puntos ***noise***
3. Asigna un arco entre los puntos ***core*** que se encuentran a una distancia menor o igual a Eps
4. Asigna cada grupo de puntos ***core*** conectados a un cluster separado
5. Asigna los puntos ***border*** a uno de los clusters de los puntos ***core*** asociados

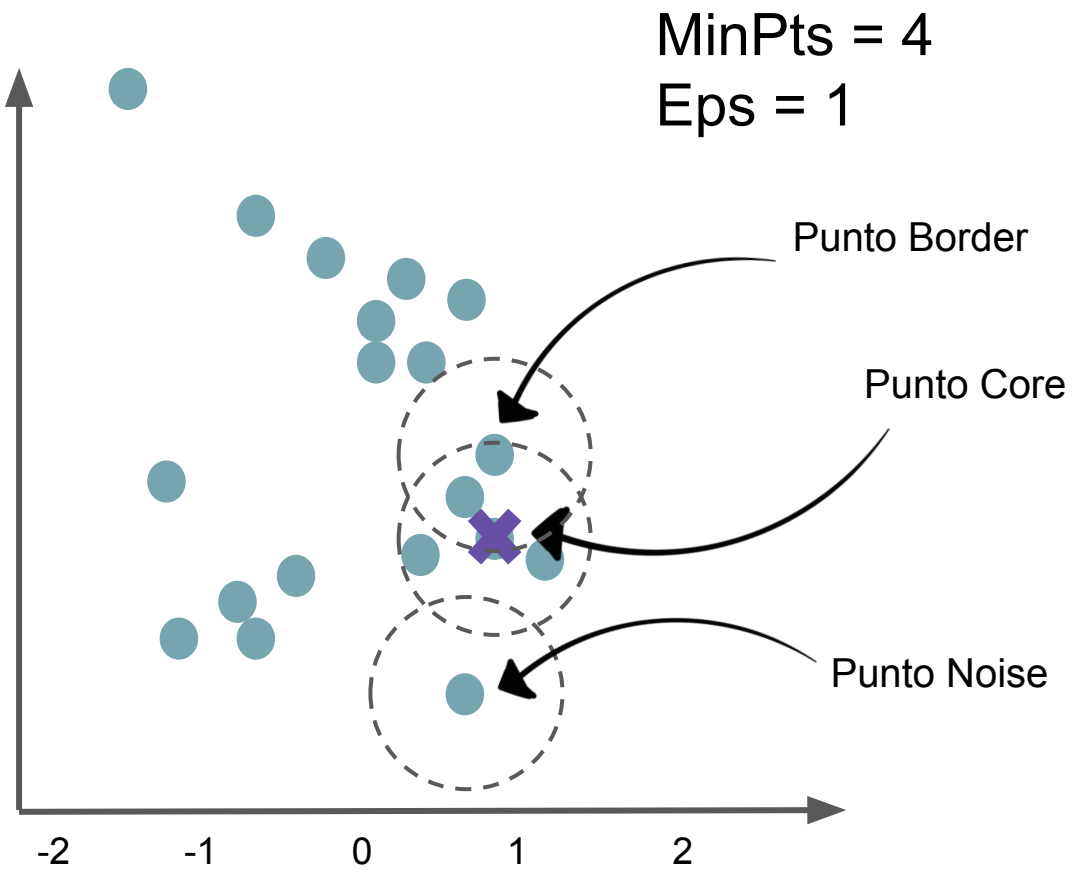
MinPts = 4
Eps = 1
Punto Border
Punto Core
Punto Noise
-2
-1
0
1
2

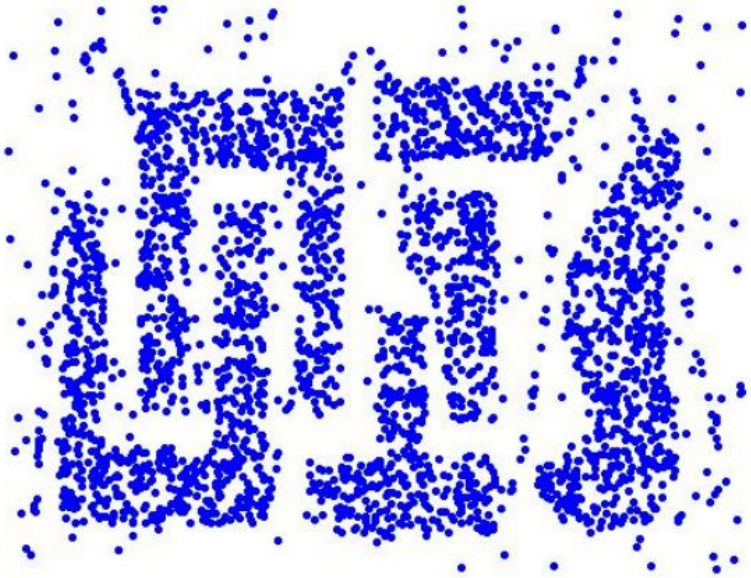

Puntos originales

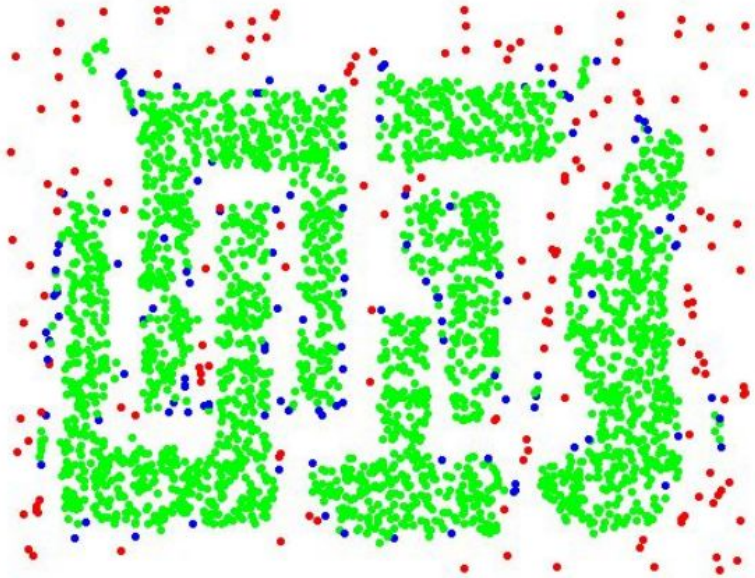

Tipos de punto: core, border y noise

Eps = 10, MinPts = 4

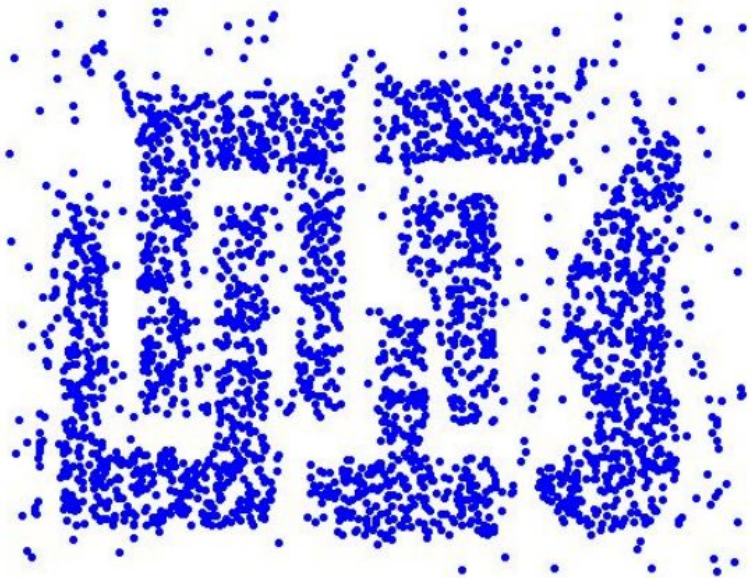

Puntos originales

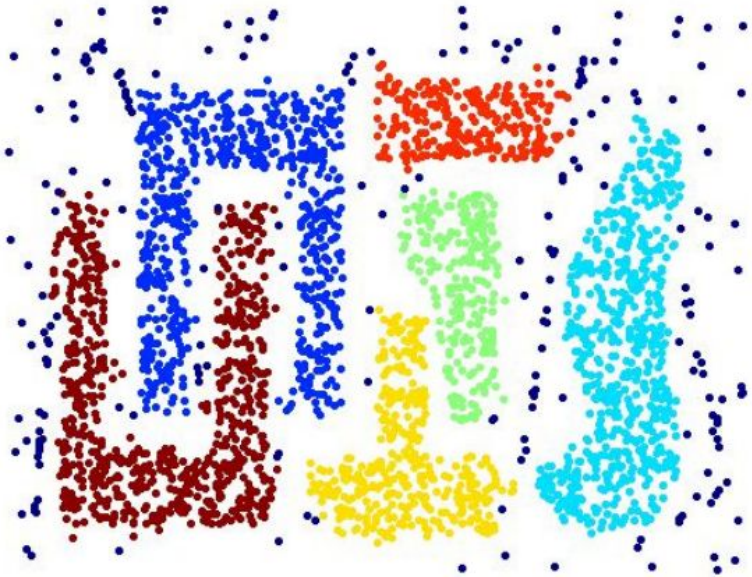

Clusters

DBSCAN: Determinando Eps (método de la rodilla)

- Para todos los puntos, calcular la distancia a su k-ésimo vecino más cercano (con k fijo, generalmente el valor de minPts)
- Ordenar los valores de k-dist de manera creciente
- Graficar k-dist vs la cantidad de puntos
- Identificar el punto de inflexión en el gráfico y seleccionar dicho valor como Eps

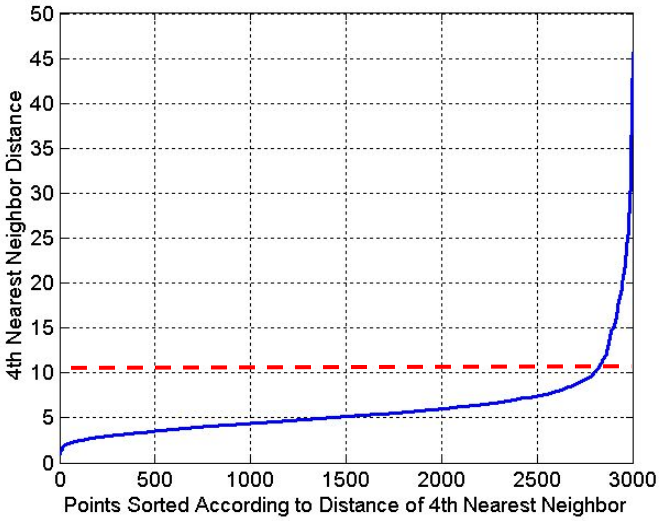

Heurística para minPts: podemos basarnos en la cantidad de dimensiones que tienen nuestros datos. minPts ≥ D + 1

¿Cuáles serían las fortalezas de este algoritmo de clustering?

- Resistente a ruido.
- Pueden identificar cluster de diferentes formas y tamaños.

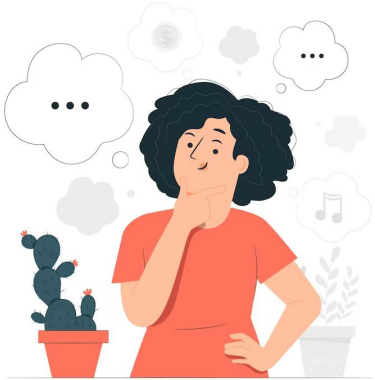

Problemas y limitaciones

- No funciona bien con densidades variables. Clusters de baja densidad se confunden con ruido.

- No funciona bien con datos de alta dimensionalidad.

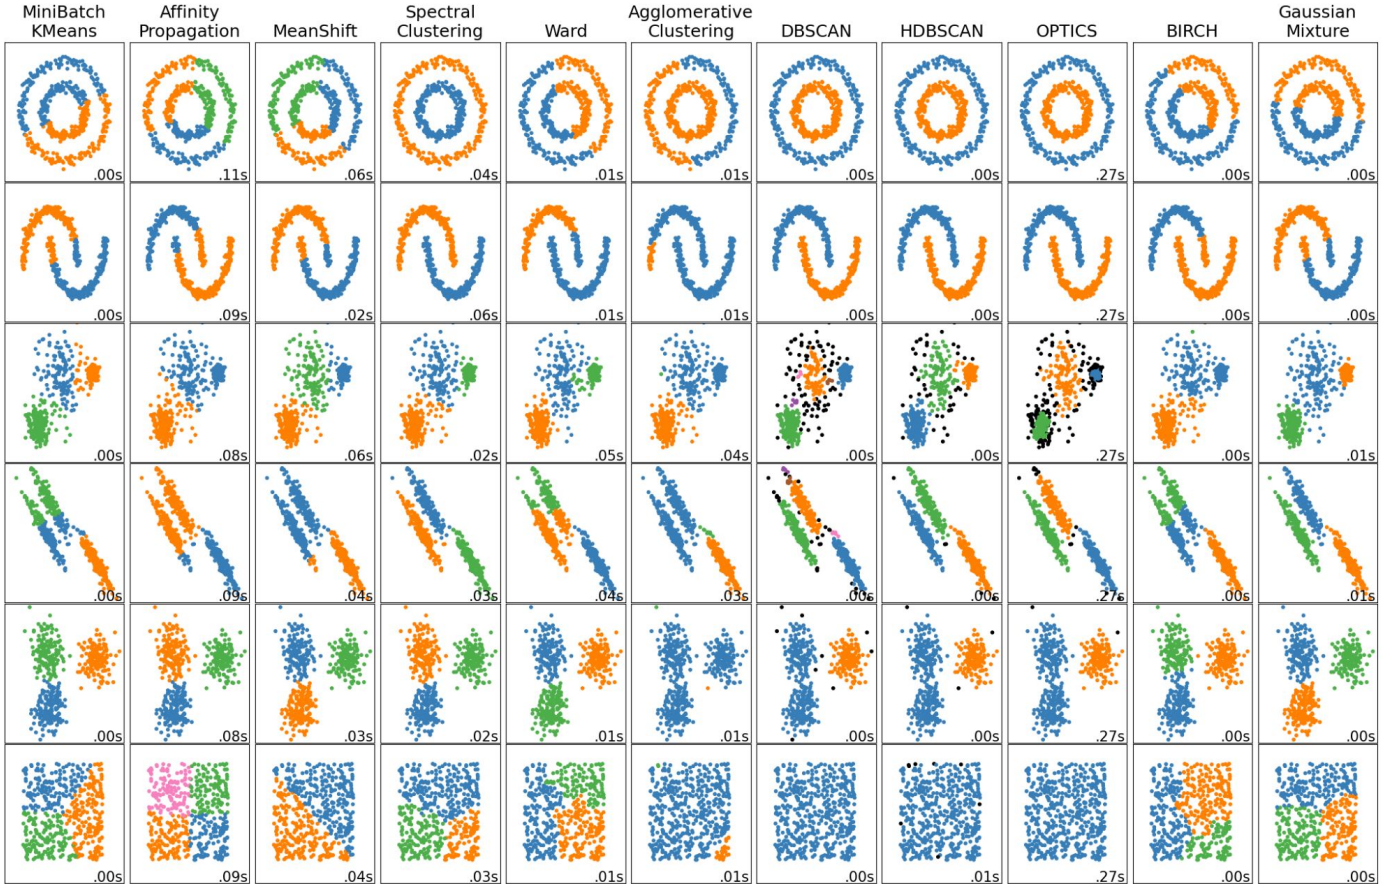

- Varios otros métodos de clustering: Ver más en https://scikit-learn.org/stable/modules/clustering.html
- Aprendizaje no supervisado puede ser usado para detección de outliers / anomalías: https://scikit-learn.org/stable/modules/outlier_detection.html

Implementación

https://colab.research.google.com/drive/1B1tcvctGq2V2Eks3lCaULc3jEF4Wg7vn

Comentarios

- Clustering nos permite encontrar agrupaciones naturales en los datos de forma automática
- Existen varios paradigmas distintos de clusterización
- **Es mucho más subjetivo y difícil de medir que aprendizaje supervisado**
- Próxima clase: ¿cómo validar que nuestro clustering es bueno?

dcc

CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

www.dcc.uchile.cl