



Minería de Datos

Clustering

Validación de Clusters

Valentin Barriere / Mauricio Cerda / Cinthia Sánchez
CC5205, Otoño 2026

Basada en versiones previas de Bárbara Poblete

¿Es necesario validar los clusters?

Clasificación

La validación es una **parte integral** del proceso.

Se cuenta con etiquetas reales (Ground Truth) para medir el desempeño de forma objetiva.

Clustering

No ocurre lo mismo...

La ausencia de etiquetas hace que la validación sea un desafío subjetivo y exploratorio.

Aprendizaje Supervisado vs. No Supervisado

Supervised

Target: $y = F(x)$: true function

Data: labeled training set $D: \{(x_i, y_i)\}$

Model: $y = G(x)$ trained to predict labels D

Goal: $E < (F(x) - G(x))^2 \approx 0$

Criteria: Accuracy, RMSE, ...

Unsupervised

Target: No true model generator

Data: Unlabeled data sample $D: \{x_i\}$

Learn: Hidden structures/patterns

Goal: Data description/compression

Criteria: Cohesion, separation, etc.

¿Cómo saber si nuestros clusters son buenos?

Contexto General

No hay una respuesta absoluta.

La calidad de un cluster **depende de la aplicación** específica.

A menudo es parte de un *proceso exploratorio* donde evaluar parece opcional.

¿Por qué evaluar?

¡Es esencial!

Siempre es posible encontrar clusters, incluso en datos aleatorios.

Enfoque por algoritmo:

- **k-means:** Usa SSE.
- **DBSCAN:** El SSE no es aplicable.

Evaluamos para:



Evitar patrones falsos

No encontrar estructuras donde solo hay ruido aleatorio.



Comparar algoritmos

Evaluar el desempeño de diferentes técnicas de clustering.



Conjuntos de clusters

Contrastar resultados globales de agrupamiento distintos.




Comparar clusters individuales


Analizar la diferencia específica entre dos grupos formados.

Clusters en datos aleatorios


Puntos Aleatorios




DBSCAN



K-Means



Complete Link



Incluso en datos puramente aleatorios, los algoritmos de clustering pueden forzar la creación de patrones inexistentes.

Aspectos de la validación



Tendencia de agrupamiento

¿Existe una estructura no-aleatoria en los datos?



Número de clusters

Encontrar la cantidad correcta de grupos.



Ajuste a los datos

Evaluar la calidad sin consultar datos externos.



Evaluación externa


Comparar con clases asignadas manualmente.




Comparación de resultados

Comparar dos conjuntos de clusters para determinar cuál es superior.

Visualizando la Matriz de Similitud




Clusters Reales




Matriz de Proximidad

Similitud: Los bloques diagonales bien definidos indican que los puntos dentro de un mismo cluster real tienen una alta proximidad natural entre sí.

Visualizando clusters sobre datos aleatorios




Asignación de Clusters




Matriz de Similitud

Algoritmo: k-means aplicado sobre distribución aleatoria de puntos.

Matrices de Similitud y Proximidad




Clusterización con K-Means




Matriz de Proximidad

Interpretación: Mientras más homogéneo sea el color en los bloques de la diagonal, mejor es la separación de los clusters en el modelo.

Matrices de Similitud y Proximidad



Clusterización con DBSCAN




Matriz de Similitud


Distancia

Interpretación: La matriz revela la estructura de los clusters. Bloques diagonales homogéneos indican clusters bien definidos por el algoritmo DBSCAN.


Comparando matrices de Proximidad



Modelo 1




Modelo 2




Modelo 3

Pregunta de evaluación: Basado en la homogeneidad de los bloques diagonales, ¿cuál modelo presenta una mejor estructura de clusters?


Comparando matrices de similitud



Modelo 1



Modelo 2



Modelo 3

Pregunta de evaluación: Basado en la homogeneidad de los bloques diagonales, ¿cuál modelo presenta una mejor estructura de clusters?

Medidas de validez



Internal Index

No-Supervisado

Evalúa la calidad del agrupamiento utilizando únicamente la información intrínseca de los datos.

- SSE (Error cuadrático)
- Cohesión
- Separación



External Index

Supervisado

Compara los resultados del clustering con una estructura externa conocida (ground truth).

- Pureza
- Entropía



Relative Index

Relativo

Compara diferentes esquemas de clustering entre sí para determinar cuál es el más adecuado.

Puede reutilizar medidas internas o externas.

Validez usando correlación (internal)

Matriz de Incidencia

Matriz $n \times n$ idealizada basada en la pertenencia a clusters:

- Una fila y columna por cada punto.
- **1**: Si los puntos coinciden en el mismo cluster.
- **0**: Si los puntos están en distintos clusters.

Matriz de Proximidad

Matriz $n \times n$ calculada a partir de los datos reales:


- Utiliza la **distancia** o **similitud** entre pares de puntos.
- Representa la estructura física real de los datos antes del clustering.

Cálculo de Correlación


Se compara la correlación entre ambas matrices (simétricas, $n(n-1)/2$ comparaciones). Una correlación fuerte indica que la estructura del cluster coincide con la proximidad natural de los datos (Point-biserial Index).

▲ **Limitación:** No es efectiva para algoritmos basados en **densidad** o **continuidad**.

Correlación usando k-means (internal)



Corr = -0.9235



Corr = -0.5810

i Nota: El valor es negativo porque se utiliza **distancia** en lugar de similitud.



Medidas internas: SSE

⚠ **Nota:** Clusters con formas complejas pueden no separarse bien con SSE.



Sum of Squared Errors (SSE)

- Índice interno fundamental para evaluar la cohesión de los clusters.
- Permite comparar 2 clusters individuales o 2 soluciones de clustering completas.
- Herramienta clave para estimar el número óptimo de clusters (método del codo).

$$SSE = \sum_{k=1}^K \sum_{\forall x_i \in C_k} \|x_i - \mu_k\|^2$$



Curva SSE para un dataset más complicado



SSE of clusters found using K-means

Metodología para validar clusters

Necesidad



Contar con una metodología para interpretar cualquier medida:

- ¿Qué es bueno?
- ¿Qué no lo es?

Solución



Usamos la **estadística** como base fundamental para crear una metodología de validación robusta.

Metodología para validar clusters



Principio Clave

Mientras más **atípico** es un resultado, más probable que sea reflejo de estructuras válidas.



Comparación

Podemos comparar índices que resultan de **datos aleatorios**, con los de nuestros datos.



Validación

Valores poco probables indican **resultados válidos**.

Metodología para validar clusters



Contexto de Uso

Al comparar resultados de dos clustering (dos cluster sets), no es muy necesario usar una metodología compleja.



El Desafío



La pregunta clave es si la diferencia es **significativa**:

- Estadísticamente robusta
- Repetible en el tiempo
- Relevante en magnitud

Metodología: Ejemplo SSE


Comparar: SSE = 0.005 contra 3 clusters de datos aleatorios.

Distribución: El histograma muestra el SSE para 500 sets de datos aleatorios (100 puntos) en el mismo rango.




Otro ejemplo: Correlación


Correlación entre matrices de incidencia y proximidad para 2 sets de datos



Corr = -0.9235



Corr = -0.5810



Medidas Internas: Cohesión y Separación



Cohesión de Clusters

Mide qué tan cercanos son los objetos dentro de un mismo cluster.

Ejemplo: SSE (Within Cluster Sum of Squares)

$$WSS = \sum_i \sum_{x \in C_i} (x - m_i)^2$$




Separación de Clusters

Mide qué tan diferente o bien separado está un cluster respecto a los demás.

Ejemplo: BSS (Between Cluster Sum of Squares)

$$BSS = \sum_i |C_i| (m - m_i)^2$$

Ejemplo



K=1 cluster:

$$WSS = (1 - 3)^2 + (2 - 3)^2 + (4 - 3)^2 + (5 - 3)^2 = 10$$

$$BSS = 4 \times (3 - 3)^2 = 0$$

$$Total = 10 + 0 = 10$$

K=2 clusters:

$$WSS = (1 - 1.5)^2 + (2 - 1.5)^2 + (4 - 4.5)^2 + (5 - 4.5)^2 = 1$$

$$BSS = 2 \times (3 - 1.5)^2 + 2 \times (4.5 - 3)^2 = 9$$

$$Total = 1 + 9 = 10$$

Medidas Internas: Cohesión y Separación




Cohesión

Suma de los pesos de todos los arcos en un cluster.



Separación

Suma de los pesos entre nodos del cluster y de otros clusters.



Enfoque basado en grafos de proximidad

Medidas Internas: Coeficiente de Silhouette

Combina ideas de cohesión y separación para puntos individuales, clusters y clusterings (promedios).
Este coeficiente se calcula para cada punto mediante la siguiente fórmula:

$$\frac{(b-a)}{\max(a,b)}$$

(a) Cohesión: Distancia promedio al resto de los puntos en su misma clase.

(b) Separación: Distancia promedio a todos los puntos del cluster más cercano.

Rango de la Métrica

$[-1, 1]$

- **1:** Bien asignado.
- **-1:** Mal asignado (existe un cluster más similar).
- **0:** Solapamiento de clusters.

Medidas Externas: Pureza y Entropía



Pureza

Nivel en que un cluster contiene elementos de una sola clase. Se utiliza la clase predominante para su cálculo.



Entropía

Cantidad de clases diferentes que contiene un cluster, representando el grado de desorden o mezcla.

Validación con Expertos



Evaluación Cualitativa

Se pueden evaluar los clusters para ver si producen el resultado esperado y comparar con otras soluciones.



Clasificación de Validación

Es posible generar una clasificación de validación basada en el juicio experto para corroborar la estructura encontrada.

La validación experta aporta una dimensión interpretativa fundamental al análisis de agrupamiento.

Comentarios sobre Clustering



Desafío de Validación

La etapa de validación es la parte más difícil y frustrante del análisis de clusters.



Necesidad Crítica

A pesar de su complejidad, este proceso es estrictamente necesario para garantizar resultados confiables.



Enfoque Híbrido

Idealmente se deben combinar medidas externas e internas para una evaluación integral.

Ejemplos de Implementación



Accede al cuaderno interactivo en Google Colab

<https://colab.research.google.com/drive/1B76wixcQt5S15Rib-5ne9wyT6BY1Llh7?usp=sharing>



Recursos prácticos para la exploración y aplicación de algoritmos de clustering.


Reducción de Dimensionalidad

Limitaciones de Linealidad

PCA es un método lineal. En estructuras no lineales complejas (como el "Swiss Roll" de la imagen), PCA puede fallar al capturar la verdadera estructura intrínseca de los datos.

Preservación Global vs. Local

PCA prioriza la varianza global, lo que podría "aplastar" las conexiones locales en este tipo de variedades curvadas, perdiendo la continuidad de los datos.



¿Cómo funcionaría PCA en este conjunto de datos?

Multi-Dimensional Scaling (MDS)

Objetivo Principal

A partir de **pares de distancias**, construir un mapa (2D) que preserve estas relaciones espaciales.

Entrada de Datos

Se utiliza una **matriz de disimilaridad**, la cual no requiere ser necesariamente una métrica formal.

Propiedades de la Proyección

La proyección genera coordenadas $\vec{x}_i(x_{i1}, x_{i2})$, y esta a una distancia $|\vec{x}_i - \vec{x}_j|$

Multi-Dimensional Scaling (MDS): Ejemplo 1


Visualización de Resultados

Matriz de Disimilaridad Reordenada

La matriz de la derecha muestra las distancias relativas entre países, donde los colores más oscuros indican una menor disimilaridad.

Coordenadas MDS

El gráfico de dispersión proyecta estos datos en un espacio bidimensional, preservando las relaciones de proximidad percibidas entre las naciones.



Multi-Dimensional Scaling (MDS): Ejemplo 2

Contexto del Experimento

Estudio de la percepción de colores realizado por Ekman (1954).

Metodología y Datos

- **Estímulos:** 14 colores que solo varían en tono (longitud de onda de 434 nm a 674 nm).
- **Participantes:** 31 personas evaluaron la similitud de todos los pares en una escala de 0 a 4.
- **Procesamiento:** Se calculó el promedio de similitud por par y se restó a 1 para obtener la **matriz de disimilaridades**.

Análisis psicofísico de la percepción del color mediante técnicas de escalamiento.

Multi-Dimensional Scaling (MDS): Ejemplo 2

Datos de Entrada

Matriz de Disimilaridad

Contiene las distancias percibidas entre 14 estímulos de color (434-674 nm).

Objetivo del Análisis

MDS busca una representación 2D que preserve estas relaciones de proximidad en un mapa visual legible.

	434	445	465	472	490	504	537	555	584	600	610	628	651
445	0.14												
465	0.58	0.50											
472	0.58	0.56	0.19										
490	0.82	0.78	0.53	0.46									
504	0.94	0.91	0.83	0.75	0.39								
537	0.93	0.93	0.90	0.90	0.69	0.38							
555	0.96	0.93	0.92	0.91	0.74	0.55	0.27						
584	0.98	0.98	0.98	0.98	0.93	0.86	0.78	0.67					
600	0.93	0.96	0.99	0.99	0.98	0.92	0.86	0.81	0.42				
610	0.91	0.93	0.98	1.00	0.98	0.98	0.95	0.96	0.63	0.26			
628	0.88	0.89	0.99	0.99	0.99	0.98	0.98	0.97	0.73	0.50	0.24		
651	0.87	0.87	0.95	0.98	0.98	0.98	0.98	0.98	0.80	0.59	0.38	0.15	
674	0.84	0.86	0.97	0.96	1.00	0.99	1.00	0.98	0.77	0.72	0.45	0.32	0.24



Representación de la matriz de disimilaridad de Ekman (1954) basada en longitudes de onda.



Multi-Dimensional Scaling (MDS): Ejemplo 2

Resultado del Análisis

La "Rueda de Colores"

MDS produce las conocidas “ruedas” de colores a partir de las distancias percibidas.

El mapa revela una estructura circular natural donde los colores se ordenan según su longitud de onda, reflejando la percepción humana.



Comparación de configuraciones obtenidas mediante MDS métrico y no métrico para los datos de Ekman.

MDS: Formalización

Definición del Problema

Objetivo

Dada una matriz de disimilaridad, MDS busca encontrar una configuración de puntos en un espacio p -dimensional que preserve las distancias originales.

Propiedad de Euclidianidad

Si es posible alcanzar la igualdad (típicamente para p alto), se denomina matriz **euclidiana**. En caso contrario, es **no-euclidiana**.

Matriz de Entrada y Búsqueda

$$D = d_{ij} \quad \vec{x}_1, \dots, \vec{x}_n \in \mathbb{R}^p$$

Criterio de Aproximación

$$d_{ij} \approx \|\mathbf{x}_i - \mathbf{x}_j\|_2 \text{ as close as possible.}$$

MDS: Formalización

Definición del Problema

Escenario

Supongamos que D es euclidiana (buscamos la igualdad). Bajo este supuesto, MDS busca resolver la configuración espacial de los puntos.

Pregunta

¿Es única la solución? ¿Por qué?

Objetivo de Optimización

$$\|x_i - x_j\| = d_{ij}$$

Nota sobre la Solución

La búsqueda de una configuración que preserve distancias implica considerar invarianzas por transformación.

MDS: Formalización

Invarianza de la Solución

¿Es la solución única?

No es una solución única. Las distancias euclidianas son invariantes ante traslaciones.

Restricción de Centrado

Para fijar una solución, se impone la restricción de centrar los datos en el origen, eliminando la ambigüedad por traslación.

Invarianza ante Traslación

$$\|x_i^* - x_j^*\| = \|(x_i + c) - (x_j + c)\| = \|x_i - x_j\| = d_{ij}$$

Condición de Centrado

$$\sum_{i=1}^n x_{ik} = 0, \quad \text{for all } k$$

MDS: variantes con re-escalamiento

Conceptos Clave

MDS Clásico

Busca encontrar coordenadas óptimas para representar los datos en un espacio de baja dimensión.

Escalamiento de Distancia

Busca relajar MDS mediante el re-escalamiento de la matriz de distancia original.

Relación de Re-escalamiento

$$f(d_{ij}) = \alpha + \beta d_{ij}.$$

Estimación de Distancias



$$d_{ij} \approx \hat{d}_{ij}$$

$$\hat{d}_{ij} \approx f(d_{ij}).$$

MDS: Ejemplo de Re-escalamiento

Análisis de Resultados

- Comparación entre **MDS clásico** (izquierda) y la variante con **re-escalado Sammon Mapping** (derecha).
- Impacto visual:
 - **Aumenta la distancia** en puntos cercanos.
 - **Comprime los puntos** más separados.




Visualización de Cohorte 1925-1929: Comparativa de Métodos



ISOMAP

Ideas

- Preservar la **geometría implícita** de los datos.
- Utilizar una **distancia geodésica** en lugar de la euclidiana.



Three steps algorithm




Representación visual del algoritmo de tres pasos ISOMAP

ISOMAP: Paso 1

Construcción del Grafo

- Calcular **K puntos vecinos** (o dentro de un radio ϵ).
- Crear un **grafo de vecindad** con arcos entre puntos cercanos.
- Asignar pesos basados en la **distancia euclidiana**.




Identificación de vecindad en la variedad (Swiss Roll)

ISOMAP: Paso 2 y 3

Cálculo de Distancias Geodésicas

- Estimar las **distancias geodésicas** reales.
- Computar todos los **caminos más cortos** entre pares de puntos.
- Utilizar el **algoritmo de Floyd-Warshall** con complejidad $O(N^2 \log(N))$.

Proyección con MDS (u otro)





Representación de caminos más cortos sobre la variedad

ISOMAP: Ejemplo Visual

Reducción de Dimensionalidad


- Visualización de la transición de **2-D** a **1-D**.
- Preservación de la **estructura local** de los datos.
- Mantenimiento de las relaciones de vecindad originales.



Comparación de proyecciones espaciales

Stochastic Neighbor Embedding

- Una versión probabilística de **ISOMAP**.
- Criterio estocástico para decidir si la **distancia local** entre puntos es significativa.
- Cada punto x_i en alta dimensión tiene una **probabilidad condicional** de tener a x_j como vecino.
- La probabilidad condicional se basa en la **distancia entre pares**.




$$p_{j|i} = \frac{e^{-d_{ij}^2 / 2\sigma_i^2}}{\sum_k e^{-d_{ik}^2 / 2\sigma_i^2}}$$

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{n}$$

SNE: Proyección en Baja Dimensión (q)

Principios de la Proyección

- Trabaja sobre el **espacio de baja dimensionalidad** para visualizar la estructura.
- Define **probabilidades simétricas** para asegurar consistencia en las relaciones.
- Evalúa la calidad comparando las **probabilidades en baja dimensión** con las afinidades originales en alta dimensión.



$$q_{ij} = \frac{e^{-d_{ij}^2}}{\sum_{k < l} e^{-d_{kl}^2}}$$

Representación visual de la vecindad (q)

SNE: Función de Costo (Divergencia KL)

Definición de la función de costo de la proyección

$$Cost = KL(P \parallel Q) = \sum_{i < j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

Costo Alto (Penalización)

Cuando p_{ij} es alto y q_{ij} es bajo.

Costo Bajo (Poca pérdida)

Cuando q_{ij} es alto y p_{ij} es bajo.

[t-Distributed] SNE (tSNE)

Problema 1: Densidad Variable

σ_i debería variar con la densidad en el espacio de mayor dimensión (perplexidad).


$$\sigma_i$$

Problema 2: El problema de la "Multitud"

- En alta dimensión hay un mayor volumen para ubicar puntos cercanos.
- En 2D, el área disponible para distancias medias es insuficiente comparado al espacio original.
- Consecuencia: Puntos a distancias medias se deben ubicar más lejos para preservar la estructura.

$$p_{j|i} = \frac{e^{-d_{ij}^2 / 2\sigma_i^2}}{\sum_k e^{-d_{ik}^2 / 2\sigma_i^2}}$$

tSNE: El Problema de la Multitud




Comparación de Activación

Gaussiana Vs t-Student: La distribución t-Student posee una **"cola"** más larga, permitiendo modelar mejor las distancias.

Efecto en la Estructura

Vecinos cercanos: Se acercan más en la proyección para preservar la cohesión local de los datos.

tSNE: El Problema de la Multitud




Comparación de Activación

Activación Gaussiana Vs t-Student: La distribución t-Student posee una **"cola" más larga**, permitiendo modelar mejor las distancias.

Efecto en la Estructura

Vecinos medios: Son alejados "un poco" en la proyección para preservar la estructura global y evitar el colapso de puntos.

tSNE: Solución al Problema de la Multitud



Comparación de Activación

Activación Gaussiana Vs t-Student: La distribución t-Student posee una **"cola" más larga**, permitiendo modelar mejor las distancias.

Efecto en la Estructura

Puntos que no son vecinos directos son **alejados** para preservar la estructura global y evitar el colapso de la visualización.

Comparación con MNIST

0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3
4	4	4	4	4	4	4	4	4	4	4	4	4	4	4	4
5	5	5	5	5	5	5	5	5	5	5	5	5	5	5	5
6	6	6	6	6	6	6	6	6	6	6	6	6	6	6	6
7	7	7	7	7	7	7	7	7	7	7	7	7	7	7	7
8	8	8	8	8	8	8	8	8	8	8	8	8	8	8	8
9	9	9	9	9	9	9	9	9	9	9	9	9	9	9	9


10 dígitos
Dimensión 762=28x28
70k ejemplos



MDS scaling



ISOMAP



tSNE