



dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Regresión

Profesores: Cinthia Sánchez y Cristian Llull

Metodología para el tratamiento de los datos

*Múltiples fuentes de datos:
Temperatura, presión,
lluvias, nubosidad, relieve,
tendencias del cambio
climático, etc...*

*Limpieza y preparación de
los datos. Trabajo con
datos faltantes,
selección/generación de
características relevantes*

*Poner el modelo en
producción*

Definición del
Problema

Recolección de
Datos

Análisis
Exploratorio de
datos

Preprocesamie
nto de datos

Entrenamiento
y Validación del
Modelo

Despliegue del
Modelo

*Heladas en el valle central
provocan pérdidas en la
producción de frutales.*

Solución: Predicción de
Heladas

*Exploración usando
estadísticas de resumen
(frecuencias, medidas de
tendencia central y
dispersión) y visualización.*

*Creación, evaluación y
ajuste de modelos de
Machine Learning*

Retroalimentación: Evaluar el
rendimiento del modelo
desplegado en los nuevos datos.
Reentrenar en caso que el modelo
quede desactualizado.

Regresión

- Técnica utilizada para modelar la relación entre una variable dependiente (objetivo) y una o más variables independientes (predictoras o explicativas).
- Se utiliza para predecir los valores numéricos de un conjunto de datos determinado.
- Viene del área de Machine Learning
- Método de “aprendizaje supervisado”

Regresión

La regresión y la clasificación (ambas tareas predictivas) son bastante similares entre sí, con la diferencia que:

- En la clasificación las salidas son discretas, en la regresión son valores continuos.

Regression Data

X ₁	X ₂	X ₃	X _p	Y
				5.2
				1.3
				23.0
				7.4

Numeric
Target

Classification Data


X ₁	X ₂	X ₃	X _p	Y
				cat
				dog
				cat
				cat

Categorical
"Labels"


Regresión

La regresión y la clasificación (ambas tareas predictivas) son bastante similares entre sí, con la diferencia que:

- En la clasificación las salidas son discretas, en la regresión son valores continuos.



Classification



Regression

Regresión

Ejemplos de aplicación:

- Modelado medioambiental.
- Predicción del consumo energético.
- Predicción o pronóstico financiero.
- Proyección de ventas.
- Estimación de la demanda de productos para la gestión del stock.

Regresión

Ejemplo: Predicción del precio de una propiedad

habitaciones_desde	bannos_desde	metros_construidos_desde	metros_terreno	precio_desde
4.0	3.0	105.0	120.0	3.051520e+08
3.0	3.0	95.0	113.0	1.928006e+08
4.0	3.0	120.0	137.0	2.663145e+08
2.0	2.0	72.0	86.0	1.886394e+08
4.0	3.0	120.0	130.0	2.912815e+08
...	...	...	...	...

x = Variables independientes (o explicativas)

y = Variable dependiente

¿Qué hace un algoritmo de Machine Learning para resolver la tarea de regresión?

Regresión

x1	x2	...	xd	y
...	...	...	...	...

A partir de los datos, el algoritmo construye una función o modelo que estima $\hat{y}$ dada una entrada x .

Algoritmo de aprendizaje



Utiliza una función de costo para medir la discrepancia (error) entre la predicción y el valor real.
Objetivo: Minimizar el error

$x = (x1, x2, ..., xd)$

Modelo de Regresión

$\hat{y} = \text{predicción}$

Modelo lineal vs no lineal



Fuente: <https://www.analyticsvidhya.com/>

Modelos de Regresión

- Un modelo de regresión se usa para modelar la relación de una variable dependiente **y** numérica con n variables independientes $x_1, x_2, \dots, x_n$.
- A grandes rasgos queremos conocer el valor **esperado** de **y** a partir los valores de **x**:

$$\mathbb{E}(y|x_1, x_2, \dots, x_n)$$

Usamos estos modelos cuando creemos que la variable de respuesta **y** puede ser modelada por otras variables independientes también conocidas como **covariables** o **atributos**.

Modelos de Regresión

- Para realizar este tipo de análisis necesitamos un dataset formado por m observaciones que incluyan tanto a la variable de respuesta como a cada uno de los atributos.
- Nos referimos al proceso de **ajustar una función de regresión** al proceso en que a partir de los datos inferimos una función de hipótesis h que nos permite predecir valores de y desconocidos usando los valores de los atributos.


Modelos de Regresión



Recordemos


- A este proceso de ajustar una función a partir de los datos se le llama en machine learning como **entrenamiento**.
- Se entiende que las funciones **aprenden** a partir de los datos.
- Como necesitamos observaciones donde el valor de y sea conocido para aprender la función, se le llama a este tipo de técnicas como técnicas de **aprendizaje supervisado**.
- Cuando y es una variable categórica hablamos de un problema de **clasificación**.

Tipos de modelos



Regresión Lineal Simple

Cuantifica el impacto de un cambio en una variable sobre otra, es decir, cuantifica la relación. La correlación sólo indica si existe una asociación fuerte, moderada o débil.



Es una forma de ajustar una línea recta óptima a los datos; **permite cuantificar relaciones y hacer predicciones.**

Regresión Lineal Simple

El modelo puede ser expresado de la siguiente manera, asumiendo una relación lineal entre las variables:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

β_0 es el intercepto de la recta (el valor de y cuando x vale cero).


β_1 es la pendiente y representa el cambio de y cuando variamos el valor de x .

ϵ corresponde a los errores asociados al modelo.

Regresión Lineal Simple

Tenemos que encontrar una función lineal o recta h_g que nos permita encontrar una estimación de y , $\hat{y}$ para cualquier valor de x con el mínimo error esperado.


$$h(x) = \beta_0 + \beta_1 x$$



Regresión Lineal Simple

Tenemos que encontrar una función lineal o recta h_g que nos permita encontrar una estimación de y , $\hat{y}$ para cualquier valor de x con el mínimo error esperado.


$$h(x) = \beta_0 + \beta_1 x$$



Regresión Lineal Simple

Tenemos que encontrar una función lineal o recta h_g que nos permita encontrar una estimación de y , $\hat{y}$ para cualquier valor de x con el mínimo error esperado.

$$h(x) = \beta_0 + \beta_1 x$$



Mínimos Cuadrados


El método de mínimos cuadrados ordinarios se usa para estimar β_0 y β_1 minimizando la suma de los errores cuadráticos (SSE) de los datos observados.

Supongamos que tenemos m observaciones de y y de x , calculamos SSE o E de error de la siguiente forma:

$$\hat{y} = h(x) = \beta_0 + \beta_1 x$$

$$E = \sum_{i=1}^m (y_i - h(x_i))^2$$

$$= \sum_{i=1}^m (y_i - \beta_0 - \beta_1 x_i)^2$$




Mínimos Cuadrados

Para encontrar los parámetros que minimizan el error calculamos las derivadas parciales de SSE respecto a β_0 y β_1 . Luego igualamos las derivadas a cero y resolvemos la ecuación para despejar los parámetros.

$$= \sum_{i=1}^m (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\frac{\partial E}{\partial \beta_0} = -2 \sum_{i=1}^m (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial E}{\partial \beta_1} = -2 \sum_{i=1}^m (y_i - \beta_0 - \beta_1 x_i) x_i = 0$$





De este sistema de ecuaciones se obtienen las soluciones normales:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^m (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Mínimos Cuadrados

El modelo ajustado representa la recta de mínimo error cuadrático.



¿Cómo evaluar
mi modelo de
regresión?

Fuente: <https://courses.lumenlearning.com/>



Recordemos

Validación de la capacidad de **generalización**

El enfoque clásico de Minería de Datos mide la capacidad del modelo para **predecir correctamente** la salida para **nuevos** datos.

Evaluación

Similar a la clasificación, medimos la capacidad del modelo para **predecir correctamente** la salida para **nuevos datos**.

1. Separar dataset en **train** y **test**.
2. Entrenar el modelo en la partición **train**.
3. Evaluar el modelo en la partición **test**. Por ejemplo, calculando el Error Absoluto Medio (MAE) o el Error Cuadrático Medio (RMSE) (predicción vs valor real).

The diagram illustrates the Mean Absolute Error (MAE) formula with the following components and annotations:

- Divide by the total number of data points:** Points to the $\frac{1}{n}$ term in the formula.
- Sum of:** Points to the summation symbol Σ .
- Actual output value:** Points to the y term inside the absolute value.
- Predicted output value:** Points to the $\hat{y}$ term inside the absolute value.
- The absolute value of the residual:** Points to the entire absolute value expression $|y - \hat{y}|$.

$$MAE = \frac{1}{n} \sum |y - \hat{y}|$$

Fuente: <https://www.aionlinecourse.com/>

Validación de la bondad de ajuste: Coeficiente de Determinación R²

- Una vez ajustado nuestro modelo lineal debemos evaluar la calidad del modelo.
- Una medida muy común es el coeficiente de determinación R². Para calcularlo debo calcular otros errores distintos a los errores cuadráticos SSE.
- Se define a la suma cuadrática total (SST) como el error predictivo cuando usamos la **media** $\bar{y}$ para predecir la variable de respuesta y (es muy similar a la varianza de la variable):

$$SST = \sum_i^m (y_i - \bar{y})^2$$

Coeficiente de Determinación R^2

- Luego tenemos a la suma de los cuadrados explicada por el modelo (SSM) que nos indica la variabilidad de los valores predichos por el modelo respecto a la media.

$$SSM = \sum_i^m (\hat{y}_i - \bar{y})^2$$

- Se define el coeficiente de determinación para un modelo lineal R^2 como:

$$R^2 = \frac{SSM}{SST} = \frac{\sum_i^m (\hat{y}_i - \bar{y})^2}{\sum_i^m (y_i - \bar{y})^2}$$

El coeficiente adquiere valores entre 0 a 1, mientras más cercano a 1, mayor será la calidad del modelo.

El valor de R^2 es equivalente a la correlación lineal (Pearsons) entre y e $\hat{y}$ al cuadrado.

$$R^2 = \text{cor}(y, \hat{y})^2$$

Consideraciones

- Introducir valores para X fuera del rango (visto en los datos) se consideraría extrapolación y puede ser muy arriesgado.
- No es recomendable utilizar un modelo para predecir fuera del rango de los datos observados sobre los que se construyó el modelo.

Regresión Lineal Múltiple

- Supongamos que tenemos n variables independientes: $x_1, x_2, \dots, x_n$.
- Intuitivamente, estas variables en conjunto podrían explicar de mejor manera la variabilidad de la variable de respuesta y que un modelo simple.
- Se define un modelo lineal multivariado de la siguiente manera:

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_n x_{i,n} + \epsilon_i \quad \forall i \in \{1, m\}$$

Regresión Lineal Múltiple

- En el modelo multivariado se extienden todas las propiedades del modelo lineal simple.
- Se puede representar el problema de manera matricial:

$$Y = X\beta + \epsilon$$

- Donde Y es un vector de $m \times 1$ de variables de respuesta:

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

Regresión Lineal Múltiple

- X es una matriz de $m \times (n + 1)$ con las variables explicativas. Tenemos m observaciones de las n variables. La primera columna es constante igual a 1, ($x_{i,0} = 1 \ \forall i$) para incluir la variable de intercepto β_0 de manera limpia.

$$X = \begin{pmatrix} x_{1,0} & x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ x_{2,0} & x_{2,1} & x_{2,2} & \cdots & x_{2,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{m,0} & x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{pmatrix}$$

- Luego, β es un vector de parámetros de $(n + 1) \times 1$

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_n \end{pmatrix}$$

Regresión Lineal Múltiple

- Finalmente, ϵ es un vector con los errores del modelo de dimensiones $m \times 1$.

$$\epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_m \end{pmatrix}$$

- Usando la notación matricial, podemos ver que la suma de los errores cuadráticos (SSE) se puede expresar como:

$$\text{SSE} = (Y - X\beta)^T (Y - X\beta)$$

- Minimizando esta expresión derivando el error en función de β e igualando a cero se llega a las ecuaciones normales:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Supuestos del Modelo Lineal

Cada vez que ajustamos un modelo lineal estamos asumiendo implícitamente ciertos supuestos sobre los datos.

01	Linealidad	La variable de respuesta se relaciona linealmente con los atributos.
02	Normalidad	Los errores tienen distribución normal de media cero: $\varepsilon_i \sim N(0, \sigma^2)$
03	Homocedasticidad	Los errores tienen varianza constante (mismo valor de σ^2).
04	Independencia	Los errores son independientes entre sí.

Interpretación Probabilística

- Considerando los supuestos anteriores podemos ver que la densidad de probabilidad (PDF) de los errores ϵ se definen por una normal de media cero y varianza constante:

$$\text{PDF}(\epsilon_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\epsilon_i^2}{2\sigma^2}\right)$$

- Esto implica que:

$$\text{PDF}(y_i|x_i; \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - h_\beta(x_i))^2}{2\sigma^2}\right)$$

Interpretación Probabilística

- Lo que implica que la distribución de y dada los valores de x y parametrizada por β sigue una distribución normal.
- Luego si uno estima los parámetros de β usando una técnica de estimación llamada **máxima verosimilitud** llega a los mismos resultados que haciendo una estimación por mínimos cuadrados.
- Esto nos dice que cuando estimamos los parámetros del modelo usando mínimos cuadrados estamos realizando las mismas hipótesis probabilísticas mencionadas anteriormente.

Ejemplo

Rape~Assault+Murder

