



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Modelos lineales

(basado en las slides de Valentin Barriere)

Profesores: Cinthia Sánchez y Cristian Llull

Aprendizaje supervisado – Modelos Lineales

Repasos

Repasos

Resumen

Optimización

Modelos de clasificación

Clasificador lineal

Regresión Lineal

Regresión Logística

Repasos

Resumen

Optimización

Modelos de clasificación

Clasificador lineal

Regresión Lineal

Regresión Logística

En resumen: Flujo del Aprendizaje Supervisado

- I **Datos etiquetados:** Conjunto de tamaño n ,
 $\mathcal{D}_n = \{(\mathbf{X}_i, Y_i), i = 1..n\}$ donde $\mathbf{X}_i$ es el vector de descriptores y Y_i la etiqueta.
- II **Modelo matemático:** Definir una función paramétrica $f_\theta(\mathbf{X})$ capaz de aproximar la etiqueta.
- III **Función de costo (ℓ):** Cuantificar el error o penalización cuando el modelo se equivoca.
- IV **Optimización (θ^*):** Encontrar los parámetros óptimos minimizando el costo agregado:

$$\theta^* = \arg \min_{\theta} \sum_i \ell(f_\theta(\mathbf{X}_i), Y_i)$$

- V **Evaluación:** Validar el rendimiento de f_{θ^*} sobre datos no vistos usando métricas adecuadas.

Repasos

Resumen

Optimización


Modelos de clasificación

Clasificador lineal

Regresión Lineal

Regresión Logística

Optimización de la función de costo



Objetivo del entrenamiento

- Encontrar el valor mínimo de la función de costo en el conjunto de entrenamiento.
- Buscamos un proceso que sea computacionalmente eficiente (rápido) y preciso.
- En modelos complejos, el Descenso del Gradiente es el estándar iterativo.

Definición del Gradiente

El gradiente $\nabla_{\theta}\ell$ indica la dirección de **máximo crecimiento** de la función de costo respecto a los parámetros θ .

- **Idea clave:** Para minimizar el costo, nos movemos en la **dirección opuesta** al gradiente.
- Sabiendo que el modelo es una función paramétrica $f_{\theta}(\mathbf{X})$, la regla de actualización es:


$$\theta \leftarrow \theta - \alpha \nabla_{\theta}\ell(Y_i, f_{\theta}(\mathbf{X}_i))$$

donde α es la **tasa de aprendizaje** (*learning rate*).

Optimización : Importancia de la tasa de aprendizaje (α)

Efecto del Learning Rate



- α **muy pequeño**: El entrenamiento avanza lento o se estanca.
- α **muy grande**: El algoritmo oscila, diverge y no logra alcanzar el mínimo.
- **Solución práctica**: Usar optimizadores adaptativos (como Adam) o reducir α gradualmente con el tiempo.



Optimización : Importancia de la tasa de aprendizaje (α)

Efecto del Learning Rate

- α **muy pequeño**: El entrenamiento avanza lento o se estanca.
- α **muy grande**: El algoritmo oscila, diverge y no logra alcanzar el mínimo.
- **Solución práctica**: Usar optimizadores adaptativos (como Adam) o reducir α gradualmente con el tiempo.



Modelos de clasificación

Outline : Modelos de clasificación

Repasos

Resumen

Optimización

Modelos de clasificación

Clasificador lineal

Regresión Lineal

Regresión Logística

Outline : Clasificador lineal

Repasos

Resumen

Optimización

Modelos de clasificación

Clasificador lineal

Linealidad e Hiperplano



Clasificador Multiclase

Aumento del Espacio

Regresión Lineal

Regresión Logística

Problemas lineales y no lineales



Clasificador Lineal

Separa el espacio de características mediante un hiperplano de decisión:

$$f_{\mathbf{w},b}(\mathbf{X}) = \text{signo}(\mathbf{W}^T \mathbf{X} + b)$$

Repaso de Geometría: Hiperplanos


Definición en $\mathbb{R}^d$

Un hiperplano $\mathcal{H}$ está definido por un vector normal $\mathbf{W}$ y un sesgo b :

$$\mathcal{H} : w_1x_1 + w_2x_2 + \dots + w_dx_d + b = \mathbf{W}^T \mathbf{X} + b = 0$$

- **Un hiperplano divide el espacio en 2 partes** (es un espacio de dimensión $d - 1$). En $\mathbb{R}^2$ (plano) es de dimensión 1 (es una recta), en $\mathbb{R}^3$ es de dimensión 2 (es un plano).
- El **signo** de $\mathbf{W}^T \mathbf{X} + b$ determina en qué lado del hiperplano se encuentra un punto $\mathbf{X}$.
- **Truco del sesgo**: Podemos absorber b concatenando un 1 al vector $\mathbf{X}$ y extendiendo $\mathbf{W}$, unificando la operación como un producto escalar puro $\langle \mathbf{W}, \mathbf{X} \rangle = 0$.

Clasificador lineal multiclase y Softmax




- Para C clases, los parámetros forman una matriz $\mathbf{W} \in \mathbb{R}^{d \times C}$ en lugar de un solo vector.
- Obtenemos un vector de puntajes (scores): $\mathbf{W}^T \mathbf{X} + \mathbf{b}$.
- La clase predicha corresponde al puntaje máximo:

$$\hat{c} = \arg \max_c (\mathbf{W}^T \mathbf{X} + \mathbf{b})_c$$

Clasificador lineal : Aumento del espacio (Kernel/Features no lineales)

Al transformar los descriptores originales, podemos resolver problemas no linealmente separables en el espacio original.



Ejemplo intuitivo

Si los datos en $\mathbb{R}^2$ forman círculos concéntricos, agregamos una dimensión no lineal como $z = x^2 + y^2$. En $\mathbb{R}^3$, los datos pasan a ser linealmente separables por un plano.

Outline : Regresión Lineal

Repasos

Resumen

Optimización


Modelos de clasificación

Clasificador lineal

Regresión Lineal

Regresión Logística

Regresión Lineal



Formulación

- Modela una variable continua Y en función de los atributos $\mathbf{X}$.
- Hipótesis: $f_{\mathbf{W},b}(\mathbf{X}) = \mathbf{W}^T \mathbf{X} + b$
- Se optimiza comúnmente minimizando la suma de errores cuadráticos (SSE).

Métricas de evaluación: Error Cuadrático Medio (MSE), Error Absoluto Medio (MAE) y el Coeficiente de Determinación (R^2), el cual representa la proporción de varianza explicada por el modelo.

Outline : Regresión Logística

Repasos

Resumen

Optimización

Modelos de clasificación

Clasificador lineal


Regresión Lineal

Regresión Logística

Regresión Logística y Función Sigmoidal

Para transformar las salidas continuas $\mathbf{W}^T \mathbf{X} + b$ en probabilidades acotadas en el intervalo $[0, 1]$, utilizamos la función sigmoidal (σ):

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Entrenamiento: Entropía Cruzada Binaria

Para $Y \in \{0, 1\}$, la función de costo basada en máxima verosimilitud es:

$$\ell(\mathbf{X}, Y; \theta) = - \left[Y \log(\hat{Y}) + (1 - Y) \log(1 - \hat{Y}) \right]$$

donde $\hat{Y} = \sigma(\mathbf{W}^T \mathbf{X} + b)$.

- **Gradiente resultante:** $\nabla_{\theta} \ell = -\mathbf{X}(Y - \hat{Y})$
- **Generalización multiclase:** Se extiende mediante la función *Softmax* y la entropía cruzada categórica para múltiples clases.

Supuestos del Modelo Lineal

Para que un modelo lineal (en especial estadístico) sea robusto y confiable en sus inferencias, se asume:

1. **Linealidad:** La relación entre los predictores y la respuesta es lineal.
2. **Normalidad:** Los errores (residuos) siguen una distribución normal $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$.
3. **Homocedasticidad:** La varianza de los errores es constante a lo largo de las observaciones.
4. **Independencia:** Los errores no están correlacionados entre sí.

¿Preguntas?