



dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Clustering I
(Introducción)

Profesores: Cinthia Sánchez y Cristian Llull

Recordatorio: Aprendizaje supervisado

- Conjunto de entrenamiento $D_n = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$
- $X = \{x_1, x_2, \dots, x_n\} \in \mathcal{X}$: atributos o features
- $Y = \{y_1, y_2, \dots, y_n\} \in \mathcal{Y}$: etiquetas o labels
- Sabemos que $(X, Y) \sim f$, pero f es desconocida
- Objetivo: construir una función $g: \mathcal{X} \rightarrow \mathcal{Y}$, que se parezca a f

Regression Data

x_1	x_2	x_3	x_n	Y
				5.2
				1.3
				23.0
				7.4

Numeric
Target

Classification Data

x_1	x_2	x_3	x_n	Y
				'cat'
				'dog'
				'cat'
				'cat'

Categorical
"Labels"

O cuando queremos descubrir
patrones/grupos naturales en los datos

¿Qué pasa cuando no tenemos etiquetas?

- Ahora tenemos sólo $D_n = \{x_1, x_2, \dots x_n\}$
- ¡Ya no tenemos Y!
- Todos los métodos que hemos estudiado hasta ahora dependen de una etiqueta, de algo a lo que nos queremos “parecer”

Aprendizaje no supervisado

Aprendizaje no supervisado


- Conseguir etiquetas suele ser un proceso costoso (dinero y/o tiempo).
- A veces, ni siquiera se sabe cómo etiquetarlos (¿cuántas etiquetas hay?).
- Por otro lado, datos no etiquetados son más fáciles de conseguir.
- Aún así, sobre los datos no etiquetados podemos aprender (o descubrir) cosas.
- Una pregunta interesante es si podemos encontrar grupos dentro de los datos -> esto es lo que se conoce como **Clustering**.

Clustering

Técnica para encontrar grupos de objetos tal que:

- Los objetos en un grupo sean similares (o relacionados) entre sí y
- Que sean diferentes (o no relacionados) a los objetos en otros grupos

Busca capturar
agrupaciones naturales
en los datos




¿Cuándo y para qué usar clustering?

Cuando necesitemos dividir nuestros datos en grupos que sean:
significativos y/o útiles

- Debemos preocuparnos de capturar la estructura natural de los datos
- A veces es sólo un punto de partida

Capturar agrupaciones naturales en los datos



Análisis de clusters es una tarea esencial para muchas aplicaciones

Por ej:


- Encontrar clusters naturales y describir sus propiedades (**data understanding**)
- Encontrar agrupamientos útiles (**data class identification**)
- Encontrar representantes para grupos homogéneos (**data reduction**)
- Encontrar objetos inusuales (**outliers detection**)
- Encontrar perturbaciones aleatorias de los datos (**noise detection**)

Formulación del problema

- Dado un conjunto de puntos, organizarlos en clusters (grupos, clases).
- Clustering: el proceso de agrupar objetos físicos en clases de objetos similares



source: <http://www.cs.put.poznan.pl/jstefanowski/sed/DM-7clusteringnew.pdf>

¿Qué es análisis de clusters?






Los grupos de elementos se identifican sólo en base a las características que tienen los datos.

La noción de cluster puede ser ambigua




¿Cuántos clusters?





La noción de cluster puede ser ambigua




¿Cuántos clusters?



Seis clusters



Dos clusters



Cuatro clusters



Ejemplos y Casos de Uso

Ciencias

- Agrupar estrellas en base a su brillo
- Explorar muestras genéticas detectando grupos y analizandolos para identificar patrones de expresión relacionados
- Agrupar sonidos de ballenas para detectar patrones y analizar su forma de comunicación
- Análisis de imágenes para agruparlas y detectar outliers que pueden ser asociados, por ejemplo, a enfermedades

Retail y ventas

- Detectar grupos de clientes para caracterizarlos y definir estrategias que mejoren su experiencia de compra
- Detectar grupos de productos en base a volumen de ventas y frecuencia de compra para tomar decisiones enfocándose en lo más importante
- Agrupar tiendas para detectar patrones de compra que dependen de la localidad

Sociedad


- Análisis de grupos en redes sociales para caracterizar fenómenos sociales
- Detectar temáticas principales presentes en medios de comunicación en un periodo determinado
- Agrupar personas que responden una encuesta para detectar estructuras naturales e implícitas
- Agrupar discursos políticos de presidentes y presidentas para detectar las temáticas principales y elementos diferenciadores

Tipos de clustering

Tipos de clustering


Particional

Divide los datos en subconjuntos sin traslape (clusters), tal que cada dato está en un solo subconjunto.



Jerárquico

Un conjunto de clusters anidados, organizados como un árbol.



Diferentes Métodos de Clustering

K-Means

Fuzzy C-means

DBSCAN

Mezcla de Gaussianas
y algoritmo EM

Método
jerárquico
aglomerativo

Mapas
auto-organizados de
Kohonen (SOM)

Diferentes Métodos de Clustering

K-Means

Fuzzy C-means

DBSCAN

Mezcla de Gaussianas
y algoritmo EM

**Método
jerárquico
aglomerativo**

Mapas
auto-organizados de
Kohonen (SOM)