




CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE


MINERÍA DE DATOS

Clase: Clustering II
(Algoritmos)

Profesores: Cinthia Sánchez y Cristian Llull



Aprendizaje
No-Supervisado




Aprendizaje
Supervisado

Tipos de clustering

Tipos de clustering


Particional

Divide los datos en subconjuntos sin traslape (clusters), tal que cada dato está en un solo subconjunto.



Jerárquico

Un conjunto de clusters anidados, organizados como un árbol.



Diferentes Métodos de Clustering

K-Means

Fuzzy C-means

DBSCAN

Mezcla de Gaussianas
y algoritmo EM

Método
jerárquico
aglomerativo

Mapas
auto-organizados de
Kohonen (SOM)

Diferentes Métodos de Clustering

K-Means

Fuzzy C-means

DBSCAN

Mezcla de Gaussianas
y algoritmo EM

**Método
jerárquico
aglomerativo**

Mapas
auto-organizados de
Kohonen (SOM)

Dataset de
atributos
numéricos

Número de
clusters K



K-Means

Algoritmo de
clustering
particional




K clusters y todos
los puntos fueron
asignados a
alguno de los
clusters.

K-means

¿Cómo funciona?

1. Se asignan K centroides iniciales.
2. Itera hasta converger:
 - a. Asignar puntos a su centroide más cercano
 - b. Recalcular centroides promediando puntos.

¿Qué es un centroide?



Sean 3 vectores de 3 dimensiones:

$$X_1 = [6, 4, 3]$$

$$X_2 = [4, 5, 1]$$

$$X_3 = [2, -3, 5]$$

El centroide de estos vectores es:

$$C(X_1, X_2, X_3) = [(6+4+2)/3, (4+5-3)/3, (3+1+5)/3] = [4, 2, 3]$$



Otras variables a tener en cuenta

- ¿Cómo se escogen centroides iniciales?

El enfoque tradicional es escogerlos aleatoriamente


- ¿Qué medida de distancia usar?

Generalmente se usa distancia Euclideana

- ¿Cómo estimar la cantidad de clusters?

Podemos usar una técnica visual: Método del codo.

¿Qué consecuencias tiene el que los clusters iniciales se asignen aleatoriamente?



SSE: Sum Square Error

Mide la varianza de un cluster

Suma de las distancias cuadradas de cada punto al centroide de su cluster asignado.

$$SSE = \sum_{i=1}^K \sum_{\mathbf{x} \in C_i} dist(\mathbf{c}_i, \mathbf{x})^2$$



SSE: Sum Square Error

Mide la varianza de un cluster


Permite calcular el aporte individual de cada cluster al SSE total.

Permite juzgar si un cluster es bueno o no.




Limitantes


K-means no
asegura encontrar
clusters óptimos



Puntos originales



Clustering óptimo




Clustering sub-optimal


Comparación de inicializaciones

Caso 1:


Aunque los centroides iniciales están todos en un único cluster, igual **se converge a los clusters deseados**.




(a) Iteration 1.



(b) Iteration 2.




(c) Iteration 3.




(d) Iteration 4.

Caso 2:


Aunque los centroides iniciales parecen estar mejor repartidos, llegamos a una **peor solución**.




(a) Iteration 1.



(b) Iteration 2.



(c) Iteration 3.



(d) Iteration 4.

La probabilidad de escoger un centroide por cada cluster óptimo es baja.

$$P = \frac{\text{\# formas de escoger un centroide de cada cluster}}{\text{\# formas de escoger K centroides}} = \frac{K!n^K}{(Kn)^K} = \frac{K!}{K^K}$$

Ej.: si $K = 10$, entonces $P = 10!/10^{10} = 0.00036$

También puede pasar que queden clusters vacíos

Esto pasa si es que no se le asignan puntos al cluster en el paso de asignación.



Algunas soluciones a estos problemas

Ejecutar K-means varias veces variando la semilla aleatoria y quedarse con el modelo de menor SSE.

Reemplazar centroides de clusters vacíos escogiendo el punto más lejano a todos los centroides como nuevo centroide u otro punto aleatorio con mayor SSE.

K-means: ¿Cómo elegir k?

- Hasta ahora, hemos asumido que k es un hiperparámetro: algo que fijamos al inicio del algoritmo.
- ¿Cómo elegimos el k óptimo?
- En aprendizaje supervisado, podíamos optimizar los hiperparámetros usando cross-validation y fijándonos en alguna métrica, pero acá no podemos
- La forma de escoger es mucho más subjetiva

K-means: ¿Cómo elegir k?

Técnica visual: **Método del codo:**

1. Calculamos el SSE para varios números de clusters*.
2. Graficamos cómo varía el SSE.
3. Elegimos el punto de inflexión, cuando añadir un nuevo cluster no provee un gran cambio en el SSE (cuando aumentar a más clusters da una mejora muy pequeña)
 - La inercia siempre disminuye al aumentar K -> no podemos simplemente elegir el K con menor inercia. Un clustering con $K=n$ (donde n es el número total de observaciones) tendrá inercia 0, y eso no sirve.

***Sum of Squared Error (SSE): scikit-learn este dato se llama inertia_**


```
sse = []  
  
clusters = list(range(1, 16))  
for k in clusters:  
    kmeans = KMeans(n_clusters=k).fit(X)  
    sse.append(kmeans.inertia_)  
  
plt.plot(clusters, sse, marker="o")  
plt.title("Metodo del codo de 1 a 15 clusters")  
plt.grid(True)  
plt.show()
```



Ojo que este método es una heurística y no siempre el codo es claramente visible.


¿Cómo afectan los outliers a K-Means?

Eliminar outliers: outliers producen centroides no representativos con alto SSE





¿Qué pasa si los datos no están normalizados?

Normalizar datos: que todos los atributos aporten lo mismo al cálculo de distancias





Otras limitantes a considerar





K-means tiene limitaciones cuando los clusters tienen diferentes densidades.

Otras limitantes a considerar




O tamaños diferentes.

Otras limitantes a considerar



O formas no esféricas


Técnica de post-procesamiento para estos casos



Usar un K más alto y luego mezclar los clusters durante una fase de post-procesamiento.

Bisecting K-means


Extensión de K-means que se basa en dividir el conjunto siempre en 2 clusters, escoger uno de ellos y continuar dividiendo en 2, iterando hasta llegar a K clusters.



Bisecting K-means

Cada división se obtiene ejecutando K-means ($k=2$)


El siguiente cluster a dividir se puede escoger considerando su tamaño, su SSE o una estrategia híbrida.



Bisecting K-means

Menos problemas de inicialización que K-means ya que realiza varios intentos de bisección y toma la que minimiza el SSE.

Si se registra la secuencia de clusters bisectados podemos producir un clustering jerárquico.



Dataset de
atributos
numéricos




**Clustering
Jerárquico
Aglomerativo**




Clusters anidados
organizados en un
árbol jerárquico.

Clustering Jerárquico

- Produce un conjunto de clusters anidados organizados en un árbol jerárquico.
- Principal fortaleza: no supone un número de clusters a priori
- Visualizaciones:
 - Dendograma: árbol que muestra las relaciones cluster-subcluster y el orden en que los clusters fueron mezclados o divididos
 - Diagrama de clusters anidados: sólo para puntos 2-dimensionales.



(a) Dendrogram.



(b) Nested cluster diagram.


Tipos de Clustering Jerárquico

En esta clase nos enfocaremos en cluster aglomerativo.

Aglomerativo	Divisivo
Empieza con cada punto como un cluster individual. En cada paso mezcla el par de clusters más cercanos hasta que queda un solo cluster o k clusters.	Empieza con un cluster que contiene todos los puntos. En cada paso divide un cluster en dos hasta que todo cluster contenga un solo punto (o haya k clusters)

¿Cómo funciona el algoritmo aglomerativo?

1. Calcular matriz de distancias
2. Sea cada punto un cluster
3. Iterar hasta que quede un cluster
 - a. Mezclar par de clusters más cercanos
 - b. Actualizar matriz de distancias



	<i>p1</i>	<i>p2</i>	<i>p3</i>	<i>p4</i>	<i>p5</i>	...
<i>p1</i>						
<i>p2</i>						
<i>p3</i>						
<i>p4</i>						
<i>p5</i>						

Matriz de distancias










 



p1 *p2* *p3* *p4* *p5* *p6* *p17* *p18*



	C1	C2	C3	C4	C5
C1					
C2					
C3					
C4					
C5					


Matriz de distancias






	C2 U			
	C1	C5	C3	C4
C1		?		
C2 U C5	?	?	?	?
C3		?		
C4		?		

Matriz de distancias



¿Cómo calcular cuáles son los clusters más cercanos?



Existen varias métricas de distancia entre clusters

MIN (single link)

MAX (complete link)

Promedio del grupo

Método de Ward




Método MIN (single link)

Considero los dos puntos más cercanos entre sí (cada uno de un cluster distinto)

Fortaleza: Puede manejar formas no elípticas.

Limitante: Sensible al ruido y outliers




Método MAX (complete link)

Considero los dos puntos más lejanos entre sí (cada uno de un cluster distinto)

Fortaleza: Menos susceptible al ruido y outliers.

Limitante: Tiende a quebrar clusters grandes y es sesgado a clusters esféricos.




Método Promedio del grupo

Distancia promedio de todos los pares de puntos (cada par tiene un punto por cluster)

Fortaleza: Menos susceptible al ruido y outliers.

Limitante: sesgado a clusters esféricos.




Método Ward

Se basa en el incremento de SSE cuando se mezclan dos clusters.




Fortaleza: Menos susceptible al ruido y outliers.

Limitante: sesgado a clusters esféricos.




$$SSE = \sum_{i=1}^K \sum_{\mathbf{x} \in C_i} dist(\mathbf{c}_i, \mathbf{x})^2$$

Distintos clusters dependiendo del método utilizado



Método de Ward




Problemas y limitaciones

- No hay una función objetivo que sea directamente minimizada.
- Sensibles a ruido y outliers.
- Dificultad para manejar clusters de distinto tamaño.
- Pueden romper clusters grandes.
- No escala muy bien.



Distancia entre clusters



Fuente: https://scikit-learn.org/stable/auto_examples/cluster/plot_linkage_comparison.html

Dataset de
atributos
numéricos

Eps: Radio
especificado

MinPts:
Número min
de puntos en
una región




DBSCAN

Algoritmo de
clustering
basado en
densidad



Conjunto de
clusters densos y
puntos que no
quedaron en
ningún cluster
(outliers)

¿Qué es la densidad?



La densidad de un punto es el número de puntos que tiene dentro de un radio dado.

- Idea: encontrar regiones de alta densidad de puntos separadas por regiones de baja densidad.
- Las regiones densas corresponden a los clusters.

Tipos de puntos

Considerando los parámetros del modelo **Eps** (radio especificado) y **MinPts** (número mínimo de puntos en una región), *existen tres tipos de puntos*:


- Punto “**core**”: punto con más de *MinPts* puntos a distancia *Eps*
- Punto “**border**”: punto con menos de *MinPts* puntos en el radio *Eps*, pero está en la vecindad de un punto core.
- Punto “**noise**”: cualquier punto que no es core ni border.




¿Cómo funciona?


1. Etiqueta todos los puntos en **core**, **border** o **noise**
2. Elimina los puntos **noise**
3. Asigna un arco entre los puntos **core** que se encuentran a una distancia menor o igual a Eps
4. Asigna cada grupo de puntos **core** conectados a un cluster separado
5. Asigna los puntos **border** a uno de los clusters de los puntos **core** asociados

MinPts = 4
Eps = 1






Puntos originales




*Tipos de punto: core,
border y noise*

Eps = 10, MinPts = 4




Puntos originales



Clusters

DBSCAN: Determinando Eps (método de la rodilla)


- Para todos los puntos, calcular la distancia a su k-ésimo vecino más cercano (con k fijo, generalmente el valor de minPts)
- Ordenar los valores de k-dist de manera creciente
- Graficar k-dist vs la cantidad de puntos
- Identificar el punto de inflexión en el gráfico y seleccionar dicho valor como Eps



Heurística para minPts: podemos basarnos en la cantidad de dimensiones que tienen nuestros datos. $\text{minPts} \geq D + 1$

¿Cuáles serían las fortalezas de este algoritmo de clustering?


- Resistente a ruido.
- Pueden identificar cluster de diferentes formas y tamaños.



Problemas y limitaciones

- No funciona bien con densidades variables. Clusters de baja densidad se confunden con ruido.
- No funciona bien con datos de alta dimensionalidad.





- Varios otros métodos de clustering: Ver más en <https://scikit-learn.org/stable/modules/clustering.html>
- Aprendizaje no supervisado puede ser usado para detección de outliers / anomalías: https://scikit-learn.org/stable/modules/outlier_detection.html

Comentarios

- Clustering nos permite encontrar agrupaciones naturales en los datos de forma automática
- Existen varios paradigmas distintos de clusterización
- **Es mucho más subjetivo y difícil de medir que aprendizaje supervisado**
- Próxima clase: ¿cómo validar que nuestro clustering es bueno?