



CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Clustering III

(Validación de Clusters y análisis descriptivo)

Profesores: Cinthia Sánchez y Cristian Llull

¿Cómo saber si nuestros clusters son buenos?


- No hay una respuesta absoluta.
- **Depende de la aplicación.**
- ¿Entonces, para qué evaluar?
 - Clustering es muchas veces parte de un proceso exploratorio.
 - Evaluar parece innecesario en estos casos (pero no!).
 - Cada algoritmo parece necesitar su propio tipo de evaluación.
 - k-means: SSE, pero no funciona para DBSCAN.

Evaluamos para:


- Evitar encontrar patrones en el ruido.
- Para comparar algoritmos de clustering diferentes.
- Para comparar conjuntos de clusters diferentes.
- Para comprar dos clusters.
- Es esencial! Porque siempre podemos encontrar clusters (hasta en datos aleatorios).

CLUSTERS EN DATOS ALEATORIOS


**PUNTOS
ALEATORIOS**




K-MEANS



DBSCAN



**COMPLETE
LINK**



Aspectos de la validación

1. Determinar la **tendencia de agrupamiento** (clustering tendency), i.e.: si existe una estructura no-aleatoria en los datos.
2. Encontrar el número correcto de clusters.
3. Evaluar qué tan bien los resultados se ajustan a los datos (sin consultar datos externos).
4. Comparar resultados con resultados externos, i.e.: clases asignadas manualmente (supervisado o eval externa).
5. Comparar dos conjuntos de clusters para saber cuál es mejor.

Medidas de validez



Internal Index

No-Supervisado

Evalúa la calidad del agrupamiento utilizando únicamente la información intrínseca de los datos.

- SSE (Error cuadrático)
- Cohesión
- Separación
- Correlación



External Index

Supervisado

Compara los resultados del clustering con una estructura externa conocida (ground truth).

- Pureza
- Entropía



Relative Index

Relativo

Compara diferentes esquemas de clustering entre sí para determinar cuál es el más adecuado.

Puede reutilizar medidas internas o externas.

Validez usando correlación (internal)

Matriz de Incidencia

Matriz $n \times n$ idealizada basada en la pertenencia a clusters:

- Una fila y columna por cada punto.
- **1**: Si los puntos coinciden en el mismo cluster.
- **0**: Si los puntos están en distintos clusters.

Matriz de Proximidad

Matriz $n \times n$ calculada a partir de los datos reales:


- Utiliza la **distancia** o **similitud** entre pares de puntos.
- Representa la estructura física real de los datos antes del clustering.

Cálculo de Correlación


Se compara la correlación entre ambas matrices (simétricas, $n(n-1)/2$ comparaciones). Una correlación fuerte indica que la estructura del cluster coincide con la proximidad natural de los datos (Point-biserial Index).

▲ **Limitación:** No es efectiva para algoritmos basados en **densidad** o **continuidad**.

Correlación usando k-means (internal)



Corr = -0.9235



Corr = -0.5810

i Nota: El valor es negativo porque se utiliza **distancia** en lugar de similitud.



Medidas internas: SSE

⚠ **Nota:** Clusters con formas complejas pueden no separarse bien con SSE.



Sum of Squared Errors (SSE)

- Índice interno fundamental para evaluar la cohesión de los clusters.
- Permite comparar 2 clusters individuales o 2 soluciones de clustering completas.
- Herramienta clave para estimar el número óptimo de clusters (método del codo).

$$SSE = \sum_{k=1}^K \sum_{\forall x_i \in C_k} \|x_i - \mu_k\|^2$$



Curva SSE para un dataset más complicado



SSE of clusters found using K-means

Enfoque visual

- Ordenar la matriz de similitud con respecto a etiquetas de clusters e inspeccionar visualmente


Ejemplo

Clustering jerárquico aglomerativo de subreddits de dieta y fitness mediante similitud de texto en las publicaciones.

Basado en el modelo de embeddings de oraciones [All MPNet Base V2](#) y la [Distancia de Incepción de Fréchet](#).

Clustermap:

<https://seaborn.pydata.org/generate-d/seaborn.clustermap.html>



Distancias comunes

Es común utilizar distancias métricas, como la distancia de Minkowski

- $r=2$, distancia Euclideana

$$p_{ij} = \left(\sum_{k=1}^d |x_{ik} - x_{jk}|^r \right)^{1/r}$$


- otras: Manhattan, y distancia no métrica, Jaccard, por ej.

- similitud coseno



$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}},$$

Visualizando la matriz de similitud (clusters reales)

Similitud



Visualizando clusters sobre datos aleatorios





K-means

Matrices de similitud/proximidad

Distancia


Clusterización con KMeans




Mientras más cerca estén los puntos en la diagonal (color más homogéneo) los modelos tienden a ser mejores

Matrices de similitud/proximidad


Clusterización con DBSCAN




Matriz de similitud




Comparando matrices de similitud



Modelo 1




Modelo 2




Modelo 3

¿Cuál es mejor?


Comparando matrices de similitud



Modelo 1





Modelo 2





Modelo 3

Medidas internas: SSE

- Clusters en figuras más complicadas no están bien separados
- Índice interno:
$$SSE = \sum_{j=1}^k \sum_{x \in C_j} ||x - \bar{c}_j||^2$$
- Permite comparar 2 clusters, o 2 soluciones de clustering
- Permite estimar el número de clusters





SSE of clusters found using K-means

Curva SSE para un dataset más complicado

Metodología para validar clusters

- Necesidad de contar con una metodología para interpretar cualquier medida (¿qué es bueno? ¿qué no?)
- Usamos la estadística para crear una metodología

Metodología para validar clusters


- Mientras más **atípico** es un resultado, más probable que sea reflejo de estructuras válidas
- Podemos comparar índices que resultan de datos aleatorios, con los de nuestros datos
- Valores poco probables indican resultados válidos

Metodología para validar clusters

- Al comparar resultados de dos clustering (dos cluster sets), no es muy necesario usar una metodología
- Pero en este caso la pregunta es si la diferencia es **significativa** (estadísticamente - repetible y en magnitud)


Metodología: Ejemplo SSE

- Comparar $SSE = 0.005$ contra 3 clusters de datos aleatorios
- Histograma muestra distribución SSE para 500 sets de datos aleatorios (100 puntos), en el mismo rango



Otro ejemplo: Correlación

- Correlación entre matrices de incidencia y proximidad para 2 sets de datos



Corr = -0.9235

Corr = -0.5810

Medidas internas:

Cohesión y separación

- **Cohesión de clusters:** mide qué tan cercanos son los objetos en un cluster (ej: SSE)
- **Separación de clusters:** mide qué tan diferente o bien separado es un cluster de otros


EJ. (SSE) Cohesión y Separación

- Cohesión se mide como **within cluster sum of squares (SSE)**

$$WSS = \sum_i \sum_{x \in C_i} (x - m_i)^2$$

- Separación se mide como **between cluster sum of squares (BSS)**

$$BSS = \sum_i |C_i| (m - m_i)^2$$



K=1 cluster:

$$WSS = (1 - 3)^2 + (2 - 3)^2 + (4 - 3)^2 + (5 - 3)^2 = 10$$

$$BSS = 4 \times (3 - 3)^2 = 0$$

$$Total = 10 + 0 = 10$$

K=2 clusters:

$$WSS = (1 - 1.5)^2 + (2 - 1.5)^2 + (4 - 4.5)^2 + (5 - 4.5)^2 = 1$$


$$BSS = 2 \times (3 - 1.5)^2 + 2 \times (4.5 - 3)^2 = 9$$

$$Total = 1 + 9 = 10$$


Medidas internas:

Cohesión y separación

- Enfoque basado en grafos de proximidad
- Cohesión: suma de los pesos de todos los arcos en un cluster
- Separación: suma de los pesos entre nodos del cluster y de otros clusters



cohesion



separation

Medidas internas:

Coeficiente de Silhouette

Combina ideas de **cohesión y separación**, pero para puntos individuales, como también para clusters y clusterings (estos últimos son promedios)

Este coeficiente calcula para cada punto:

- 1) Su distancia promedio al resto de los puntos en su misma clase (a)
- 2) Su distancia promedio a todos los puntos del cluster más cercano (b)

$$\frac{(b-a)}{\max(a,b)}$$

- Esta métrica está en un rango entre -1 y 1:
 - 1 significa que algo está bien asignado
 - -1 significa que algo está mal asignado porque hay otro cluster más similar
 - 0 significa que hay solapamiento de clusters.

Pureza y Entropía

- Pureza: Nivel en que un cluster contiene elementos de una sólo clase (se usa la clase predominante)
- Entropía: Cantidad de clases diferentes que contiene un cluster

-

Validación con Expertos

- Se pueden evaluar los clusters para ver si producen el resultado esperado y comparar con otras soluciones
- Se puede generar una clasificación de validación

Comentario final

- La etapa de validación es la parte más difícil y frustrante del análisis de clusters
- Sin embargo es necesario
- Idealmente se deben combinar medidas externas e internas

Comentario final

- La etapa de validación es la parte más difícil y frustrante del análisis de clusters
- Sin embargo es necesario
- Idealmente se deben combinar medidas externas e internas

Si quiere profundizar los conceptos:

<https://www.kaggle.com/code/jhskaggle/clustering-evaluation>

Implementación



<https://colab.research.google.com/drive/1B76wixcQt5S15Rib-5ne9wyT6BY1Lh7?usp=sharing>

Más allá de las métricas: Análisis descriptivo

Las métricas responden

- ¿Los grupos están bien separados?
- ¿Cuántos clusters conviene usar?
- Silhouette, inercia

El análisis descriptivo responde

- ¿Qué tienen en común sus objetos?
- ¿En qué se diferencia del resto?
- ¿Qué nombre le daríamos?

Un cluster sin interpretación es solo una etiqueta numérica.

El objetivo es entender y nombrar cada grupo.

Cómo describir cada cluster

1 Perfil del cluster

Media o mediana de cada variable por cluster.
Usen mediana si hay valores extremos.

2 Comparación con el total

Comparen cada cluster con el promedio global.
Las variables que más se alejan son las que lo definen.

3 Variables categóricas

Proporción de cada categoría dentro del cluster frente a la proporción en toda la base.

4 Ejemplos representativos

Ver los casos más cercanos al centroide.
Seleccionar ejemplos ayuda a entender el grupo.

Visualizaciones útiles: boxplots por cluster, heatmap de perfiles y barras de proporciones.

De perfil a nombre

Ejemplo ilustrativo: clientes de una tienda online

Cluster	Rasgos distintivos	Nombre
C0	Compra semanal, gasto bajo, usa la app	Habituales digitales
C1	Pocas compras al año, gasto alto en fechas especiales	Compradores de temporada
C2	Antes activos, sin compras en 6 meses	Clientes en riesgo

Al realizar clustering en sus proyectos

Hacer este análisis, describiendo al menos:

- Tamaño de cada cluster.
- 2 o 3 características que lo distinguen.
- Uno o más ejemplos representativos por cluster.
- Un nombre corto y breve descripción de cada cluster.
- Si un cluster no tiene un perfil claro, prueben otro número de clusters (k) o revisen las variables usadas, comparando con las métricas. **Es posible que no exista un patrón de agrupación!**

Ojo: El nombre debe salir de los datos, no de lo que esperaban encontrar.