



dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Sesgos y Causalidades

Profesores: Cinthia Sánchez y Cristian Llull


Actualmente se genera una cantidad sin precedentes de información día a día.

Es relativamente fácil obtener acceso.



Los descubrimientos que podemos hacer a partir de la gran cantidad de datos que existe hoy pueden ser fabulosos





**Como individuos, no somos solo
quienes se benefician de los
análisis generados por estos
datos....**

nosotros somos los datos



Los datos se ocupan para tomar decisiones sobre nosotros.

Algunas de ellas con importantes consecuencias.

Valores

Para evaluar la ética de un algoritmo se trabaja sobre valores y principios que nos guían en la toma de decisiones.

- Valores y principios universales (dentro de lo posible):
 - Definidos por grupos diversos
 - Involucrando diferentes actores
 - Aprobados ampliamente

Por ejemplo, los valores que propone UNESCO.

Valores

Valores propuestos por UNESCO:

- Respeto, protección y promoción de los **derechos humanos** y libertades fundamentales, así como la dignidad humana.
- Prosperidad del medio ambiente y los ecosistemas.
- Garantizar la diversidad y la inclusión.
- Vivir en sociedades pacíficas, justas e interconectadas.

Contenido de la clase

Reconocer sesgos

Qué es el sesgo, de dónde viene, tipos y ejemplos


Correlación vs causalidad

Por qué un modelo preciso puede aprender lo incorrecto

Análisis de caso

Trabajo en grupos y presentación


Reconocer Sesgos



Caso: Herramientas policiales predictivas


Modelos basados en la localidad para predecir cuándo y dónde podría ocurrir un crimen.

Modelos basados en la persona para predecir participación futura en un crimen.



Los sesgos y discriminación en el mundo físico se amplifican en modelos predictivos

<https://www.technologyreview.com/2020/07/17/1005396/predictive-policing-algorithms-racist-dismantled-machine-learning-bias-criminal-justice/>



Caso: embeddings

Modelos de lenguaje son entrenados con millones de documentos en la web.

Nos permiten transformar palabras en vectores numéricos de dimensión fija.



Nos permiten comparar palabras y detectar similitudes semánticas.

También nos permiten realizar analogías entre palabras.




Fig. 7. Word analogies as parallelograms.



Tokyo → Japan

Paris →

man → computer
programmer

woman →


[Bolukbasi et al. \(2016\). Man is to Computer
Programmer as Woman is to Homemaker?
NeurIPS.](#)



Caso: LLMs

Lejos de corregir el problema, hoy lo seguimos teniendo.


Estudio sobre sesgo en grandes modelos de lenguaje evaluó cómo plataformas líderes como Gemini, GPT y DeepSeek mantienen sesgos.



Caso: LLMs


Manifiestan inclinaciones políticas, ideológicas, de género y de alianza a pesar de estar alineadas para ser neutrales.

<https://arxiv.org/html/2511.08225v2>



¿Qué significa “sesgo”?

Sesgo cognitivo: atajos mentales, como el sesgo de confirmación o de disponibilidad.



Sesgo social: normas culturales y estereotipos de una sociedad.



En esta clase: un sesgo es un cambio en la decisión causado por una variable que no es causal.

Sesgo (Bias)

- Desviación sistemática de un valor real, ya sea positiva o negativa.
- Preocupación ética: “Inclinación sistemática en la toma de decisiones que resulta en resultados injustos” [CDEI]
- **La preocupación se acentúa cuando los resultados negativos afectan de manera desproporcionada a ciertos grupos.**

Sesgo (Bias)

En casos de trato injusto relacionado con características protegidas, como género o etnia, el sesgo **puede constituir discriminación ilegal** según las leyes pertinentes.

Ej. en Chile, la Ley 20.609 (Ley Zamudio) establece medidas contra la discriminación arbitraria.

Sesgo (Bias)

Puede surgir en diferentes etapas:




En cada etapa una decisión humana puede introducir o amplificar un sesgo. Por eso no basta con revisar el modelo al final.

Algoritmos entrenados en datos históricos tienden a replicar y amplificar sesgos presentes en esos datos.

Sesgo (Bias)


Tipos de sesgos durante la selección y preprocesamiento de datos:

- **Sesgo de muestra**
- Sesgo de selección
- Sesgo de confirmación
- Sesgo de disponibilidad



La muestra no representa a la población que se quiere modelar. Debería reflejar tanto como se pueda a la realidad que se pretende modelar.

Sesgo (Bias)




Ej. Detección de patrones de movilidad urbana en Santiago, usando solo encuestas en paraderos o datos de la tarjeta Bip!.

Sesgo (Bias)


Tipos de sesgos durante la selección y preprocesamiento de datos:

- Sesgo de muestra
- **Sesgo de selección**
- Sesgo de confirmación
- Sesgo de disponibilidad



Elegimos qué datos o variables incluir y dejamos fuera factores relevantes para los casos futuros.

Sesgo (Bias)




Ej. Caracterización de los patrones de sueño: ¿considera distintos factores que pueden afectar los patrones de sueño, como el cuidado de niños/as?

Sesgo (Bias)

Tipos de sesgos durante la selección y preprocesamiento de datos:

- Sesgo de muestra
- Sesgo de selección
- **Sesgo de confirmación**
- Sesgo de disponibilidad



Nos puede llevar a preferir inconscientemente los datos que confirman lo que ya creemos.

Sesgo (Bias)

Ej. Un equipo cree que los clientes abandonan un servicio por el precio. Al revisar los reclamos:

Reclamos sobre precio

**Se revisan y se etiquetan como
relevantes**

Reclamos sobre fallas técnicas

Se descartan como “ruido”

El análisis confirma la hipótesis inicial, aunque la causa real puede ser otra.

Sesgo (Bias)

Tipos de sesgos durante la selección y preprocesamiento de datos:

- Sesgo de muestra
- Sesgo de selección
- Sesgo de confirmación
- **Sesgo de disponibilidad**



Cuando utilizamos los datos que están más fácilmente disponibles.

Sesgo (Bias)



Ej. Estudio de opinión pública respecto al proceso constituyente en base a redes sociales (Instagram), considera solamente la opinión de personas que ocupan activamente esa red social, que siguen cuentas políticas y que además acostumbran a dejar comentarios.

Sesgo (Bias)

Efectos:

- Poca validez y confiabilidad de los resultados
- Bajo rendimiento y precisión de los modelos
- Pérdida de significado y valor de los resultados
- Implicaciones éticas y sociales

Correlación vs Causalidad



Correlaciones espurias

Optimizar una función de pérdida da el mejor rendimiento posible, pero el modelo aprende correlaciones: no distingue si son causales o espurias.






Figure 1: Explicación de las decisiones de un clasificador Husky/Lobo

Correlaciones espurias



(a) Husky classified as wolf



(b) Explanation

- El modelo clasifica este husky como lobo.
- La explicación muestra que mira la nieve, no el animal.


El modelo aprendió “nieve”, no “lobo”.

Comete errores que perjudican a los huskies que viven en lugares nevados.

¿Qué es una correlación espuria?


Dos variables aparecen asociadas sin que una cause la otra, **por azar** o **por una tercera variable oculta** (variable de confusión).

En husky/lobo, “nieve” comparte información con “animal”. El modelo la usa porque es más fácil.



Distancia Neptuno-Tierra vs. cobertura de bosque amazónico

Correlaciones espurias o Variables de Confusión




Caso 1: correlación espuria

Un día soleado impacta tanto en accidentes por ahogamiento como en ventas de helados.

Con suficientes variables y muestras, el modelo debería funcionar.

¿Qué pasa si no tenemos la variable clima?
Parece que los helados se relacionan con los ahogamientos.



Caso 2: variable de confusión


Los factores de confusión son causas comunes.

Es imposible medir el impacto de la educación sobre el desempeño laboral si una tercera variable influye en ambas.

La solución es fijar una variable para estudiar las otras.

Ej: Información faltante en las observaciones

Veamos el ejemplo simple de un modelo que predice el género de una persona usando el largo del cabello (una variable booleana).



- Las predicciones serán correctas para los grupos mayoritarios.
- Para minimizar el error, se apoyará en la probabilidad a priori del largo del cabello respecto al género.
- El cabello está correlacionado con el género, pero no lo causa.

El error no es solo ruido

Tomando el ejemplo anterior: un modelo predice el género de una persona usando solo el largo del cabello.

- Se apoya en lo más frecuente en los datos (el prior).
- Acierta para los grupos mayoritarios.
- El modelo no se equivoca al azar: falla siempre con los mismos grupos (hombres con cabello largo, mujeres con cabello corto).

	Cabello largo	Cabello corto
Mujer	✓ acierta	✗ error
Hombre	✗ error	✓ acierta

Los errores se concentran en mujeres con cabello corto y hombres con cabello largo: un sesgo sistemático contra esos grupos.

Sesgo del pasado

- Los modelos aprenden patrones del pasado.
- Pero los usamos para predecir el futuro.

Ej. El modelo aprendió que las niñas tienen menos probabilidad de obtener empleos bien remunerados.



¿Queremos un modelo que use las desigualdades del pasado para decidir el futuro?

Sesgo (Bias)



Ej. Sistema COMPAS para predecir la probabilidad de volver a delinquir: los falsos positivos se daban desproporcionadamente en afrodescendientes (ProPublica, 2016).

Sesgo (Bias)



Ej. Algoritmos de contratación y reclutamiento: tendencia a descartar a los solicitantes por su raza o sexo.

¿Cómo se ve un modelo injusto?

Predicciones sesgadas hacia un grupo


Ej. más riesgo de reincidencia predicho para personas afrodescendientes.

Desempeño distinto entre grupos

Ej. reconocimiento facial que falla más con ciertos grupos; reconocimiento de voz que solo entiende algunos acentos del español.

Sesgo (Bias)

Ejemplo: Detección facial



<https://www.media.mit.edu/projects/gender-shades/overview/>

Joy Buolamwini, MIT thesis. 2017

Sesgo (Bias)

Ejemplo: Detección facial

Gender Classifier	Darker Male	Darker Female	Lighter Male	Lighter Female	Largest Gap
 Microsoft	94.0% 	79.2% 	100% 	98.3% 	20.8% 
 FACE++	99.3% 	65.5% 	99.2% 	94.0% 	33.8% 
 IBM	88.0% 	65.3% 	99.7% 	92.9% 	34.4% 



En resumen

1

Correlaciones espurias

Correlaciones espurias: mejoran la precisión, pero no son robustas ante cambios reales en los datos.

2

Consideraciones éticas

- Excluir variables sensibles puede reducir sesgos, pero disminuir la precisión.
- Incluirlas puede perpetuar desigualdades y dañar a grupos vulnerables (como los huskies con nieve o las mujeres con cabello corto).

3

Detección de sesgos

- Existen múltiples técnicas para detectar sesgos.
- También se pueden usar enfoques de ML causal para obtener modelos más confiables.

¿Cómo detectar sesgos?

Separa las variables en causales (VC), no causales (VNC) y atributos sensibles (AS):

1

Evaluar por grupo

Separa el conjunto de prueba según AS y compara métricas.

2

Comparar modelos

Entrena solo con VC y con VC + VNC. Compara el rendimiento.

3

Revisar pesos

Mira cuánto pesa cada VNC en las decisiones del modelo.

4

Quitar una a la vez

Fija o quita cada VNC y mide cómo cambia el modelo.

Quitar el atributo sensible no basta: otras variables pueden actuar como proxy.

Análisis de Caso



Análisis de Caso

1

Dividirse en grupos

Un caso por grupo.

2

Analizar el caso

Responder las siguientes preguntas e identificar riesgos éticos.

3

Presentar

Cada grupo presenta sus riesgos y su reflexión.

Preguntas guía

- 1 ¿Qué mide realmente la variable objetivo? ¿Es lo que queremos predecir?
- 2 ¿Qué tipos de sesgo pueden aparecer en los datos?
- 3 ¿Hay variables que actúan como proxy de atributos sensibles, o correlaciones espurias?
- 4 ¿Quién se ve afectado si el modelo se equivoca?
- 5 ¿Qué harían para detectar y mitigar estos riesgos?

Caso 1: Industria de la Salud

Se desarrolla un algoritmo de inteligencia artificial para apoyar la toma de decisiones. El algoritmo genera un índice de riesgo para cada nuevo paciente que predice si requiere cuidados adicionales y prioridad de atención médica.

Para el entrenamiento del modelo se usan registros históricos de pacientes. Las características consideradas por el modelo incluyen datos personales de cada paciente y un listado de enfermedades subyacentes. Como variable objetivo se utiliza una variable construida a partir del número total de atenciones médicas y el gasto total en atenciones médicas de cada paciente.

Caso 2: Banca y Finanzas

Un equipo de desarrollo en el sector financiero está creando un modelo de inteligencia artificial para evaluar la solvencia crediticia de los solicitantes de préstamos. El modelo se propone automatizar el proceso de toma de decisiones, asignando puntajes de riesgo crediticio a los clientes potenciales.

El modelo utiliza datos financieros como ingresos, historial crediticio, deudas, etc. y datos demográficos como edad, género, ubicación, estado civil, etc.

La variable objetivo a considerar es la solvencia crediticia, es decir un puntaje que refleja la probabilidad de que un solicitante cumpla con sus obligaciones crediticias.

Caso 3: Proceso de Contratación

Un equipo de desarrollo está diseñando un modelo de inteligencia artificial para automatizar el proceso de contratación en una empresa. El objetivo es agilizar la selección de candidatos y mejorar la eficiencia en la toma de decisiones.

El modelo utiliza datos históricos de procesos de contratación realizados en últimos años en la empresa para su entrenamiento. Estos incluyen características extraídas del currículum como experiencia laboral, habilidades, educación, etc. No se utilizan datos demográficos como género, edad o ubicación para evitar introducir sesgos.

Como variable objetivo se considera si la persona fue contratada.

Caso 4: Educación

Un colegio decide utilizar modelos generativos de lenguaje y de imágenes como ChatGPT y DALL·E para generar cuentos sobre diferentes profesiones. El objetivo es proporcionar a los estudiantes historias creativas que inspiren interés en diversas carreras y fomenten la imaginación.

Para la creación de los cuentos los profesores y profesoras utilizan prompts como “Crea un cuento corto y realista para niños sobre un día en un hospital que muestre el trabajo que realizan las personas que trabajan en ese lugar”.

Caso 5: Detección de actitud criminal

Una municipalidad decide implementar tecnología avanzada basada en cámaras en autobuses y calles para detectar actitudes criminales sospechosas. El objetivo es mejorar la seguridad pública mediante la identificación temprana de comportamientos potencialmente delictivos.

Para su desarrollo utilizan cámaras de vigilancia avanzadas instaladas en autobuses y áreas urbanas.

El sistema utiliza algoritmos de reconocimiento de imágenes y comportamiento que analizan vestimentas, gestos, movimientos y comportamientos para identificar actitudes criminales sospechosas.