

dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Interpretabilidad, equidad y ética

Profesores: Cinthia Sánchez y Cristian Llull

Clase pasada

Cuatro estrategias para detectar sesgo.

1. Evaluar por grupo
2. Comparar modelos (¿Caja negra o modelo interpretable?)
3. Revisar pesos (coeficientes)
4. Quitar una variable a la vez (Importancia por permutación)

Recordatorio: quitar el atributo sensible no basta. Otras variables pueden servir como proxies.

Contenido y objetivos de la clase

¿Por qué importa?	Interpretabilidad	Equidad	Cerrar el loop	Actividad



Explicar qué aprendió un modelo y saber si la explicación es confiable



Medir la equidad por grupo y justificar un criterio



Ubicar en qué etapa del sistema nace un problema

Caso: predicción de riesgo en neumonía

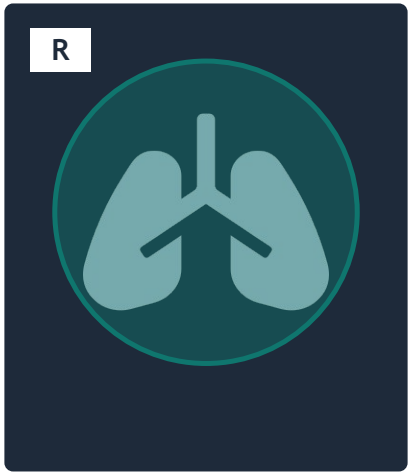


El patrón era real. La conclusión, peligrosa.

Se detectó solo porque el modelo se podía leer.

Caruana, R. et al. (2015). Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission. KDD.

Caso: COVID-19 en radiografías de tórax



Lo esperado: los pulmones



Lo que miró: marcas de la fuente

Positivos de una fuente, negativos de otra: aprendió la fuente

Parecía preciso, pero fallaba en hospitales nuevos

Ni la validación externa bastó para descubrirlo

Es el husky y la nieve de la clase pasada, ahora en medicina.

DeGrave, A. J., Janizek, J. D. y Lee, S.-I. (2021). AI for radiographic COVID-19 detection selects shortcuts over signal. Nature Machine Intelligence.

Caso: subsidios en Países Bajos

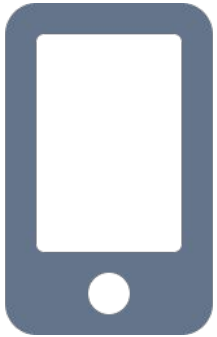


Tener nacionalidad no neerlandesa subía el puntaje de riesgo.

Miles de familias acusadas por error. El algoritmo fue una pieza de un escándalo más amplio.

Amnistía Internacional (2021). Xenophobic machines: Discrimination through unregulated use of algorithms in the Dutch childcare benefits scandal.
DutchNews (2021). Dutch government collapses in fall out from child benefit scandal.

Caso: derecho a explicación



10 €

al mes · contrato telefónico

RECHAZADO

Puntaje de solvencia calculado automáticamente

Tribunal de Justicia de la UE · 27 feb. 2025

Entregar el algoritmo no basta.

La explicación debe permitir entender y reclamar.

Sugiere explicar cómo un cambio en los datos habría cambiado el resultado -> **explicación contrafactual**

Tribunal de Justicia de la UE (2025). Sentencia C-203/22, Dun & Bradstreet Austria. Comunicado de prensa 22/25.

Decisiones automatizadas en Chile

1 dic. 2026

Entra en vigencia la Ley 21.719: derechos frente a decisiones automatizadas (art. 8° bis)

117

algoritmos públicos identificados en el Estado chileno (2024)

80%

de los sistemas sin información en el sitio web de su institución (estudio 2021)

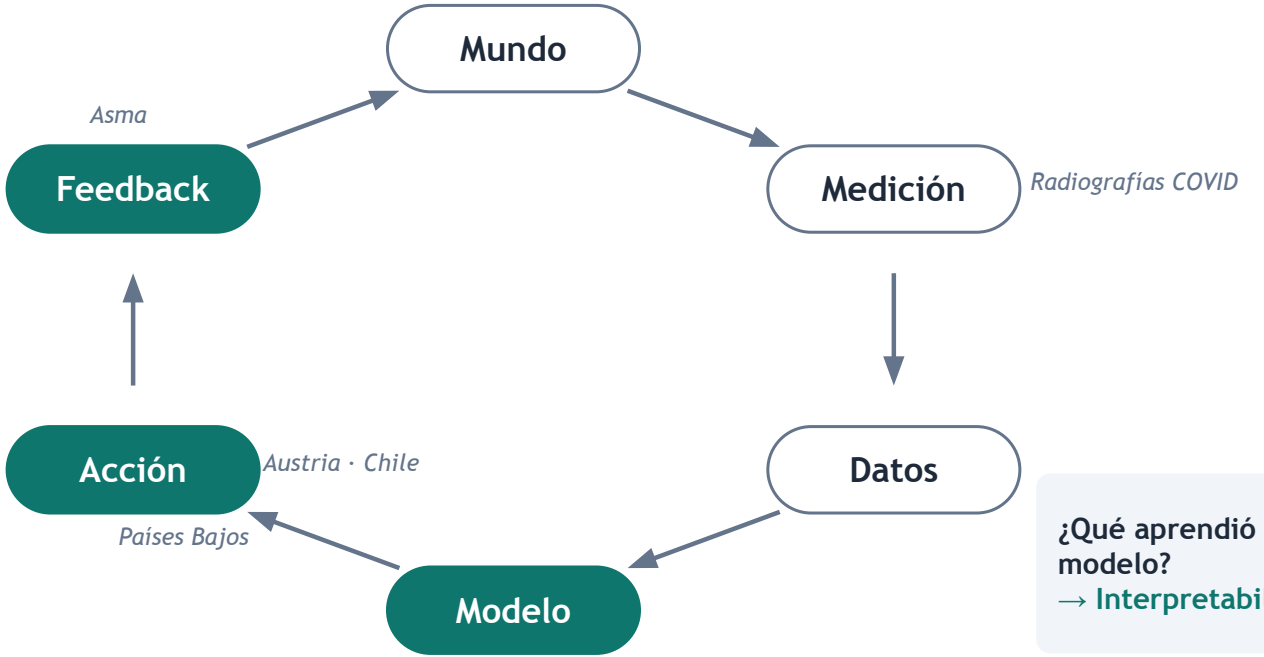
Se suma a la Ley Zamudio que vimos la clase pasada.

Ley N° 21.719 (2024). Regula la protección y el tratamiento de los datos personales y crea la Agencia de Protección de Datos Personales. BCN.
Red RAICA (s. f.). Informe nacional de Chile (cita el catastro GobLab UAI de 2024).
GobLab UAI y Consejo para la Transparencia (2021). Transparencia algorítmica en el sector público.

Ciclo de un sistema de machine learning

Las decisiones del modelo cambian el mundo que después volvemos a medir.

¿Qué le hace el sistema al mundo?
→ Ética



¿A quién dañan sus errores?
→ Equidad

¿Qué aprendió el modelo?
→ Interpretabilidad

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.

¿Qué es la interpretabilidad?

Explicar o presentar un modelo en términos que una persona entienda.

Quien desarrolla	Quien regula	Persona afectada
¿Está fallando?	*¿Cumple la ley?*	*¿Por qué?*

Interpretable
se entiende por sí mismo

Explicable
necesita una explicación externa

Doshi-Velez, F. y Kim, B. (2017). Towards A Rigorous Science of Interpretable Machine Learning. arXiv.
Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence.

Incompletitud vs. incertidumbre

¿Cuándo hace falta explicar?

Incertidumbre

Lo que no sabemos, pero podemos medir

Ej.: una posición estimada con error medible → intervalo de confianza (EDA II)

≠

Incompletitud

Lo que quedó fuera de la formulación del problema

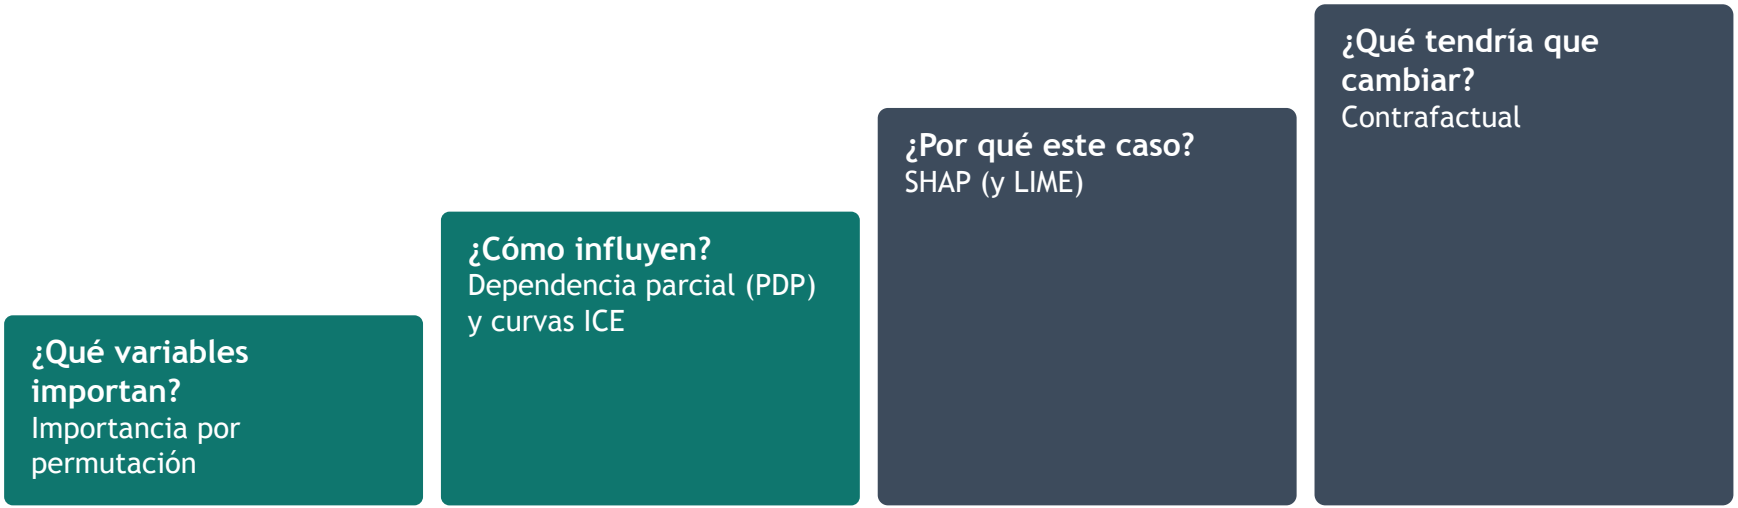
Ej.: el objetivo no incluía la política de atención del hospital (asma)

Doshi-Velez, F. y Kim, B. (2017). Towards A Rigorous Science of Interpretable Machine Learning. arXiv.

Métodos de interpretabilidad

GLOBAL **LOCAL**

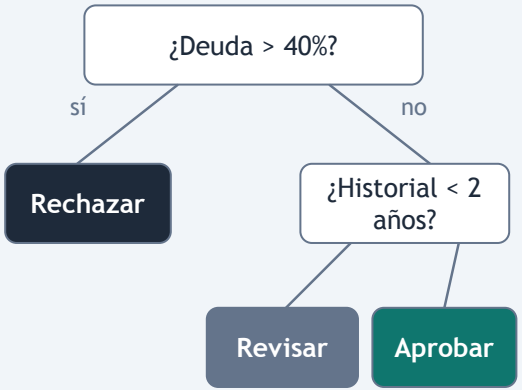
Global: cómo funciona el modelo en general · Local: por qué decidió este caso



¿Le creo a la explicación? Evaluar la explicación

Modelos interpretables por diseño

Árbol corto

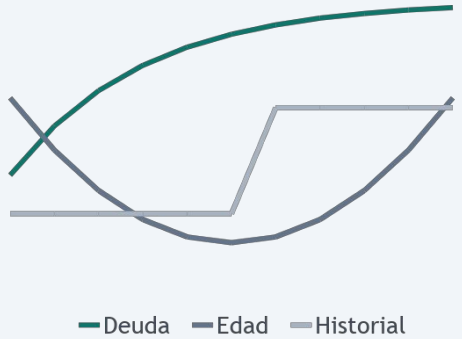


Regresión logística

Variable	β
Deuda / ingreso	0,70
Historial (años)	−0,40
Ingreso	−0,25
Edad	0,05

Un peso por variable

GAM



Una curva por variable, se suman

Si son pequeños, se leen. Un árbol de profundidad 15 es difícil de interpretar.

Caruana, R. et al. (2015). Intelligible Models for HealthCare: Predicting Pneumonia Risk and Hospital 30-day Readmission. KDD.

Coeficientes en regresión logística

$$\beta = 0{,}7 \rightarrow e^{0{,}7} \approx 2{,}0$$

Por cada unidad más de deuda, las chances de impago se duplican, manteniendo lo demás constante.

Chances (odds)

$$p / (1 - p)$$

Si p = 0,8, las chances son 4 a 1. e^β dice por cuánto se multiplican.

Escala

Comparen solo variables estandarizadas

Colinealidad

Variables correlacionadas se reparten el peso

Causalidad

Describe al modelo, no al mundo

Caja negra vs. modelo interpretable

Caja negra + explicación

Boosting, redes neuronales

La explicación es una aproximación



Modelo interpretable

Árbol corto, logística, GAM

La estructura es la explicación

Rudin (2019): en decisiones de alto impacto, preferir modelos interpretables. En datos tabulares, la pérdida de desempeño suele ser pequeña.

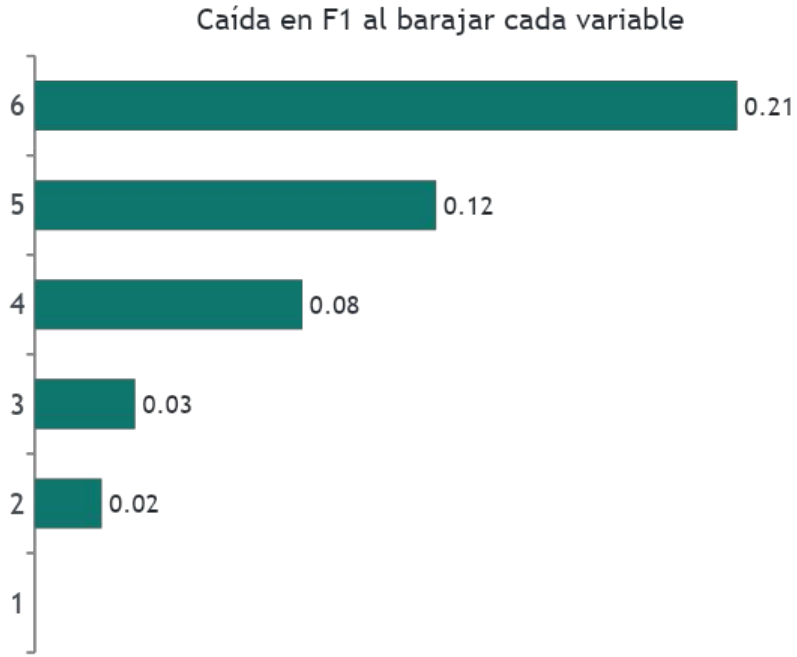
Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence.

Importancia por permutación

1. Mide la métrica en test (ej. F1)
2. Baraja una columna: rompe su relación con y
3. Mide de nuevo: la importancia es la caída
4. Repite K veces y promedia

$$I_j = s - \frac{1}{K} \sum_{k=1}^{K} s_{k,j}$$

sklearn.inspection.permutation_importance



Ejemplo: promedio de 10 permutaciones

Breiman, L. (2001). Random Forests. Machine Learning, 45, 5–32.

Importancia de atributos: limitaciones



Importancia por impureza

feature_importances_ se calcula en train y favorece variables con muchos valores distintos

Ej.: El ID del cliente sale muy importante



Variables correlacionadas

Al barajar una, el modelo usa la otra: ambas parecen poco importantes

Ej.: Ingreso y patrimonio



Casos imposibles

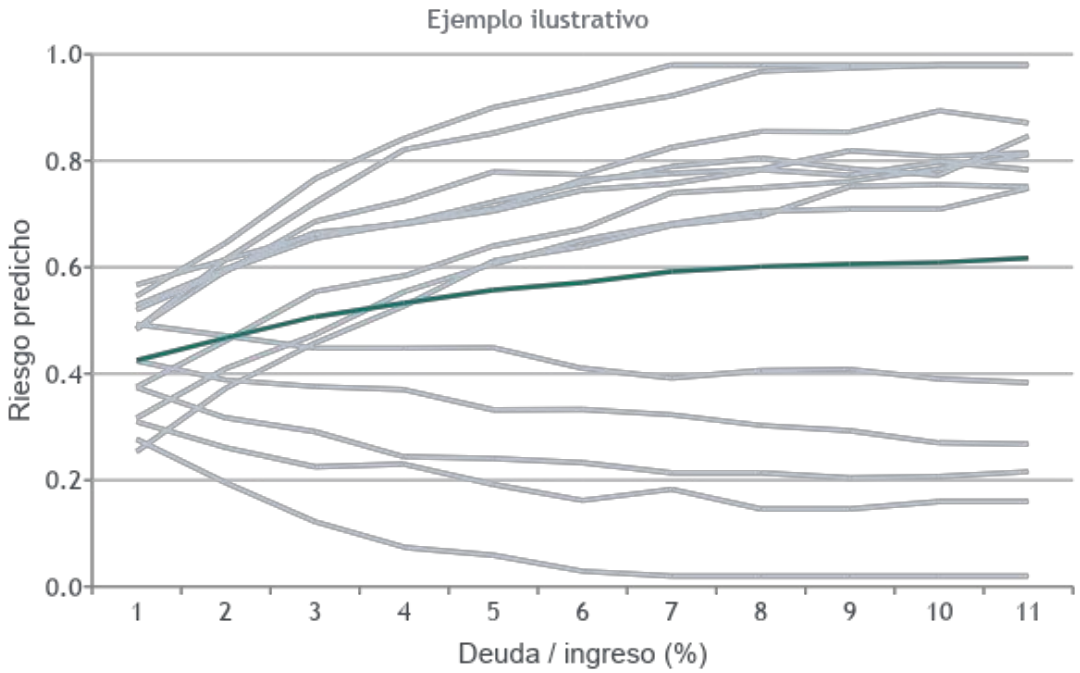
Barajar mezcla valores que no existen juntos: el modelo extrapola

Ej.: 20 años de edad y 40 de experiencia laboral

Strobl, C., Boulesteix, A.-L., Zeileis, A. y Hothorn, T. (2007). Bias in random forest variable importance measures. BMC Bioinformatics.
Hooker, G., Mentch, L. y Zhou, S. (2021). Unrestricted permutation forces extrapolation. Statistics and Computing (versión arXiv).

Dependencia parcial (PDP) y curvas ICE

Modelo



PDP (línea verde)
La predicción promedio al variar una variable

ICE (líneas grises)
Una curva por persona

Si unas suben y otras bajan
El promedio engaña (Simpson, EDA II)

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of Statistics.
Goldstein, A., Kapelner, A., Bleich, J. y Pitkin, E. (2015). Peeking Inside the Black Box: Visualizing Statistical Learning With Plots of Individual Conditional Expectation. JCGS.

Explicaciones locales: LIME y SHAP

LIME

Imita al modelo cerca de un caso con un modelo lineal simple.

Es el método del husky y la nieve de la clase pasada.

Inestable: dos ejecuciones pueden dar dos explicaciones distintas.

SHAP

$$f(x) = \mathbb{E}[f(X)] + \phi_1 + \phi_2 + \cdots + \phi_p$$

Reparte la predicción entre las variables, como un premio entre jugadores (valores de Shapley).

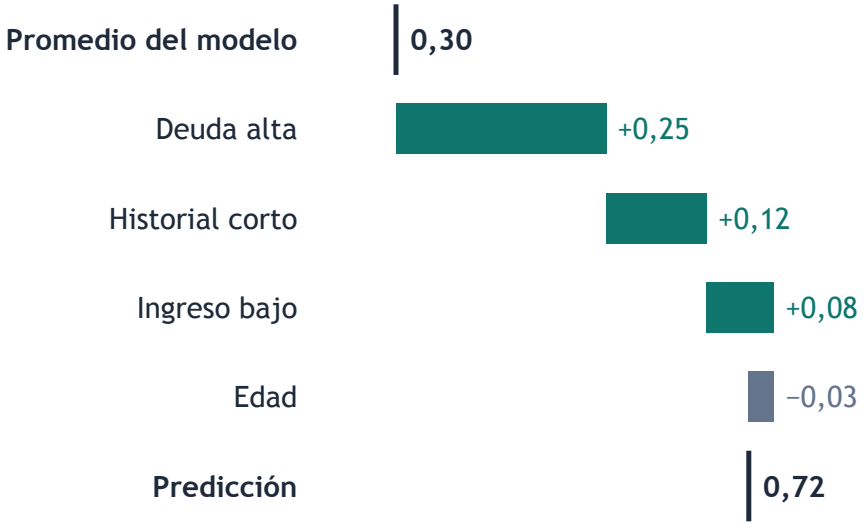
Promedio + aportes = predicción exacta.

Exacto cuesta 2^p subconjuntos (como en selección de atributos); para árboles hay una versión rápida.

Ribeiro, M. T., Singh, S. y Guestrin, C. (2016). "Why Should I Trust You?": Explaining the Predictions of Any Classifier. KDD.
Lundberg, S. M. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.

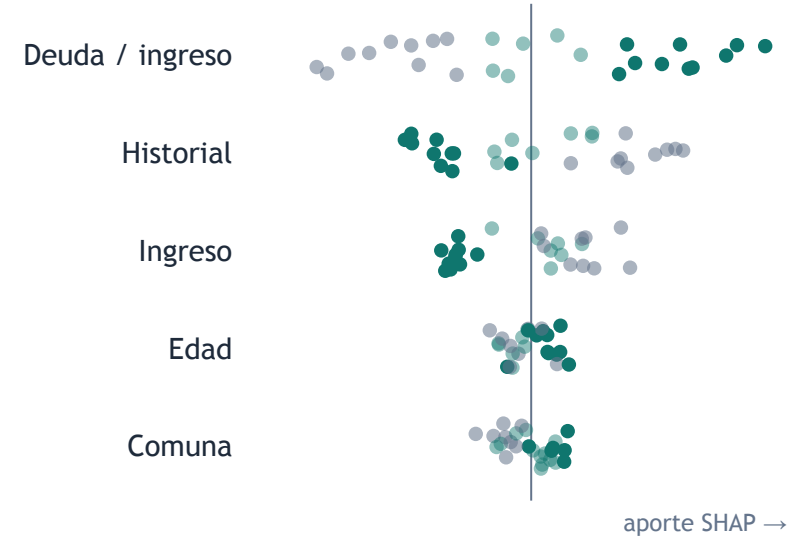
SHAP: lectura de gráficos

Waterfall: una persona



Verde: sube el riesgo (hacia el rechazo) · Gris: lo baja

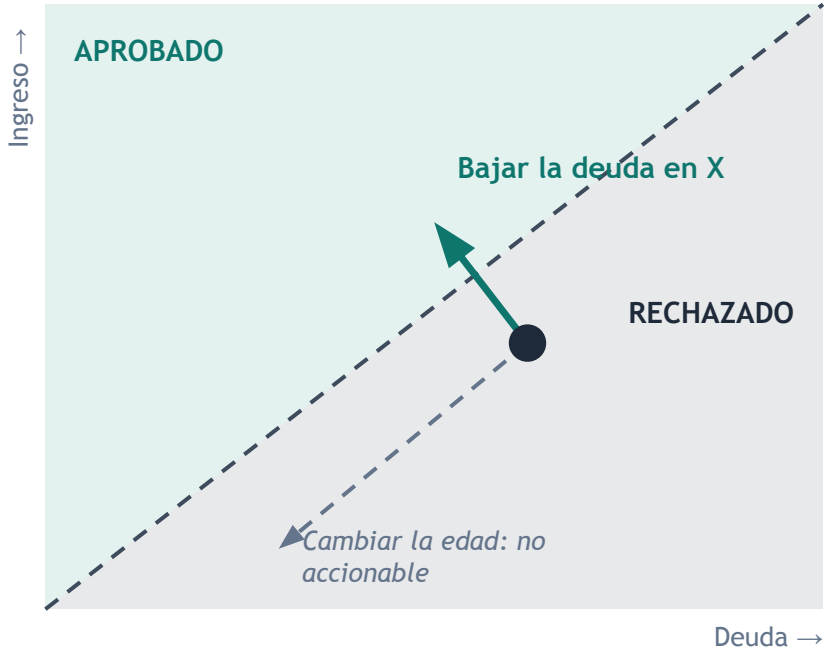
Beeswarm: todas las personas



Color = valor de la variable: **bajo (gris claro)** → **alto (verde)**

Lundberg, S. M. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.

Explicaciones contrafactuales



"Si tu deuda hubiera sido menor en X, te aprobaban."

- El cambio más pequeño que da vuelta la decisión
- Accionable: algo que la persona pueda cambiar
- No exige abrir el modelo (útil con secreto comercial)

Es lo que sugirió el tribunal europeo .

Wachter, S., Mittelstadt, B. y Russell, C. (2018). Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR. Harvard Journal of Law & Technology.
Ustun, B., Spangher, A. y Liu, Y. (2019). Actionable Recourse in Linear Classification. FAT*.

Sesgo, disparidad y discriminación

“Sesgo” en Modelos Lineales
el término b del hiperplano

“Sesgo” en Estadística
un estimador que en promedio no acierta

“Sesgo” en Clase pasada
un cambio en la decisión causado por una variable no causal

Disparidad
resultados distintos entre grupos

¿injustificada y dañina?

Una disparidad, por sí sola, no prueba discriminación

Discriminación
disparidad injustificada y dañina

Y **lo que pasó**
pagó / no pagó

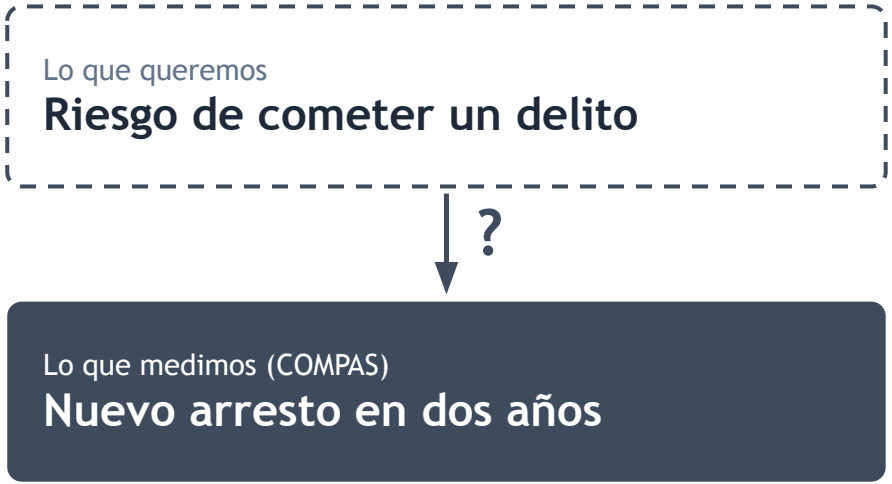
$\hat{Y}$ **la decisión del modelo**
aprobado / rechazado

A **el grupo (atributo sensible)**
por ejemplo, género

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.

Variable objetivo como constructo

Constructo: concepto que no se observa directamente



Los arrestos dependen de dónde patrulla la policía.

El modelo aprende la etiqueta, con sus sesgos.

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.
ProPublica (2016). ProPublica Responds to Company's Critique of Machine Bias Story.

Criterios de equidad de grupo

Independencia

paridad demográfica

La misma tasa de aprobación en todos los grupos

$$P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$$

Separación

igualdad de oportunidades si solo miramos Y = 1

Los mismos errores en todos los grupos

$$P(\hat{Y} = 1 \mid Y = y, A = a) = P(\hat{Y} = 1 \mid Y = y, A = b)$$

Suficiencia

calibración por grupo

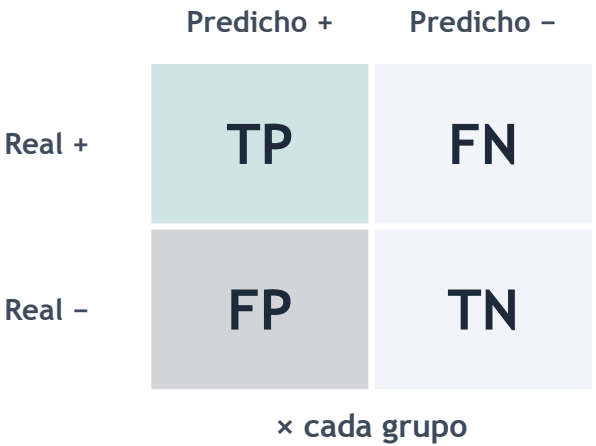
Un mismo puntaje significa lo mismo en todos los grupos

$$P(Y = 1 \mid \hat{Y} = 1, A = a) = P(Y = 1 \mid \hat{Y} = 1, A = b)$$

¿Por qué por grupo? Gender Shades (clase pasada) y la paradoja de Simpson (EDA II).

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.
Hardt, M., Price, E. y Srebro, N. (2016). Equality of Opportunity in Supervised Learning. NeurIPS.

Equidad en la matriz de confusión



Criterio	Tasa a comparar	Nombre en Clasificación I
Independencia	(TP + FP) / n	tasa de selección
Igualdad de oportunidades	TP / (TP + FN)	recall (TP rate)
Separación	TP rate y FP / (FP + TN)	recall y FP rate
Suficiencia	TP / (TP + FP)	precision

Grupos pequeños dan tasas ruidosas: reporten intervalos. ¿Confiarían igual con 20 pasajeros que con 216?

Fairlearn (s. f.). Assessment: MetricFrame. Documentación oficial.

Caso: COMPAS y criterios de equidad

ProPublica

45% vs. 23%

Entre quienes no reincidieron: marcados de alto riesgo (personas afroamericanas vs. blancas)

Mira el FP rate · separación

Northpointe

≈60% = ≈60%

Entre los marcados de alto riesgo: reincidieron, en ambos grupos

Mira la precision · suficiencia

Las dos cifras son correctas. El debate era qué criterio importa más.

Angwin, J., Larson, J., Mattu, S. y Kirchner, L. (2016). Machine Bias. ProPublica.
ProPublica (2016). ProPublica Responds to Company's Critique of Machine Bias Story.

Estrategias de mitigación

Antes: Cambiar los datos

Reponderar: dar a cada ejemplo un peso para que grupo y etiqueta queden independientes

Durante: Cambiar el entrenamiento

Optimizar el desempeño con un límite a la disparidad (Fairlearn)

Después: Cambiar la decisión

Umbrales distintos por grupo: un punto en la curva ROC de cada grupo

Ninguna es automática:

Quitar un proxy puede bajar el desempeño

Tratar distinto por grupo puede cuestionarse legalmente

Kamiran, F. y Calders, T. (2012). Data preprocessing techniques for classification without discrimination. Knowledge and Information Systems.
Agarwal, A. et al. (2018). A Reductions Approach to Fair Classification. ICML.
Hardt, M., Price, E. y Srebro, N. (2016). Equality of Opportunity in Supervised Learning. NeurIPS.

Selección del criterio de equidad

¿Quién paga cada tipo de error?

Tipo de decisión	Error más dañino	Criterio sugerido
Punitiva: detención, investigación de fraude	**Falso positivo**	**Igual FP rate**
Beneficio: beca, tratamiento médico	**Falso negativo**	**Igual recall**
Puntaje que interpreta un juez o analista	**Puntaje engañoso**	**Calibración por grupo**

Ciclos de retroalimentación

Feedback loops: las decisiones del modelo modifican los datos futuros

Ciclo desbocado: policía predictiva



Tráfico: todos toman la ruta “libre” y se congestiona

Buscador: lo primero recibe más clics, y esos clics entrenan

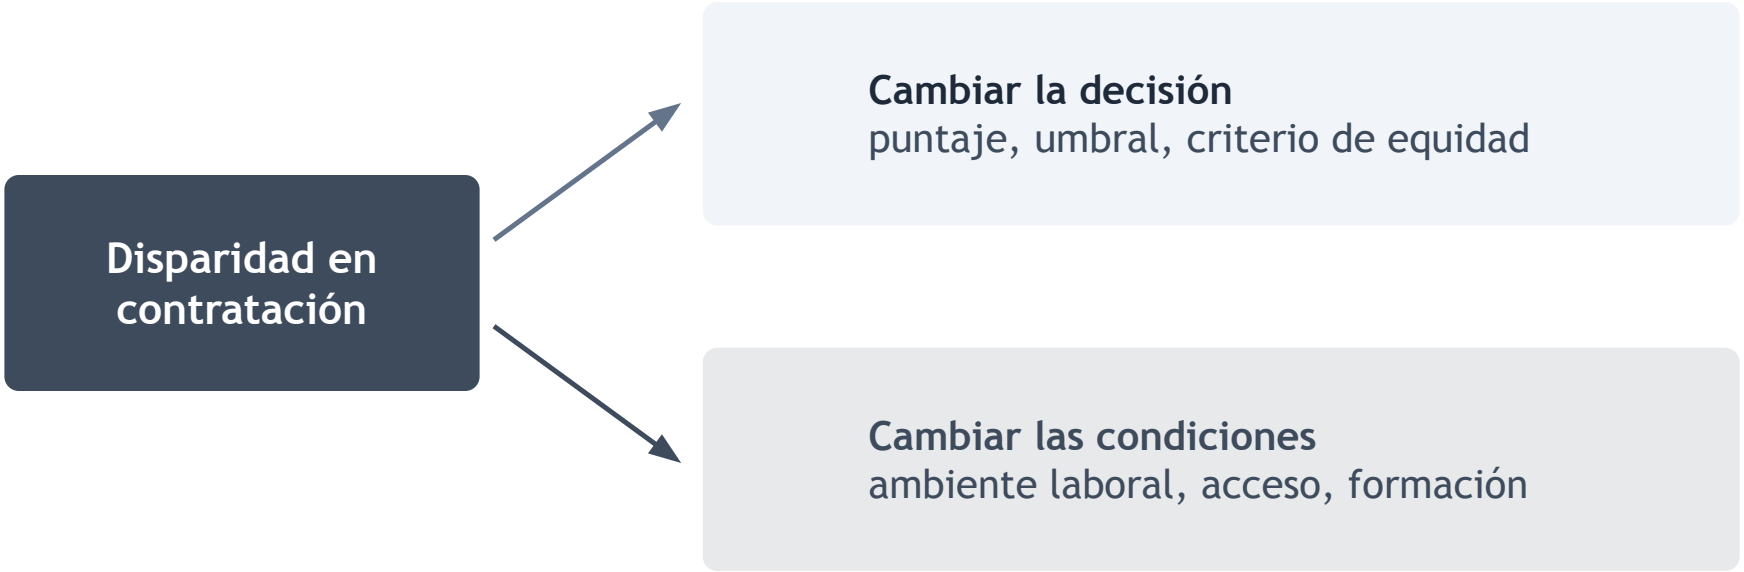
Asma: la atención del hospital produjo los datos

Países Bajos: Amnistía lo describió como un ciclo discriminatorio.

Evaluar en test no basta: hay que monitorear después de desplegar.

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.
Amnistía Internacional (2021). Xenophobic machines: Discrimination through unregulated use of algorithms in the Dutch childcare benefits scandal.

Predicción vs. intervención



Un modelo equitativo puede dejar intacto un ambiente hostil que explica parte de la disparidad.

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.

Daños de asignación y de representación

Daño de asignación

Se niega un recurso u oportunidad



Crédito · empleo · COMPAS

Daño de representación

Se refuerza un estereotipo



“hombre es a programador como mujer es a dueña de casa” (clase pasada)

Barocas, S., Hardt, M. y Narayanan, A. (2023). Fairness and Machine Learning: Limitations and Opportunities. MIT Press.

Documentación y marco regulatorio

Los valores UNESCO de la clase pasada -> documentos:



Model card

Ficha del modelo: desempeño por grupo y limitaciones



Datasheet

Ficha del dataset: origen, cómo se midió y quién falta



Evaluación de impacto

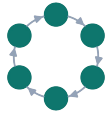
GobLab UAI: gratuita, abierta y en español

UE: alto riesgo (crédito, empleo, educación) desde el 2 dic. 2027

Chile: Ley 21.719 desde el 1 dic. 2026; proyecto de ley de IA en el Senado

Mitchell, M. et al. (2019). Model Cards for Model Reporting. FAT*.
Gebru, T. et al. (2021). Datasheets for Datasets. Communications of the ACM.
ChileCompra (2024). GobLab UAI presentó nueva herramienta para una IA responsable y ética.
Reglamento (UE) 2026/1744 (2026). Ómnibus Digital sobre IA, que modifica el Reglamento (UE) 2024/1689. Diario Oficial de la UE.
Senado de Chile (2026). Senadores conocen propuesta del Ejecutivo para ley marco de IA.

Buenas prácticas a lo largo del ciclo



Todo el ciclo

Un checklist que recorre el ciclo

Mundo

¿A quién afecta la decisión?

Medición

¿Qué mide realmente la etiqueta?

Datos

¿Quién falta? ¿Qué grupos son pequeños?

Modelo

Permutación y SHAP

Acción

Métricas por grupo y criterio elegido

Feedback

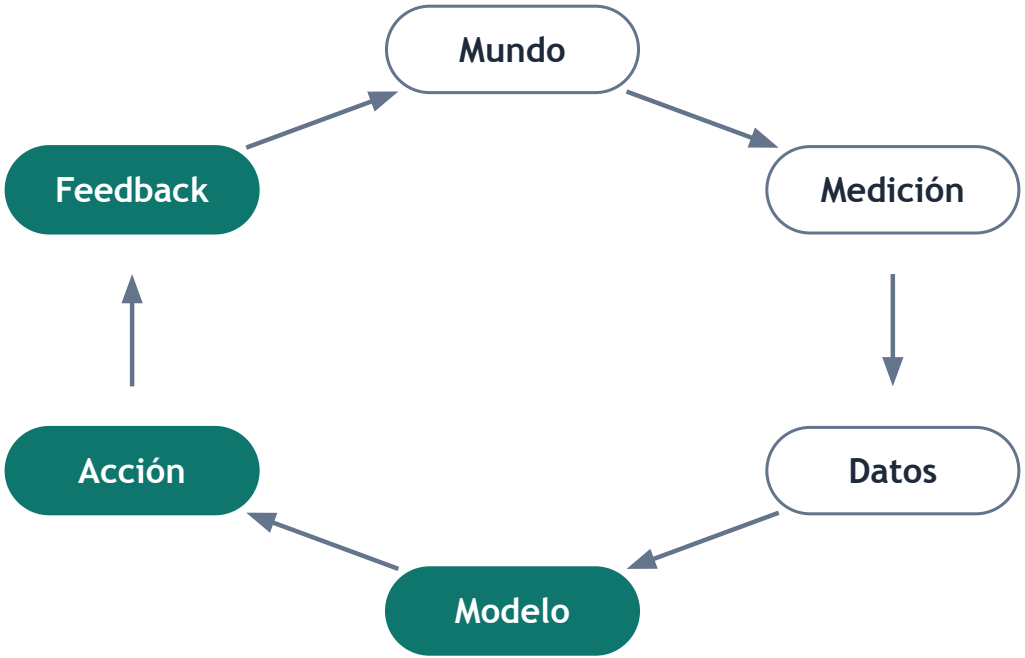
¿Qué datos producirá el despliegue?

Actividad grupal

10 minutos: elijan un método de explicabilidad (ej: LIME, SHAP, etc), profundicen y luego expliquenlo a la clase brevemente

En resumen

¿Qué le hace al mundo?
La acción cambia los datos: documenten y monitoreen



¿A quién dañan sus errores?
Midan por grupo: elegir un criterio es decidir quién paga

¿Qué aprendió el modelo?
Elijan el método por la pregunta y validen la explicación

Aplicación al proyecto (Hito 2)

Presentación del Hito 2

Permutación en test, no solo feature_importances_

Datos sobre personas: métricas por grupo con intervalos

Una frase: ¿qué mide realmente su variable objetivo?

Pregunta (escalera, lámina 12)	Herramienta en Python
¿Qué variables importan?	sklearn.inspection.permutation_importance
¿Cómo influyen?	sklearn.inspection.PartialDependenceDisplay
¿Por qué este caso?	shap: gráficos waterfall y beeswarm
¿Qué tendría que cambiar?	dice-ml, o búsqueda manual de cambios mínimos
¿Cómo le va a cada grupo?	fairlearn.metrics.MetricFrame