

dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

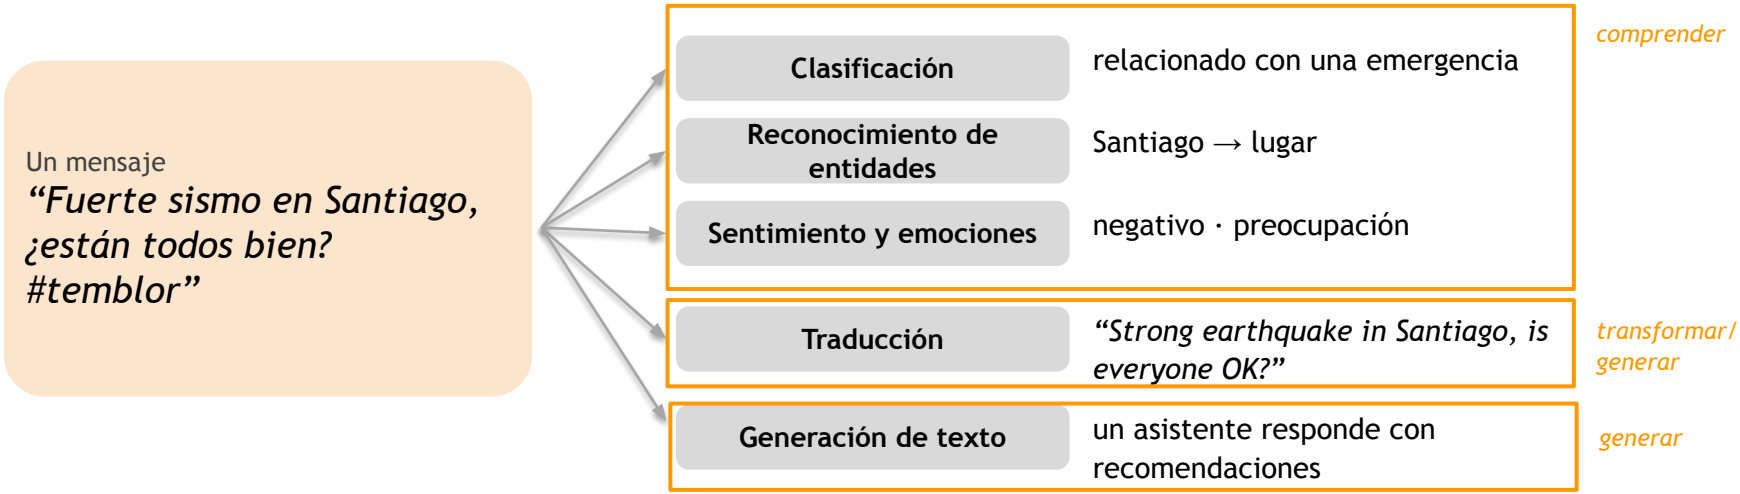
MINERÍA DE DATOS

Clase: Introducción a NLP (Procesamiento de lenguaje natural)

Profesores: Cinthia Sánchez y Cristian Llull

¿Qué es Procesamiento de Lenguaje Natural (NLP)?

Rama de la inteligencia artificial que desarrolla métodos para que los computadores procesen, comprendan y generen lenguaje humano, escrito u oral.



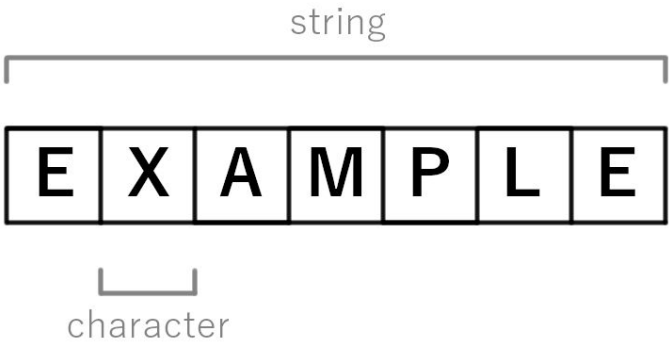
El texto es un dato no estructurado: para clasificarlo o agruparlo con lo visto en el curso, primero hay que **representarlo como vectores**.

Jurafsky, D. y Martin, J. H. (2026). Speech and Language Processing.

Texto

Datos tipo texto: Pueden verse como una cadena (string) o como datos multidimensionales, dependiendo de cómo se representen.

- Por ejemplo: en su forma pura, un documento de texto corresponde a una cadena en la que cada cadena es una secuencia de caracteres.



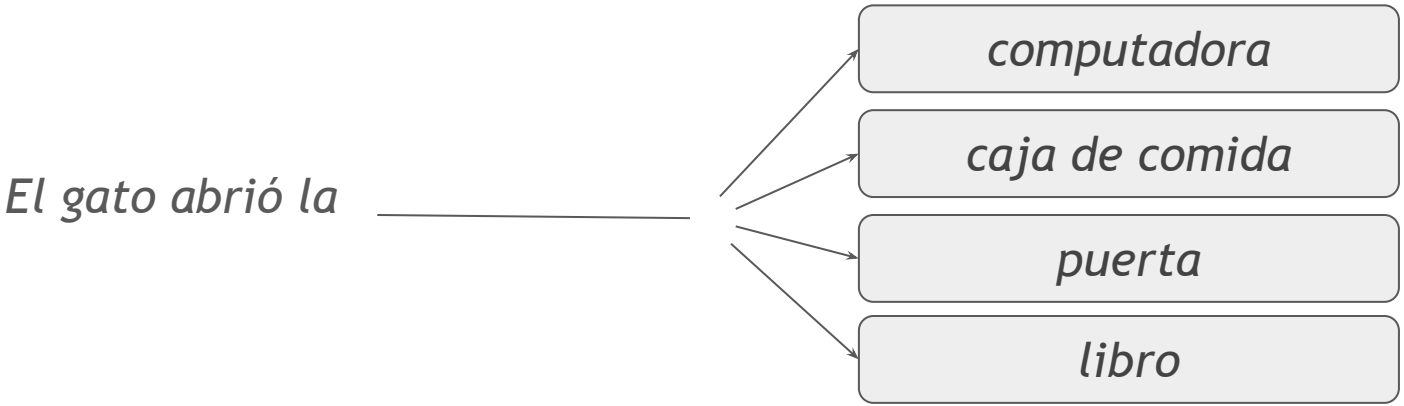
https://commons.wikimedia.org/wiki/File:String_example.png

Complejidades del lenguaje humano

- **Ambigüedad**:
  - Por ejemplo: “ayer comí pizza con amigos”, “ayer comí pizza con piña”, “ayer comí pizza con tenedor”. Las tres frases tienen la misma estructura, pero la palabra “con” modifica a distintas partes de la oración.
- **Dinamismo**: el lenguaje cambia y evoluciona con el tiempo.
- **Discreto**: las letras son la unidad básica del lenguaje escrito, pero no se puede inferir la relación entre palabras a partir de sus letras. Ej: “guitarra” y “bajo”.
- **Composicionalidad**: el significado de una frase va más allá de las palabras que la conforman.
- **Sparseness**: la cantidad de combinaciones que se pueden formar a partir de palabras. (símbolos discretos) es prácticamente infinita => aun con un conjunto gigantesco de datos, es probable que encontremos frases que no aparecen en dicho conjunto.

¿Qué es un modelo de lenguaje?

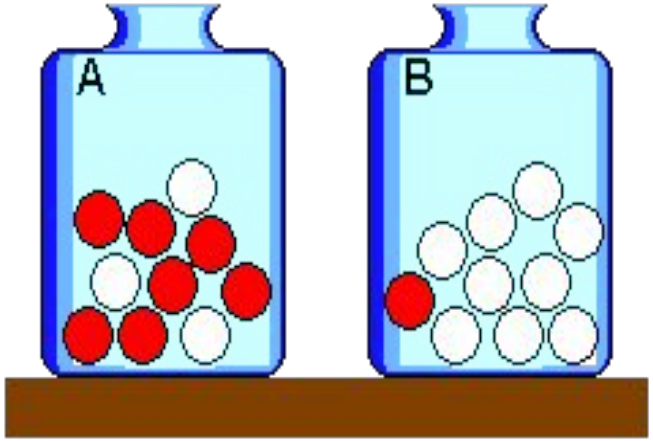
Un modelo que asigna una probabilidad a cualquier frase.



Idea: El modelo asigna mayor probabilidad a las frases fluidas (que tienen sentido, que son gramaticalmente correctas). Estima esta función de probabilidad a partir del texto (corpus).

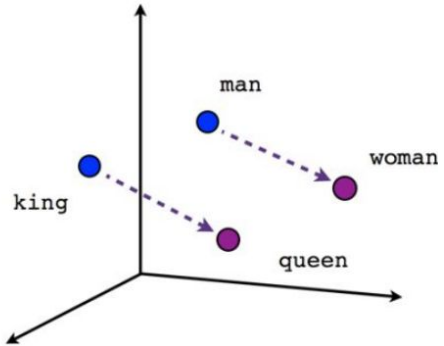
¿Qué es un modelo de lenguaje?

- Los modelos de lenguaje pueden generar oraciones, haciendo un muestreo secuencial sobre las probabilidades.
- Análogo a sacar bolitas de una urna, donde cada bolita tiene un tamaño proporcional a sus frecuencias relativas.
- También sirve para predecir la palabra más probable; es decir, predecir la siguiente palabra.



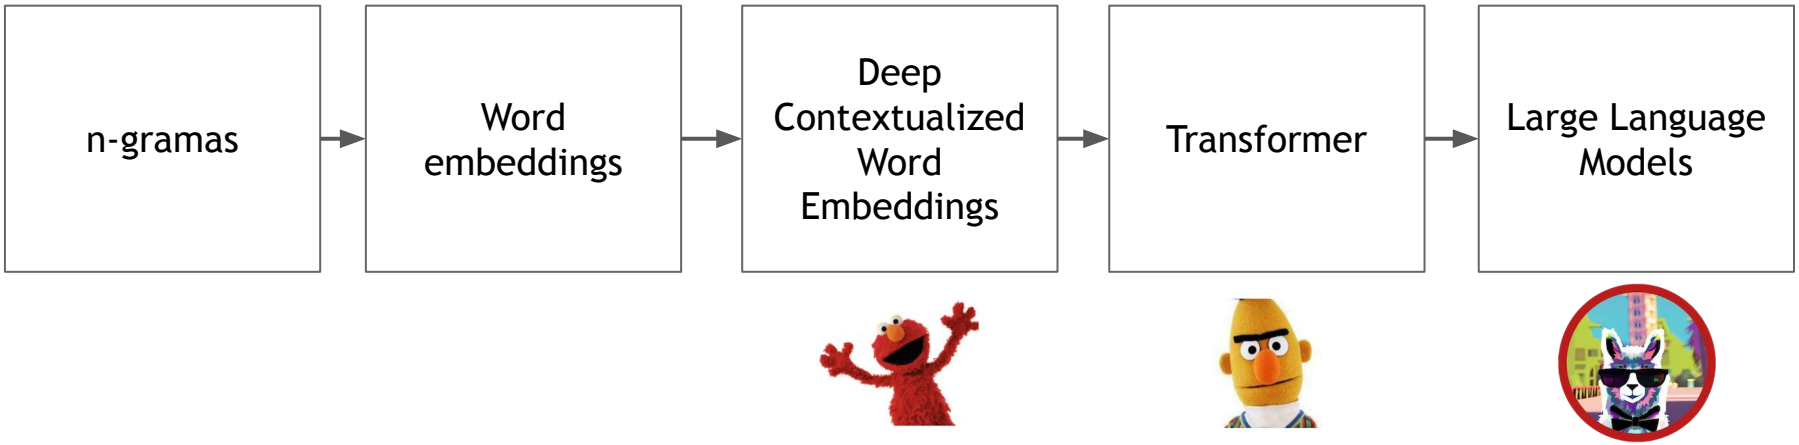
Representación vectorial

Modelo de espacio vectorial: Los documentos de texto suelen representarse en forma de espacio vectorial. Existen diferentes formas de crear estas representaciones.



Male-Female

Técnicas de Representación de Texto



N-gramas

Los documentos de texto suelen representarse en forma de espacio vectorial.

- **N-gramas:** secuencias continuas de palabras o símbolos o tokens en un documento. Pueden definirse como las secuencias vecinas de elementos en un documento. Ejemplo para la oración: *Fuerte sismo en Santiago*

n	Tipo	Ejemplo
1	Unigram	[“fuerte”, “sismo”, “en”, “santiago”]
2	Bigram	[“fuerte sismo”, “sismo en”, “en santiago”]
3	Trigram	[“fuerte sismo en”, “sismo en santiago”]
n	n-gram	

Frecuencia de n-gramas

Cuando son unigramas, es decir, basadas en las frecuencias de las palabras:

- Una **representación dispersa** es una forma de describir un documento en la que los atributos corresponden a las palabras extraídas del corpus y su valor viene dado por un valor de importancia, por ejemplo, su **frecuencia**.
- Se caracteriza por un gran número de atributos irrelevantes, por ejemplo, un gran número de atributos con valor cero.
- **Técnicas:** Bag-of-Words (BoW), Term Frequency Inverse Document Frequency (TF-IDF)

Bag-of-Words (bolsa de palabras)

- Enfoque popular en el que las frecuencias de las palabras son los valores de los atributos.
- Se basa en una matriz en la que una fila representa un documento con una columna para cada palabra del vocabulario.

mensaje	fuerte	sismo	en	santiago	temblor	talca	réplica	tras	y	fiesta
Fuerte sismo en Santiago	1	1	1	1	0	0	0	0	0	0
Fuerte temblor en Talca	1	0	1	0	1	1	0	0	0	0
Réplica tras réplica en Talca	0	0	1	0	0	1	2	1	0	0
Sismo y réplica en Santiago	0	1	1	1	0	0	1	0	1	0
Fiesta en Santiago	0	0	1	1	0	0	0	0	0	1

vector del documento

- El conjunto de vectores de todos los documentos representa un **modelo de espacio vectorial**.

Bag-of-Words (bolsa de palabras)

- Esta **representación dispersa** es muy redundante porque la mayoría de los atributos tienen un valor de cero, lo que indica que no hay ocurrencias.
- Esta representación ignora varios aspectos como el orden de las palabras, sus combinaciones y sus significados. Ignora la polisemia (dependiente del contexto). N-gramas con n > 1 conserva algo de orden y contexto local.

mensaje	fuerte	sismo	en	santiago	temblor	talca	réplica	tras	y	fiesta
Fuerte sismo en Santiago	1	1	1	1	0	0	0	0	0	0
Fuerte temblor en Talca	1	0	1	0	1	1	0	0	0	0
Réplica tras réplica en Talca	0	0	1	0	0	1	2	1	0	0
Sismo y réplica en Santiago	0	1	1	1	0	0	1	0	1	0
Fiesta en Santiago	0	0	1	1	0	0	0	0	0	1

Bag of words (BoW): TF-IDF

- Pondera la frecuencia según qué tan únicas son las palabras en cada documento.

- TF-IDF es una forma de calcular los pesos de un término (o palabra), que combina la frecuencia del término (TF) y la frecuencia inversa del documento (IDF).
- TF cuenta el número de ocurrencias de cada término **t** en un documento dado **d.** Se divide por la longitud del documento como una forma de normalización.
- IDF mide la importancia o rareza de cada término **t** en el corpus, donde **D** es el número total de documentos en el corpus y **Dt** representa el número de documentos que contienen el término **t.**

$$tf(t,d) = \frac{count(t,d)}{|d|}$$

$$idf(t,D) = \log_2\left(\frac{|D|}{|D_t|}\right)$$

$$tfidf(t,d,D) = tf(t,d) \cdot idf(t,D))$$

Modelos de Lenguaje Neuronales

Word embeddings: Los LMs neuronales (2000) se usan de forma masiva con el lanzamiento de Word2Vec en 2013.

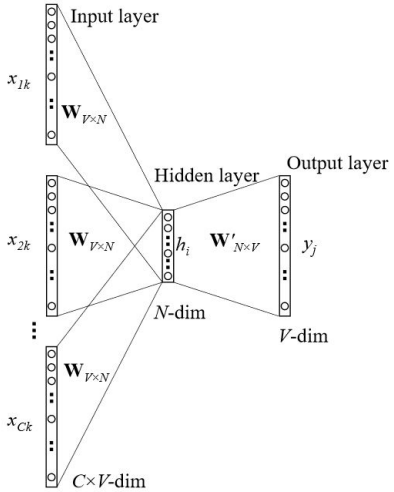


Figure 2: Continuous bag-of-word model

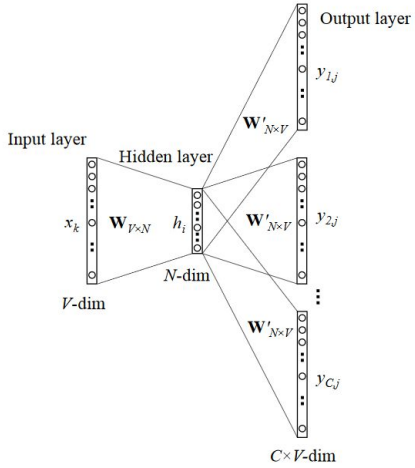


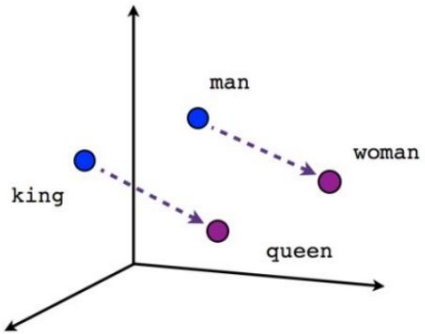
Figure 3: The skip-gram model

https://devopedia.org/word2vec

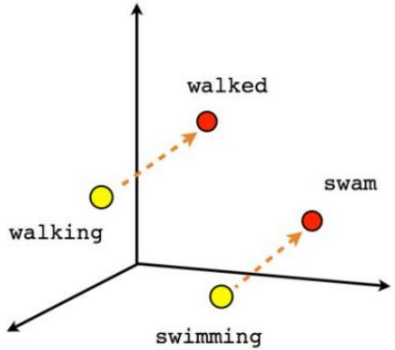
Felipe Bravo Márquez. Un recorrido por los Modelos de Lenguaje. Desde Shannon a GPT-4. Universidad de Chile. https://relela.com/seminars/

Modelos de Lenguaje Neuronales

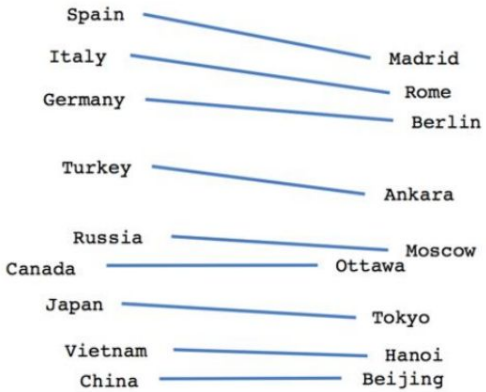
Word embeddings: Los LMs neuronales (2000) se usan de forma masiva con el lanzamiento de Word2Vec en 2013.



Male-Female



Verb tense



Country-Capital

Modelos de Lenguaje Neuronales

Word vectors en analogías:

Ejemplos considerando género

```
wordvectors.most_similar_cosmul(positive=['rey','mujer'],negative=['hombre'])
```

```
[('reina', 0.9141066670417786),
 ('isabel', 0.8743277192115784),
 ('princesa', 0.843113124370575),
 ('infanta', 0.8425983190536499),
 ('monarca', 0.8357319831848145),
 ('hija', 0.8211697340011597),
 ('consorte', 0.8179485201835632),
 ('iv', 0.813984215259552),
 ('esposa', 0.8115168213844299),
 ('ii', 0.8099035620689392)]
```

Ejemplos considerando conjugaciones

```
wordvectors.most_similar_cosmul(positive=['jugar','canta'],negative=['cantar'])
```

```
[('juega', 0.8944003582000732),
 ('jugando', 0.8376926183700562),
 ('jugará', 0.834348201751709),
 ('jugador', 0.8295056819915771),
 ('jugó', 0.8156978487968445),
 ('jugado', 0.8147079348564148),
 ('futbolista', 0.7927162647247314),
 ('juegue', 0.7921290397644043),
 ('fútbol', 0.7888965606689453),
 ('juegan', 0.7832154631614685)]
```

Jorge Pérez. spanish-word-embeddings. https://github.com/dccuchile/spanish-word-embeddings/blob/master/examples/Ejemplo_WordVectors.md

Modelos de Lenguaje Neuronales

Word vectors en analogías:

Ejemplos capitales y países

```
wordvectors.most_similar_cosmul(positive=['santiago','venezuela'],negative=['chile'])
```

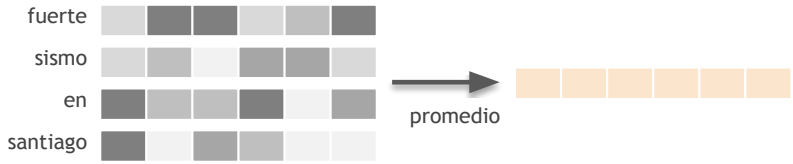
```
[('caracas', 0.8996074795722961),
 ('bolívar', 0.8295609354972839),
 ('mérida', 0.8287113308906555),
 ('maracaibo', 0.826995849609375),
 ('miranda', 0.8242772817611694),
 ('santa', 0.8197780847549438),
 ('trujillo', 0.8175155520439148),
 ('pérez', 0.8143640756607056),
 ('rafael', 0.8114412426948547),
 ('lara', 0.8102367520332336)]
```

Jorge Pérez. spanish-word-embeddings. https://github.com/dccuchile/spanish-word-embeddings/blob/master/examples/Ejemplo_WordVectors.md

¿Cómo representamos oraciones?

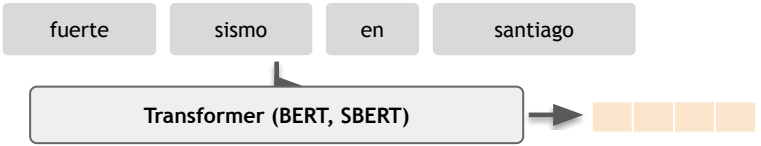
Ejemplo: *“Fuerte sismo en Santiago”*

Promedio de word embeddings



- Vector denso (p. ej., 300 dimensiones).
- Pierde el orden: “sismo antes del concierto” = “concierto antes del sismo”.

Embeddings de oración



- Cada palabra se representa según su contexto, y luego se resume en un vector.
- Sentence-BERT se entrena para que oraciones similares queden cerca.

Con un vector por oración podemos medir similitud (coseno), agrupar textos (clustering) y clasificarlos.

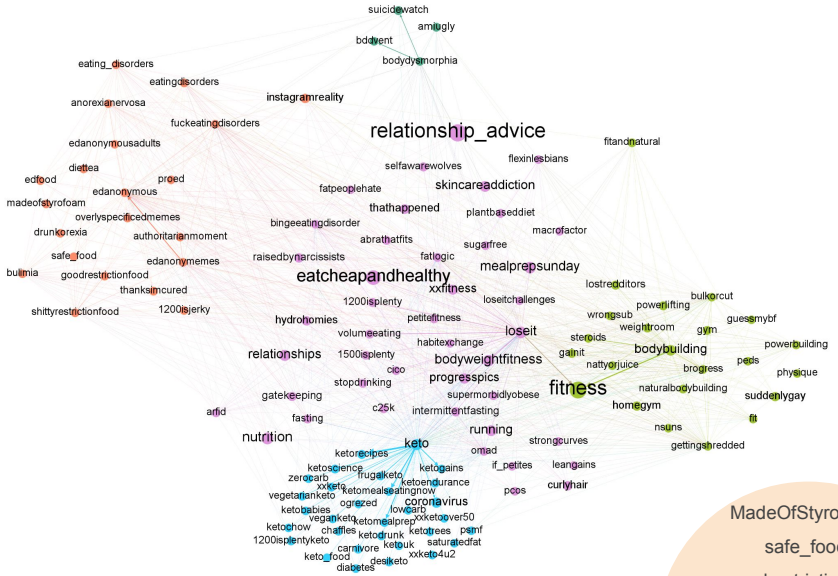
Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP.

Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings

Tolga Bolukbasi[1], **Kai-Wei Chang**[2], **James Zou**[2], **Venkatesh Saligrama**[1,2], **Adam Kalai**[2]
[1]Boston University, 8 Saint Mary's Street, Boston, MA
[2]Microsoft Research New England, 1 Memorial Drive, Cambridge, MA
tolgab@bu.edu, kw@kwchang.net, jamesyzou@gmail.com, srv@bu.edu, adam.kalai@microsoft.com

https://proceedings.neurips.cc/paper_files/paper/2016/file/a486cd07e4ac3d270571622f4f316ec5-Paper.pdf

26 ED related subreddits



BDDvent, SuicideWatch, amiugly

MadeOfStyrofoam, safe_food, goodrestrictionfood, overlyspecificEDmemes, EdAnonymousAdults, **Instagramreality, EDFood, drunkorexia**

bodyweightfitness, intermittentfasting, Volumeeating, 1200isplenty, xxfitness, **cico, fasting**

Fitness, steroids, gainit, nattyorjuice, weightroom

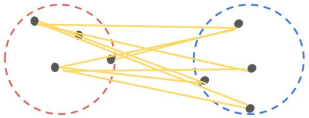
ketorecipes, ketomealseatingnow, KetoMealPrep, ketogains, xxketo

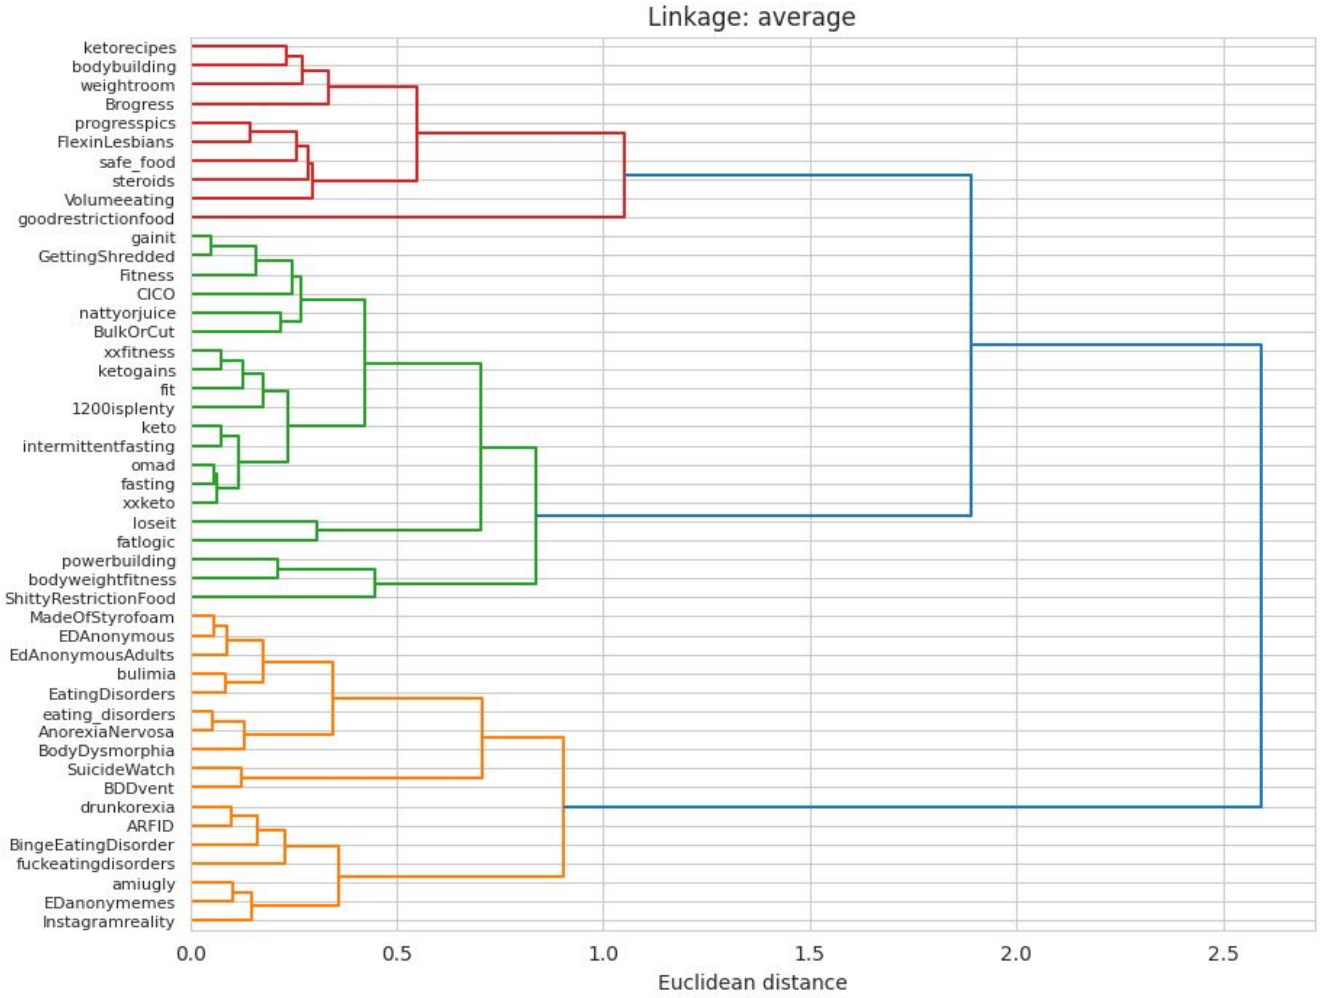
28 **new** ED related subreddits

Text similarity

Cosine distance between corpora centroids

average method

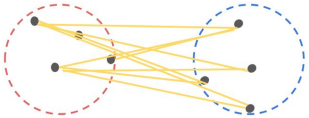


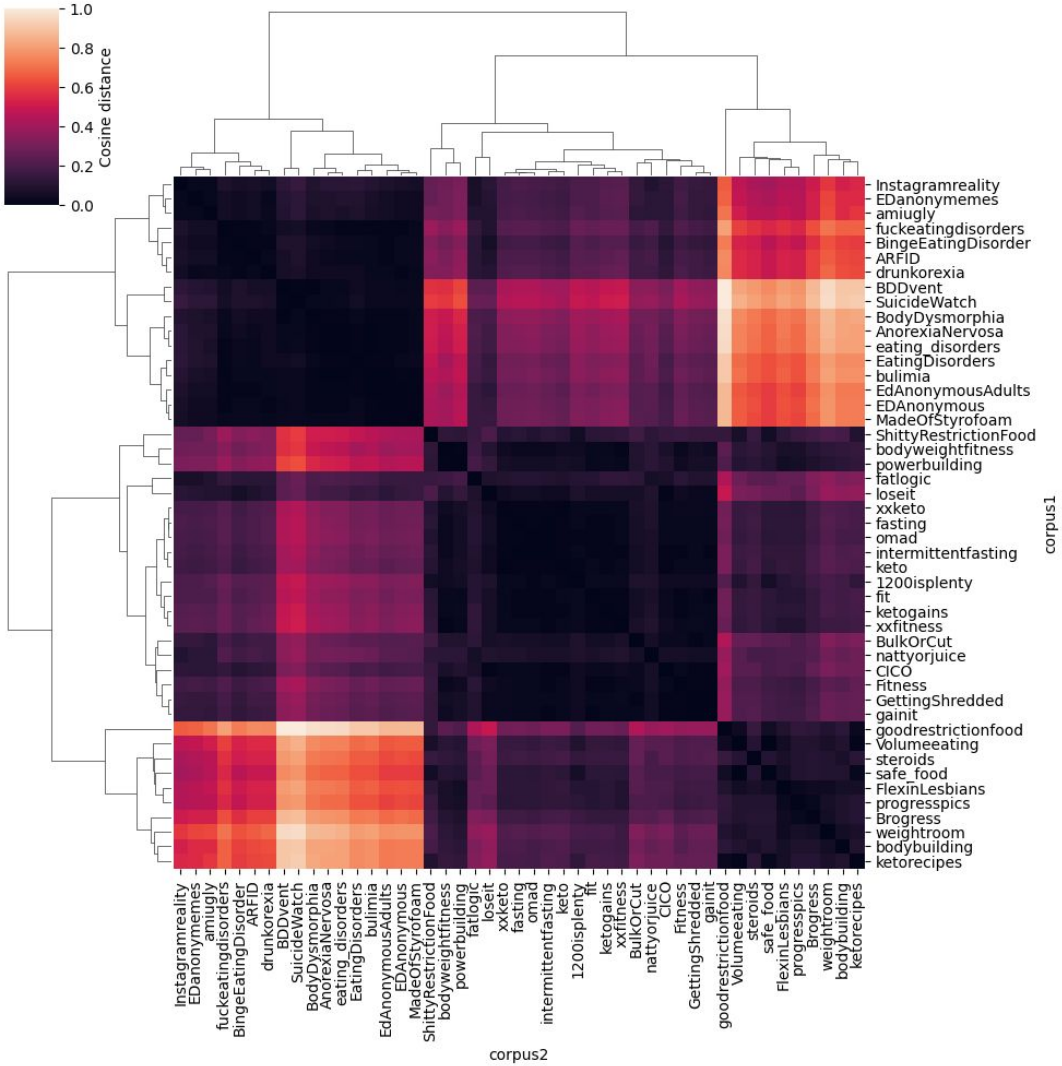


Text similarity

Cosine distance between corpora centroids

average method

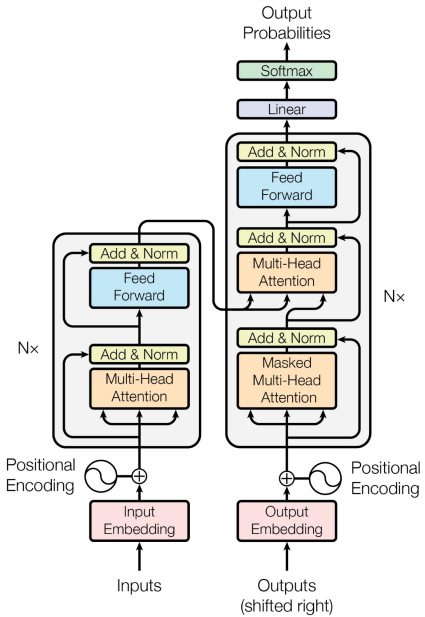




Large Language Models (LLMs)

Un LM es un modelo generativo probabilístico para el lenguaje natural. Un LM grande es un tipo de LM caracterizado por un mayor número de parámetros entrenables.

LM se basan en una arquitectura **transformer** que depende por completo de la **autoatención**.



Vaswani *et al.*, 2017. Attention Is All You Need

Language Models

Masked LM

Predice un token enmascarado utilizando el enfoque de contexto de atención bidireccional. Por ejemplo, BERT.

$$\mathcal{L} = (X_{\Pi}|X_{-\Pi}) = \frac{1}{n}\sum_{k=1}^{n} \log\ p\left(x_{\pi_k}|X_{-\Pi};\theta\right),$$



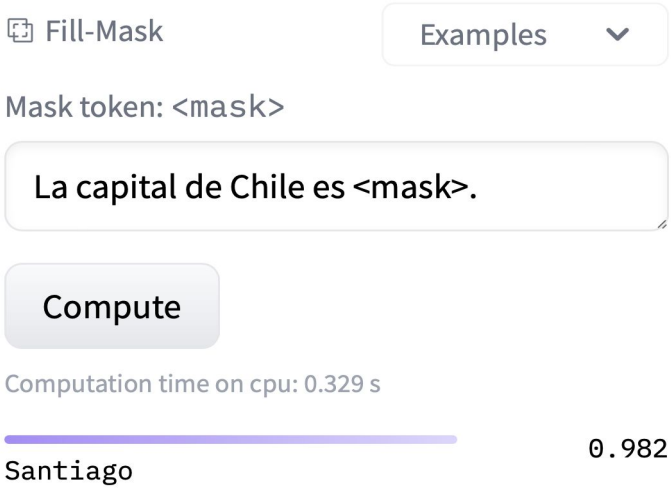
Causal LM

Predice el siguiente token basándose en los tokens anteriores (autorregresivo). Por ejemplo, GPT.

$$\mathcal{L}(X) = \sum_{n=1}^{N} log\ p(x_n,\ |\ x_1, \cdots, x_{n-1};\theta),$$



Language Models



huggingface.co/FacebookAI/roberta-large



huggingface.co/mistralai/Mistral-7B-v0.1

Representaciones de palabras



4096 dimensiones

Reducción de dimensionalidad TSNE

Large Language Models. Cambio de Fase: GPT-3 (2020)

- GPT-3: otro LM basado en el Transformer con casi 200 mil millones de parámetros y entrenado sobre un corpus gigante (casi 500 mil millones de tokens).
- **In-context learning:** pueden resolver otras tareas de NLP usando zero y few-shot learning. Toda la magia está en el **prompt**.

Zero-shot

```
1  Translate English to French:      ← task description
2  cheese =>                         ← prompt
```

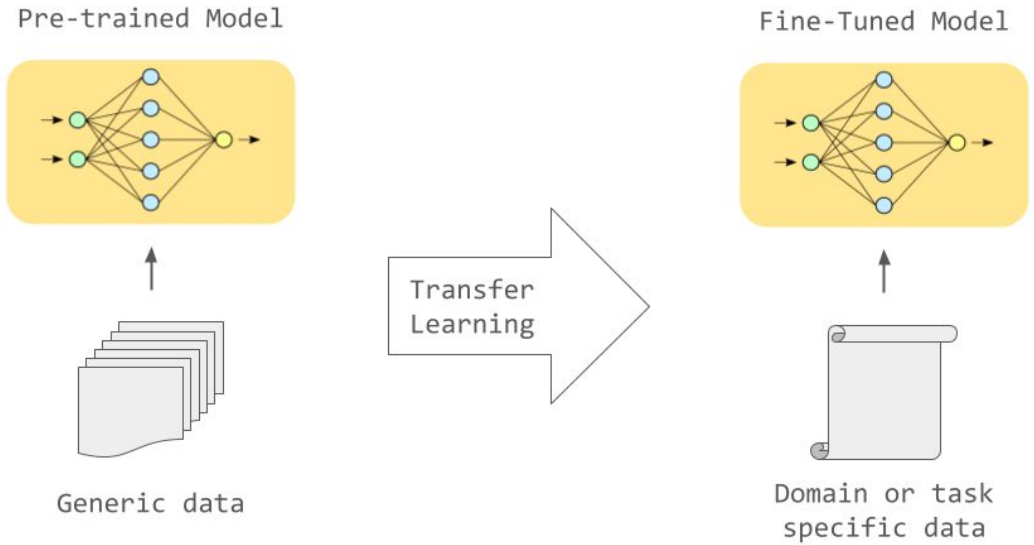
One-shot

```
1  Translate English to French:      ← task description
2  sea otter => loutre de mer        ← example
3  cheese =>                         ← prompt
```

Felipe Bravo Márquez. Un recorrido por los Modelos de Lenguaje. Desde Shannon a GPT-4. Universidad de Chile. https://relela.com/seminars/

Modelos de lenguaje especializados en diálogo (o chatbots)

Alinear el modelo de lenguaje (pre entrenado) con la intención del usuario mediante un ajuste fino (**fine-tuning**). Ejemplo: GPT3 -> ChatGPT.



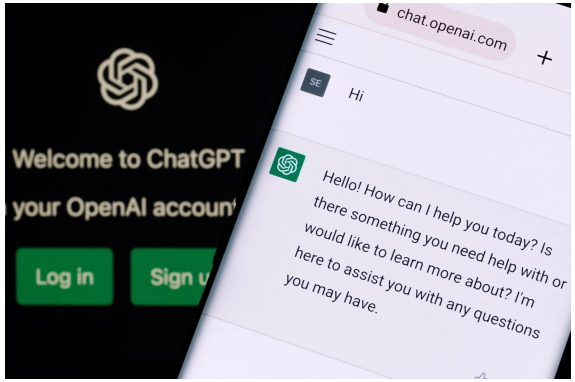
Fuente de la imagen: https://www.labellerr.com/blog/hands-on-with-fine-tuning-llm/

¿Cómo funciona ChatGPT?

ChatGPT (2022)

- Modelo lanzado por OpenAI a fines del 2022.
- Usa Crowdsourcing para mejorar sus respuestas, su proceso de fine-tuning usa **Reinforcement Learning from Human Feedback (RLHF).**

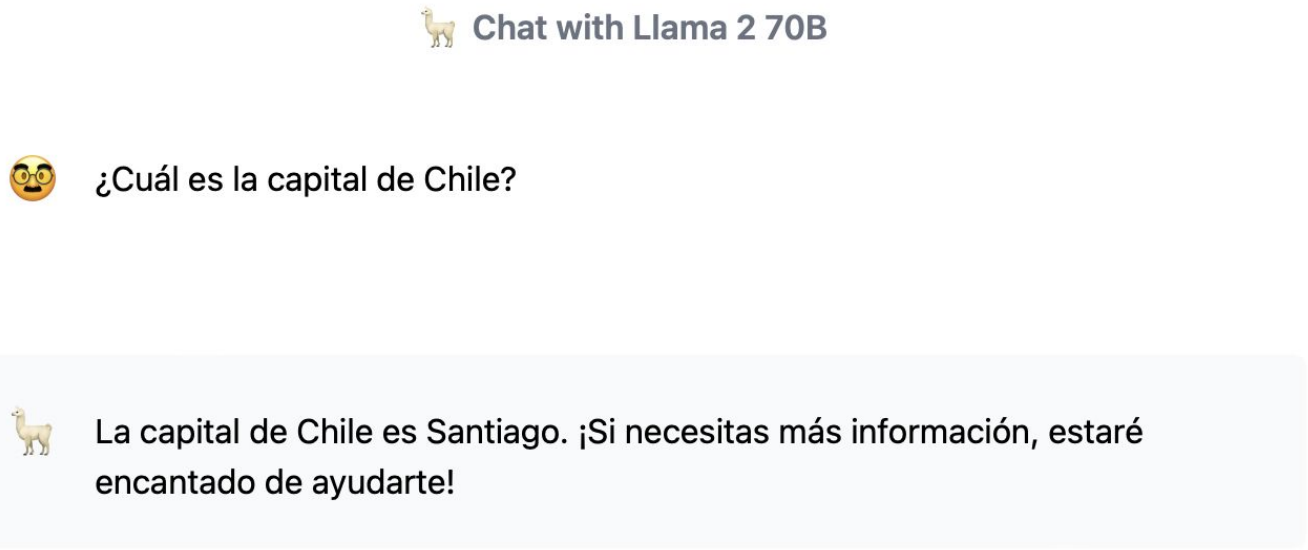
≈ ChatGPT 3.5: 175B, ChatGPT 4: 1.76 T de parámetros.





Crowd-sourcing: La Clave del Éxito
Personas que etiquetan manualmente conversaciones del modelo pre-entrenado.

Modelos de lenguaje especializados en diálogo (o chatbots)



https://www.llama2.ai

Preprocesamiento del texto

Es el primer paso de los proyectos de NLP basados en bolsa de palabras o TF-IDF. Algunos de los pasos del preprocesamiento son:

- Eliminación de puntuación (. ¡ ! $ ( ) * % @)
- Eliminación de URLs
- Eliminación de stopwords (artículos, pronombres, preposiciones, etc.)
- Conversión a minúsculas
- Eliminación de tildes
- Tokenización (dividir el texto en piezas llamadas tokens)
- Stemming: recorta la palabra a su raíz (“corriendo” → “corr”)
- Lematización: la lleva a su forma de diccionario (“corriendo” → “correr”)

Con BERT o LLMs no conviene eliminar stopwords, tildes ni puntuación: estos modelos traen su propio tokenizador (por subpalabras) y usan esa información como contexto.

Ejemplos: https://www.kaggle.com/code/sudalairajkumar/getting-started-with-text-preprocessing

Ejemplo

Detección de mensajes de redes sociales relacionados con eventos de emergencia

Proceedings of the Seventeenth International AAAI Conference on Web and Social Media (ICWSM 2023)

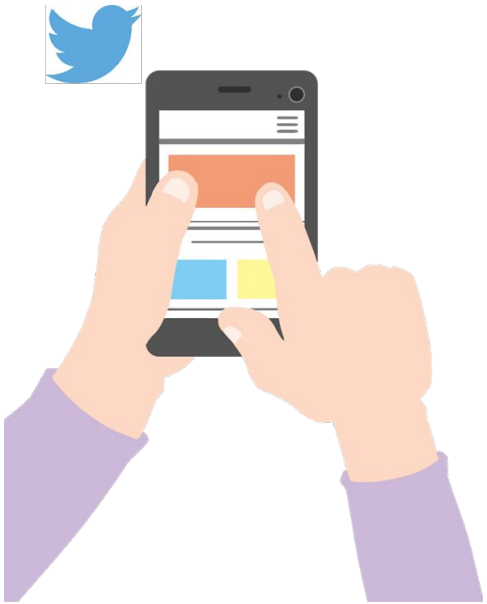
Cross-Lingual and Cross-Domain Crisis Classification for Low-Resource Scenarios

Cinthia Sánchez[1,2], Hernan Sarmiento[1,2], Andres Abeliuk[1,3], Jorge Pérez[4], Barbara Poblete[1,2,3]

[1]Department of Computer Science, University of Chile, Santiago, Chile
[2]Millennium Institute for Foundational Research on Data (IMFD), Santiago, Chile
[3]National Center for Artificial Intelligence (CENIA), Santiago, Chile
[4]Cero.ai, Santiago, Chile

https://ojs.aaai.org/index.php/ICWSM/article/view/22185

Importancia de las redes sociales durante eventos de crisis

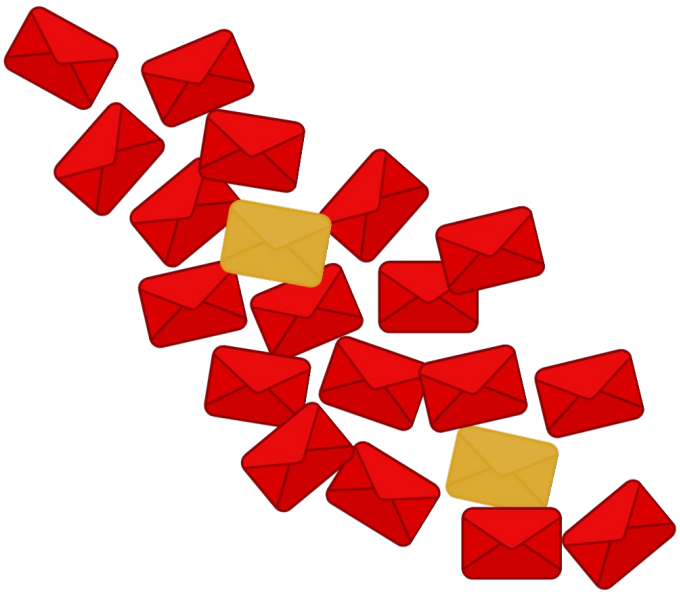


Difusión rápida de información crítica.

Los usuarios pueden proporcionar información desde el lugar de los hechos.

Conocimiento oportuno de (parte de) la realidad durante una emergencia.

Desafíos de las redes sociales durante eventos de crisis

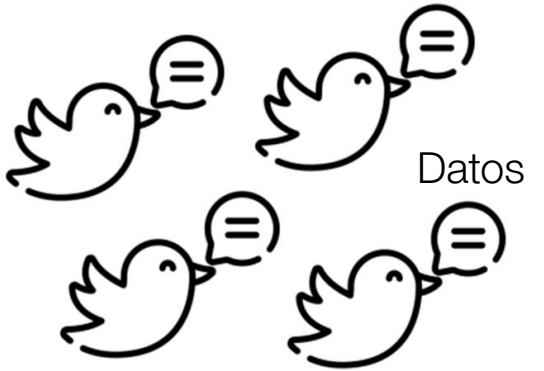


Sobrecarga de información en las redes sociales.

Información incompleta, incorrecta o falsa.

- Eliminar el ruido
- Priorizar la información a monitorear

Objetivo: Crear un modelo que detecte automáticamente los mensajes relevantes, en múltiples idiomas.



Datos

Algoritmo de aprendizaje

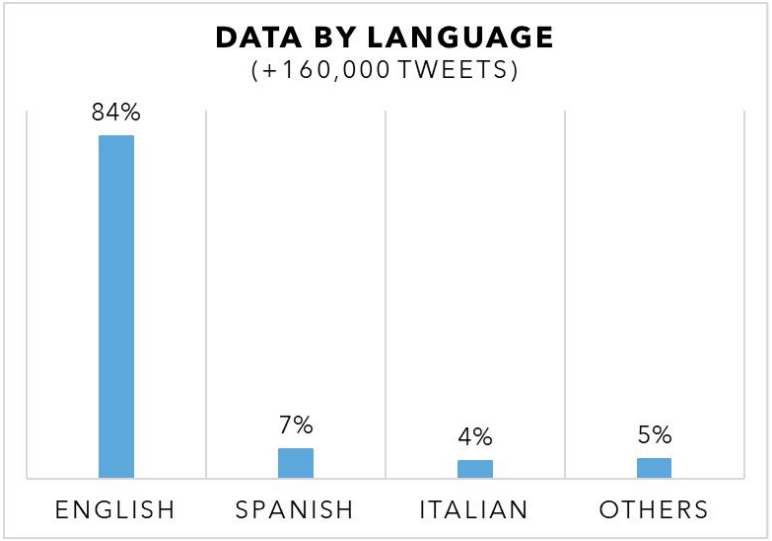


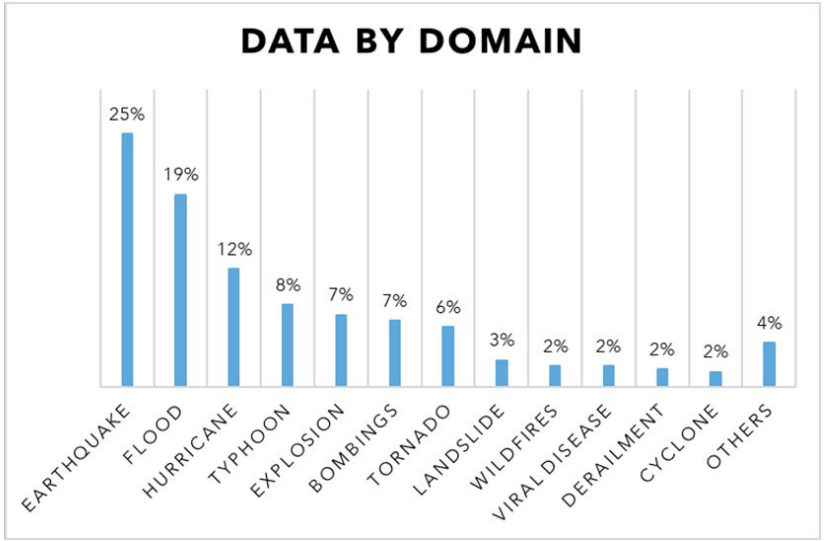
Modelo
(Clasificación)

Mensajes	¿Relevante para la crisis?
Ascienden 52 los muertos y 1,2 millones de afectados por terremoto en Guatemala: La cifra de muertos por el... http://t.co/YyCHBArU	Sí
No sé si preocuparme porque no sentí el temblor de ahorita o qué.	No
...	

Nuevos mensajes	¿Relevante para la crisis?
Fuerte terremoto de 6,5 magnitud en #Ecuador. https://t.co/vU4N7babRb	?

**Consideramos que un mensaje está relacionado con eventos de crisis cuando hace referencia implícita o explícita a algún evento de desastre.*





CRISISNLP Natural Language Processing

CrisisLex

The Dataverse® Project

GitHub

¿Cómo aprovechar los datos etiquetados de idiomas de altos recursos y de dominios de crisis bien conocidos para nuevos idiomas y dominios de bajos recursos?

Subconjunto de datos experimentales

Language	Domain	Events	Crises	Related	Not related	Total
English	Earthquake	11	Nepal, Chile 2014, California, Pakistan, Ecuador, Mexico, Bohol, Costa Rica, Iraq_Iran, Emilia, Guatemala	13,870	6,832	20,702
	Explosion	1	West Texas	4,415	4,641	9,056
	Flood	9	Alberta, Queensland, Pakistan, India, Colorado, Philippines, Sri Lanka, Manila, Sardinia	13,445	10,389	23,834
Spanish	Earthquake	5	Chile 2014, Chile 2010, Ecuador, Guatemala, Costa Rica	5,356	1,394	6,750
	Explosion	1	Venezuela	747	50	797
Italian	Earthquake	2	Emilia, L'Aquila	3,260	705	3,965
	Flood	2	Sardinia, Genova	1,759	138	1,897

67,001

Subconjunto de datos experimentales

~67,000 mensajes.

related (64%)

not-related (36%)



Earthquakes (46.9%)



Floods (38.4%)



Explosions (14.7%)



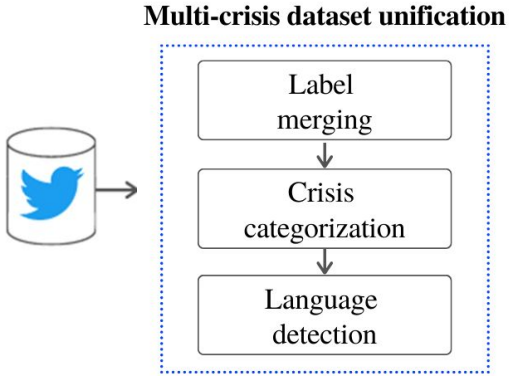
80.0% of English

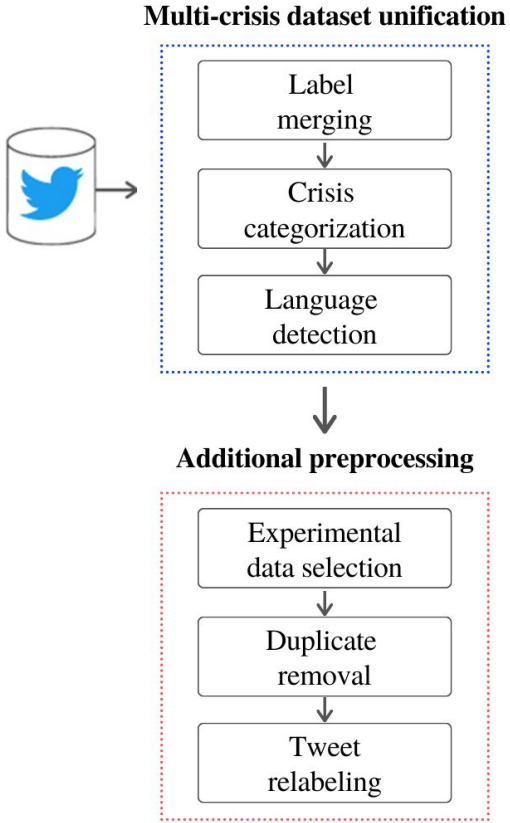


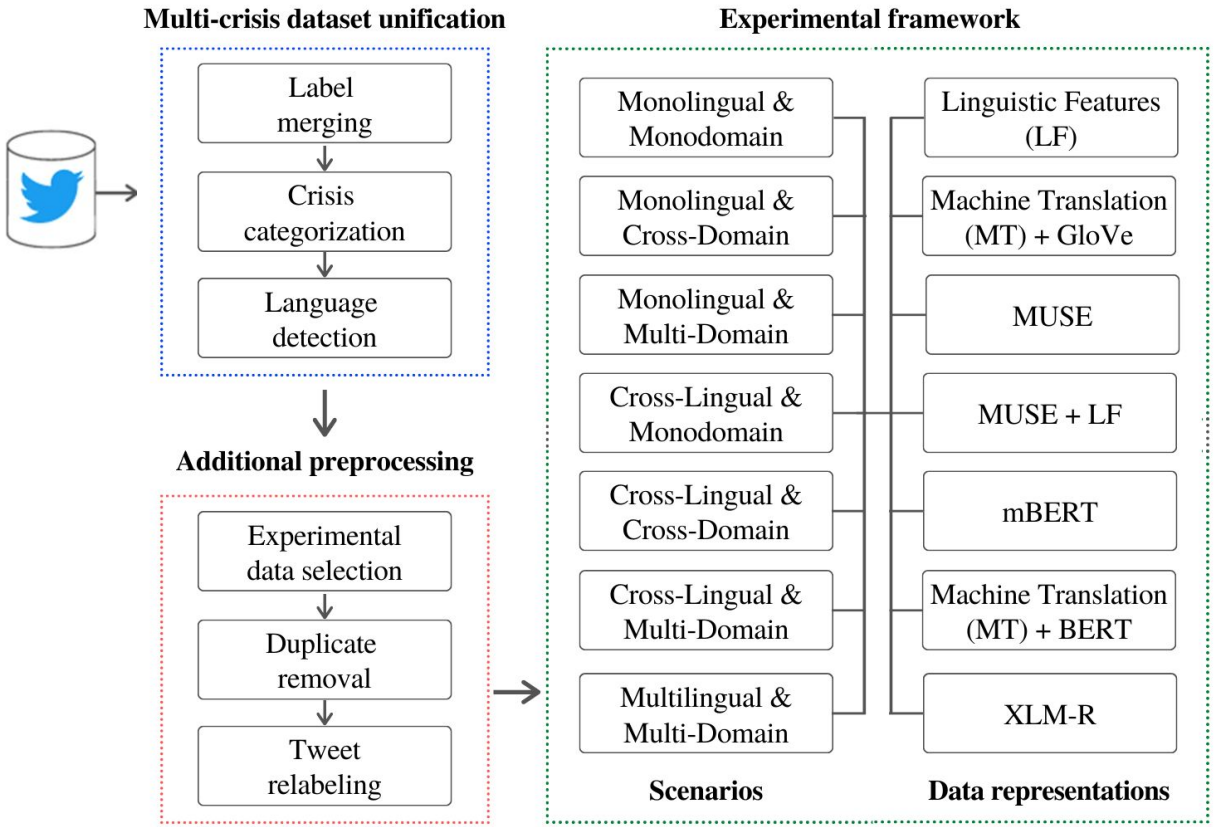
11.3% in Spanish

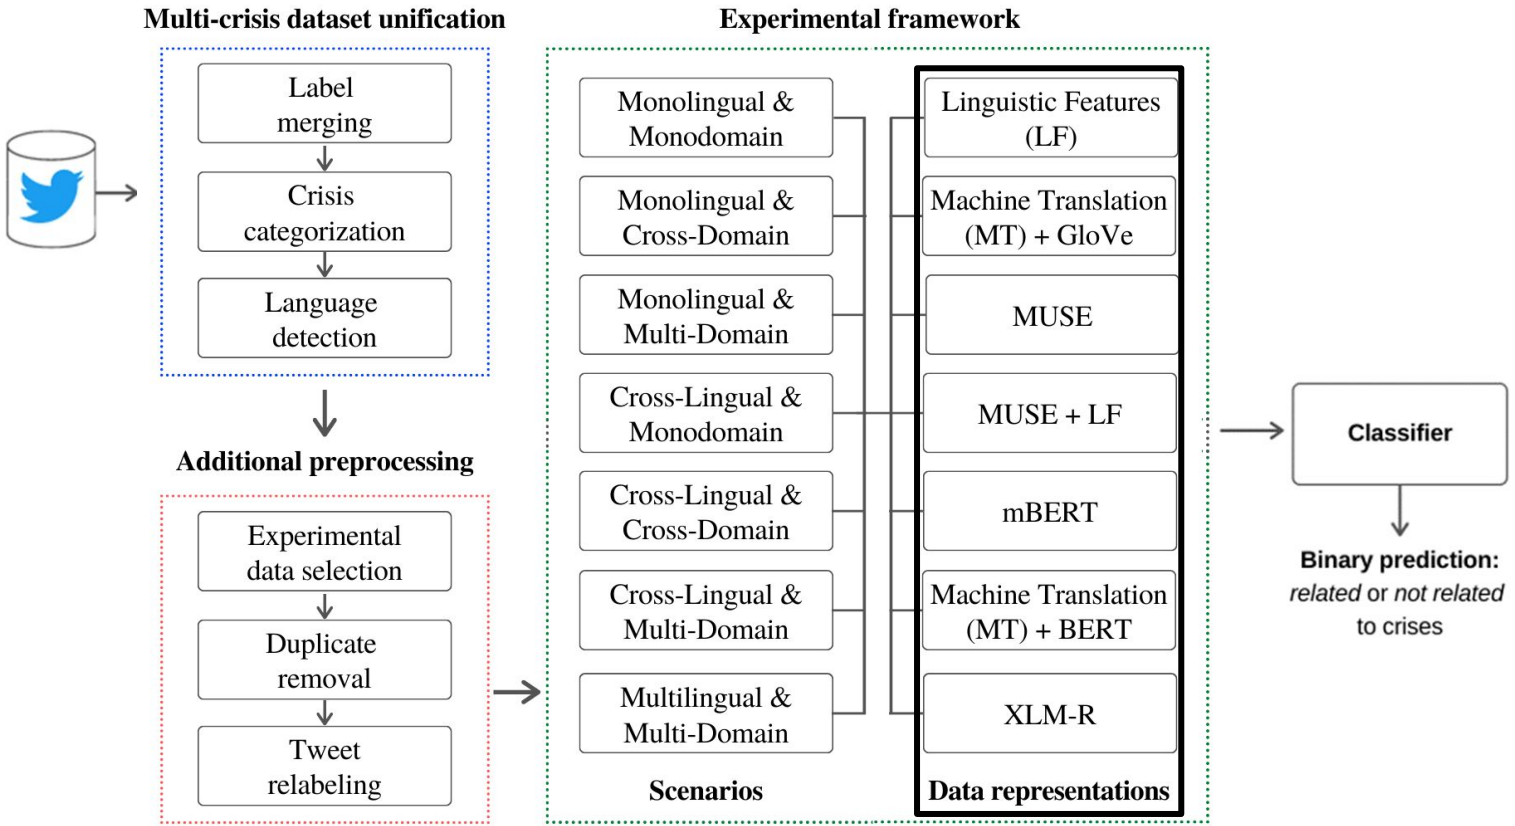


8.7% in Italian

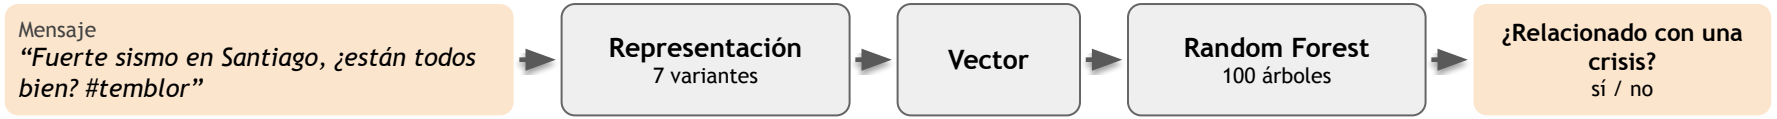

Multi-crisis dataset unification
Label merging
Crisis categorization
Language detection


Multi-crisis dataset unification
Label merging
Crisis categorization
Language detection
Additional preprocessing
Experimental data selection
Duplicate removal
Tweet relabeling


Multi-crisis dataset unification
Label merging
Crisis categorization
Language detection
Additional preprocessing
Experimental data selection
Duplicate removal
Tweet relabeling
Experimental framework
Monolingual & Monodomain
Monolingual & Cross-Domain
Monolingual & Multi-Domain
Cross-Lingual & Monodomain
Cross-Lingual & Cross-Domain
Cross-Lingual & Multi-Domain
Multilingual & Multi-Domain
Linguistic Features (LF)
Machine Translation (MT) + GloVe
MUSE
MUSE + LF
mBERT
Machine Translation (MT) + BERT
XLM-R
Scenarios
Data representations


Multi-crisis dataset unification
Label merging
Crisis categorization
Language detection
Additional preprocessing
Experimental data selection
Duplicate removal
Tweet relabeling
Experimental framework
Monolingual & Monodomain
Monolingual & Cross-Domain
Monolingual & Multi-Domain
Cross-Lingual & Monodomain
Cross-Lingual & Cross-Domain
Cross-Lingual & Multi-Domain
Multilingual & Multi-Domain
Scenarios
Linguistic Features (LF)
Machine Translation (MT) + GloVe
MUSE
MUSE + LF
mBERT
Machine Translation (MT) + BERT
XLM-R
Data representations
Classifier
Binary prediction:
related or not related
to crises

Representaciones de datos



Atributos lingüísticos (LF)
48 atributos diseñados a mano

caracteres	53
palabras	8
hashtags	1
menciones	0
links	0
signos ?	1
tiene ubicación	sí

+ sentimiento, entidades nombradas y categorías gramaticales (POS)

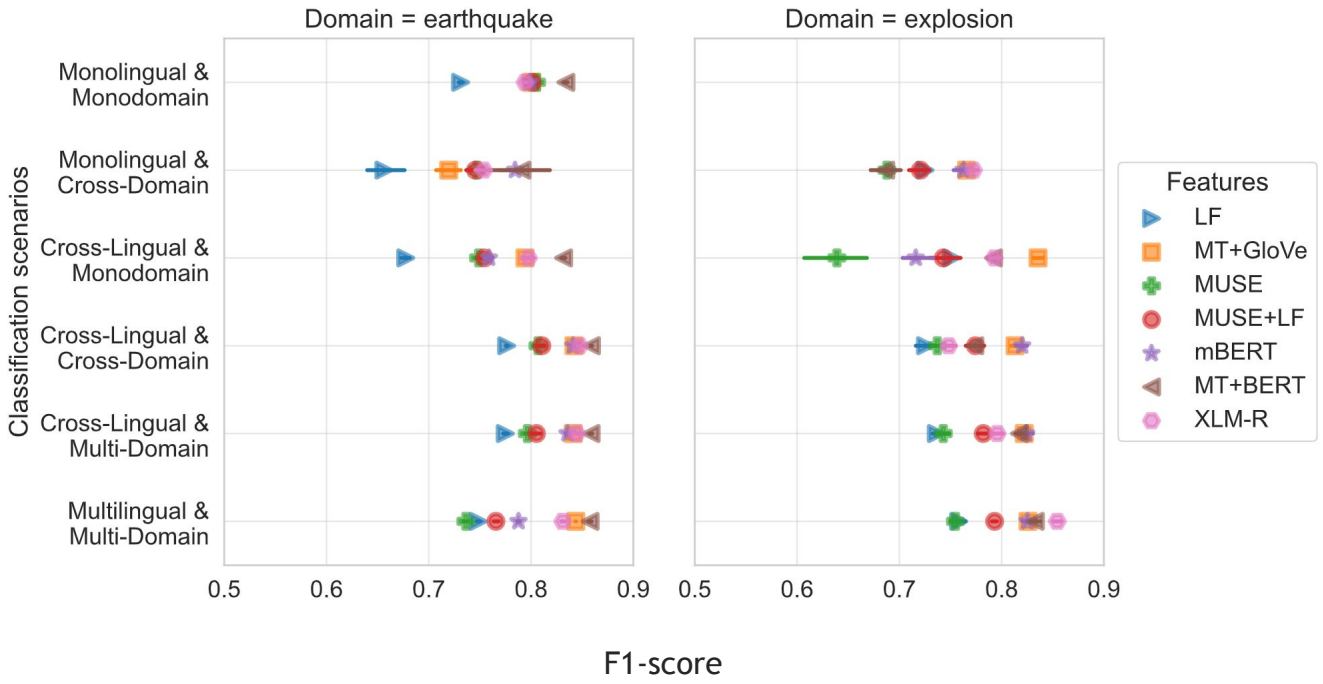
48 dim

	Traducir al inglés Google Translate → modelo en inglés	**Multilingüe** un solo espacio para varios idiomas
Estáticas un vector por palabra	**MT + GloVe** GloVe entrenado con tweets 100 dim	**MUSE** fastText alineado entre idiomas (Wikipedia) **MUSE + LF: se combina con los 48 atributos** 300 dim
Contextuales el vector depende de la oración	**MT + BERT** BERT en inglés (Wikipedia y BookCorpus) 768 dim	**mBERT · XLM-R** mBERT: 104 idiomas (Wikipedia) · XLM-R: 100 idiomas (CommonCrawl) 768 dim

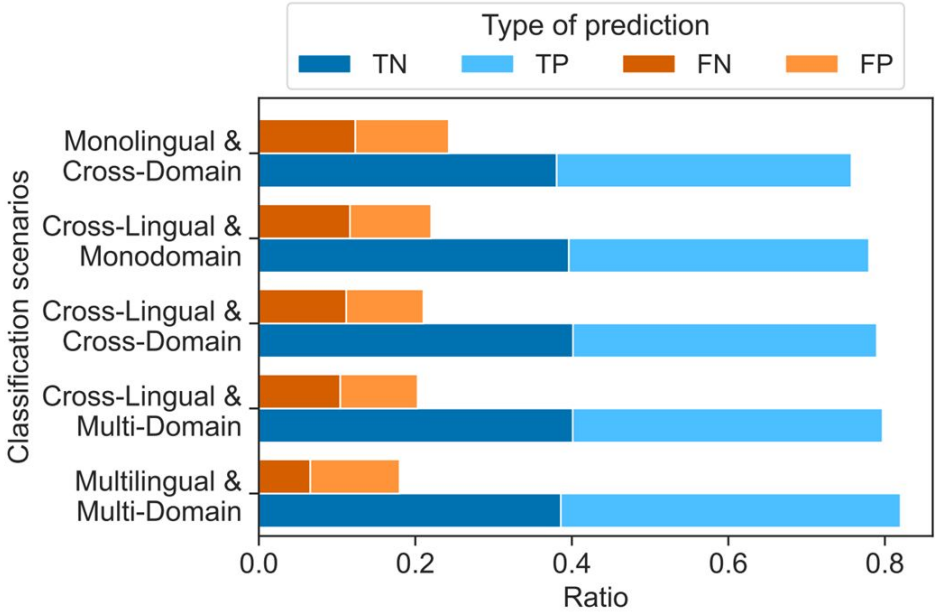
Cada mensaje es el promedio de los vectores de sus palabras o tokens (desconocidas → vector cero).

Sánchez, C., Sarmiento, H., Abeliuk, A., Pérez, J. y Poblete, B. (2023). Cross-Lingual and Cross-Domain Crisis Classification for Low-Resource Scenarios. ICWSM.

Resultados (Español)



Principales resultados: Es posible aprovechar los datos en inglés para clasificar los mismos o nuevos tipos de eventos en español e italiano (80,0% F1 score).



Predicciones de mensajes en español e italiano utilizando nuestro mejor modelo (MT+BERT)

Aciertos:
TN = True Negative
TP = True Positive
Errores:
FN = False Negative
FP = False Positive

Sitios recomendados

https://sbert.net/

https://huggingface.co/