

dcc CIENCIAS DE LA COMPUTACIÓN
UNIVERSIDAD DE CHILE

MINERÍA DE DATOS

Clase: Introducción a la Visión Computacional

Profesores: Cinthia Sánchez y Cristian Llull

Hoja de Ruta

1. Introducción y Motivación
2. Fundamentos de procesamiento clásico
3. De la Regla al Deep Learning
4. Preguntas y cierre

Introducción

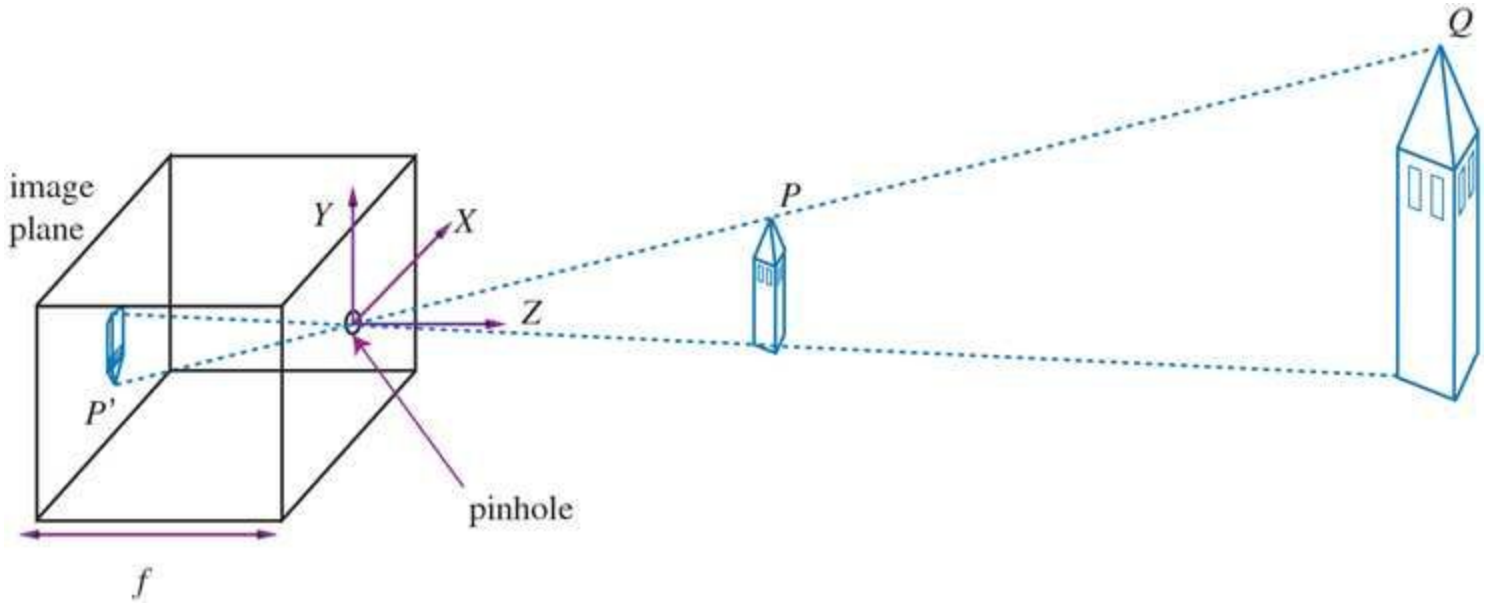
¿Qué es Visión Computacional?

Disciplina científico-ingenieril que **extrae descripciones explícitas, geométricas y semánticas del mundo físico desde imágenes/video**.

Idea central: resolver un problema inverso mal condicionado:

- mundo 3D → proyección 2D con pérdida de profundidad
- infinitas escenas 3D pueden generar la misma imagen 2D
- se necesitan priors físicos/estadísticos: suavidad, iluminación, reflectancia, aprendizaje

Misma imagen, diferente profundidad



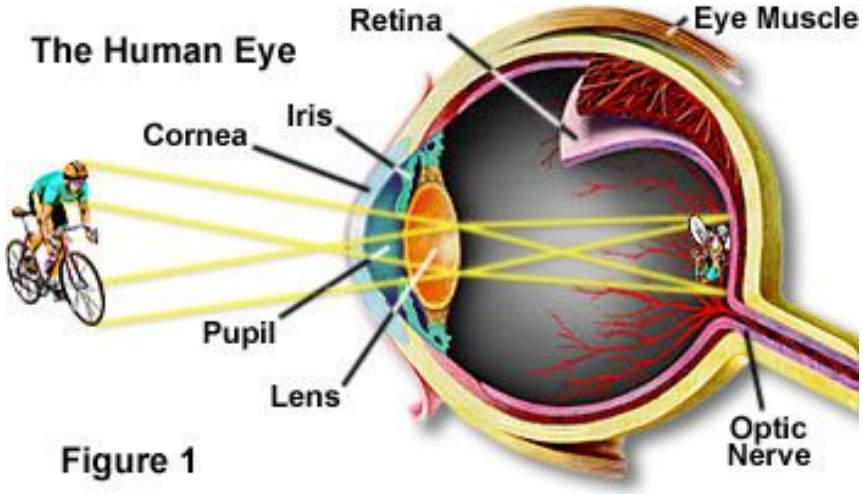
Russell, S., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4.ª ed.). Pearson, Fig. 25.2

Misma imagen, diferente profundidad

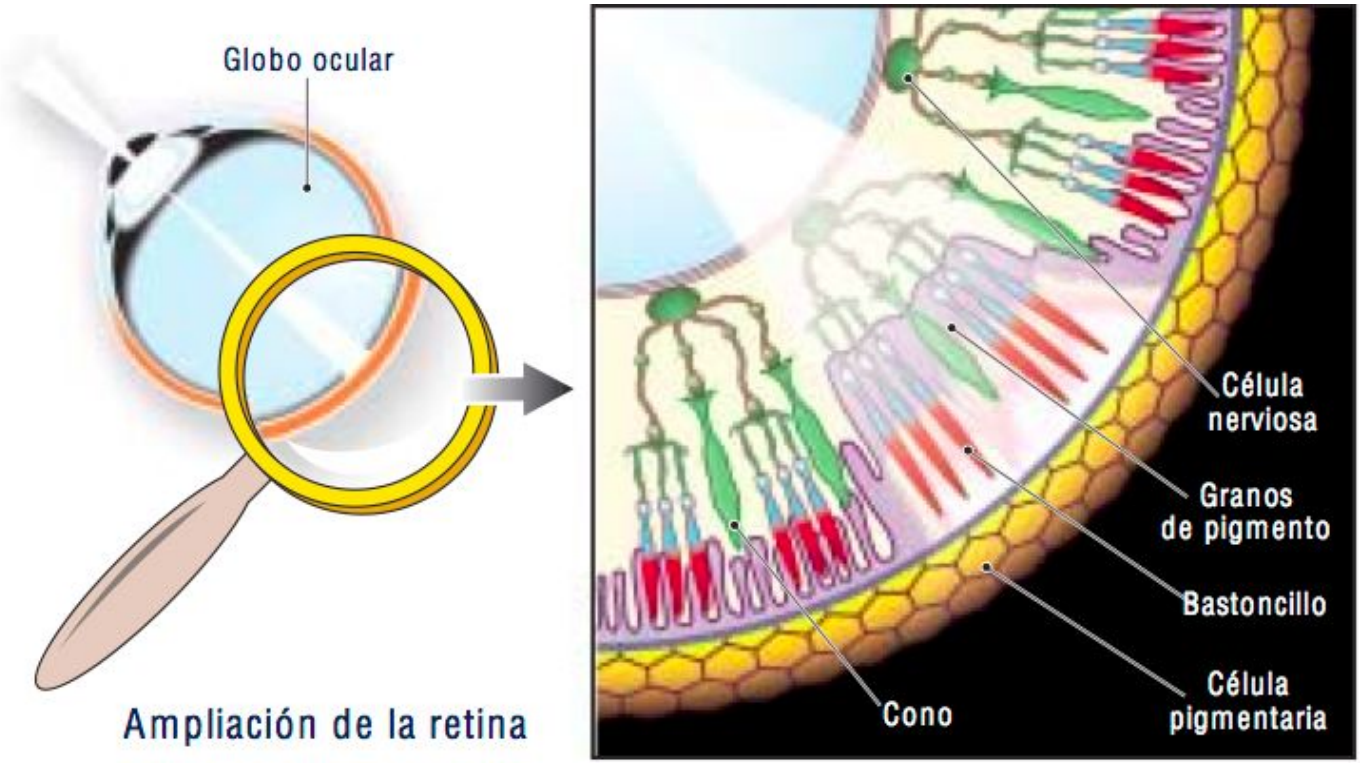




El Ojo Humano



Retina: disociación de colores



Nuestra visión

Es una interpretación de las señales que llegan al cerebro.

Cada uno puede interpretar cosas distintas.

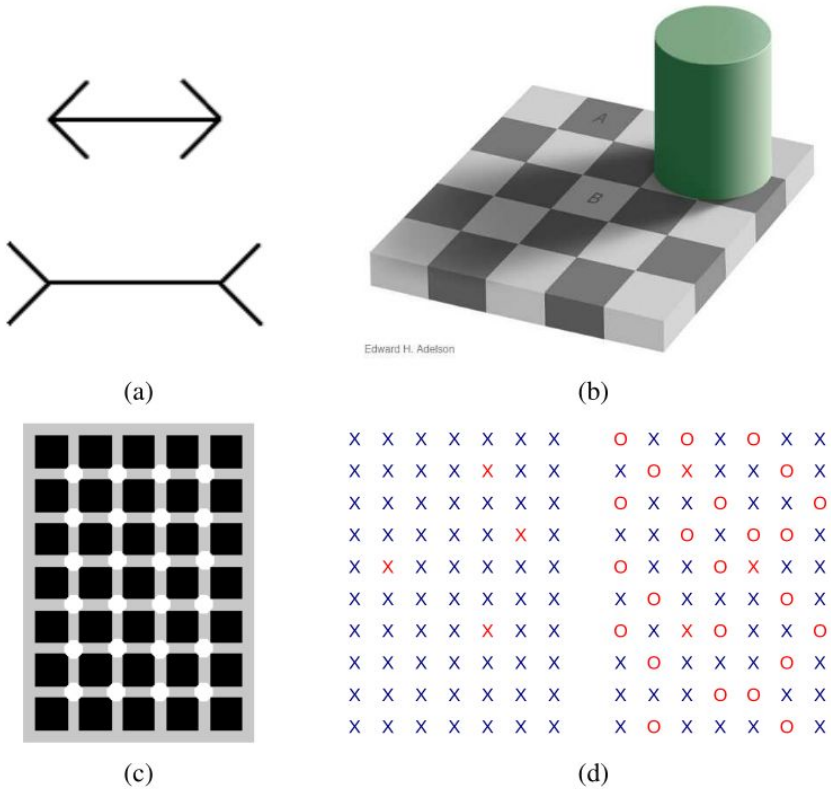


https://en.wikipedia.org/wiki/The_dress

Visión Humana

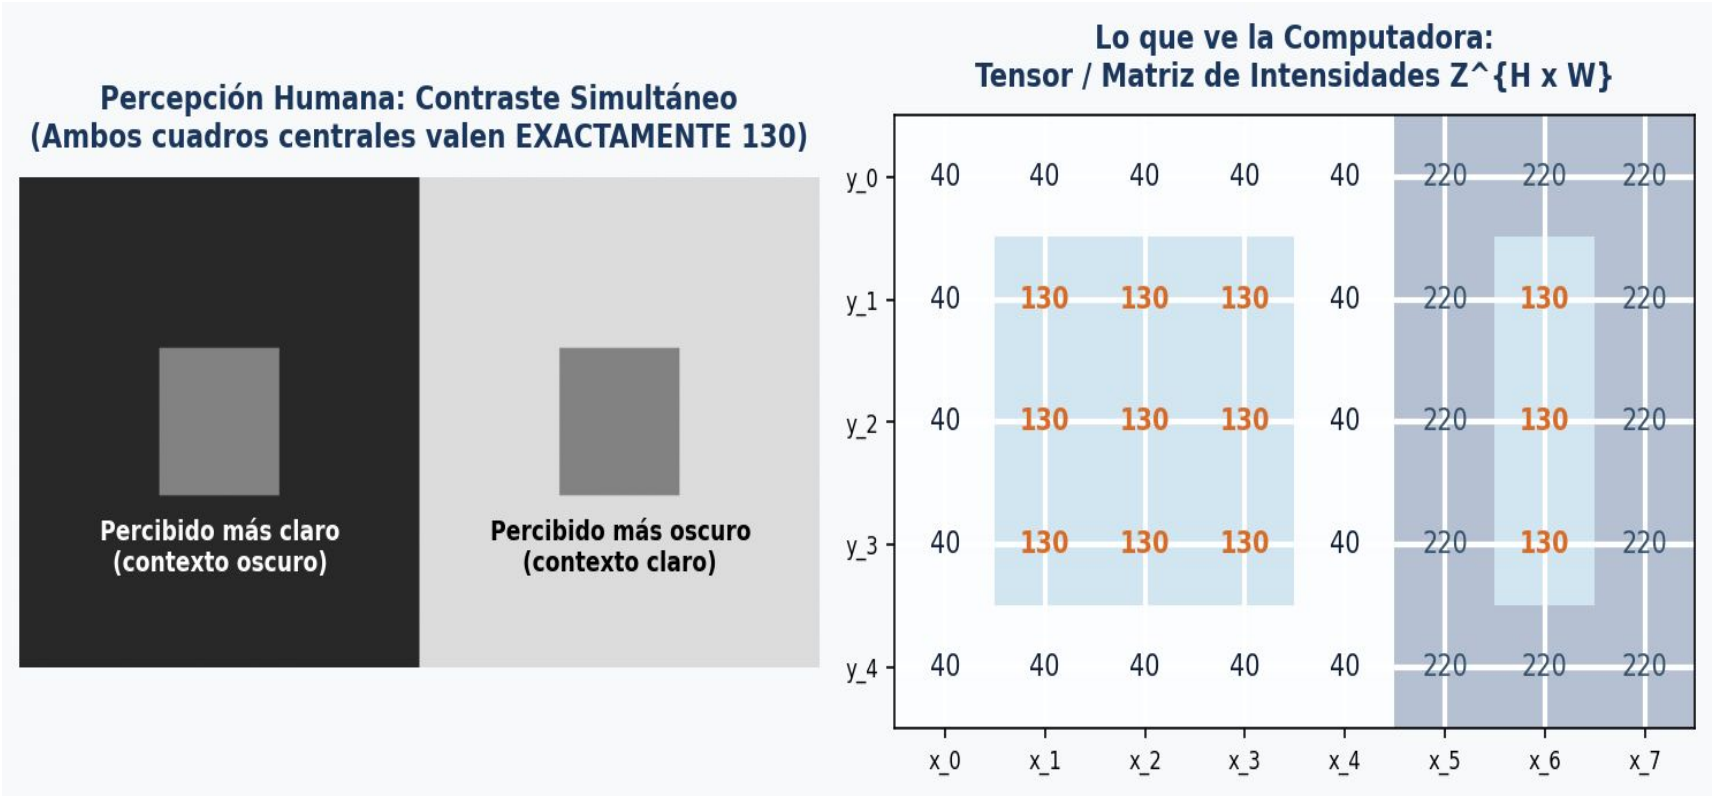
Biológica, activa, contextual e interpretativa.

No medimos radiancia absoluta, sino que inferimos reflectancia y propiedades semánticas del entorno.

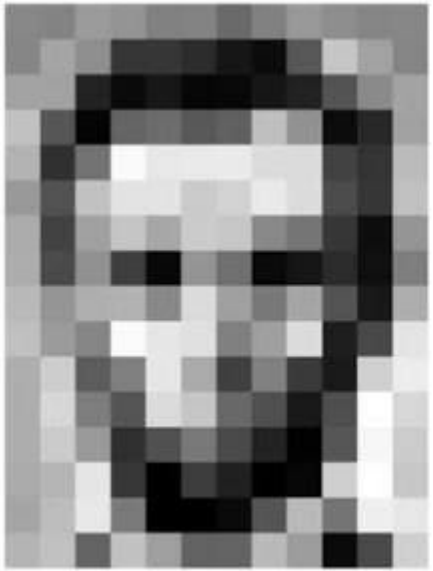


Szeliski, R. (2022). Computer Vision: Algorithms and Applications (2nd Edition). Springer Nature.

Visión Humana vs. Visión de Computador



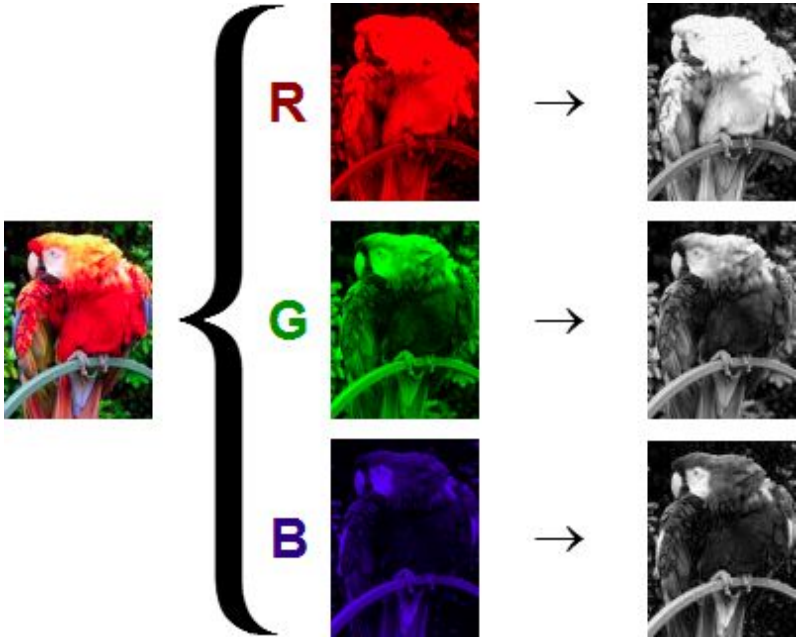
Visión computacional

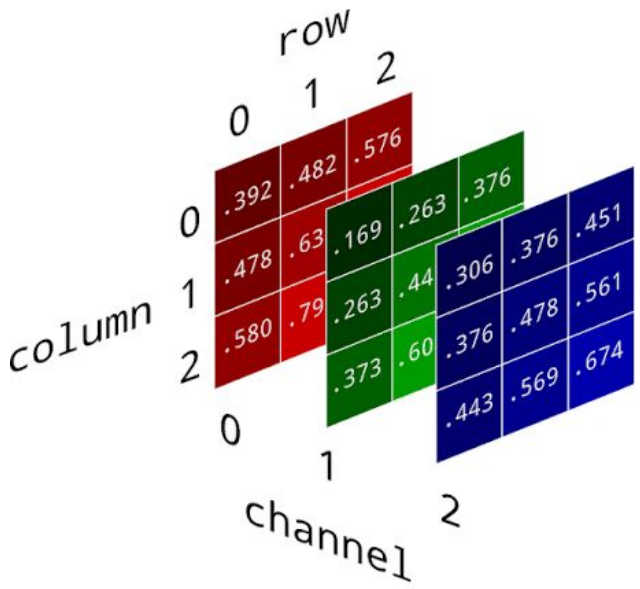


157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	105	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	86	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	105	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	86	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

Representación matricial





La naturaleza numérica de la imagen

- Imagen digital: arreglo discreto bidimensional o tridimensional (tensor) de números finitos.
    - En escala de grises: Matriz de tamaño H × W donde cada celda (píxel) contiene un número escalar que cuantiza la intensidad luminosa (típicamente uint8, [0, 255]).
    - En color: Tensor tridimensional de dimensiones H × W × C (donde C = 3 canales: Rojo, Verde, Azul en RGB; o BGR en OpenCV)
- **Resolución y memoria**: Una imagen HD de 1920 × 1080 × 3 contiene 6.220.800 valores numéricos que deben procesarse por cuadro.

Consecuencias para la Minería de Datos

- **Maldición de la Dimensionalidad**: al 'aplanar' (flatten) una imagen de 256×256×3 a un vector, obtiene 196.608 columnas tabulares.
- Pérdida de Topología Espacial:
  Al aplanar, el algoritmo olvida que el píxel (i, j) es adyacente a (i+1, j) y a (i, j+1).
- Hiperdispersión de datos.
- **Regla práctica**: no aplanar imágenes crudas; extraer descriptores compactos o embeddings.

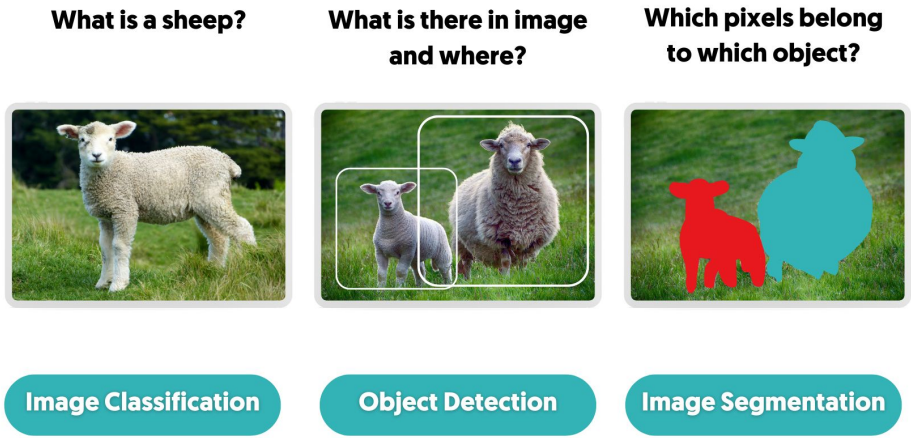
Fundamentos de Procesamiento Clásico

Tareas comunes en Visión

1. Image Classification:
¿Qué hay en la imagen?
Asigna una única etiqueta global a toda la foto (ej. 'Perro: 94%').

2. Object Detection:
¿Dónde está y qué es?
Retorna cajas delimitadoras (Bounding Boxes) con coordenadas [x, y, w, h], etiqueta de clase y puntaje de confianza (ej. YOLO).

3. Image Segmentation:
¿A qué objeto pertenece cada píxel?
Clasificación a nivel de píxel.



Pipeline de la visión computacional

1. Adquisición y Calibración

- Sensores CCD/CMOS y lentes.
- Modelado pinhole y perspectiva.
- Balance de color e iluminación.
- Muestreo y normalización [0, 1].

2. Preprocesamiento Espacial

- Reducción de ruido gausiano.
- Filtros espaciales y CLAHE.
- Gradientes, Sobel y bordes Canny.
- Pirámides multirresolución.

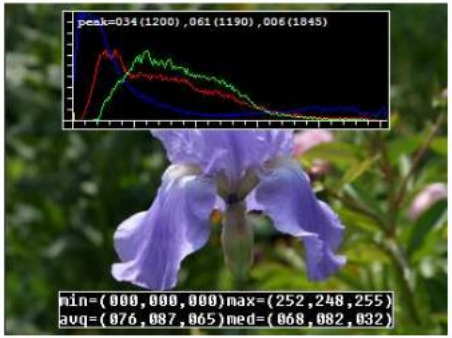
3. Extracción de Atributos

- Clásica: SIFT, HOG, GLCM, BoW.
- Codebook k-means como diccionario.
- Profunda: CNNs (ResNet, MobileNet).
- Vectores densos GAP (embeddings).

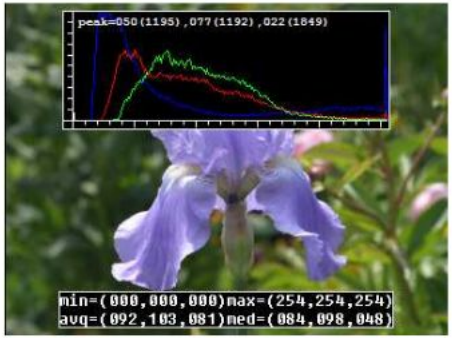
4. Algoritmos de Minería de Datos y Toma de Decisiones

- Inserción en DataFrame.
- Clasificación con SVM o XGBoost.
- Clustering k-means / DBSCAN.
- Búsqueda métrica y vecinos k-NN.

Operadores por pixel



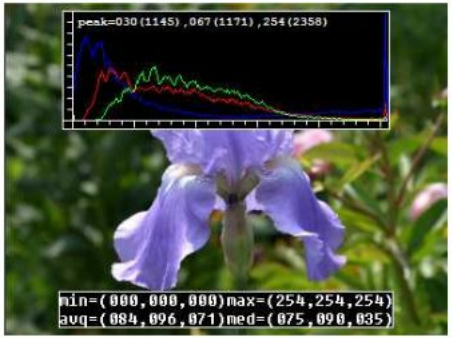
(a)



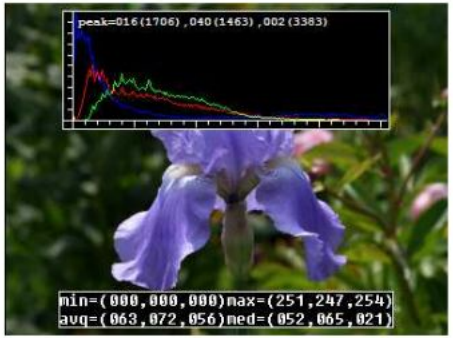
(b)

Depende únicamente del pixel que se está mirando.

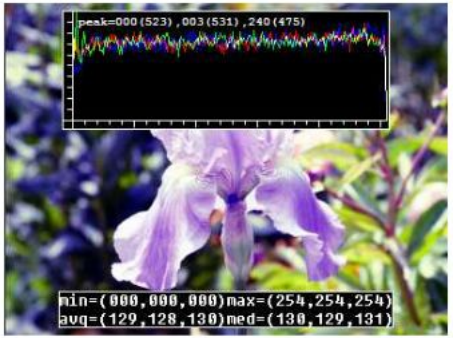
Uso de mapa de histograma.

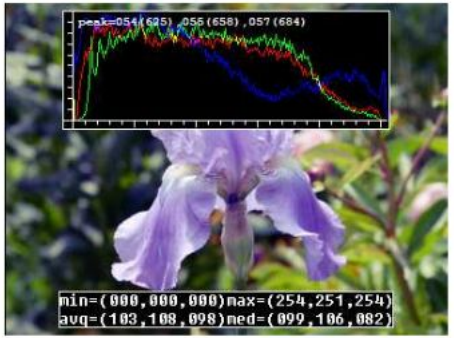


(c)



(d)





Szeliski, R. (2022). Computer Vision: Algorithms and Applications (2nd Edition). Springer Nature.

Algunas transformaciones

- Inversión (Negativo): s = 255 - r
- Transformación Logarítmica: s = c · log(1 + r) (expande rangos oscuros en espectros de Fourier).
- Corrección Gamma: s = c · r^γ (calibración de monitores y sensores).
- Binarización por Umbral (Thresholding):

  s = 255 si r >= T sino 0

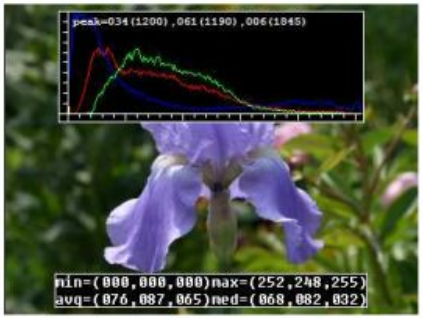
- Método de Otsu: Encuentra el umbral T óptimo que minimiza la varianza intra-clase en el histograma.

Image matting y compositing

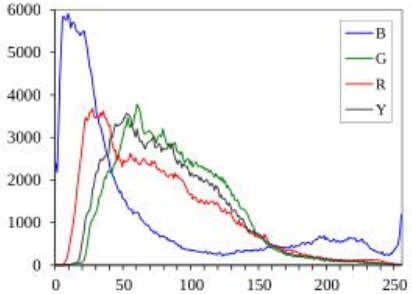


(Chuang, Curless et al. 2001) © 2001 IEEE

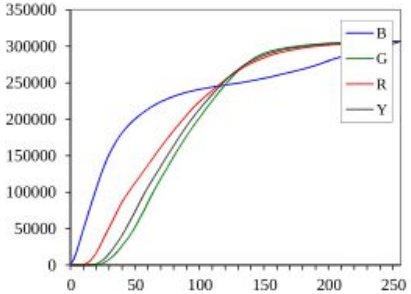
Análisis de Histograma y Ecualización



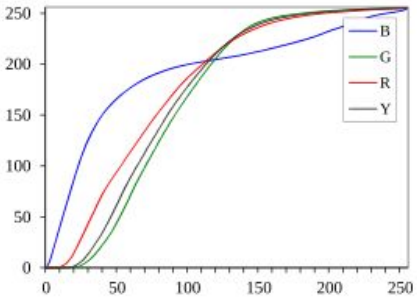
(a)



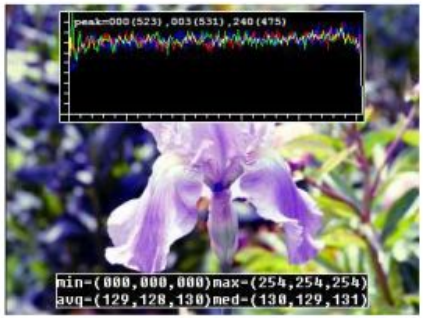
(b)



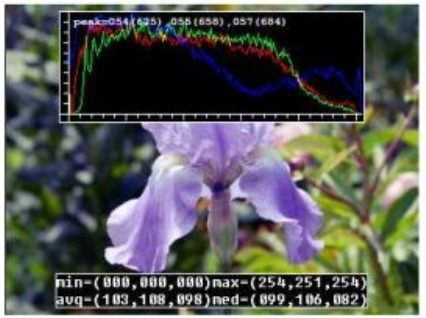
(c)



(d)



(e)



(f)

Szeliski, R. (2022). Computer Vision: Algorithms and Applications (2nd Edition). Springer Nature.

Filtros y Convolución

- El objetivo es extraer información de la vecindad, no solo del pixel.

- Convolución/correlación discreta 2D:

  $$S(x,y) = \Sigma\Sigma\ I(x+u,y+v) \cdot K(u,v)$$

- Un kernel K se desliza sobre la imagen y mide correlación local con un patrón.
- Propiedades:
  - Linealidad.
  - Invarianza a traslación.
  - Asociatividad.
  - Conmutatividad con la derivada.

Convolución

45	60	98	127	132	133	137	133
46	65	98	123	126	128	131	133
47	65	96	115	119	123	135	137
47	63	91	107	113	122	138	134
50	59	80	97	110	123	133	134
49	53	68	83	97	113	128	133
50	50	58	70	84	102	116	126
50	50	52	58	69	86	101	120

$f(x,y)$

*

0.1	0.1	0.1
0.1	0.2	0.1
0.1	0.1	0.1

$h(x,y)$

=

69	95	116	125	129	132
68	92	110	120	126	132
66	86	104	114	124	132
62	78	94	108	120	129
57	69	83	98	112	124
53	60	71	85	100	114

$g(x,y)$

Kernels comunes

$$\frac{1}{K^2}\begin{bmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & 1 & \vdots \\ 1 & 1 & \cdots & 1 \end{bmatrix} \qquad \frac{1}{16}\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \qquad \frac{1}{256}\begin{bmatrix} 1 & 4 & 6 & 4 & 1 \\ 4 & 16 & 24 & 16 & 4 \\ 6 & 24 & 36 & 24 & 6 \\ 4 & 16 & 24 & 16 & 4 \\ 1 & 4 & 6 & 4 & 1 \end{bmatrix} \qquad \frac{1}{8}\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \qquad \frac{1}{4}\begin{bmatrix} 1 & -2 & 1 \\ -2 & 4 & -2 \\ 1 & -2 & 1 \end{bmatrix}$$

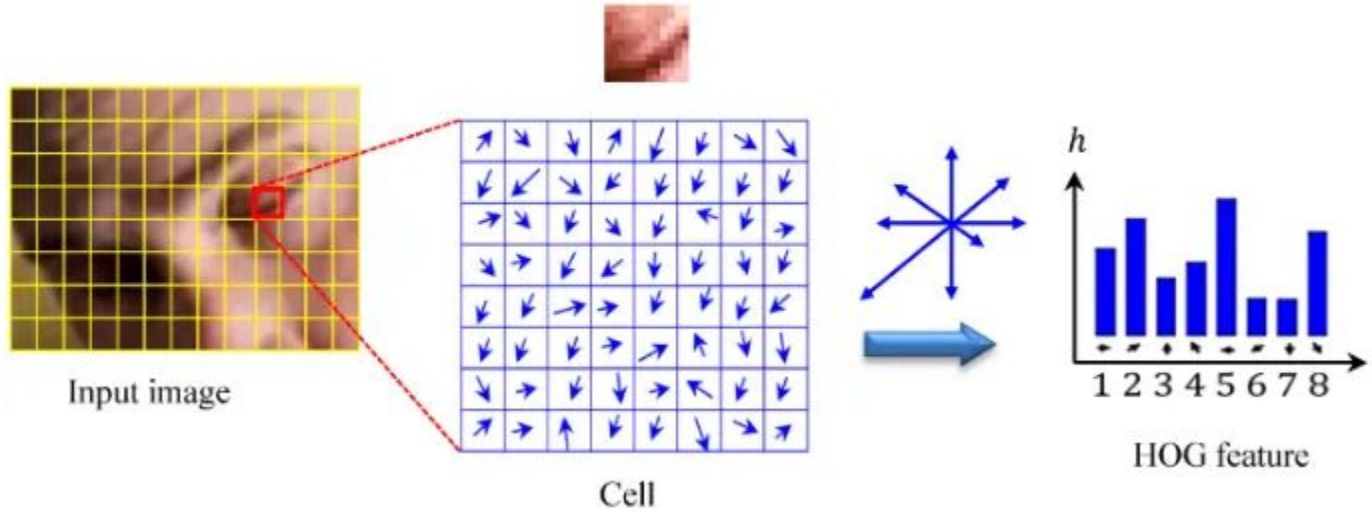
$$\frac{1}{K}\begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix} \qquad \frac{1}{4}\begin{bmatrix} 1 & 2 & 1 \end{bmatrix} \qquad \frac{1}{16}\begin{bmatrix} 1 & 4 & 6 & 4 & 1 \end{bmatrix} \qquad \frac{1}{2}\begin{bmatrix} -1 & 0 & 1 \end{bmatrix} \qquad \frac{1}{2}\begin{bmatrix} 1 & -2 & 1 \end{bmatrix}$$



(a) box, $K = 5$ (b) bilinear (c) “Gaussian” (d) Sobel (e) corner

Extracción de Features

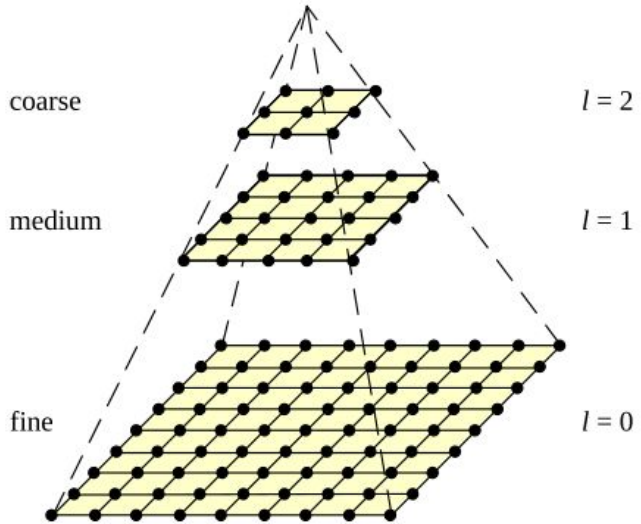
HOG: Histogram of Oriented Gradients

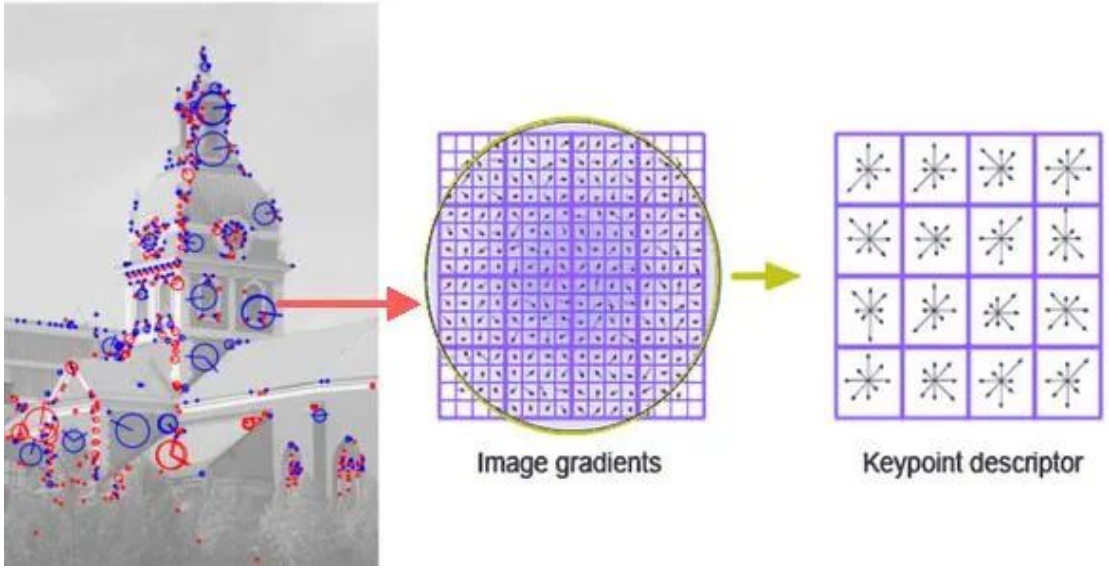


https://medium.com/@danyang95luck/comparison-of-hog-histogram-of-oriented-gradients-and-sift-scale-invariant-feature-transform-e2b17f61c9a3

Extracción de Features

SIFT: Scale-Invariant Feature Transform



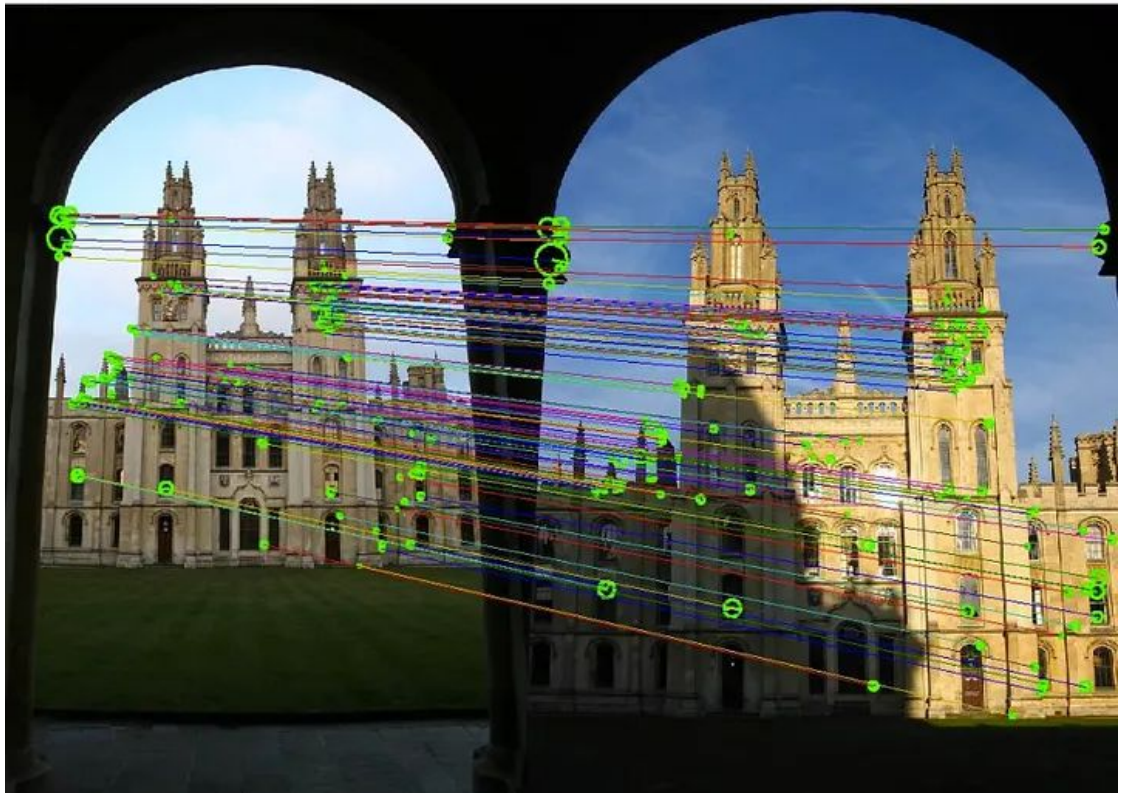


Un filtro gaussiano por nivel.

Detección de key points.

https://medium.com/@danyang95luck/comparison-of-hog-histogram-of-oriented-gradients-and-sift-scale-invariant-feature-transform-e2b17f61c9a3

Feature matching con SIFT



https://medium.com/@danyang95luck/comparison-of-hog-histogram-of-oriented-gradients-and-sift-scale-invariant-feature-transform-e2b17f61c9a3

Bag of Visual Words

- En NLP: Un documento se representa contando la frecuencia de aparición de palabras de un diccionario.
- En Visión por Computador (BoW / BoF):

1. Extracción: Se extraen millones de descriptores locales (SIFT) de miles de imágenes de entrenamiento.
2. Clustering No Supervisado: Se aplica k-means para hallar k centroides representativos (ej. k = 1.000 'palabras visuales' o 'Visual Words').
3. Cuantización Vectorial: Cada descriptor de una nueva imagen se asigna a su palabra visual más cercana.
4. Histograma Final: La imagen se convierte en un vector de k dimensiones listo para Scikit-Learn.

Paradigmas de Deep Learning

De Features Diseñadas a Mano a Deep Learning

Paradigma Tradicional (1990 - 2011)

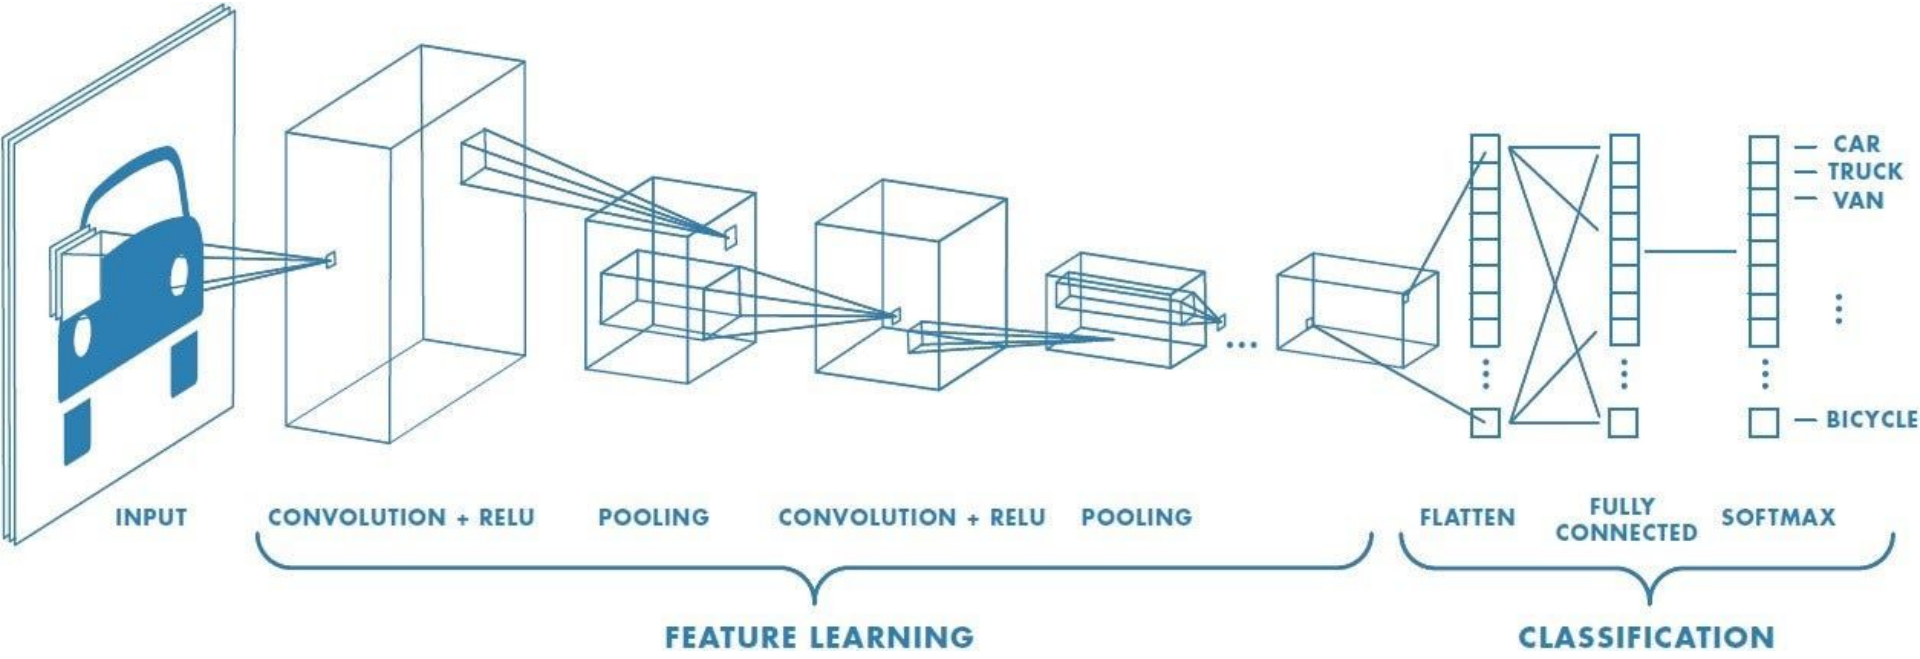
- Feature Engineering
- Expertos humanos: operadores para invarianzas específicas (esquinas Harris, SIFT para escala, HOG para personas).
- Descriptores fijos e inmutables durante el entrenamiento.
- Pipeline desconectado en dos fases:
  1. Extracción de vectores fijos de atributos (SIFT, GLCM, color).
  2. Entrenamiento de un clasificador lineal (SVM, Random Forest).
- Cuello de botella: Si la característica diseñada a mano no captura la sutileza de la clase, el modelo predictivo fracasa inevitablemente.

Paradigma Deep Learning (2012 - Presente)

- Aprendizaje de representaciones de extremo a extremo (End-to-End Representation Learning)
- Filtros no se diseñan a mano: sus pesos numéricos se inicializan al azar y se aprenden mediante *backpropagation*.
- Optimización conjunta:
  - La función de pérdida del clasificador final guía directamente qué patrones visuales deben aprender los filtros de las primeras capas.
- Adaptabilidad total al dominio:
  - Si el objetivo es detectar tumores o piezas mecánicas, la red aprende automáticamente los filtros específicos para esas texturas.

CNN

Convolutional Neural Networks.



CNN: Kernel Convolucional

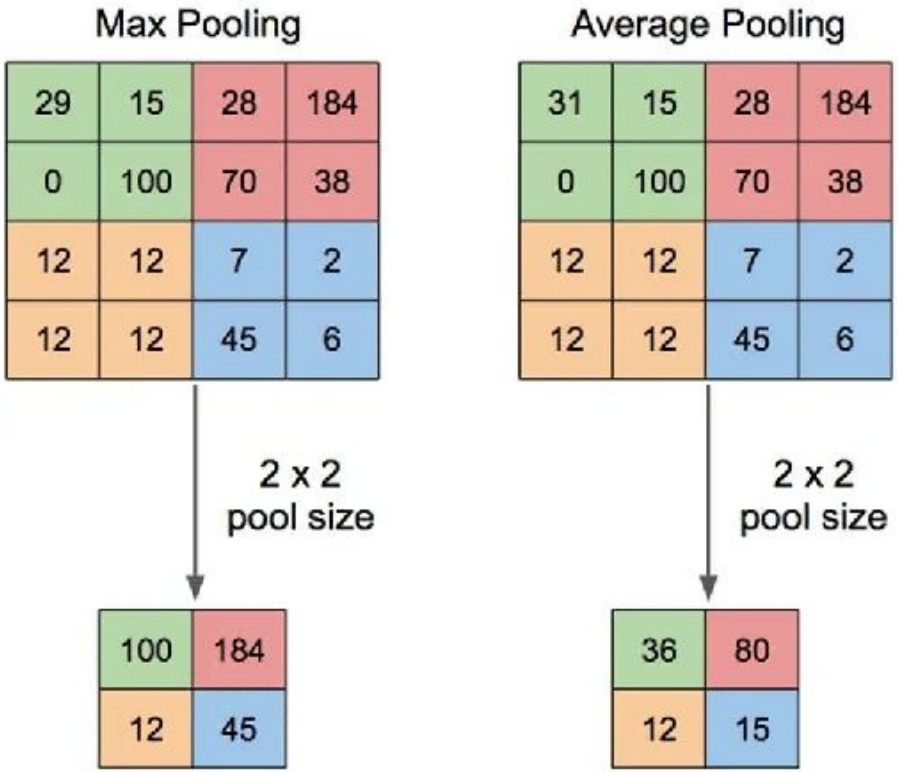
- Compartición de pesos (Weight Sharing): El mismo kernel K se desliza sobre toda la imagen. Reduce millones de parámetros a solo unos pocos cientos.
- Campos Receptivos Locales: Cada neurona solo procesa un parche pequeño de la entrada, preservando la topología espacial.
- Hiperparámetros fundamentales:
    - Tamaño del kernel: Típicamente 3×3 o 5×5.
    - Stride (Paso): Avance del kernel (stride=1 preserva resolución, stride=2 submuestrea a la mitad).
    - Padding: Añadir ceros en los bordes ('same' preserva H×W; 'valid' reduce bordes).

CNN: No Linealidad y Pooling

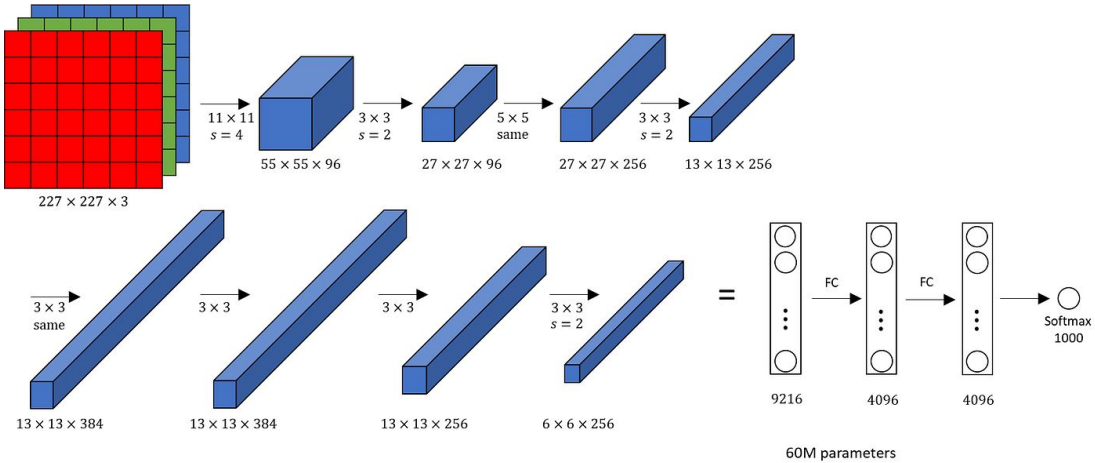
- Activación ReLU: f(x) = max(0, x)
- Introduce no-linealidad sin saturar en valores positivos. Esencial para apilar decenas de capas.
- Capas de Pooling (Submuestreo Espacial):
- Max Pooling 2×2 con stride 2: Toma el valor máximo de cada cuadrícula de 4 píxeles.
- Ventajas:

1. Reduce la dimensionalidad espacial a la cuarta parte (H/2 × W/2).
2. Confiere invarianza local a pequeñas traslaciones.
3. Amplía el campo receptivo efectivo de las capas subsiguientes.

Pooling Operation



AlexNet

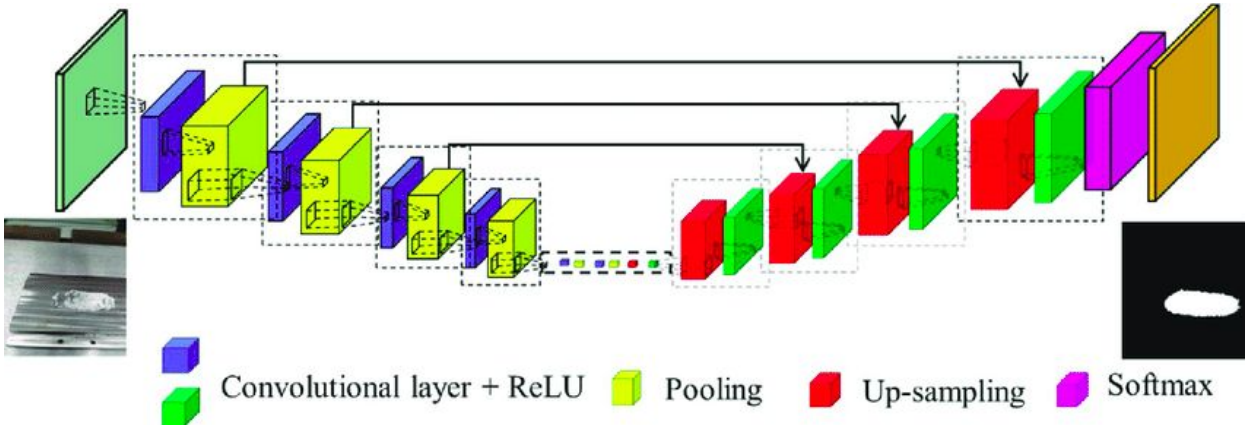


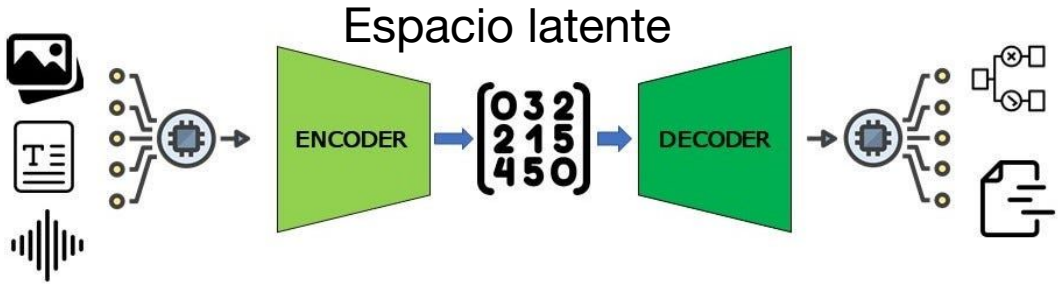
- Capa convolucional: kernels aprendidos; compartición de pesos.
- ReLU: max(0,x); introduce no-linealidad.
- Max pooling 2×2: reduce dimensión, da invarianza local.
- Jerarquía: bordes → texturas → partes → objetos.

Jerarquía de representaciones

- La Jerarquía Visual Emergente (Zeiler & Fergus)
- Capas Iniciales (Conv1, Conv2):
    - Detectan primitivas visuales de bajo nivel: bordes orientados tipo Gabor, gradientes de color simples, contraste de esquinas.
    - Totalmente genéricas (idénticas entre distintas tareas y datasets).
- Capas Intermedias (Conv3, Conv4):
    - Combinan bordes para formar texturas complejas, patrones repetitivos, mallas, curvas y siluetas geométricas.
- Capas Profundas (Conv5, bloques residuales):
    - Detectan partes complejas de objetos: ojos, ruedas de automóviles, hocicos de animales, alas de aves.
- Capas Finales: Espacio de decisión semántico desacoplado.

Encoder-Decoder





Transfer learning y Extracción de Embeddings con GAP

- ¿Cómo usamos imágenes en minería de datos sin millones de fotos ni semanas de GPU?
- El Procedimiento Estándar:

1. Tomar una red moderna pre-entrenada en ImageNet (ResNet-50, MobileNetV2, EfficientNet).

2. Remover la última capa densa (el clasificador de 1.000 clases).

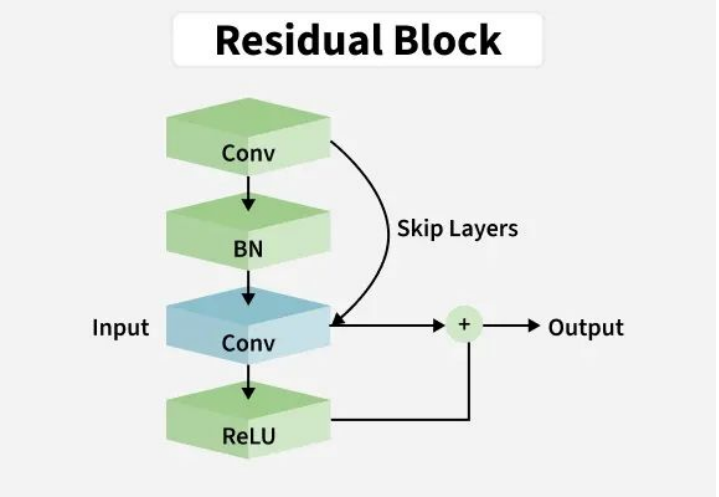
3. Extraer el vector de salida del Global Average Pooling (GAP).

4. Se obtiene un embedding denso de 512, 1280 o 2048 dimensiones que condensa la semántica visual de la imagen.

5. Normalizar con norma L2 e insertar en un DataFrame de Pandas.

ResNet

- El problema de la degradación:
  Apilar más de 20 capas convolucionales degradaba el entrenamiento (desvanecimiento del gradiente).
- El Bloque Residual (Skip Connection):
  - $y = F(x, \{W_i\}) + x$
- En lugar de forzar a la red a aprender un mapeo completo H(x), aprende el residuo F(x) = H(x) - x.
- Resultado: Redes de 50, 101 y 152 capas entrenables con convergencia estable, superando por primera vez el nivel de error humano en ImageNet (<3.57%).

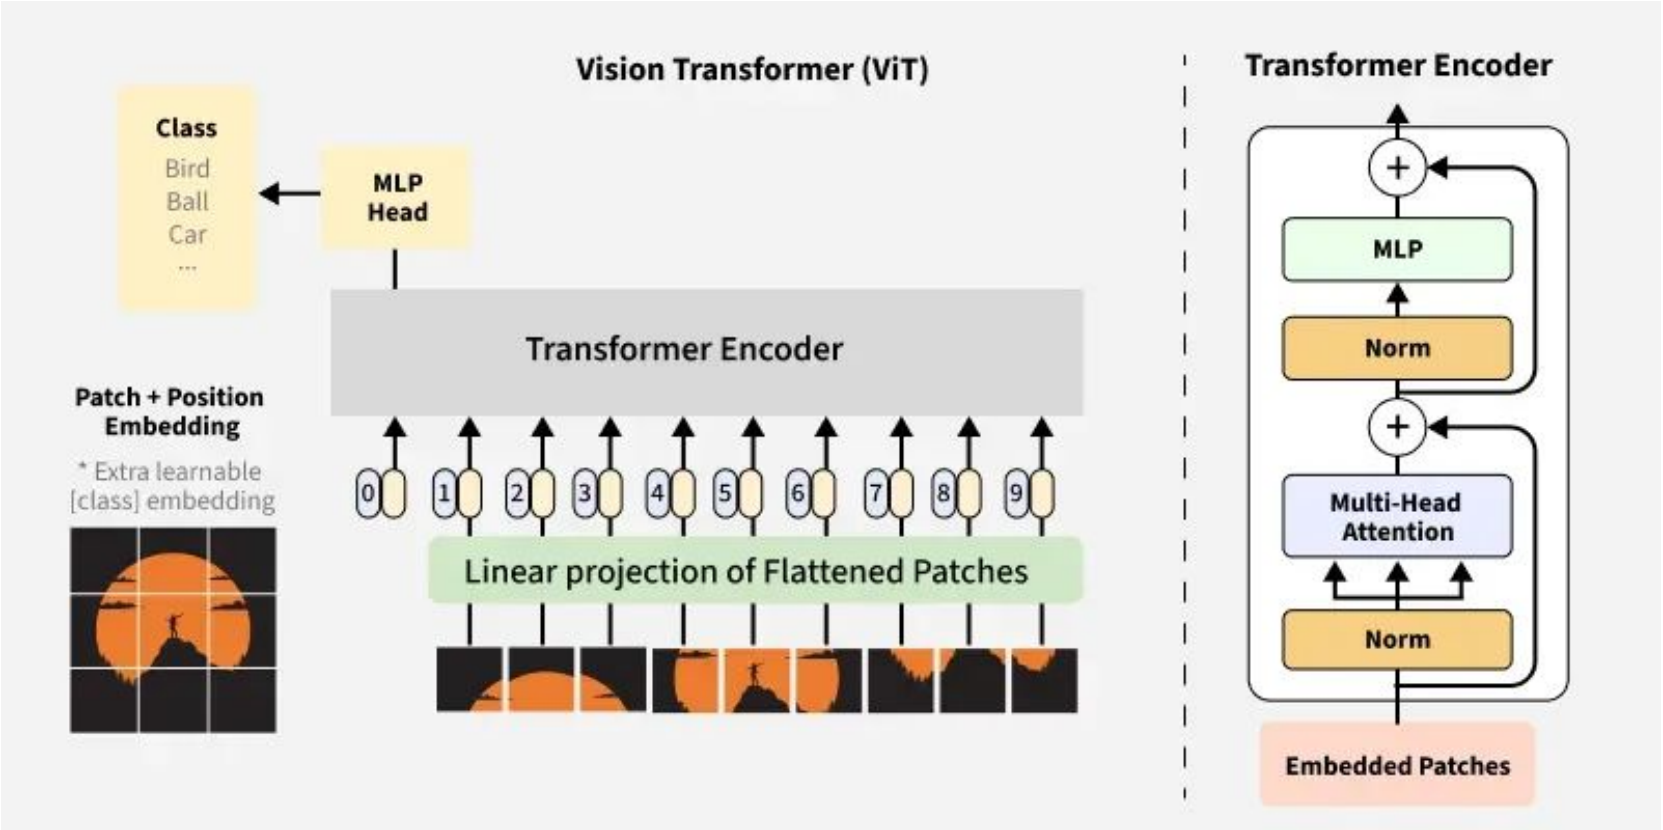


ResNet, He et al. 2016

ViT (Vision Transformer)

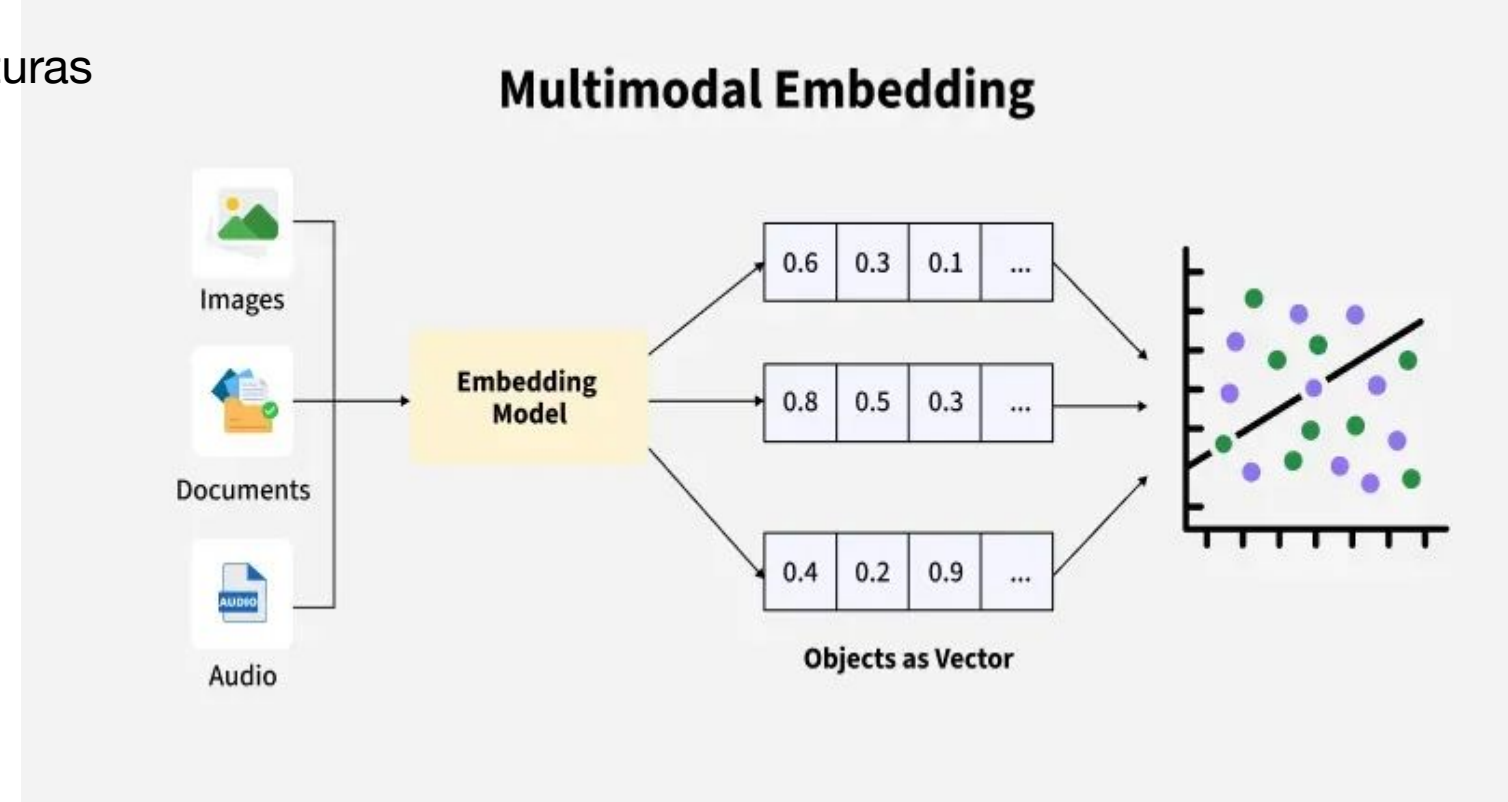
- Vision Transformers (ViT, Dosovitskiy et al. 2020)
- La imagen como secuencia de parches: Divide la imagen en cuadrículas (e.g. 16 × 16 píxeles), proyectándolos como 'tokens' idénticos a palabras de texto.
- Mecanismo de Auto-Atención Multi-Cabeza (Self-Attention):
    - Cada parche atiende directamente a todos los demás parches de la imagen sin restricciones de vecindad local.
- Sin sesgo inductivo convolucional:
    - Requiere datasets masivos (JFT-300M) para pre-entrenar, pero a gran escala supera a las mejores CNNs en modelado global.

ViT


Vision Transformer (ViT)
Class
Bird
Ball
Car
...
MLP Head
Transformer Encoder
Patch + Position Embedding
* Extra learnable [class] embedding
0
1
2
3
4
5
6
7
8
9
Linear projection of Flattened Patches
Transformer Encoder
MLP
Norm
Multi-Head Attention
Norm
Embedded Patches

Redes multimodales

Las arquitecturas permiten “fusionarse”!



Aplicaciones y Riesgos

Usos comunes

- Movilidad: FaceID, fotografía computacional, ADAS, autos autónomos, ALPR.
- Salud: segmentación de tumores, retinopatía, patología digital.
- Industria/minería: control de calidad, grietas, fatiga en operadores CAEX.
- Agro/retail: selección de fruta, producto, búsqueda visual.
- AR: Google Lens, filtros, realidad aumentada.

Sesgo de dataset y “mundo cerrado”

- Torralba & Efros: los benchmarks son “mundos cerrados”.
- El modelo aprende artefactos del dataset: fondos, fotógrafos, poses, cámaras.
- Name That Dataset!: un SVM adivinaba el dataset con 39% vs. 8.3% azar.
- Negative set bias: qué se usa como negativo condiciona la frontera.
- Desplome cruzado: mismo modelo, otro dataset → caída fuerte.

Domain Shift, Robustez y Adversarial

- Cambios de iluminación, clima, lentes sucias, oclusiones, ángulos.
- Modelo con 98% en validación puede caer a 40% en producción.
- Adversarial examples: ruido imperceptible cambia la predicción.
- Data drift: la distribución de embeddings cambia con el tiempo.

Ética, privacidad y equidad

- Vigilancia y biometría sin consentimiento.
- Sesgos demográficos: mayores falsos positivos en minorías.
- Regulación: GDPR, leyes de IA, explicabilidad.
- En minería de datos: auditar, documentar y validar con grupos subrepresentados.

Preguntas Resumen

¿Qué es?
Resolver el problema inverso 3D→2D con priors; transformar píxeles en descripciones.

¿Cómo se utiliza?
Pipeline: adquisición → preprocesamiento → features/embeddings → minería.

¿Día a día?
FaceID, fotos, autos, salud, industria, agro, AR.

¿De qué cuidarse?
Dataset bias, domain shift, adversarial, privacidad, leakage, drift.